esprit
Se former autrement

Informatique Décisionnelle



Année Universitaire:2023-2024



CONFÉRENCE DES GRANDES ÉCOLES

Cti Commission des Titres d'Ingénieur

European Accreditation of Engineering Programmes EUR-ACE®

cdio CONCEIVE DESIGN IMPLEMENT OPERATE

Partie 1:
Introduction Générale



1 C’est quoi l’informatique décisionnelle?

Terme générique qui englobe les applications, l'infrastructure, les outils et les meilleures pratiques permettant l'accès et l'analyse de l’information afin d’améliorer et d’optimiser les décisions et les performances. [GARTNER]



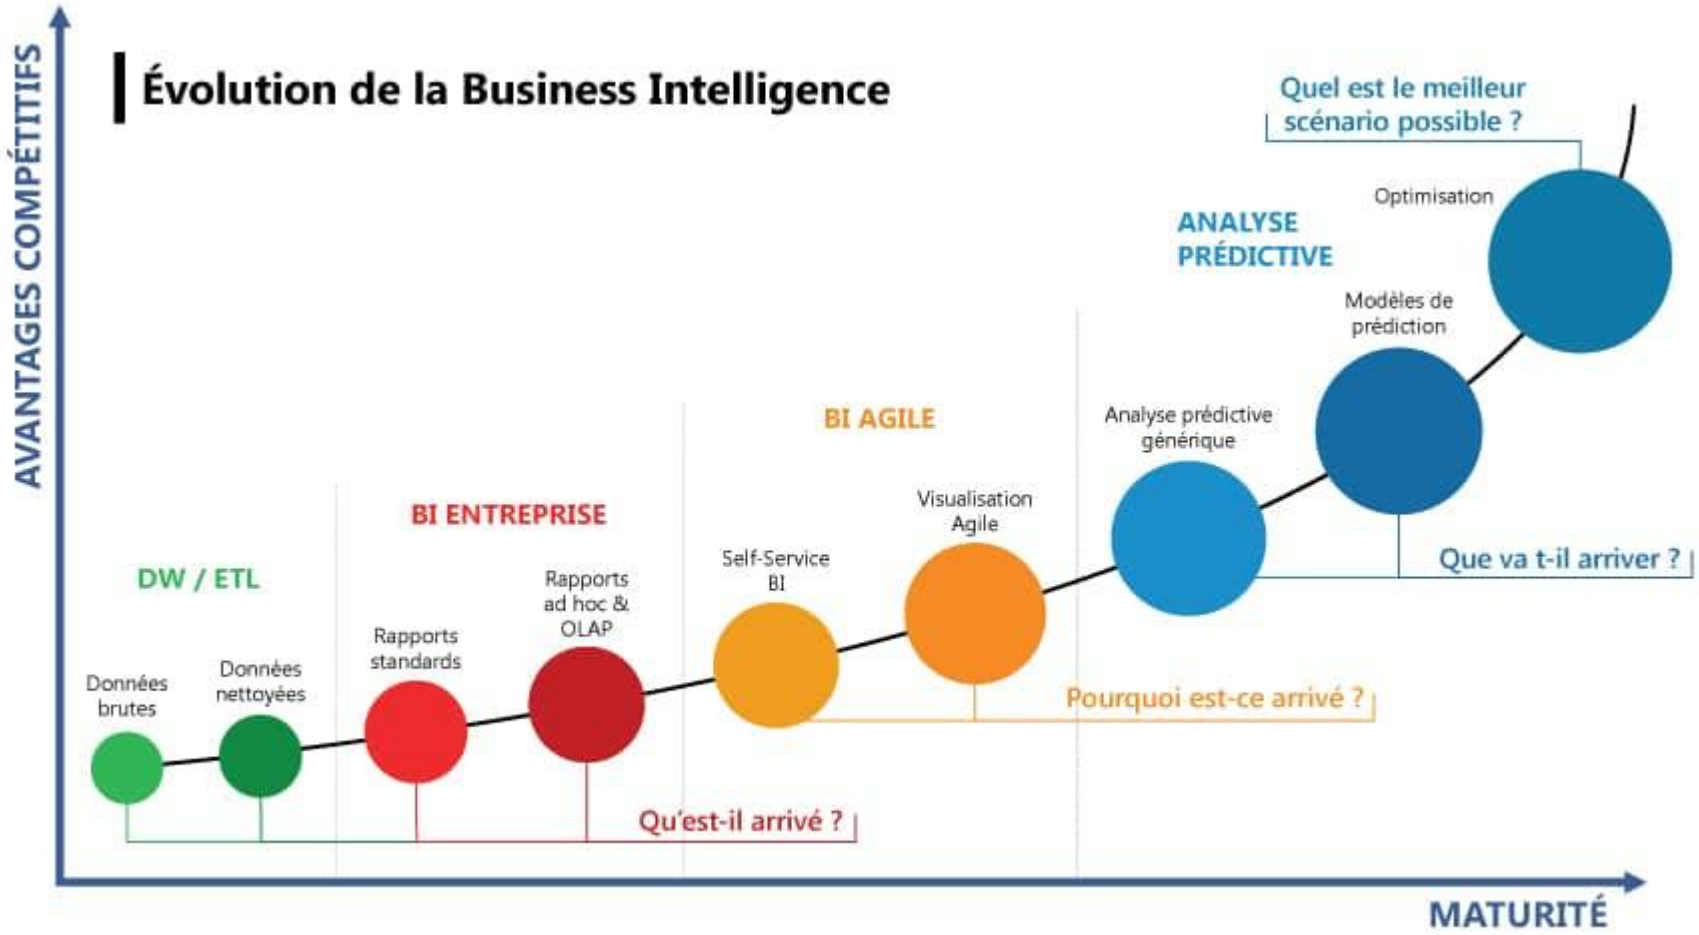
C’est quoi l’informatique décisionnelle?

- L'informatique décisionnelle est l'ensemble des méthodes, moyens et outils informatiques utilisés pour piloter une entreprise et aider à la prise de décision.
- L'aide à la prise de décision est la responsabilité de quelques personnes dans l'entreprise appelés décideurs.
- L'informatique décisionnelle (BI) est une solution informatique permet de **collecter**, **de traiter** et **d’analyser** toutes les données de l'entreprise selon des critères spécifiques ou externe . Les résultats de cette analyse permettent aux **managers** d'obtenir **une vue globale** sur leur activité





3 Évolution de l'informatique décisionnelle



L'Intérêt de l'informatique décisionnelle?

Les décideurs d'une entreprise doivent pouvoir répondre à un certain nombre de question pour diriger leur entreprise :

- Qui sont mes clients ?
- Pourquoi sont ils mes clients ?
- Comment cibler ma clientèle ?
- Quel est l'évolution de tel produit ?
- Qui sont mes employés ? ...



L'objectif est donc d'apporter aux décideurs d'une entreprise les moyens de répondre à ces questions, de connaître les tendances des clients pour ainsi bien anticiper les réactions de ses derniers et donc de fidéliser les clients.

Nouveaux besoins!

Pour prendre de **«bonnes décisions »**, on doit pouvoir:

- Accéder en temps réel aux données de l'entreprise,
- Traiter ces données, Extraire l'information pertinente de ces données, par exemple pour savoir :

1. **Q**uels sont les résultats des ventes par gamme de produit et par région de l'année dernière ? !
2. **Q**uelle est l'évolution des chiffres d'affaires par type de magasin et par période ? !
3. **C**omment qualifier les acheteurs de mon produit X ?



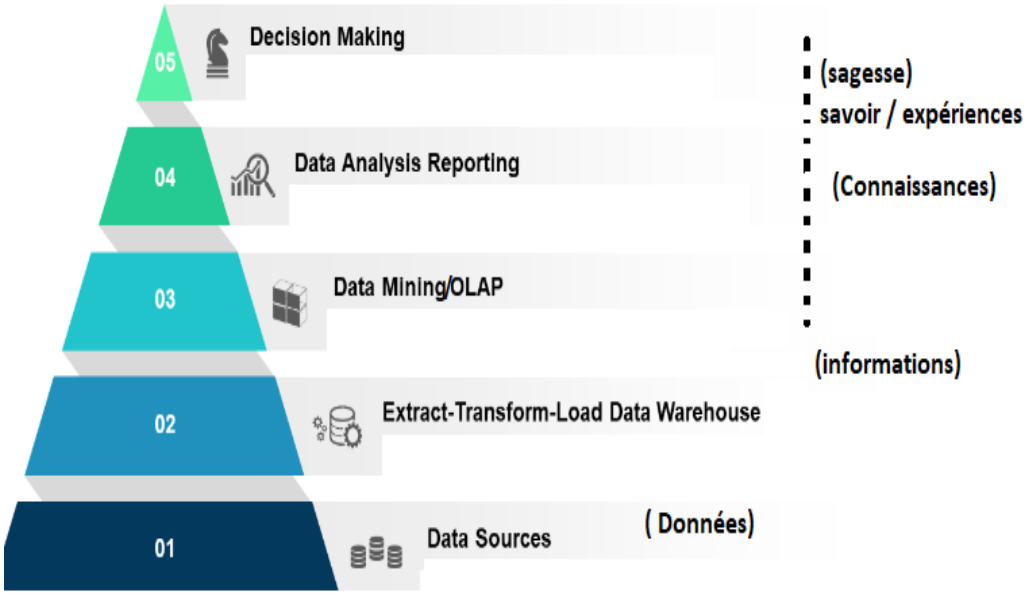
Problématique

- La prise de décisions stratégiques dans une organisation nécessite le recours et le croisement de multiples informations qui concernent tous les départements : production, RH, achats, ventes, marketing, service après-vente, maintenance, R&D...

- Or ces données sont généralement :
  - **éparpillées** au sein des départements et non connectées entre elles
  - **hétérogènes** dans leurs formats techniques et leurs organisations structurelles, voire leurs sémantiques
  - **implémentées pour l'action** et non pour l'analyse
  - **volatiles**, au sens où leur mise à jour peut conduire à oublier des informations obsolètes

Objectifs d'un système décisionnel

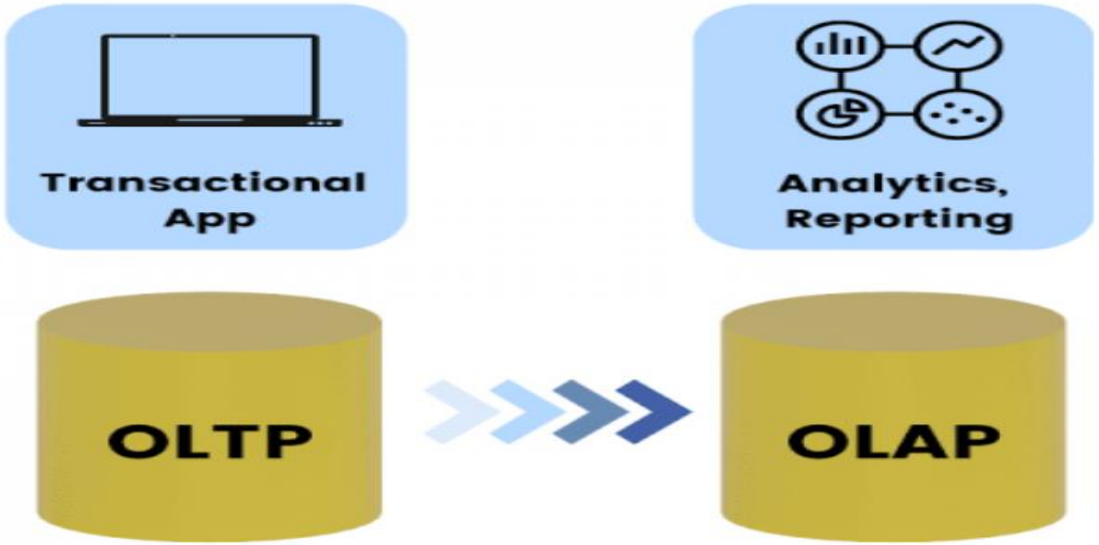
- Transformer un système d'information qui avait une vocation de production en un système d'information décisionnel.
- Transformation des données de production en informations stratégiques
- Les données doivent être :
  - Extraites
  - Groupées et organisées
  - Corrélées
  - Transformées (résumé, agrégation)



OLTP et OLAP (1/3)

Les systèmes informatiques peuvent se subdiviser en deux.

- Le **système transactionnel OLTP (**On-Line Transaction Processing)
- Le **système analytique OLAP**. (On-Line Analytical Processing)



OLTP et OLAP (2/3)

- Les systèmes **OLTP** servent, en général, de source de données pour les systèmes **OLAP** qui sont quant à eux, source d'analyse des données qui vont permettre d'aboutir à la décision.

- Vous comprendrez alors qu'OLTP et OLAP ont des objectifs opposés et ont un stockage de données différent faisant l'objet de requêtes différentes.

OLTP vs OLAP (3/3)

Caractéristiques	OLTP	OLAP
Applications	production	aide à la décision
Utilisateurs	un département professionnel IT	transversal (entreprise) décideur non IT
Données	normalisées, non agrégées	dénormalisées, agrégées
Requêtes	simples, nombreuses, régulières, prévisibles, répétitives	complexes, peu nombreuses, irrégulières, non prévisibles
Nb tuples invoqués par requête (moyenne)	dizaines	millions
Taille données	100 MB à 1 GB	1 GB à 1 TB
Ancienneté des données	récente, mises à jour	historique
Rapidité de traitement	typiquement très rapide	dépend de la quantité de données impliquées

Partie 2:
Entrepôt de données (Datawarehouse)



Data Warehouse ou entrepôt de données

Définition et objectifs (1/4)

- Les datawarehouse sont des systèmes conçus pour l'aide à la prise de décision. (Mode de travail: **OLAP** On-Line Analytical Processing)
- D'après BILL Inmon (1996) :

« Un DW est une collection de données orientées sujet, intégrées, non volatiles, historisées, organisées pour la prise de décision. »

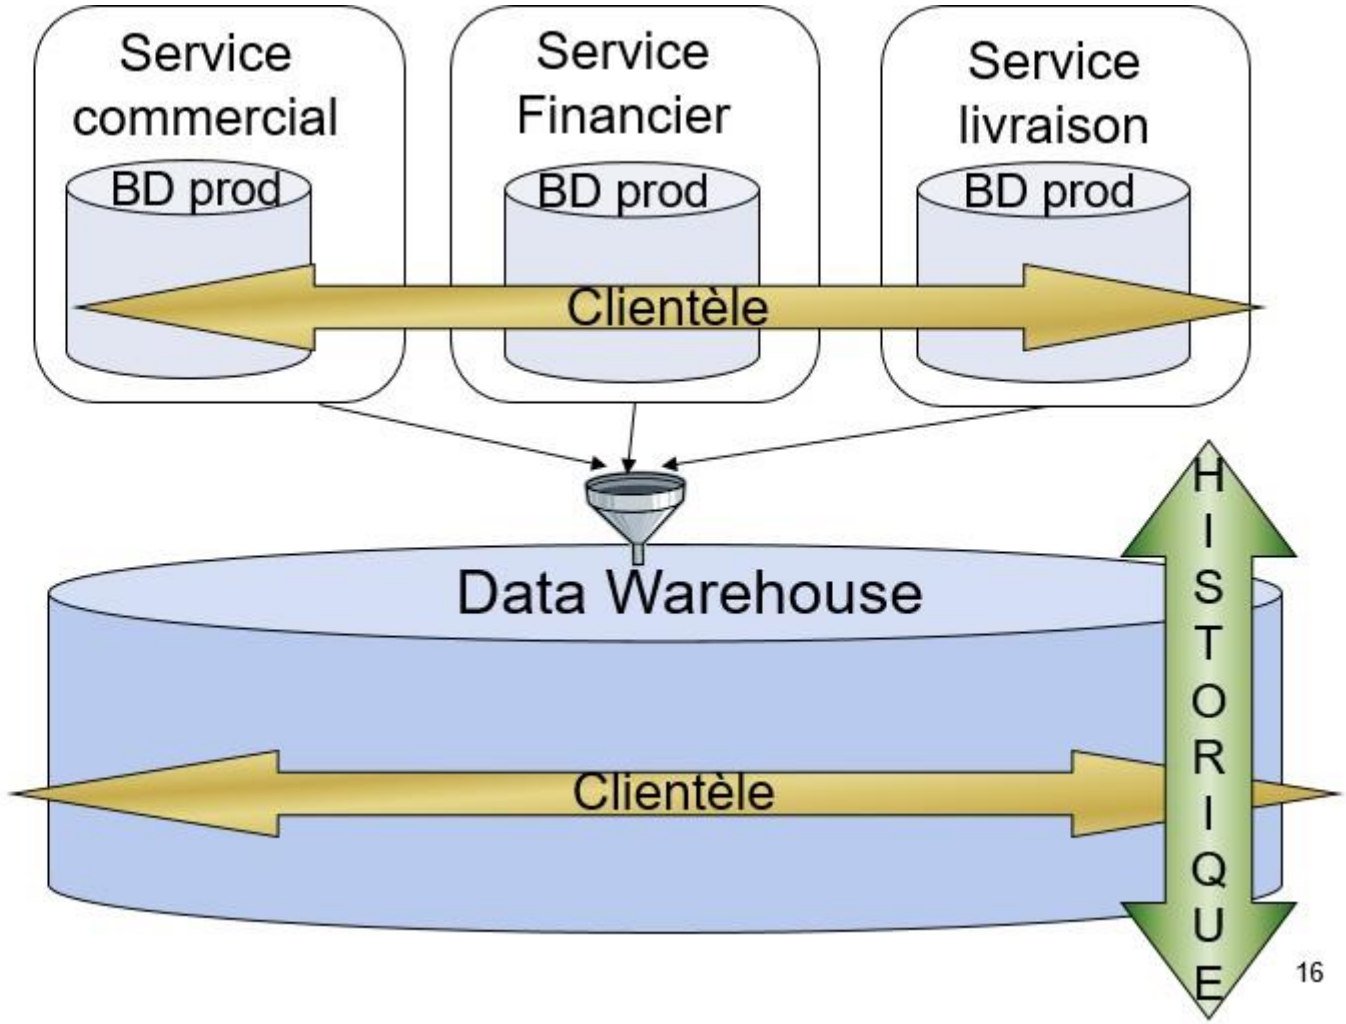
- Les objectifs principaux sont
  - regrouper, organiser des informations provenant de sources diverses,
  - les intégrer et les stocker pour donner à l'utilisateur une vue orientée métier (sujet),
  - retrouver et analyser l'information facilement et rapidement.

Data Warehouse ou entrepôt de données

Définition et objectifs (2/4)

OLTP: On-Line Transactional Processing

OLAP: On-Line Analitical Processing



Data Warehouse ou entrepôt de données

Définition et objectifs (3/4)

Dans un entrepôt de données les données sont:

Orientées sujet: thèmes par activités majeures ; Le datawarehouse est lui organisé autour des sujets majeurs de l'entreprise.

Intégrées: Les données proviennent de plusieurs sources différentes. Avant d'être intégrées au sein du datawarehouse elles doivent être mise en forme et unifiées afin d'en assurer la cohérence. Cela nécessite une forte normalisation.



Data Warehouse

Datawarehouse ou entrepôt de données

Définition et objectifs (4/4)

Non volatiles: Un datawarehouse veut conserver la traçabilité des informations et des décisions prises.
Les données ne sont ni modifiées ni supprimées. Une requête émise sur les mêmes données à plusieurs mois d'intervalles doit donner le même résultat.

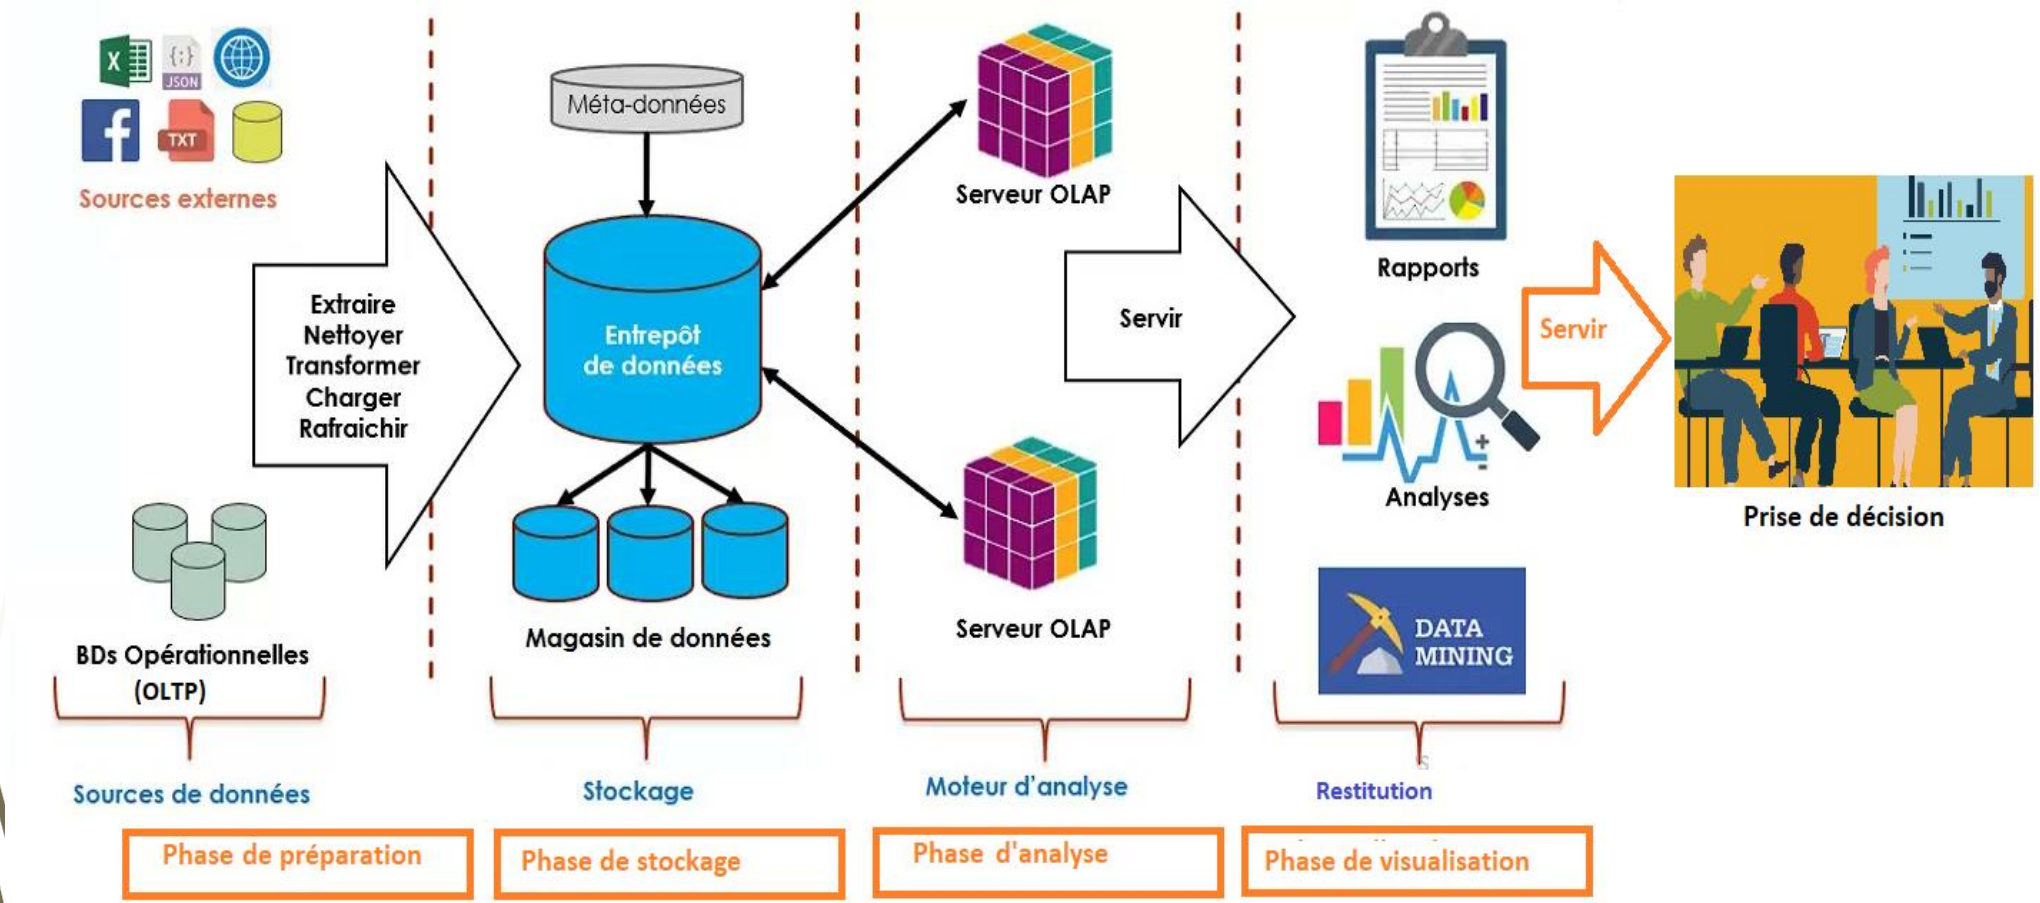
Historisées: Contrairement au système de production les données ne sont jamais mises à jour. Chaque nouvelle données est insérées. Un référentiel de temps doit être mis en place afin de pouvoir identifier chaque donnée dans le temps.

Pourquoi ne pas réutiliser les SGBD?

- Les SGBD sont des systèmes dont le mode de travail est transactionnel (**OLTP** On-Line Transaction Processing).
- Permet d'insérer, modifier, interroger des informations rapidement, efficacement, en sécurité.
- Deux objectifs principaux :
  - Sélectionner, ajouter, mettre à jour et supprimer des tuples
  - Ces opérations doivent pouvoir être effectuées très rapidement, et par de nombreux utilisateurs simultanément.

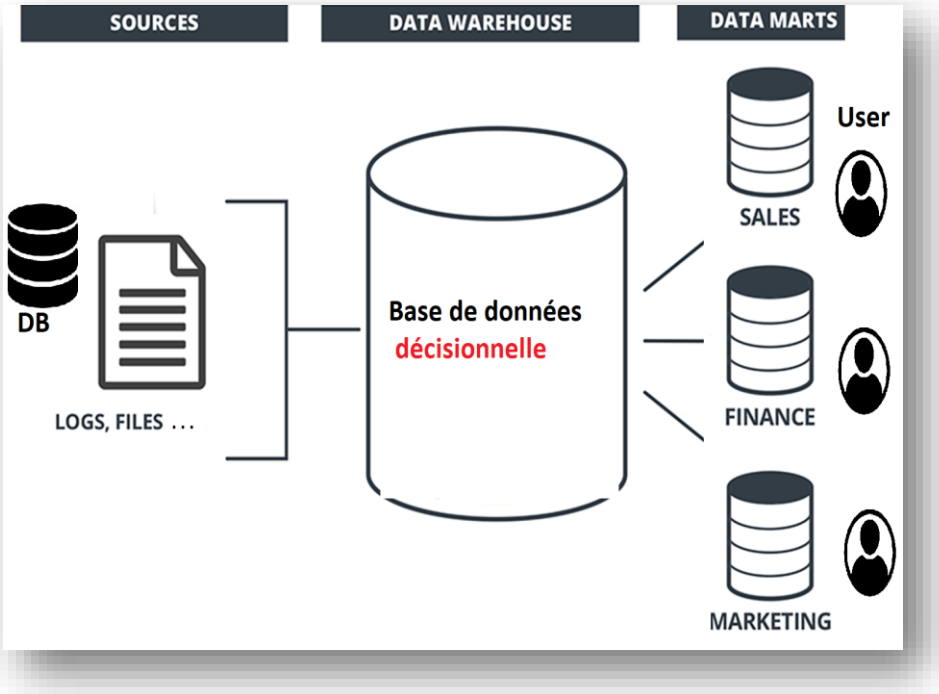
Pour conclure, il convient de noter que les systèmes OLTP ne sont pas bien adaptés à l'analyse de données

Architecture Globale d'un système décisionnel



Data Warehouse et Datamart

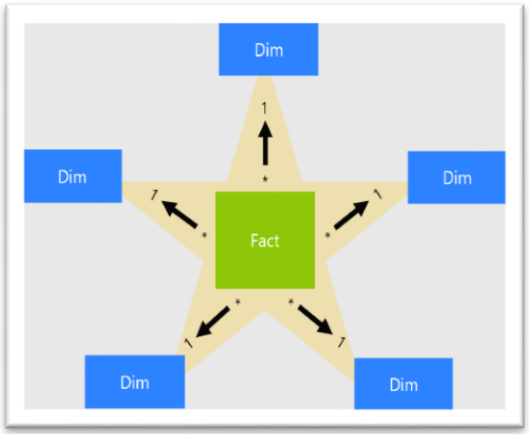
- Un Data Warehouse et un Data Mart se distinguent par le spectre qu'il recouvre :
  - Le Data Warehouse recouvre l'ensemble des données et problématiques d'analyse visées par l'entreprise.
  - Le Datamart recouvre une partie des données et problématiques liées à un métier ou un sujet d'analyse en particulier.
  - Un Datamart est un sous-ensemble du Data Warehouse de l'entreprise, obtenu par extraction et agrégation des données de celui-ci.



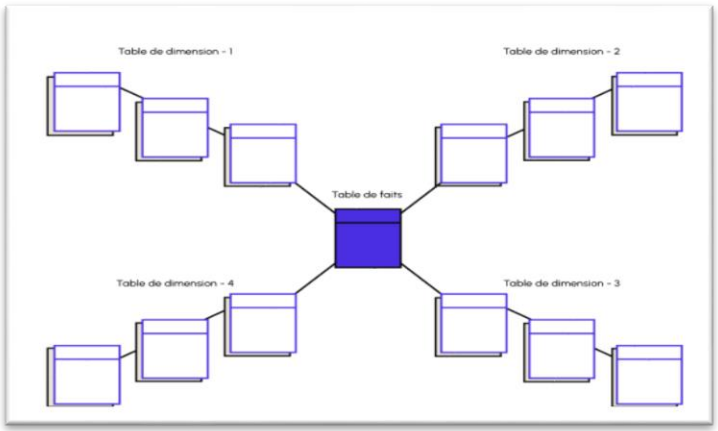
Datawarehouse ou entrepôt de données

Modélisation (1/2)

- Il existe trois schémas possibles pour la modélisation de l'entrepôt :
  - Le schéma en étoile
  - le schéma en flocon.
  - Le schéma en constellation



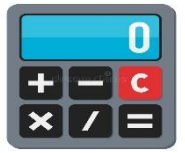
- Quel que soit le modèle considéré, on distinguera :
  - **la table des faits** qui contient l'information à analyser (par exemple les ventes)
  - **des tables de dimensions** qui contiennent les informations sur les dimensions d'analyse (par exemple le lieu, le temps, la description du produit).



Datawarehouse ou entrepôt de données

Modélisation (2/2)

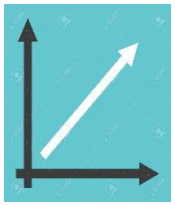
- Pour la Modélisation conceptuelle BD : entité et relation
- Pour la Modélisation de **DW** : dimension et mesure
- Les mesures sont les valeurs numériques que l'on compare



(ex : montant_ventes, qte_vendue)

  - Ces valeurs sont le résultat d'une opération d'agrégation des données

- Les dimensions sont les points de vues depuis lesquels les mesures peuvent être observées :



  - Ex : date, localisation, produit, etc.
  - Elles sont stockées dans les tables de dimensions

Modélisation du DW

Dimension

- Une dimension peut être définie comme :
  - un thème, ou un axe (attributs), selon lequel les données seront analysées
  - Ex : Temps, Région, Produits...
- Une dimension contient des membres organisés en hiérarchie:
  - Chacun des membres appartient à un niveau hiérarchique (ou niveau de granularité) particulier
  - Ex : pour la dimension Temps:
    - année – semestre – mois – jour

Modélisation du DW

Mesure – fait – table de faits

- Une mesure est un élément de donnée sur lequel portent les analyses, en fonction des différentes dimensions
  - **Exemple :** coût des travaux, nombre d'accidents, ventes
- Un fait représente la valeur d'une mesure, mesurée ou calculée, selon un membre de chacune des dimensions
  - **Exemple** : «250 000 euros » est un fait qui exprime la valeur de la mesure « coût des travaux » pour le membre « 2002 » du niveau année de la dimension « temps » et le membre « Versailles » du niveau « ville » de la dimension « découpage administratif »
- Les mesures sont stockées dans les tables de faits
  - Table de fait contient les valeurs des mesures et les clés vers les tables de dimensions

Le Modèle en étoile

Avantages et inconvénients

- Une (ou plusieurs) table(s) de faits comprenant une (ou plusieurs) mesures.
- Plusieurs tables de dimension dénormalisées
- Les tables de dimension n'ont pas de lien entre elles

Avantages :

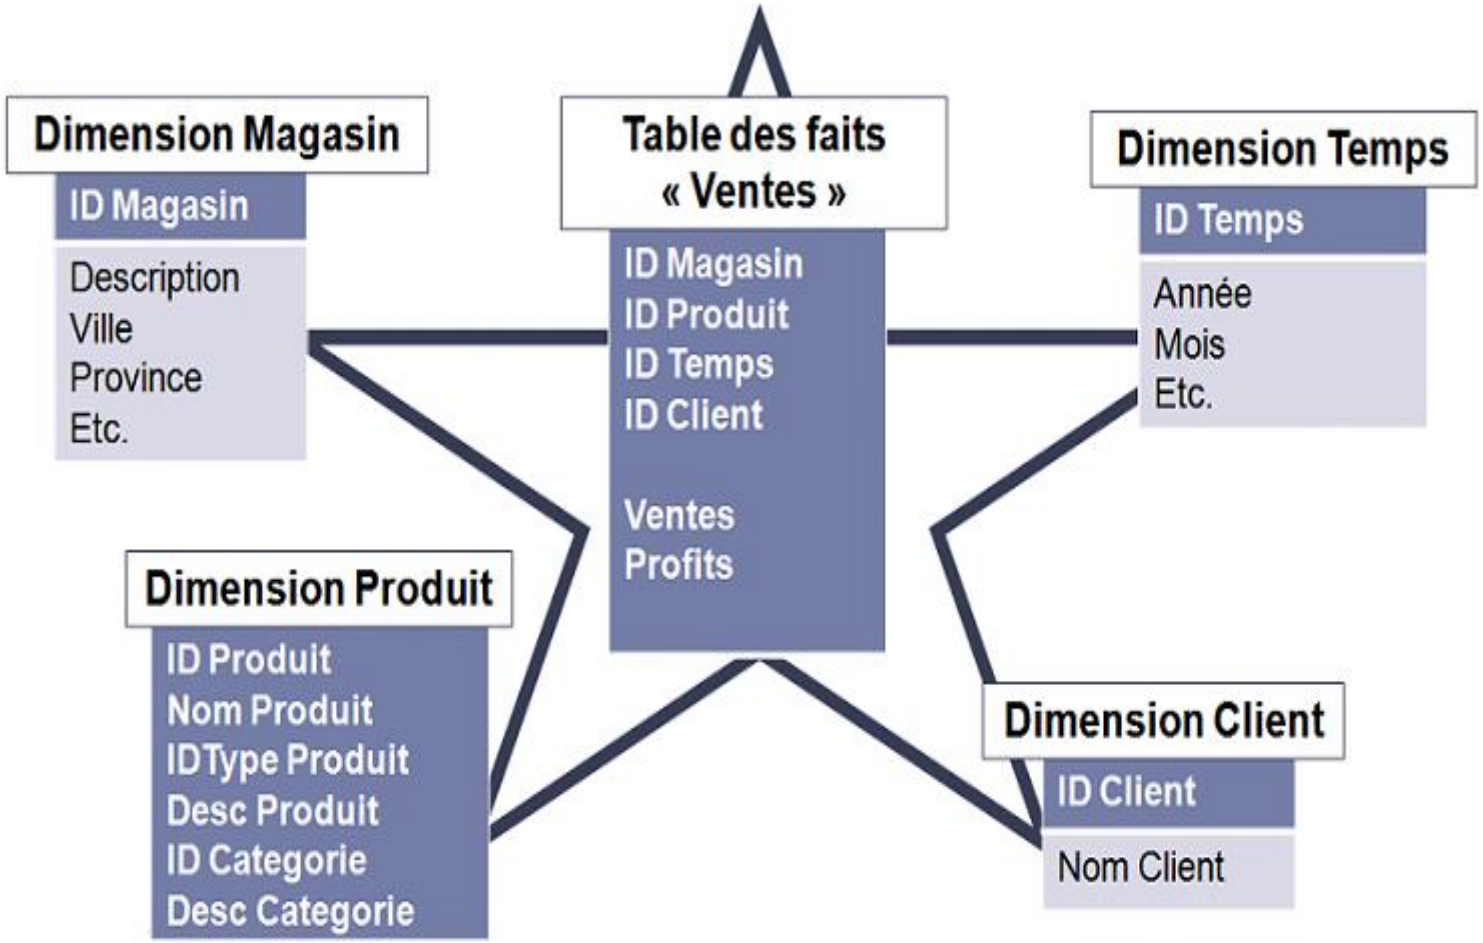
- Facilité de navigation
- Alimentation facile.
- Performances : nombre de jointures limité ; gestion des données creuses.
- Gestion des agrégats

Inconvénients :

- Toutes les dimensions ne concernent pas les mesures
- Redondances dans les dimensions

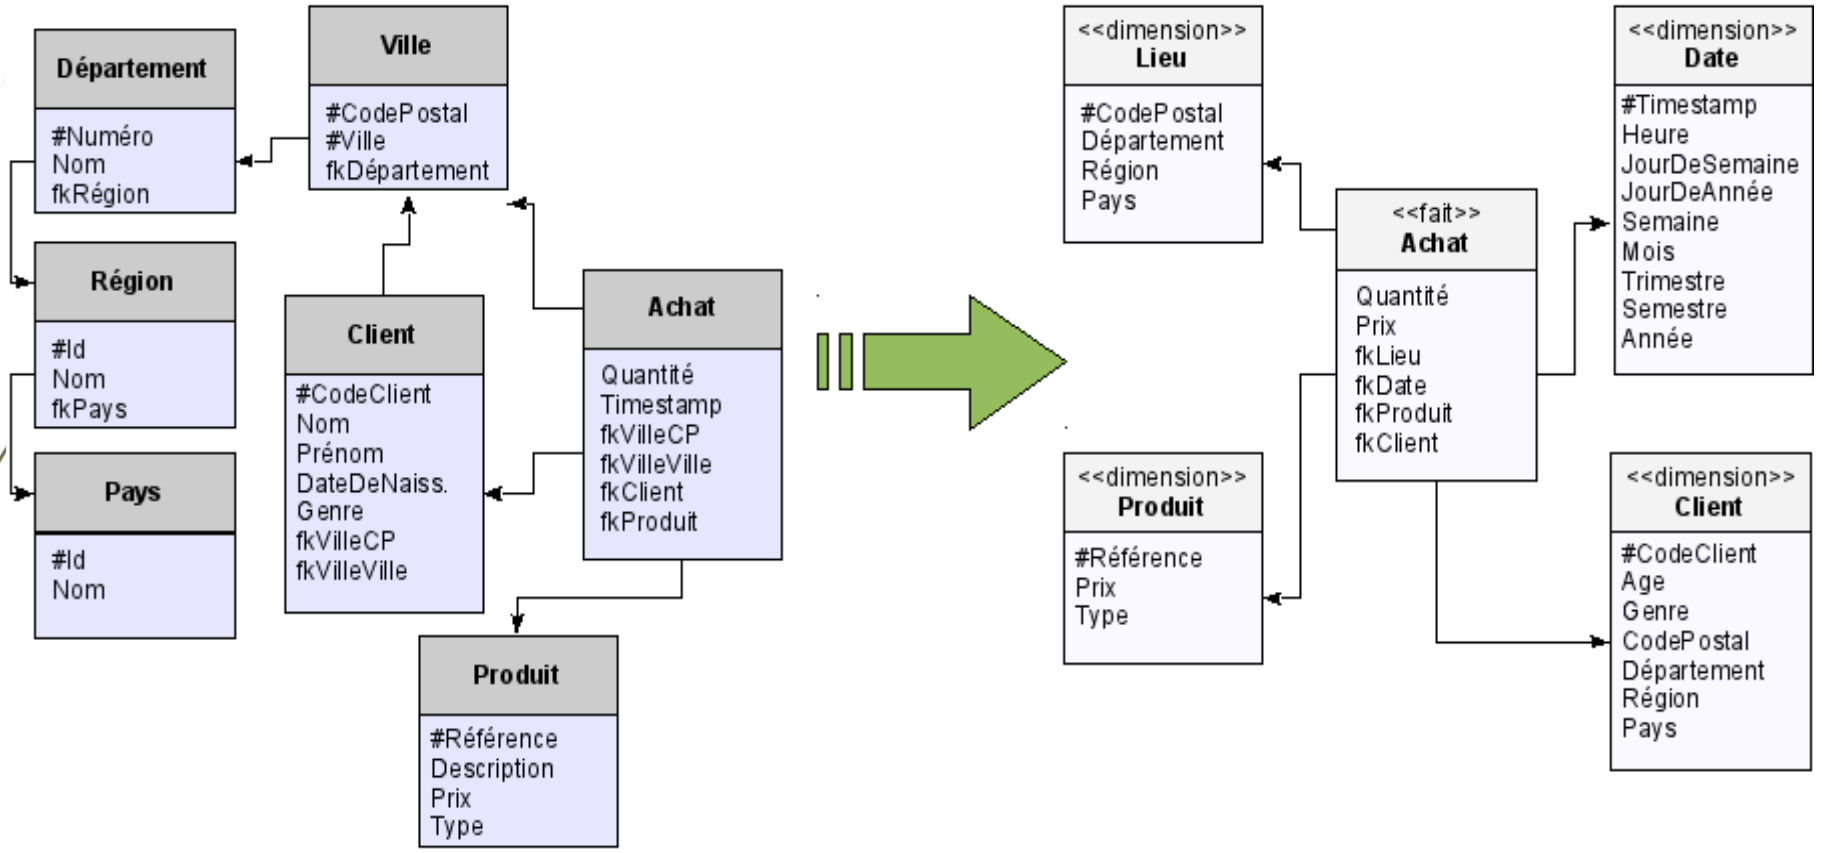
Le Modèle en étoile

Exemple1



Le Modèle en étoile

Exemple2



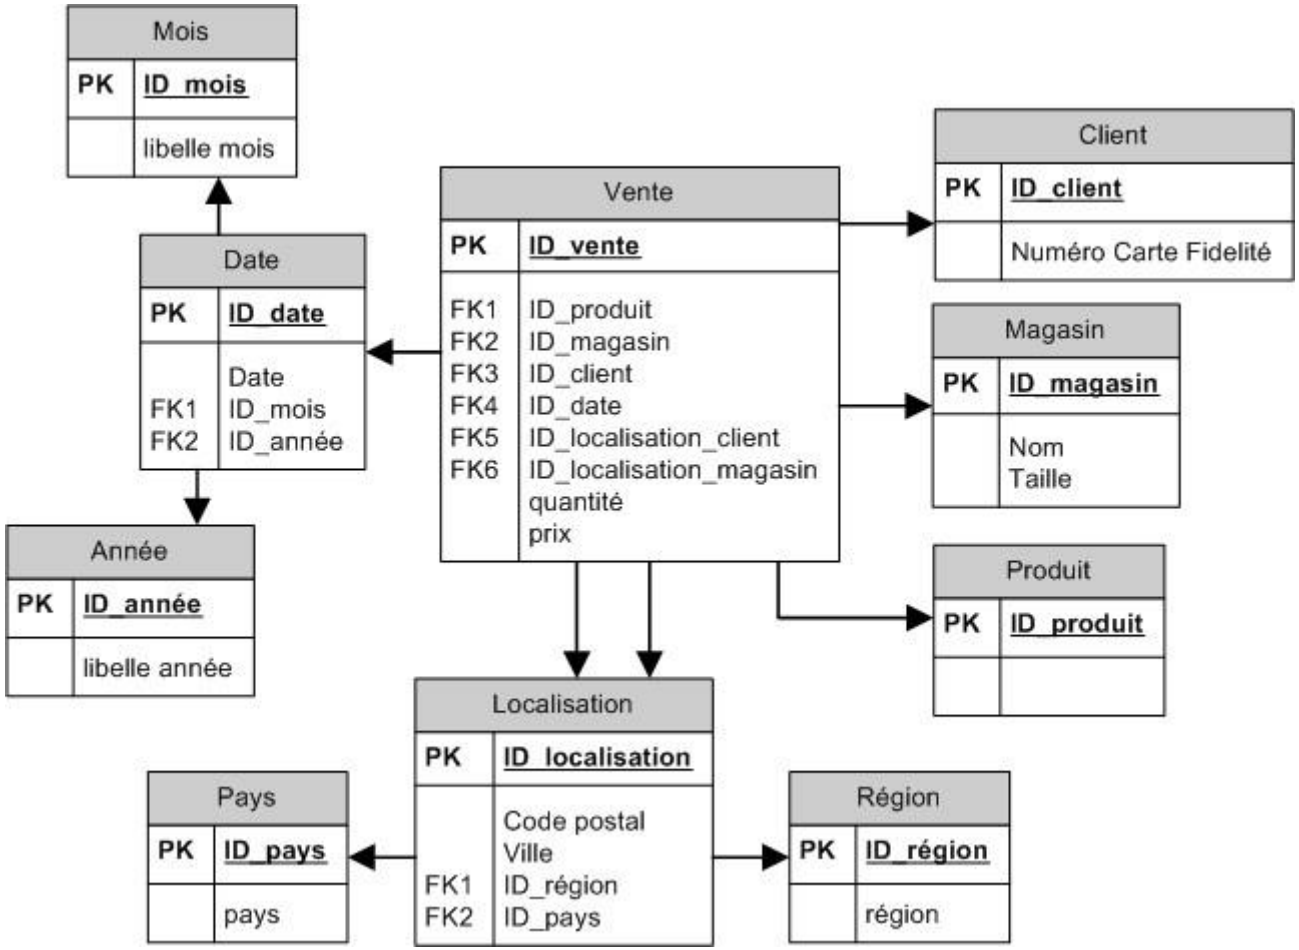
Le Modèle en flocons

Avantages et inconvénients

- Le schéma en flocon est dérivé du schéma en étoile où les tables de dimensions sont normalisées (la table des faits reste inchangée).
- Avec ce schéma, chacune des dimensions est décomposée selon sa (ou ses) hiérarchie(s).
  - Exemple : Commune, Département, Région, Pays, Continent
- Utilisé lorsque les tables sont trop volumineuses
  - Avantages :
    - réduction du volume,
  - Inconvénients :
    - navigation difficile,
    - nombreuses jointures.
    - Alimentation complexe.

Le Modèle en flocons

Exemple

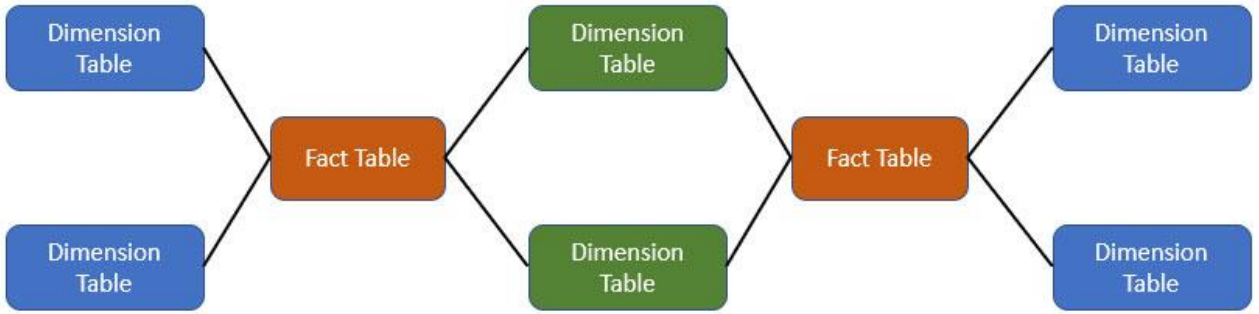


Modèle en constellation

Présentation

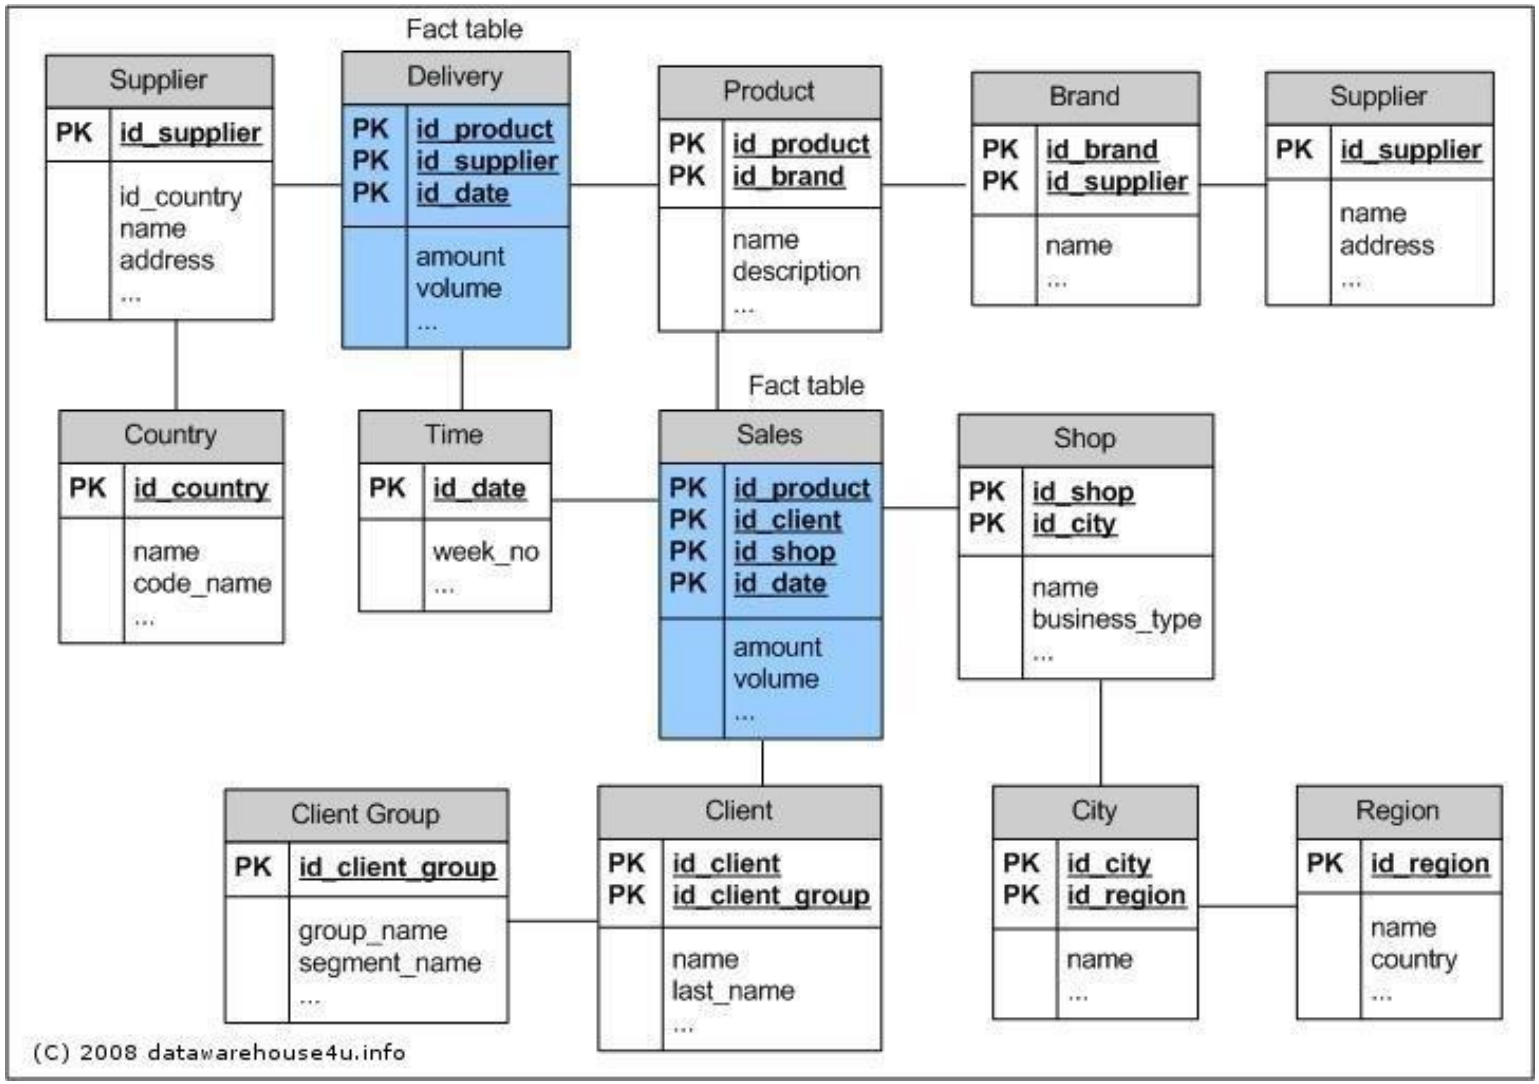
- La modélisation en constellation consiste à fusionner plusieurs modèles en étoile qui utilisent des dimensions communes.

- Un modèle en constellation comprend donc plusieurs tables de faits et des tables de dimensions communes ou non à ces tables de faits.



Modèle en constellation

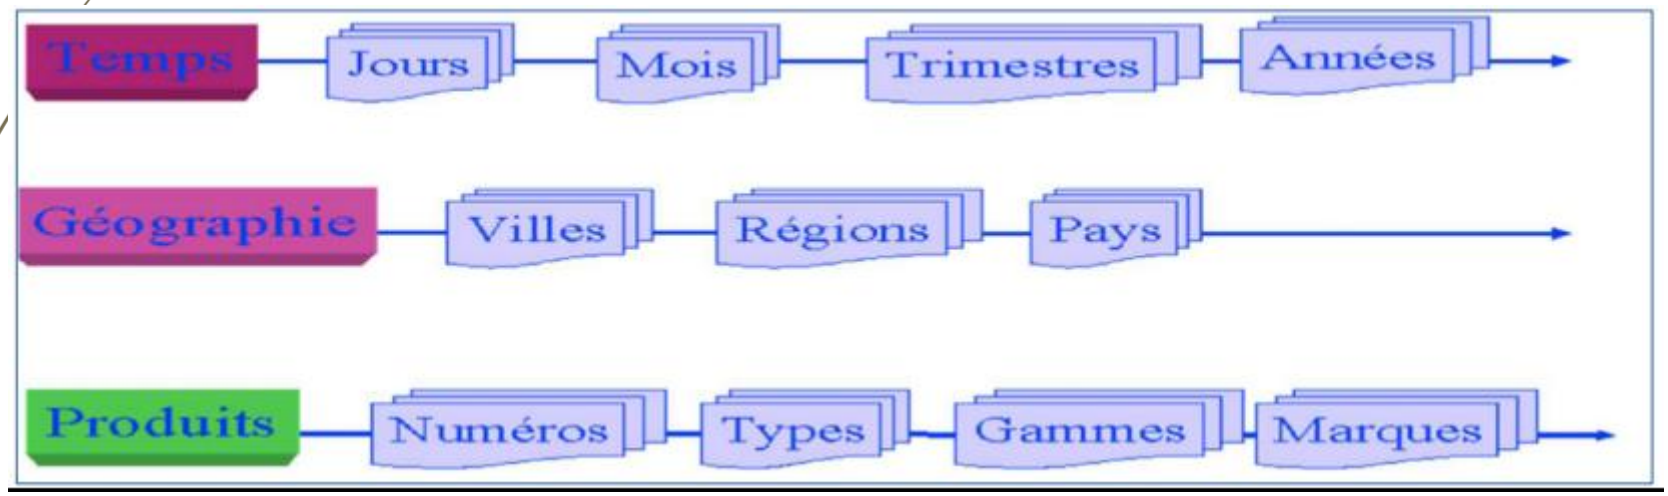
Exemple



Hiérarchie des paramètres d'une dimension

- Une mesure est généralement analysée selon les dimensions qui le caractérisent.
- Nécessaire de définir pour chaque dimension ses différents niveaux de détail définissant ainsi une (ou plusieurs) hiérarchie(s) de paramètres

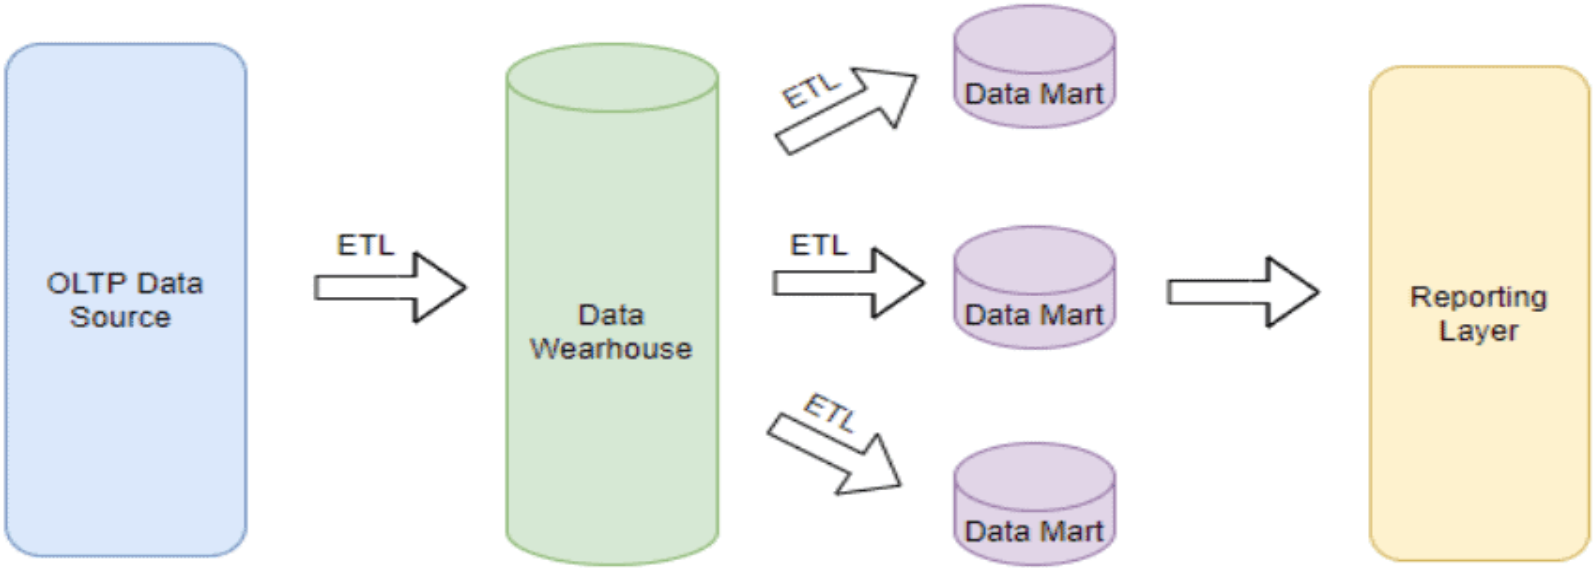
Exemple :



Approches Modélisation DataWarehouse

- **L'approche d'Inmon (ou approche Top-Down):**

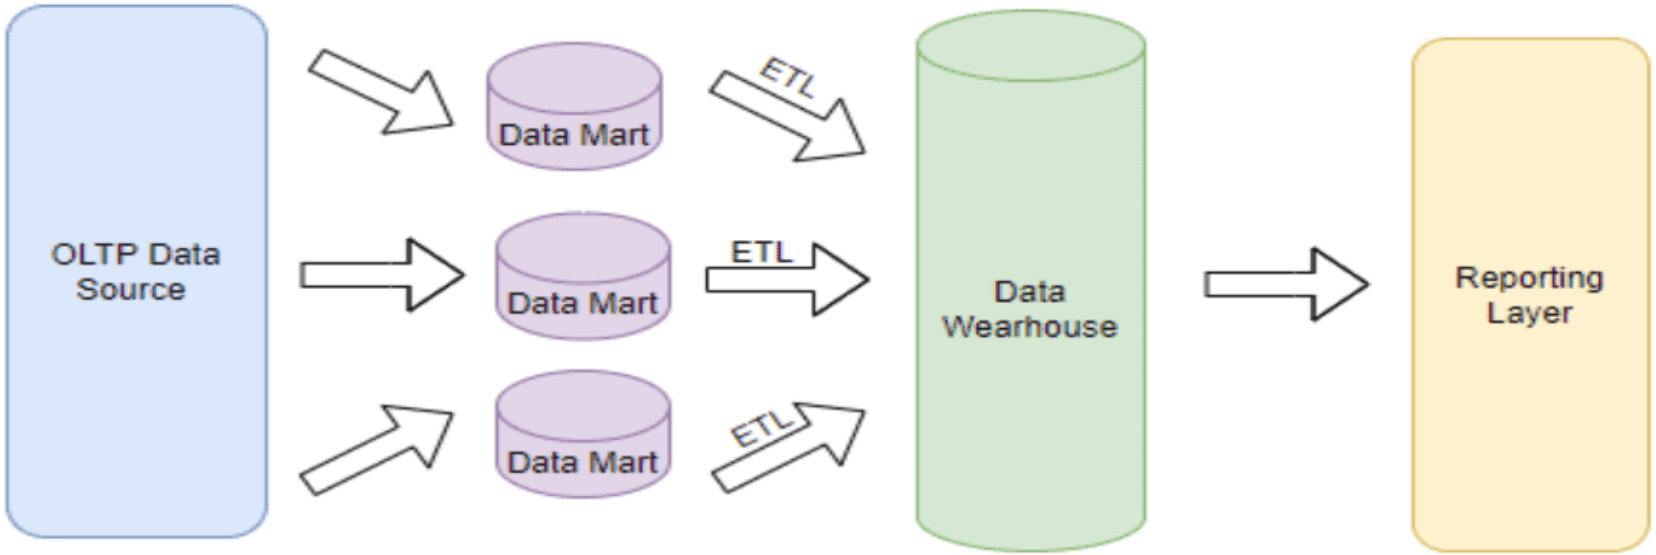
le Data Warehouse est un référentiel centralisé d'entreprise stockant l'information au niveau le plus détaillé. Des Datamarts modélisés sous forme de schémas en étoile sont ensuite crées à partir de ce Data Warehouse.



Approches Modélisation DataWarehouse

- **L'approche de Kimball (ou approche Bottom-Up)**

Le Data Warehouse peut être vu comme l'union des datamarts cohérents entre eux grâce aux dimensions conformes (data warehouse bus). La modélisation dimensionnelle permet un requetage facile et performant pour les utilisateurs.

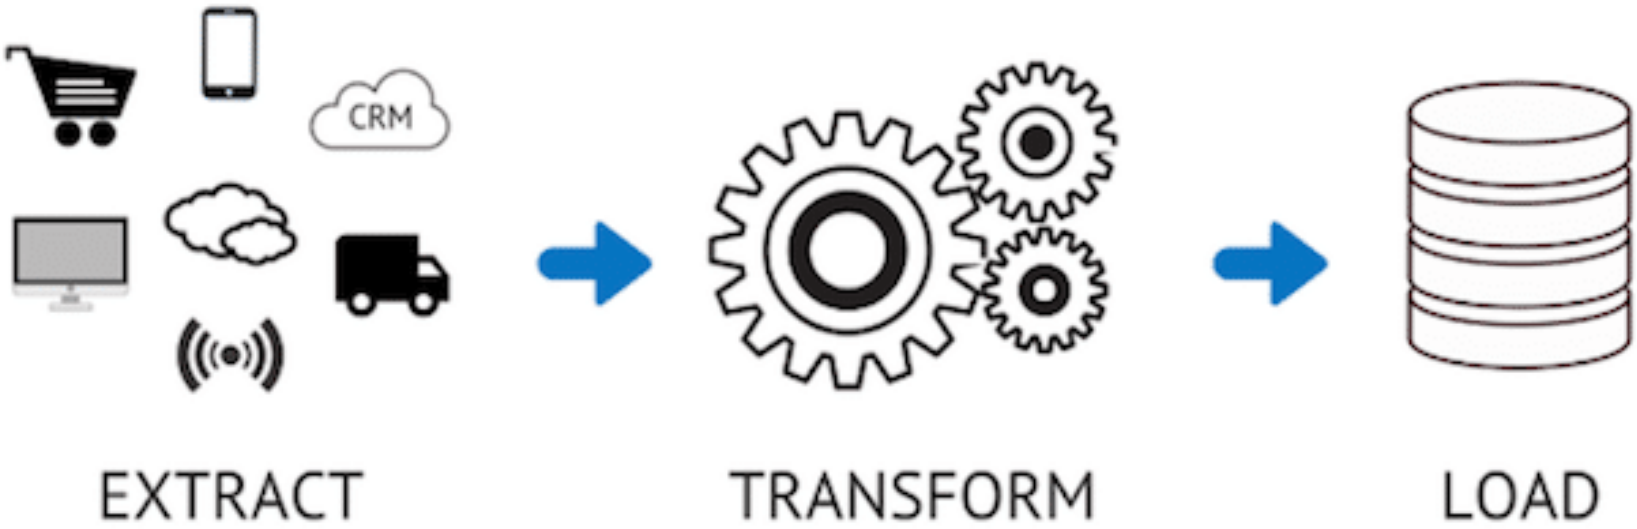


Partie 3:
Notions de la BI



ETL: Extract Transform Load

Processus permettant de collecter des données en provenance de sources multiples pour ensuite les convertir dans un format adapté à une Data Warehouse et les y transférer



ODS vs STAGING AREA

- **Points Communs:**

  Permettent de stocker les données extraites des SI sources

  Faire des opérations sur ces données

- **Différences:**

  Dans le cas du staging Area, les données sont détruites directement après avoir été chargées dans le Datawarehouse mais pas pour l'ODS où les données auront quand même une durée de vie plus longue.

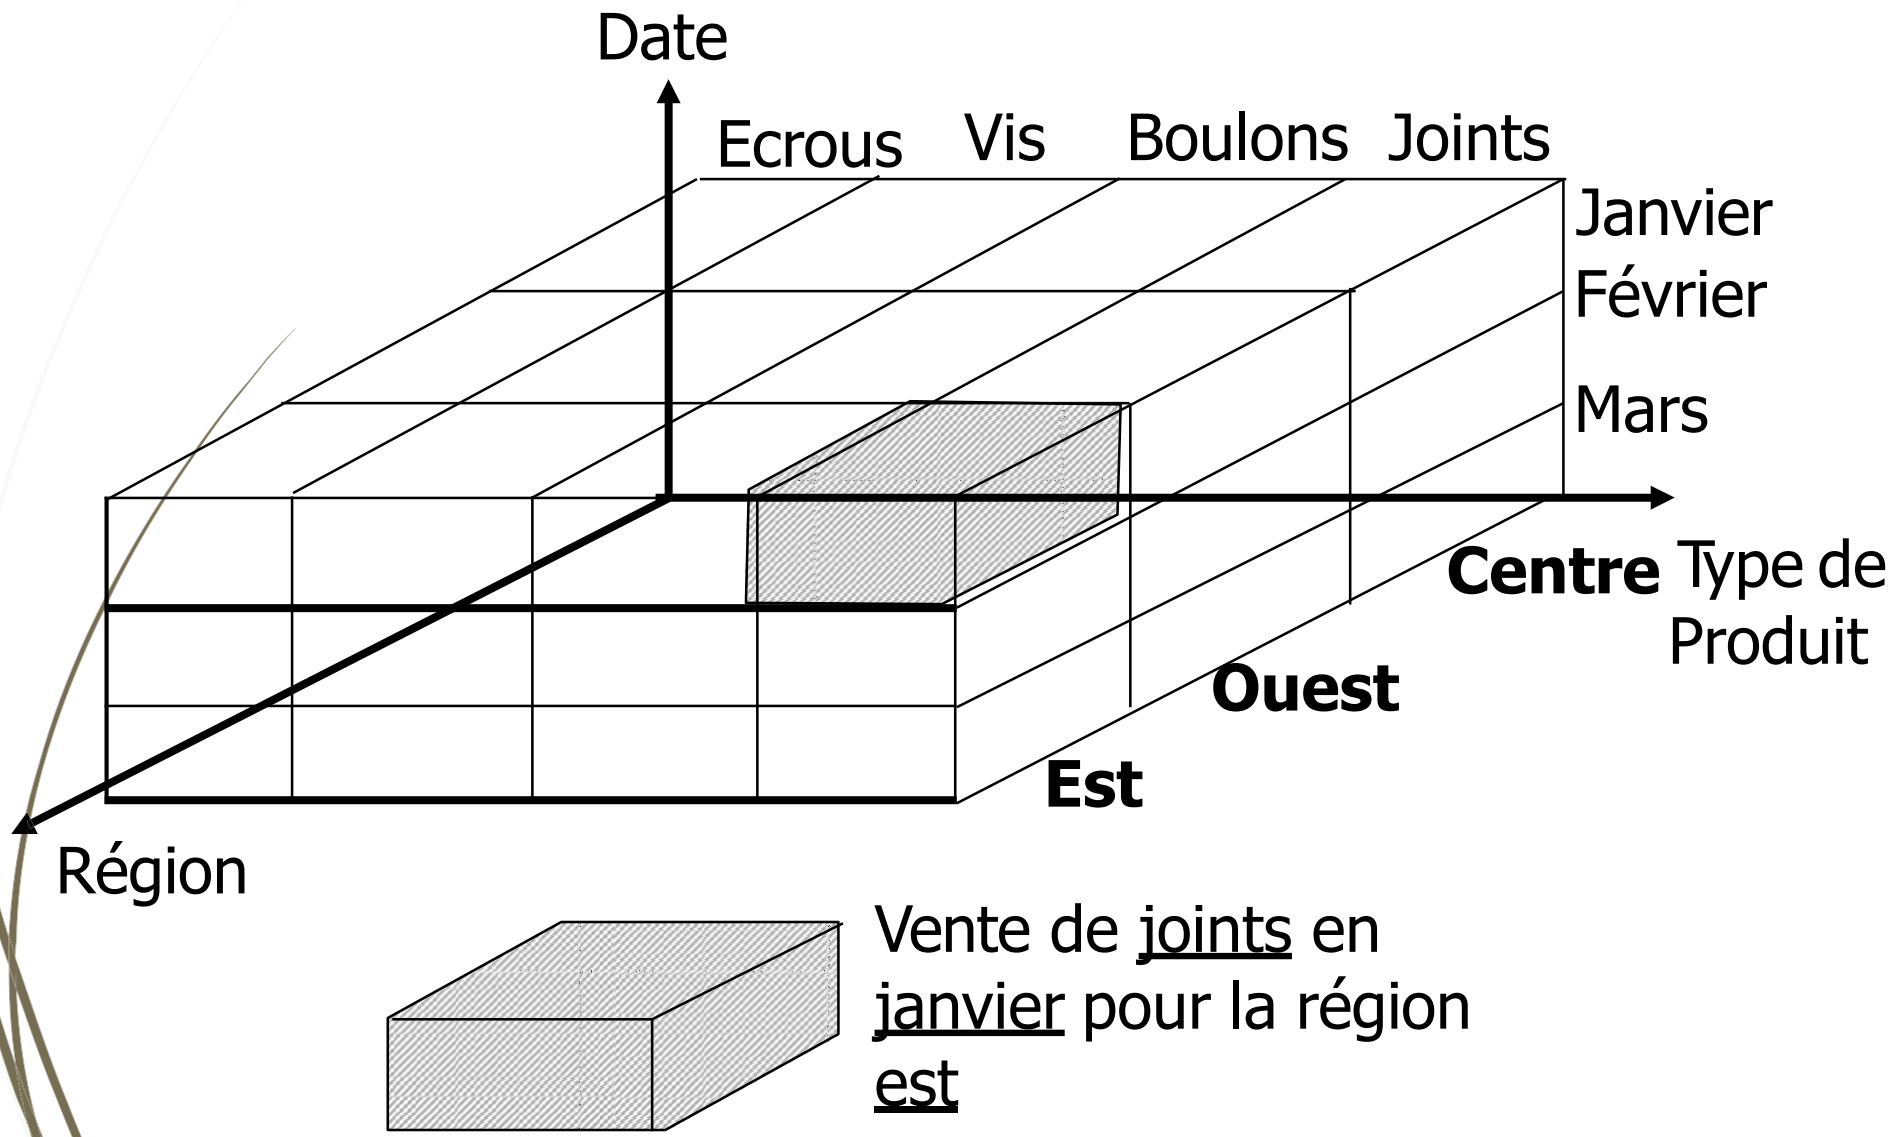
  l'ODS répond plus à une problématique de reporting immédiat dans le sens où l'ODS sera mis à jour plus souvent que le datawarehouse : on pourrait dire que l'ODS pourrait être alimenté toutes les semaines et le Datawarehouse une fois par mois.

Partie 4:
Cube OLAP



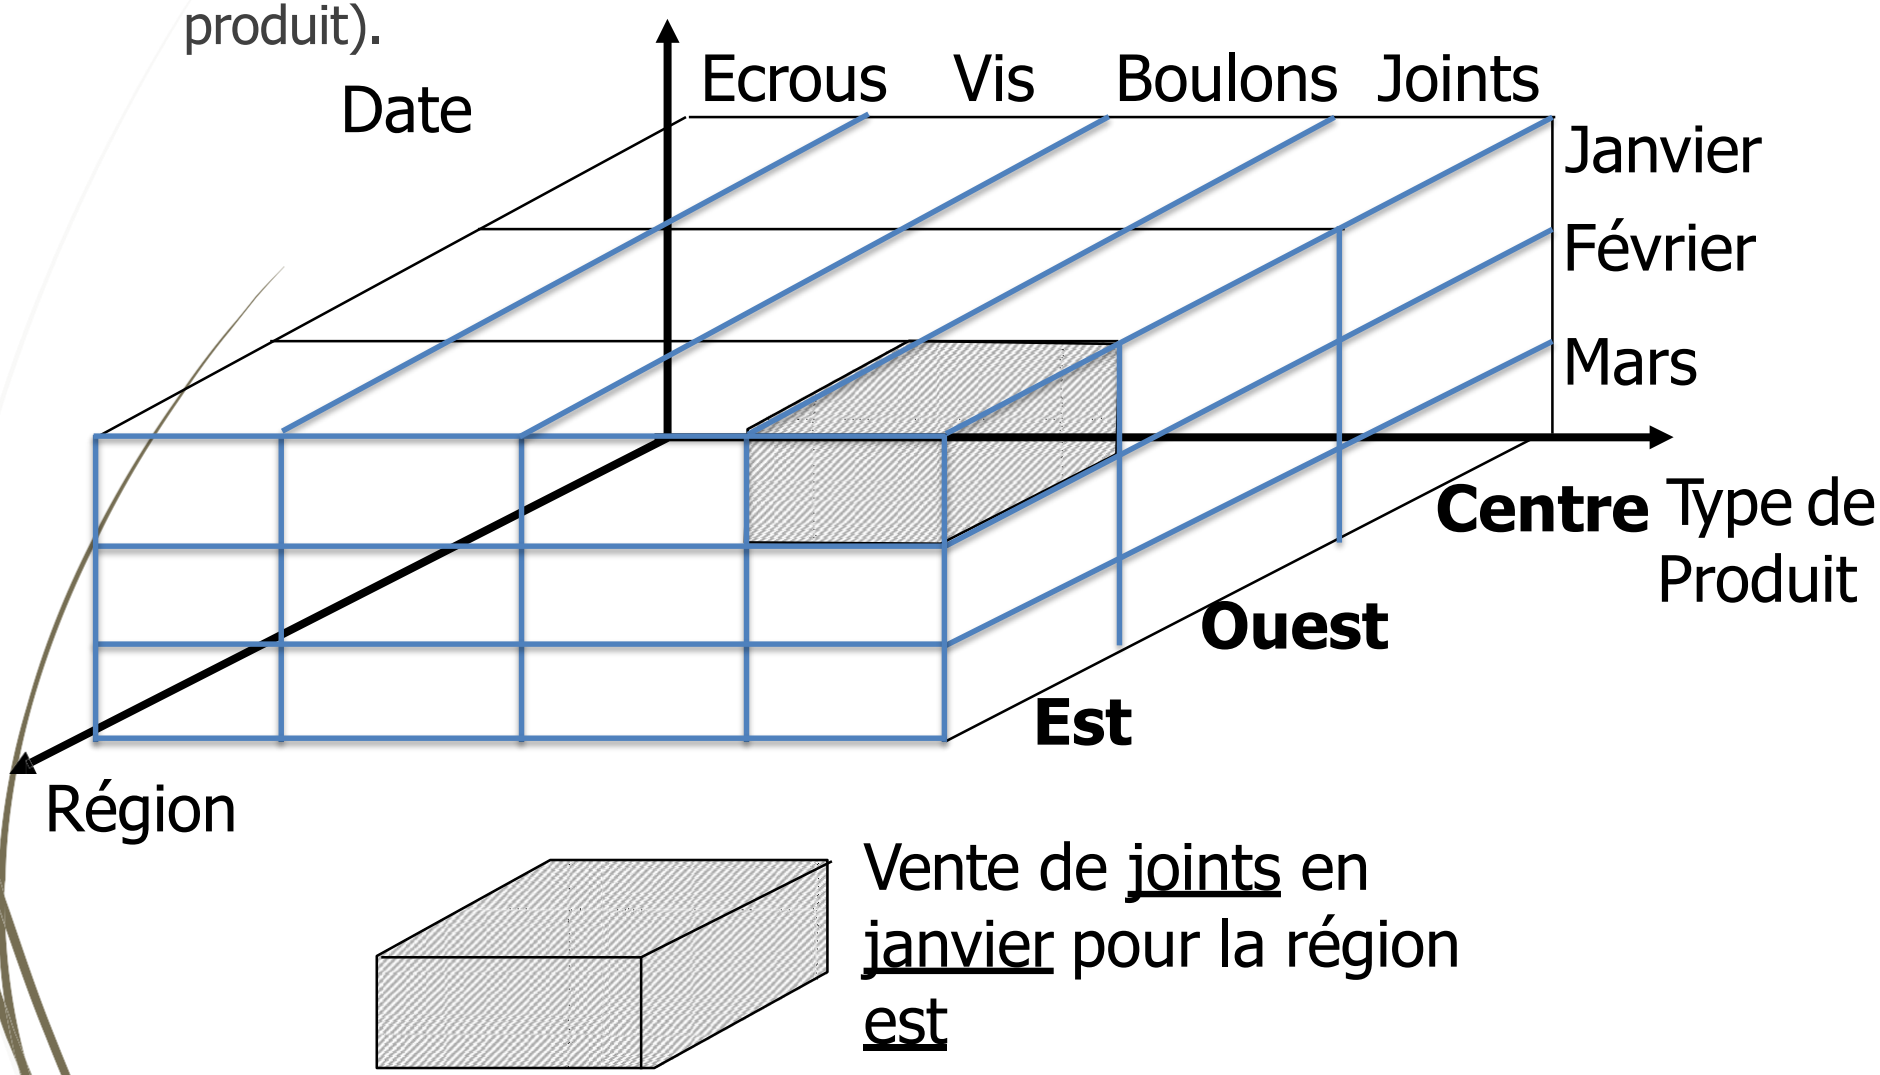
Cube OLAP

- représentation des données sous forme multidimensionnelle



Cube OLAP

- Axes: dimensions (date, type de produits, région),
- Chaque cellule de l'hypercube contient une mesure calculée (vente de produit).

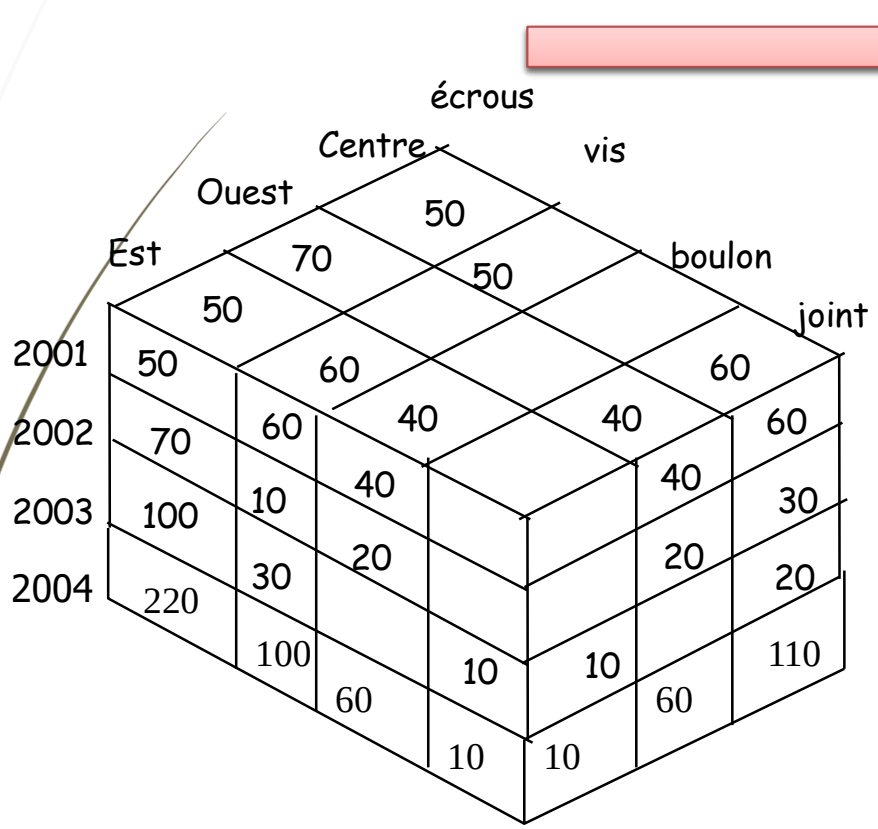


Vente de joints en janvier pour la région est

Manipulation d'un cube OLAP

SLICING: Sélection de tranches du cube par des prédicats selon une dimension

Slice

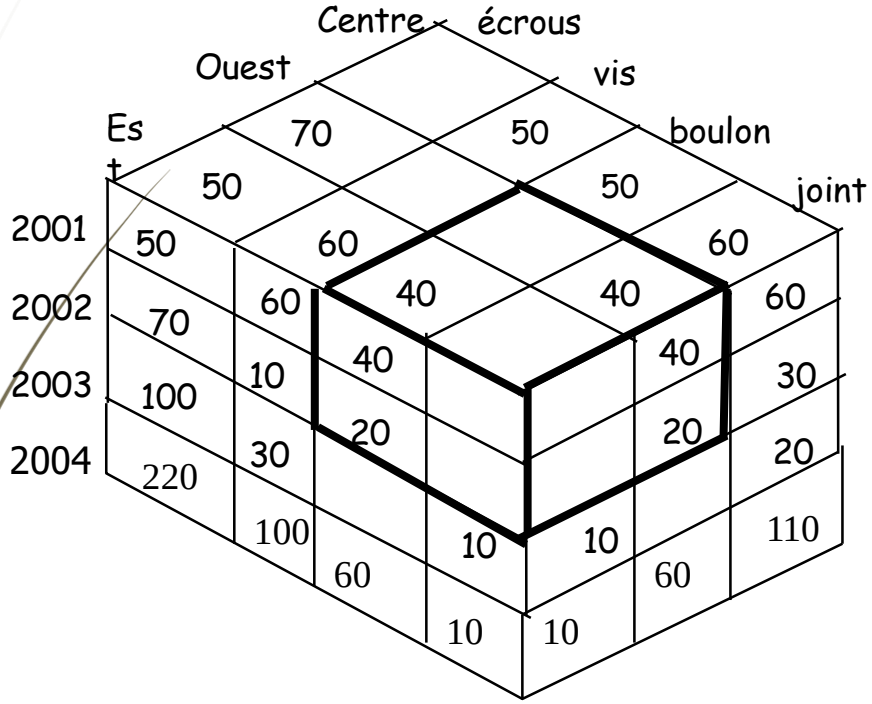


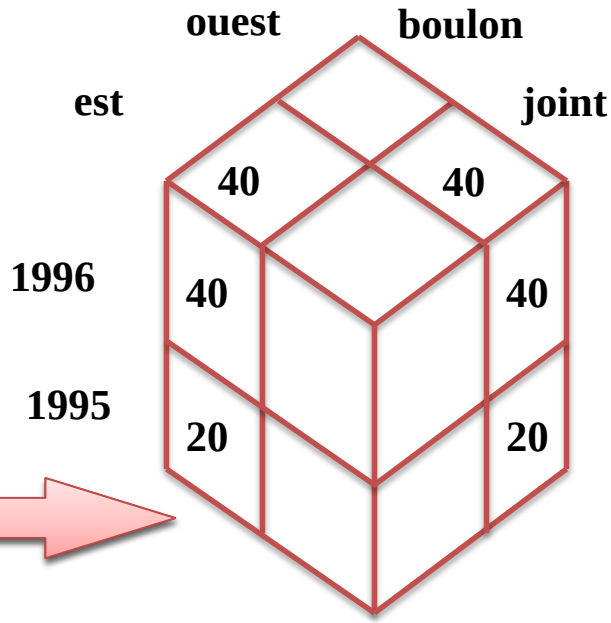
Slice **(2004)**

Ventes 2004	écrou	vis	boulon	joint
est	220	100	60	10
ouest	160	50	10	60
centre	20	150	170	110

Manipulation d'un cube OLAP

DICING: extraction d'un sous-cube

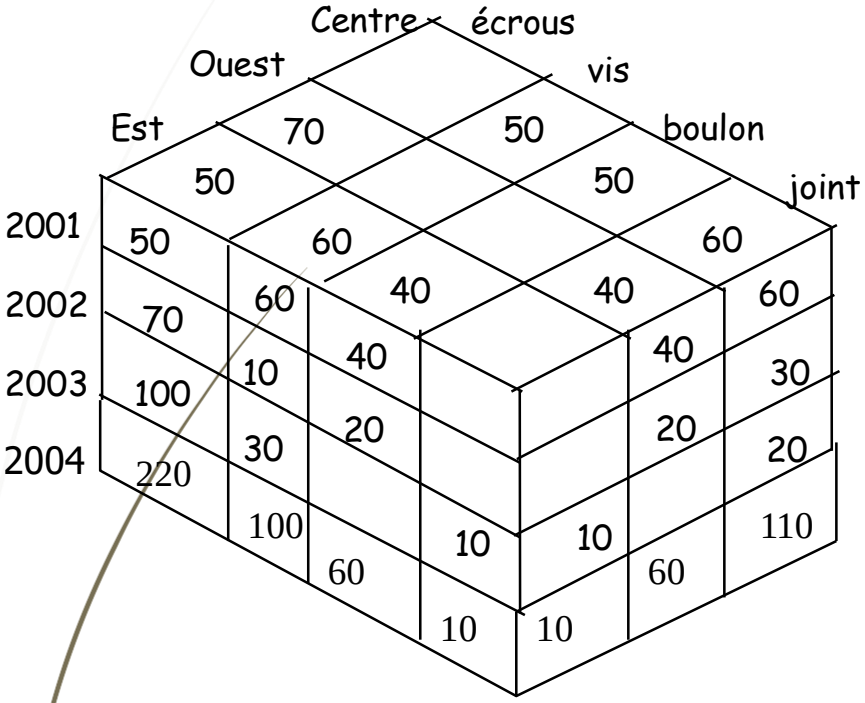




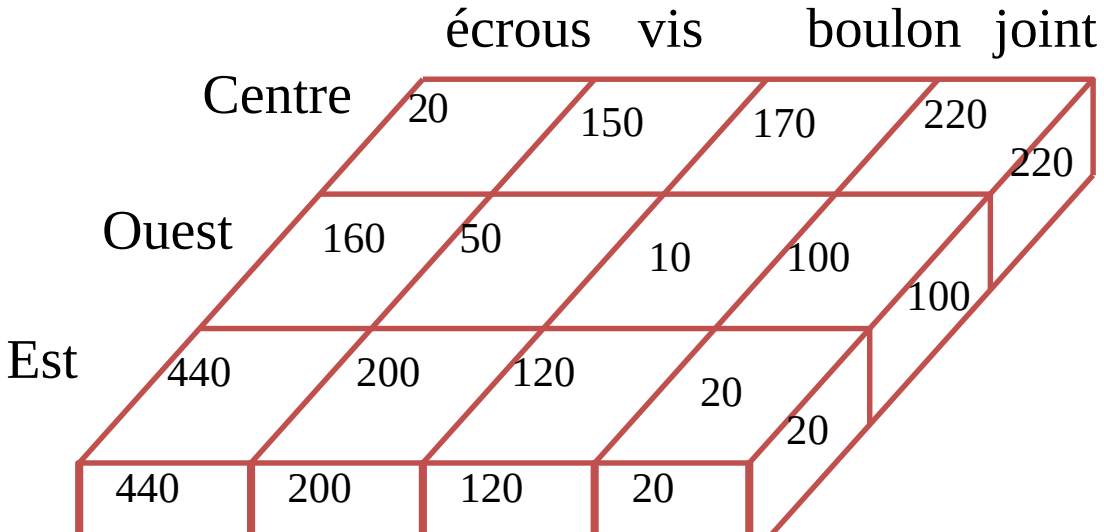
Dice

Manipulation d'un cube OLAP

- **Roll-Up:** représenter les données du cube à un niveau de granularité supérieur conformément à la hiérarchie définie sur la dimension.

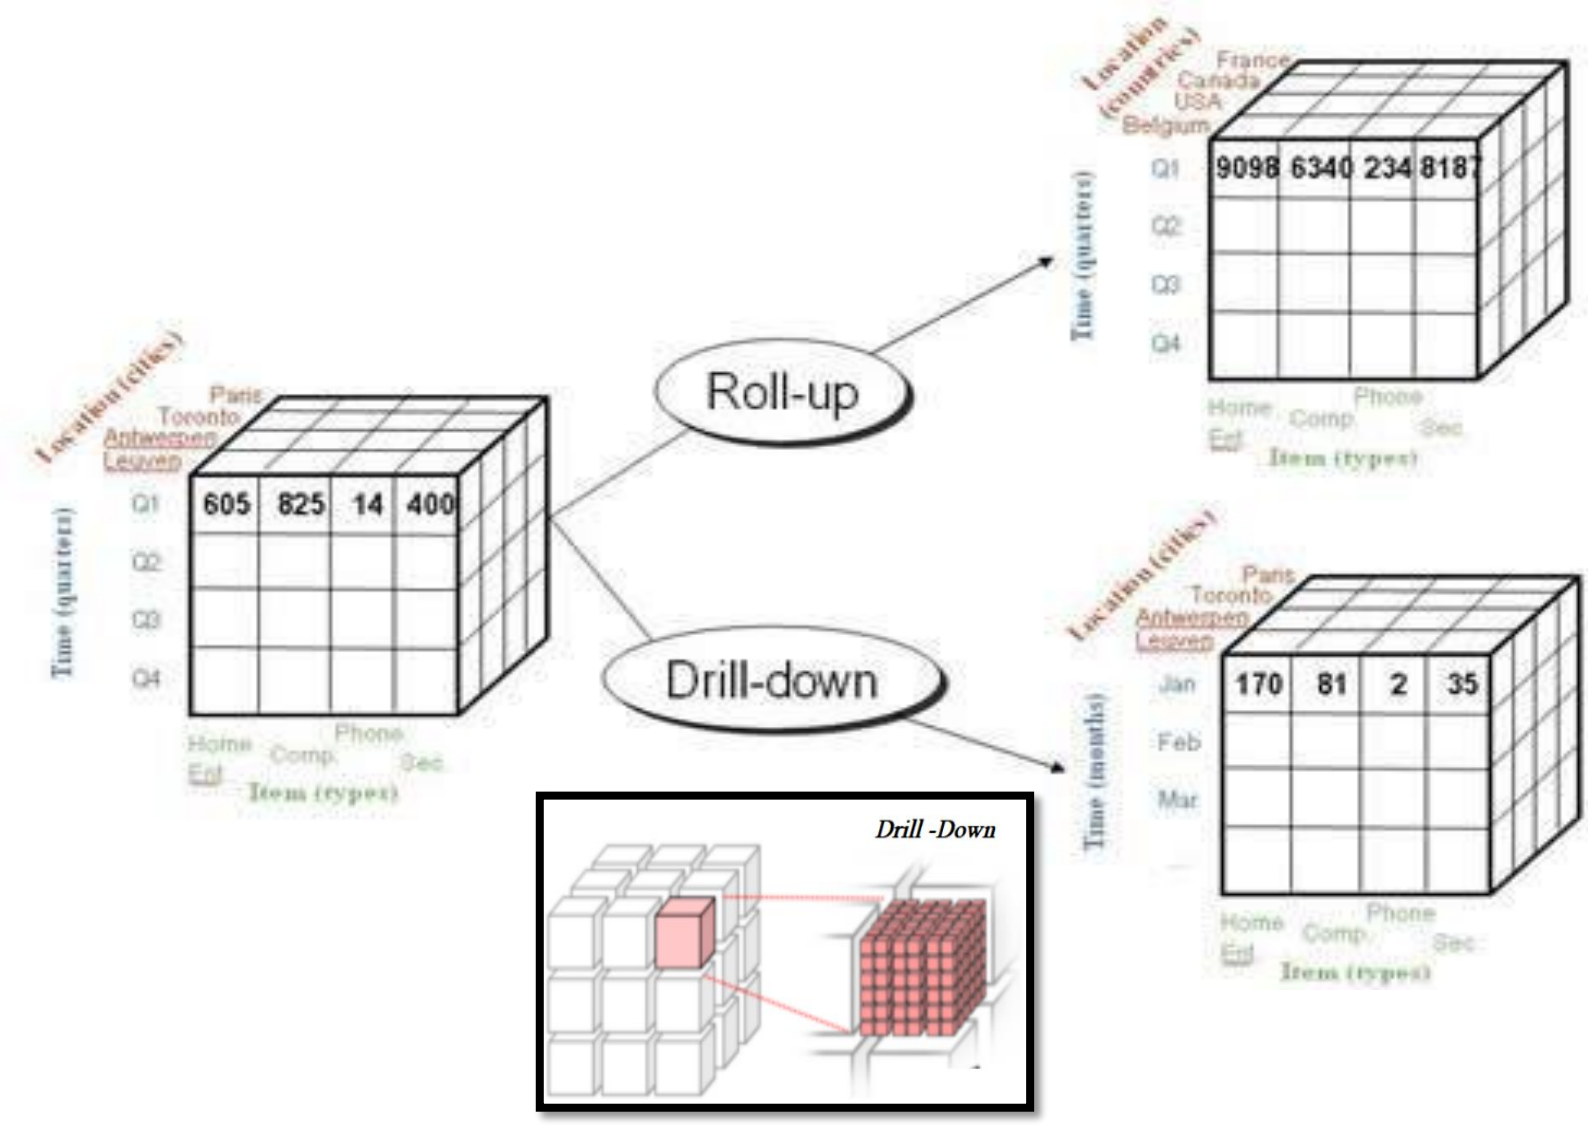


Roll up sur année

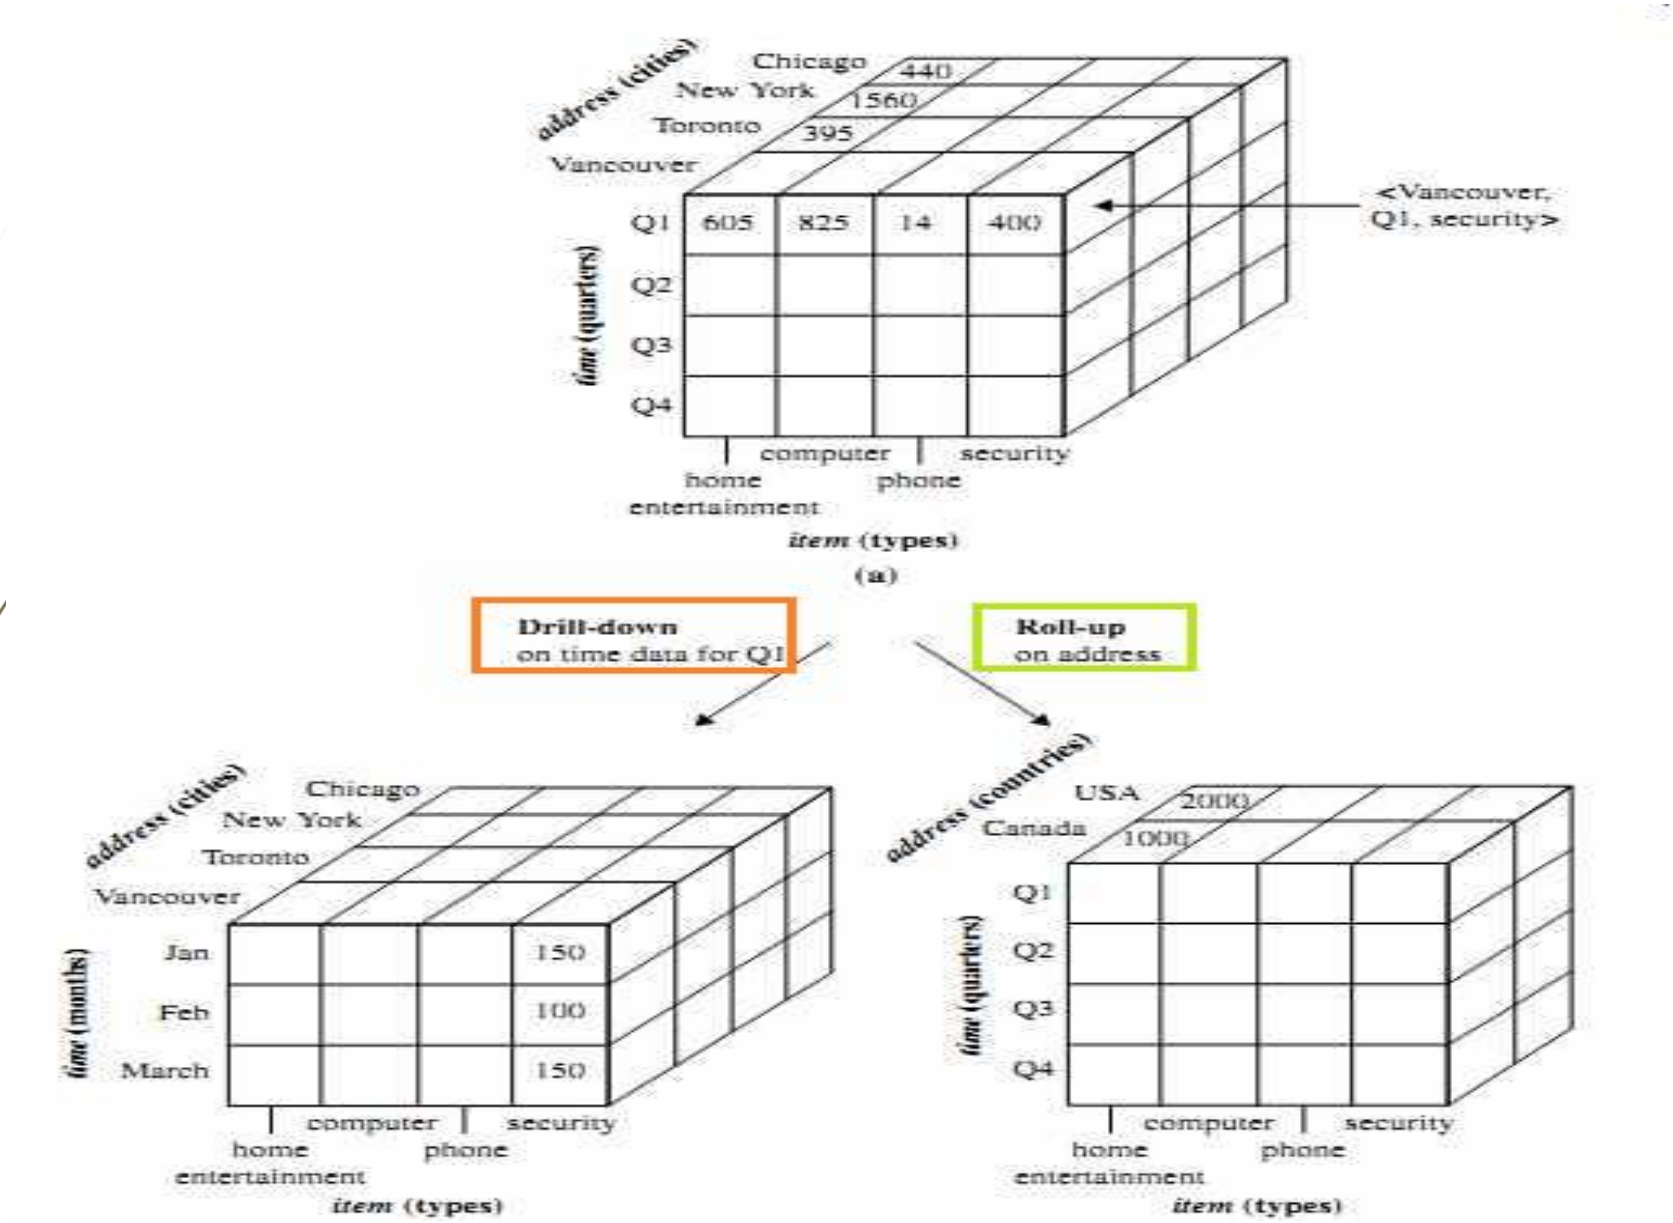


Manipulation d'un cube OLAP

- **Drill-Down:** à représenter les données du cube à un niveau de granularité de niveau inférieur, donc sous une forme plus détaillée.



Manipulation d'un cube OLAP

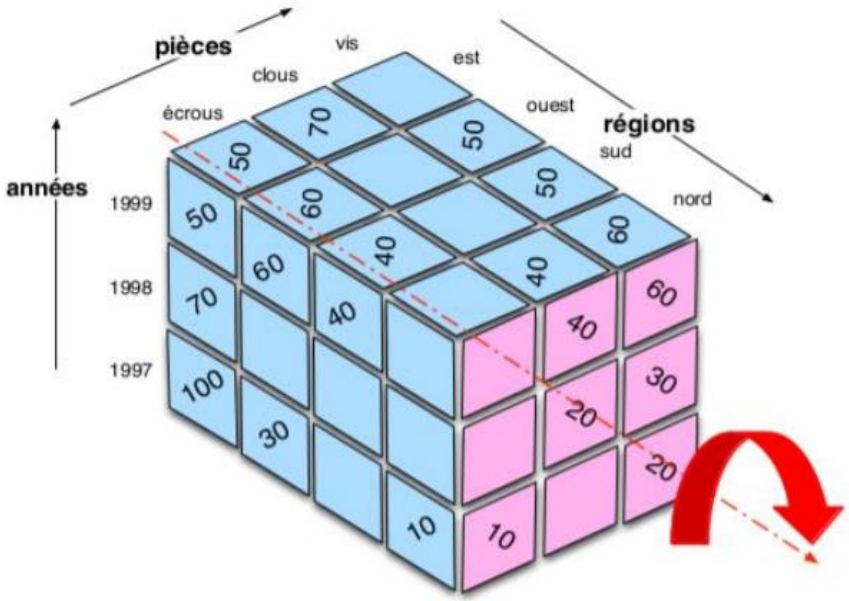


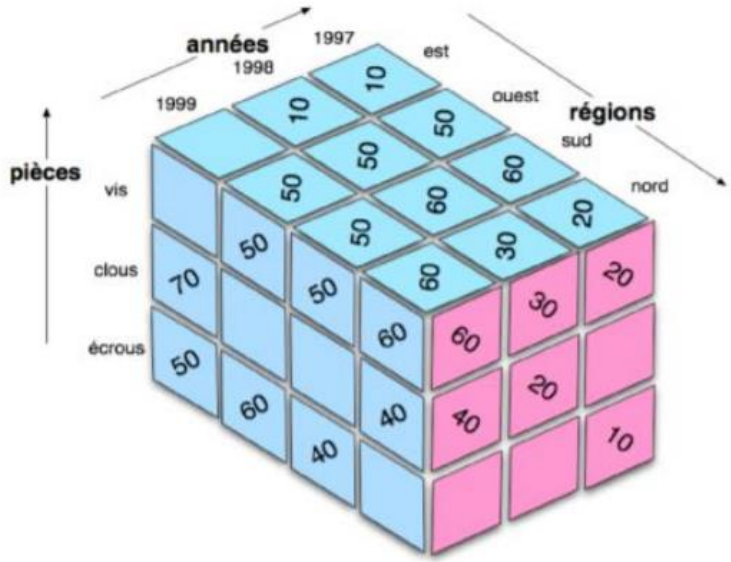
Manipulation d'un cube OLAP

- Concerne la représentation, permet un changement de points de vue selon différentes dimension.

Exemple 1:

- **Rotate (ou pivot):** consiste à faire une rotation à un cube autour d'un de ses axes, de manière à présenter un ensemble de faces différent.

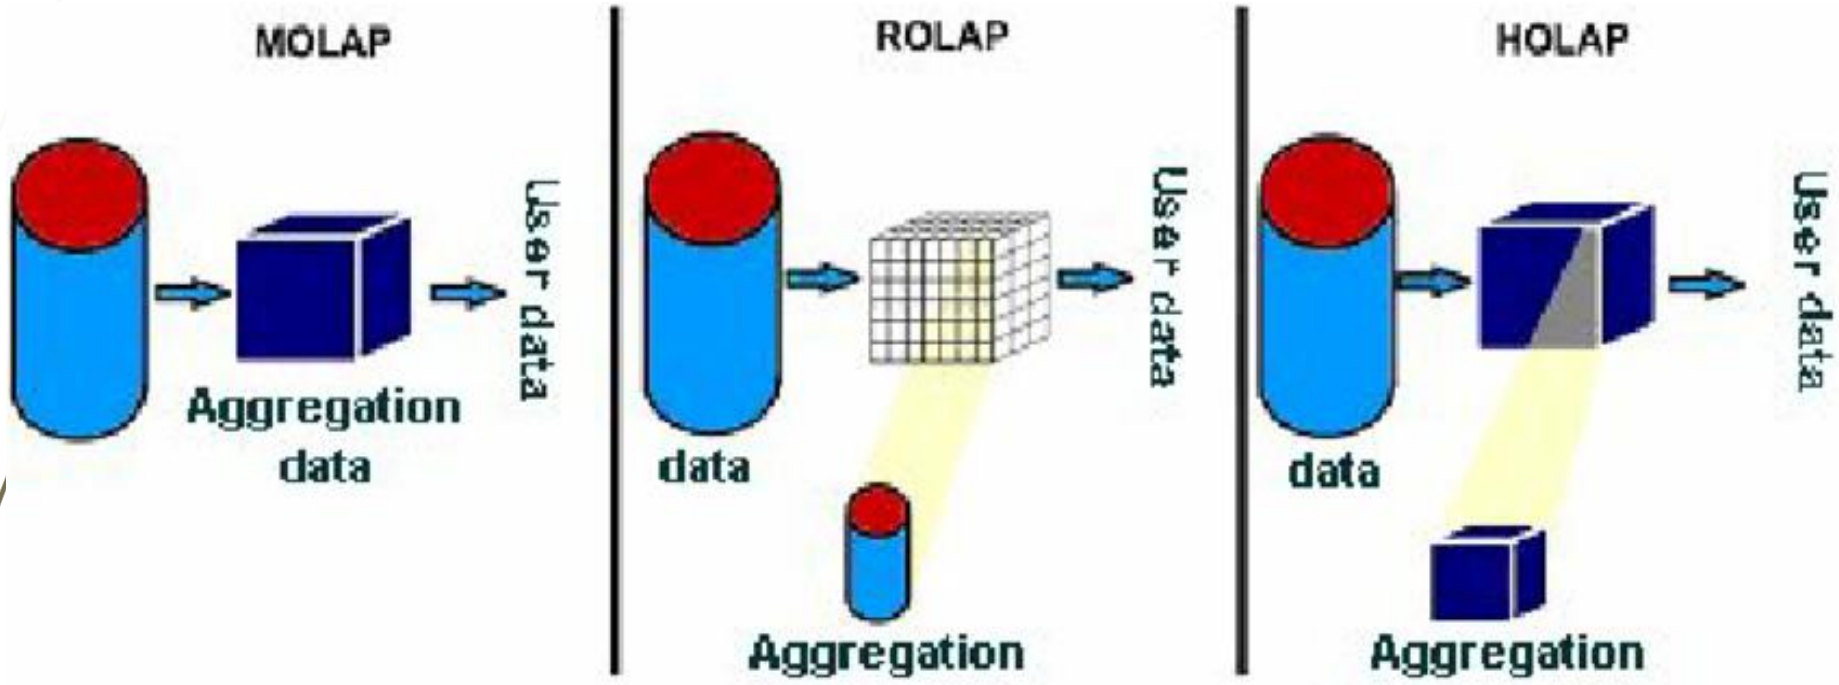




Types de Cubes

- **Relational OLAP (ROLAP)**
  - Données sont stockées dans un SGBD relationnel
  - Un moteur OLAP permet de simuler le comportement d'un SGBD multi-dimensionnel
- **Multidimensional OLAP (MOLAP)**
  - Structure de stockage en cube
  - Accès direct aux données dans le cube
- **Hybrid OLAP (HOLAP)**
  - Données stockées dans SGBD relationnel (données de base) + structure de stockage en cube (données agrégées)

MOLAP vs ROLAP vs HOLAP



Références

Modes of data storing based on [15]. | Download Scientific Diagram (researchgate.net)

Kimball vs Inman - Data Analytics Team (d-a-team.com)

Concept de Business Intelligence à l'aide de conception pyramidale. Étapes du flux de traitement : sources de données, ETL, OLAP datawarehouse -- l'exploitation de données, analyse des données - 2002 Image Vectorielle Stock - Alamy (alamyimages.fr)