DATA MINING

Chapitre 0: introduction à
la fouille de données

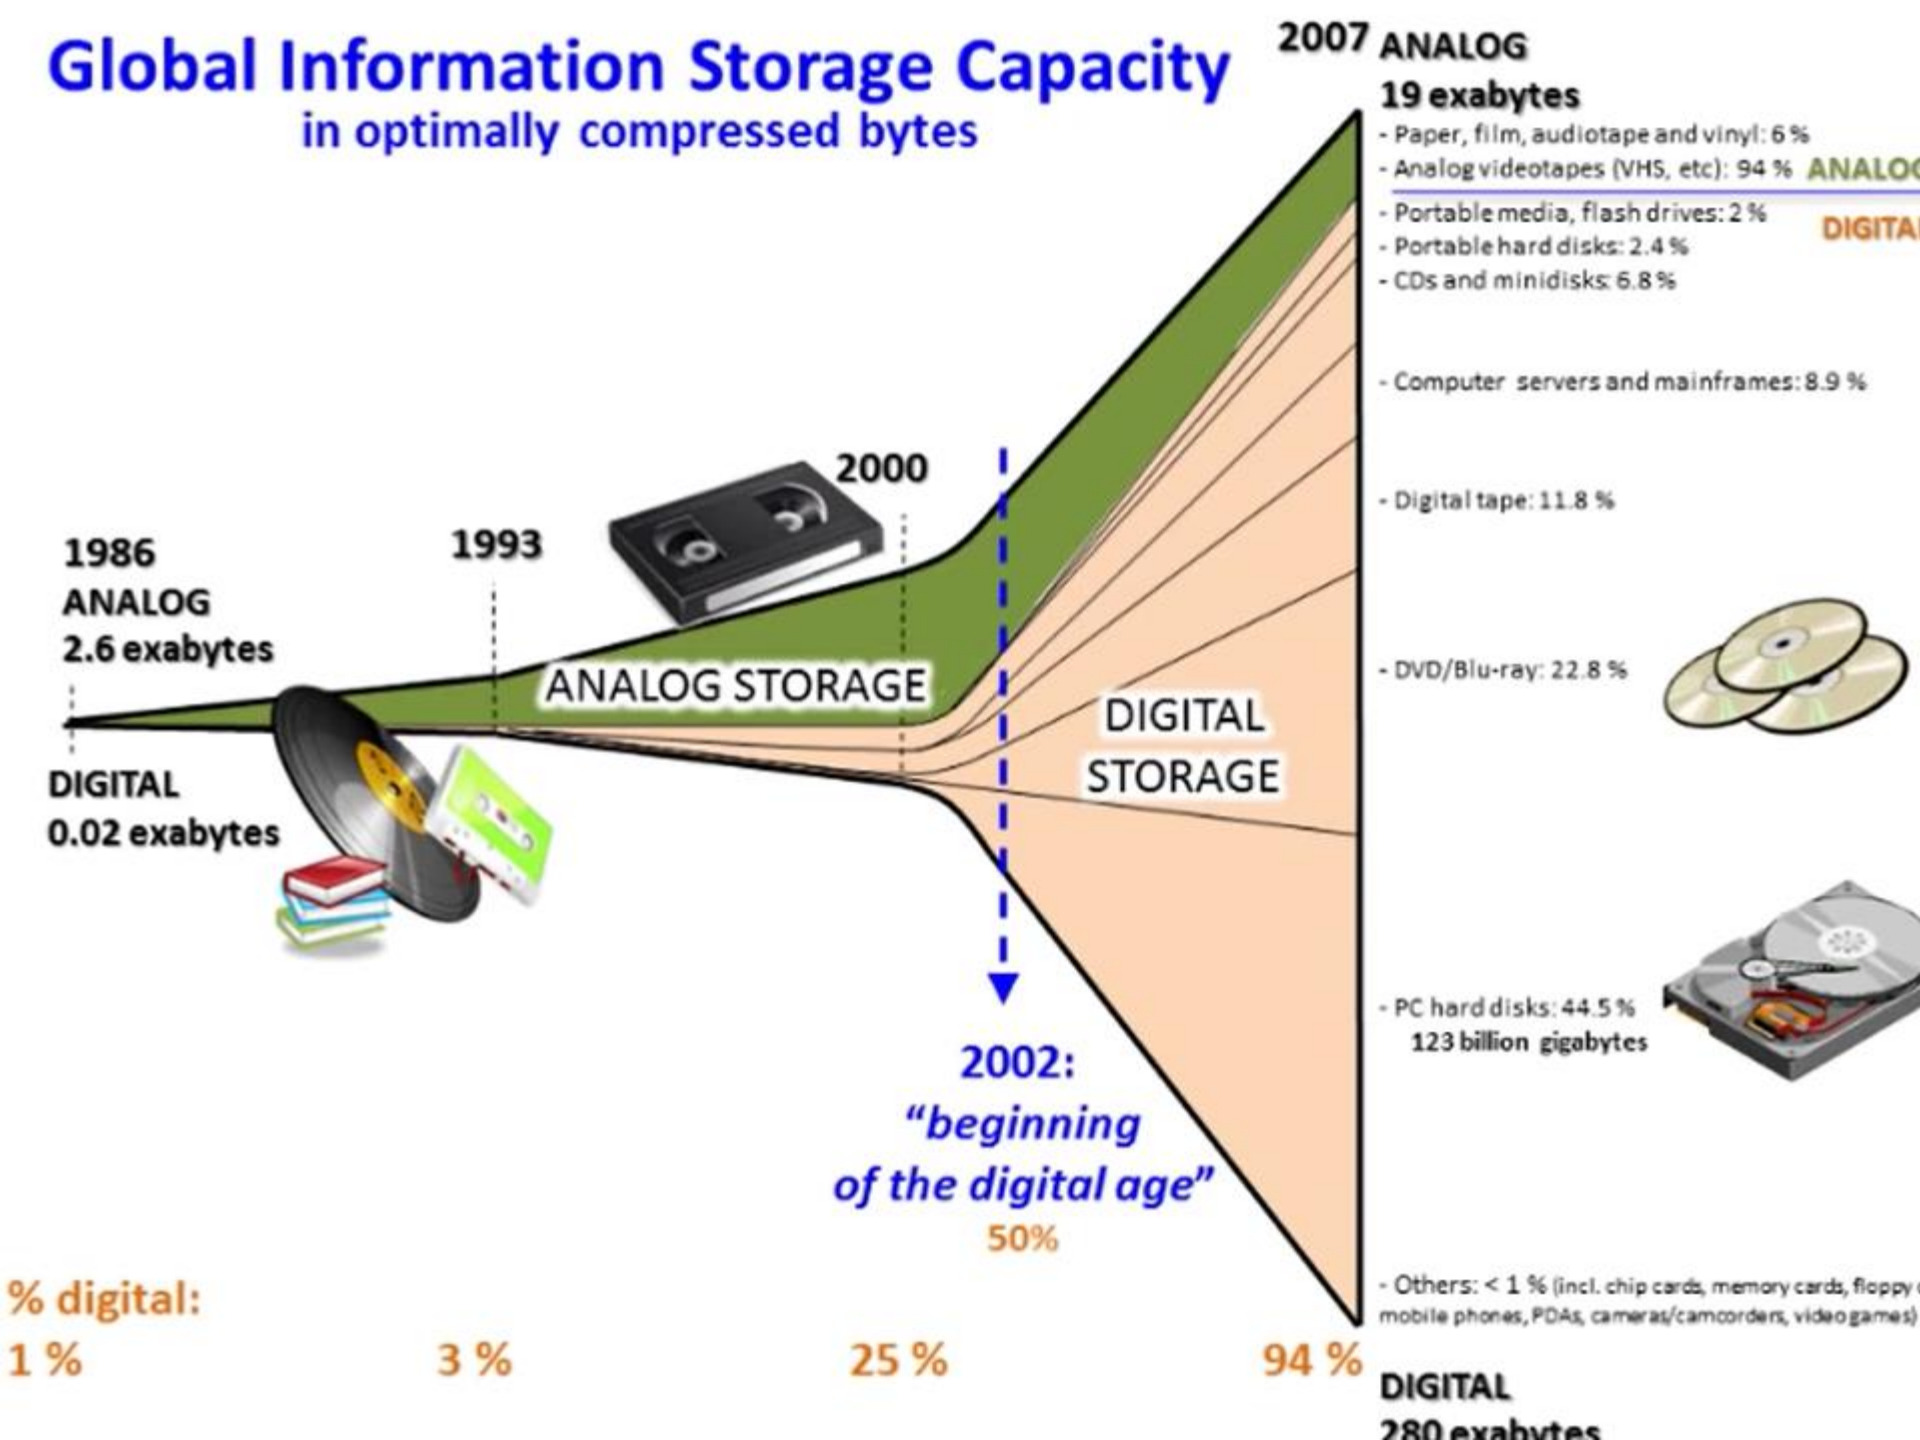
4 ERP-BI-4TWIN-4SAE-4INFINI
2023-2024

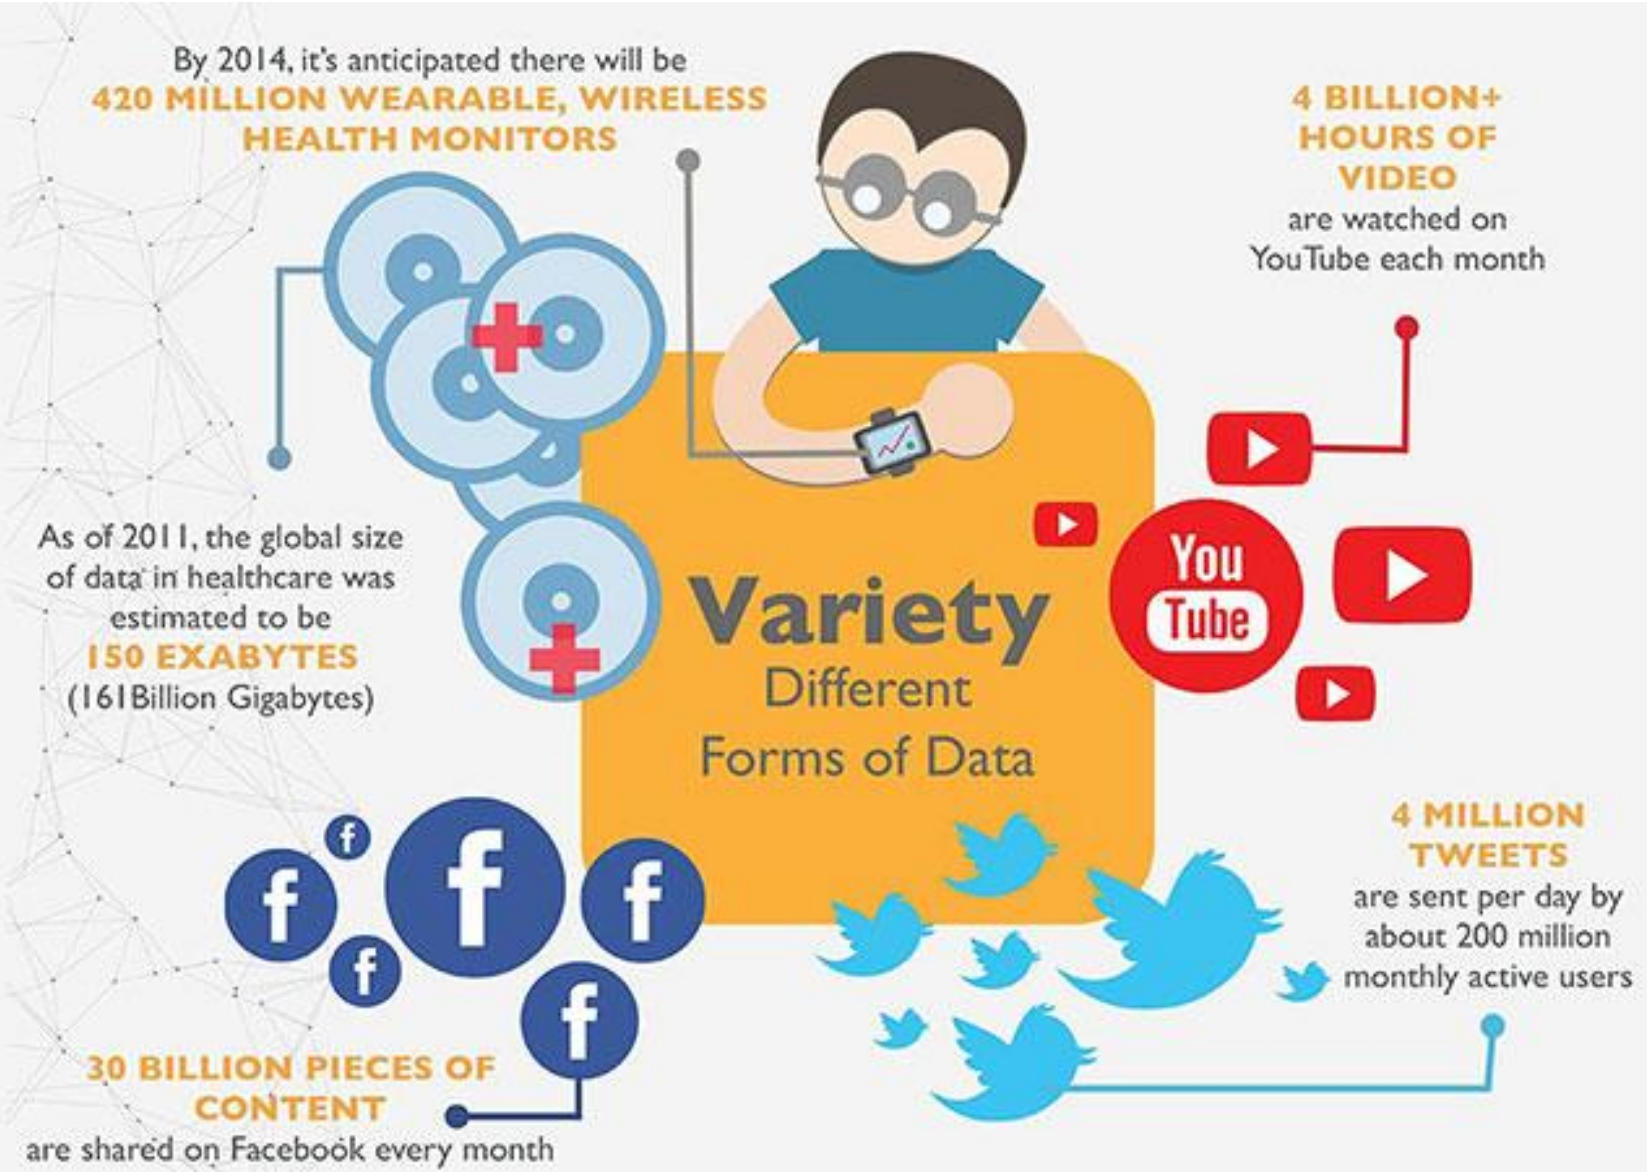
Mohamed Heny SELMI- Wiem Trabelsi

- **Les données ? Les sources? Les types ?**
- **Le Big Data**
- **Le Business Intelligence**
- **Analyser, décrire, résumer, prédire, …Décider ;)**
- **Le Data Mining :**
    - Définition
    - Aspect pluridisciplinaire
    - Applications
    - Finance, Marketing,
    - méthodes et algorithmes
    - Processus et méthodologies
    - À retenir !

Global Information Storage Capacity

in optimally compressed bytes




By 2014, it's anticipated there will be
420 MILLION WEARABLE, WIRELESS HEALTH MONITORS
4 BILLION+ HOURS OF VIDEO
are watched on YouTube each month
As of 2011, the global size of data in healthcare was estimated to be
150 EXABYTES
(161Billion Gigabytes)
Variety
Different Forms of Data
You Tube
4 MILLION TWEETS
are sent per day by about 200 million monthly active users
30 BILLION PIECES OF CONTENT
are shared on Facebook every month


COLLECTION
STORAGE
RESEARCH
BIG
DATA
SHARED
ANALYSIS
EXABYTE
VISUALIZATION
VOLUME

DIVERSITÉ DE DONNÉES









































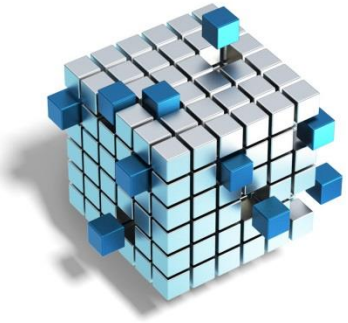


LES APPROCHES « BUSINESS INTELLIGENCE »















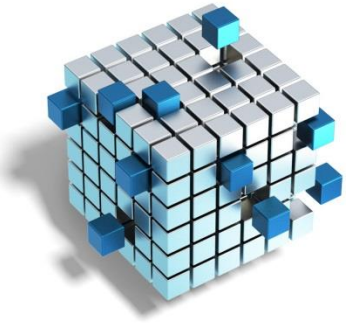
Et si on veut aller plus loin :

Décider !









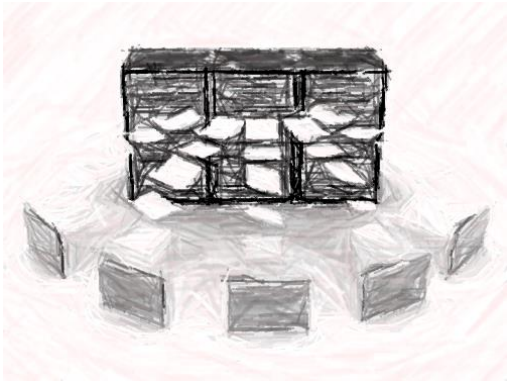


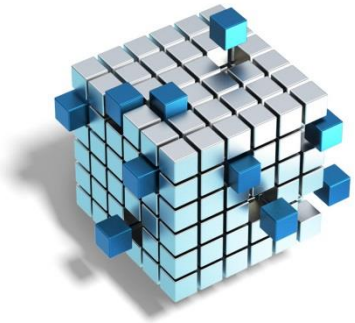




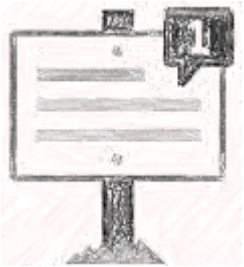









IBM
Cognos
Explore
Business KPIs
Business Performance Monitor

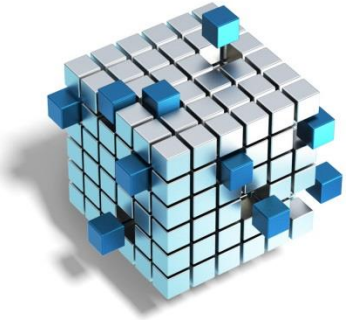








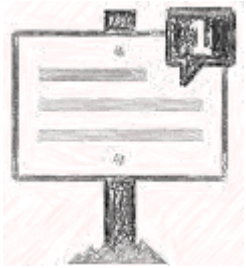




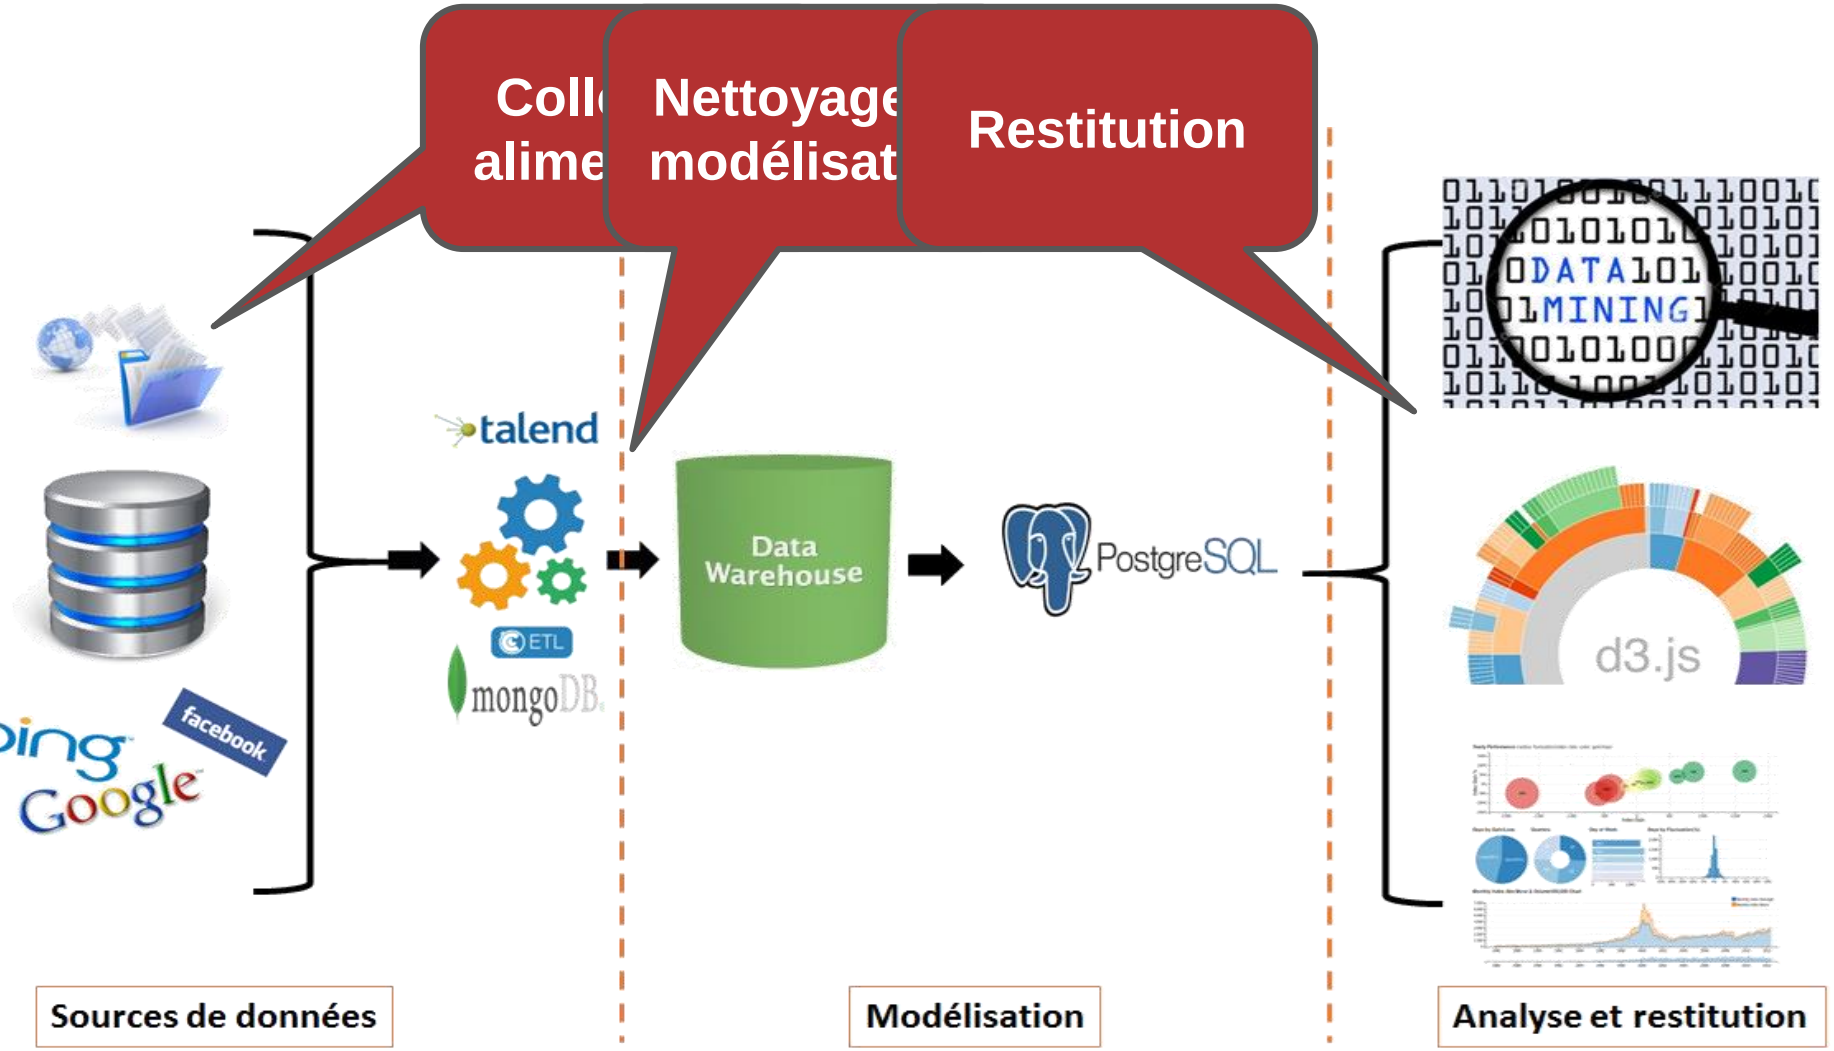


Solution :
Fouiller dans les données





CHAINE DÉCISIONNELLE



DÉFINITION



C’est l’ensemble des algorithmes, méthodes et technologies inspirés de plusieurs autres disciplines, propres ou non au DM

pouvant servir à remplacer ou à aider l’expert humain ou le décideur dans un domaine spécifique dans le cadre de prise de décision, et ce en fouillant dans des bases de données décisionnelles des corrélations, des associations, des comportements homogènes, des formules de lien entre indicateurs, des spécification par rapport à une thématique bien déterminée, etc.

Cet ensemble de techniques peut être une étape fondamentale dans tout processus ECD (KDD) ou bien l’intervention de l’intelligence artificielle, la reconnaissance de forme, et la statistique décisionnelle dans tout processus de Business Intelligence afin de transformer tout système d’aide à la décision en un système DECISONNEL au vrai sens du mot.

ENJEUX



- Simplifier la production de données ou informations structurées et porteuses de sens

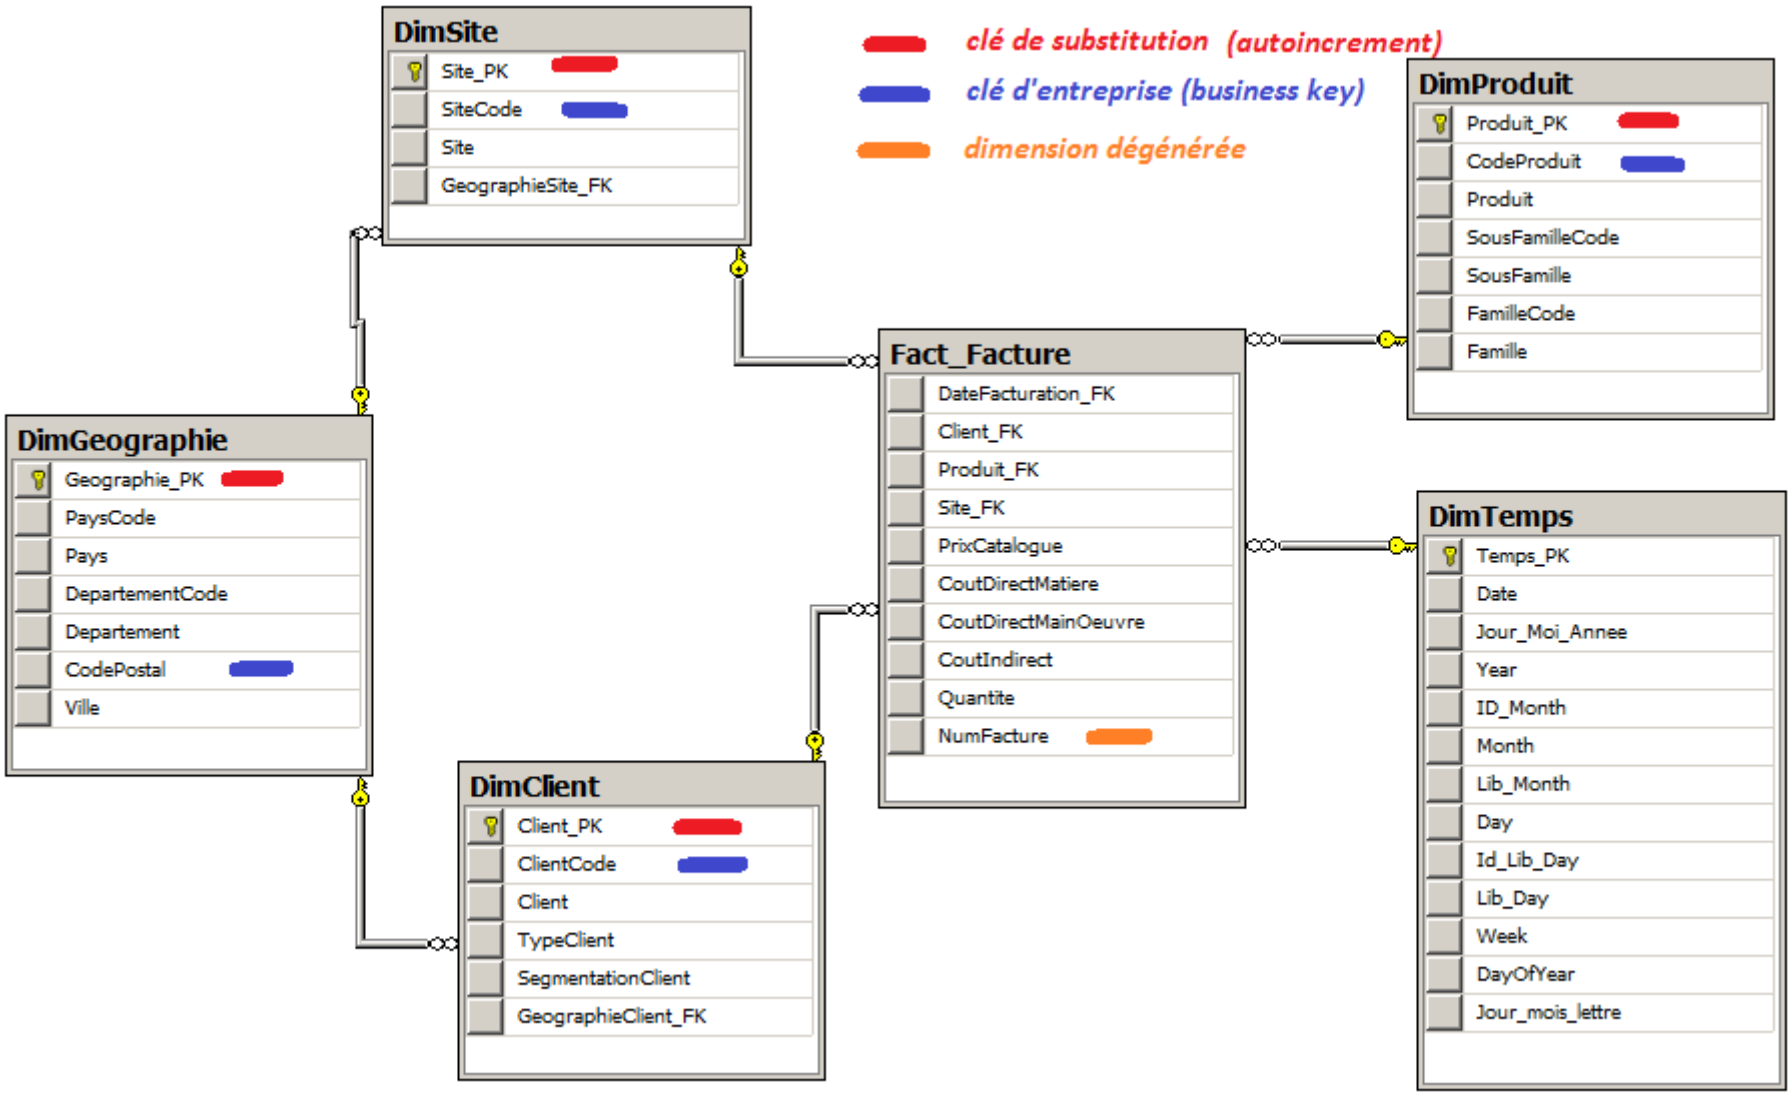
- Créer du sens et des connaissances à partir de données non enrichies et non structurées

- Analyser des tendances sur la durée

- Permettre la création de modèles sur des historiques de données

- Analyse prédictive

STRUCTURATION DE DONNÉES



ENTREPÔT DE DONNÉES

	A	B	C	D	E	F	G	H
1	age	sexe	typedouleur	sucre	tauxmax	angine	depression	coeur
2	70	masculin	D	A	109	non	24	presence
3	67	feminin	C	A	160	non	16	absence
4	57	masculin	B	A	141	non	3	presence
5	64	masculin	D	A	105	oui	2	absence
6	74	feminin	B	A	121	oui	2	absence
7	65	masculin	D	A	140	non	4	absence
8	56	masculin	C	B	142	oui	6	presence
9	59	masculin	D	A	142	oui	12	presence
10	60	masculin	D	A	170	non	12	presence
11	63	feminin	D	A	154	non	40	presence
12	59	masculin	D	A	161	non	5	absence
13	53	masculin	D	A	111	oui	0	absence
14	44	masculin	C	A	180	non	0	absence
15	61	masculin	A	A	145	non	26	presence
16	57	feminin	D	A	159	non	0	absence
17	71	feminin	D	A	125	non	16	absence
18	46	masculin	D	A	120	oui	18	presence
19	53	masculin	D	B	155	oui	31	presence
20	64	masculin	A	A	144	oui	18	absence

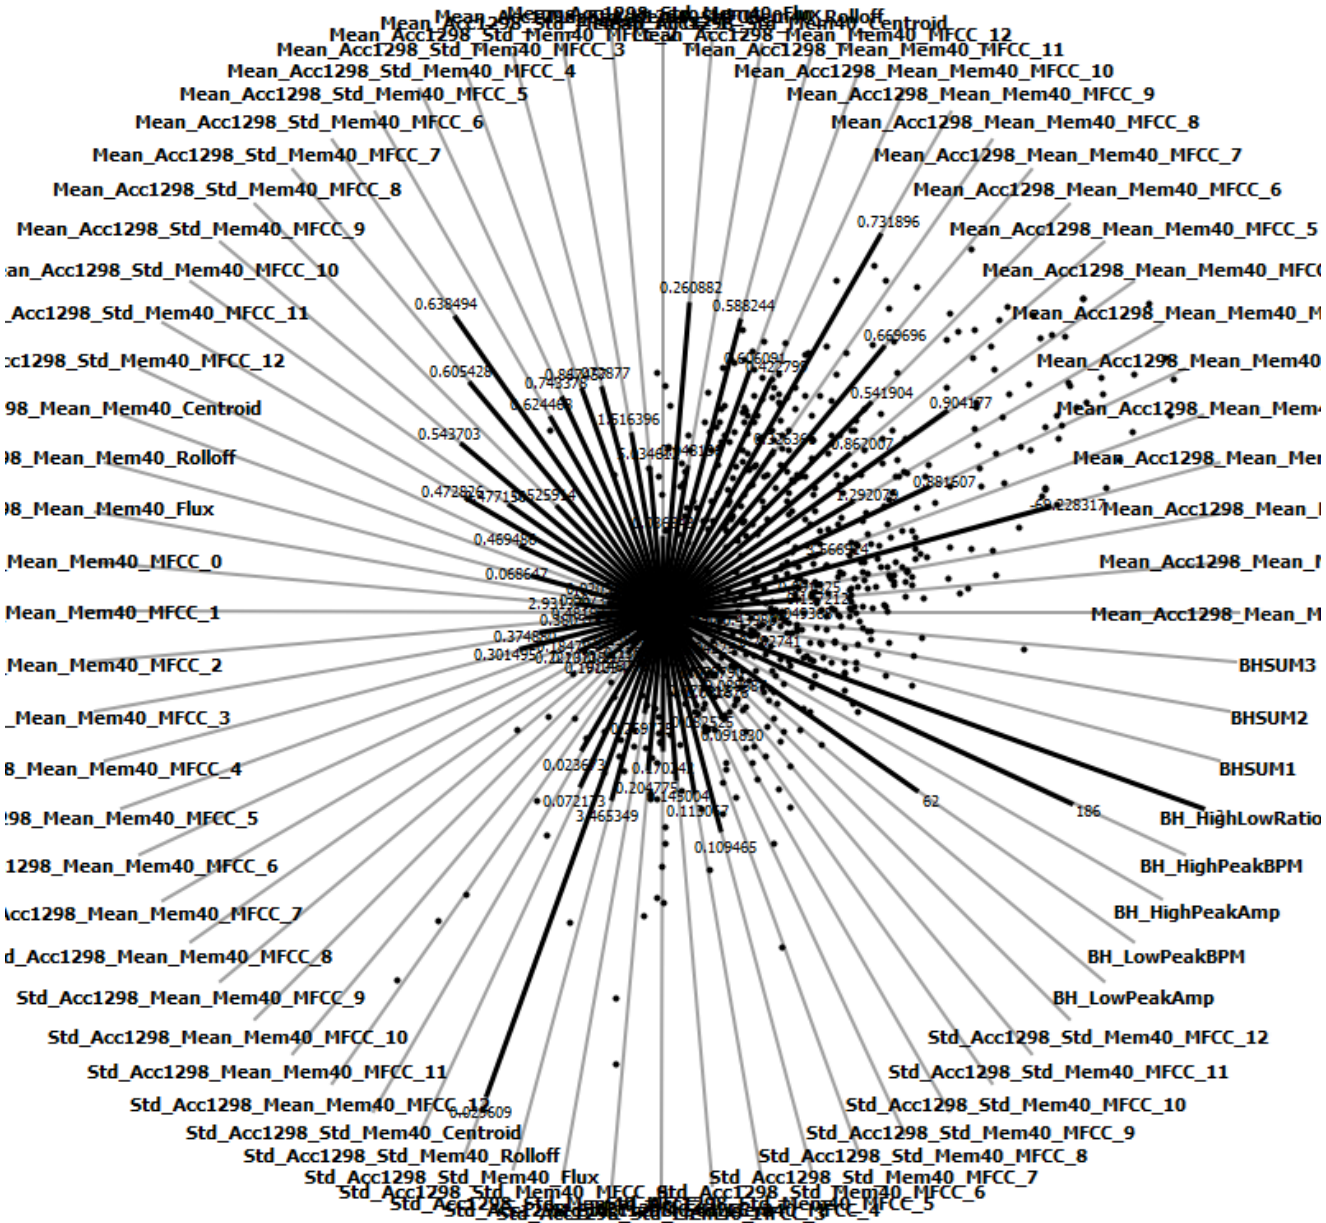
Axes d'analyse

Mesures

Clef de substitution

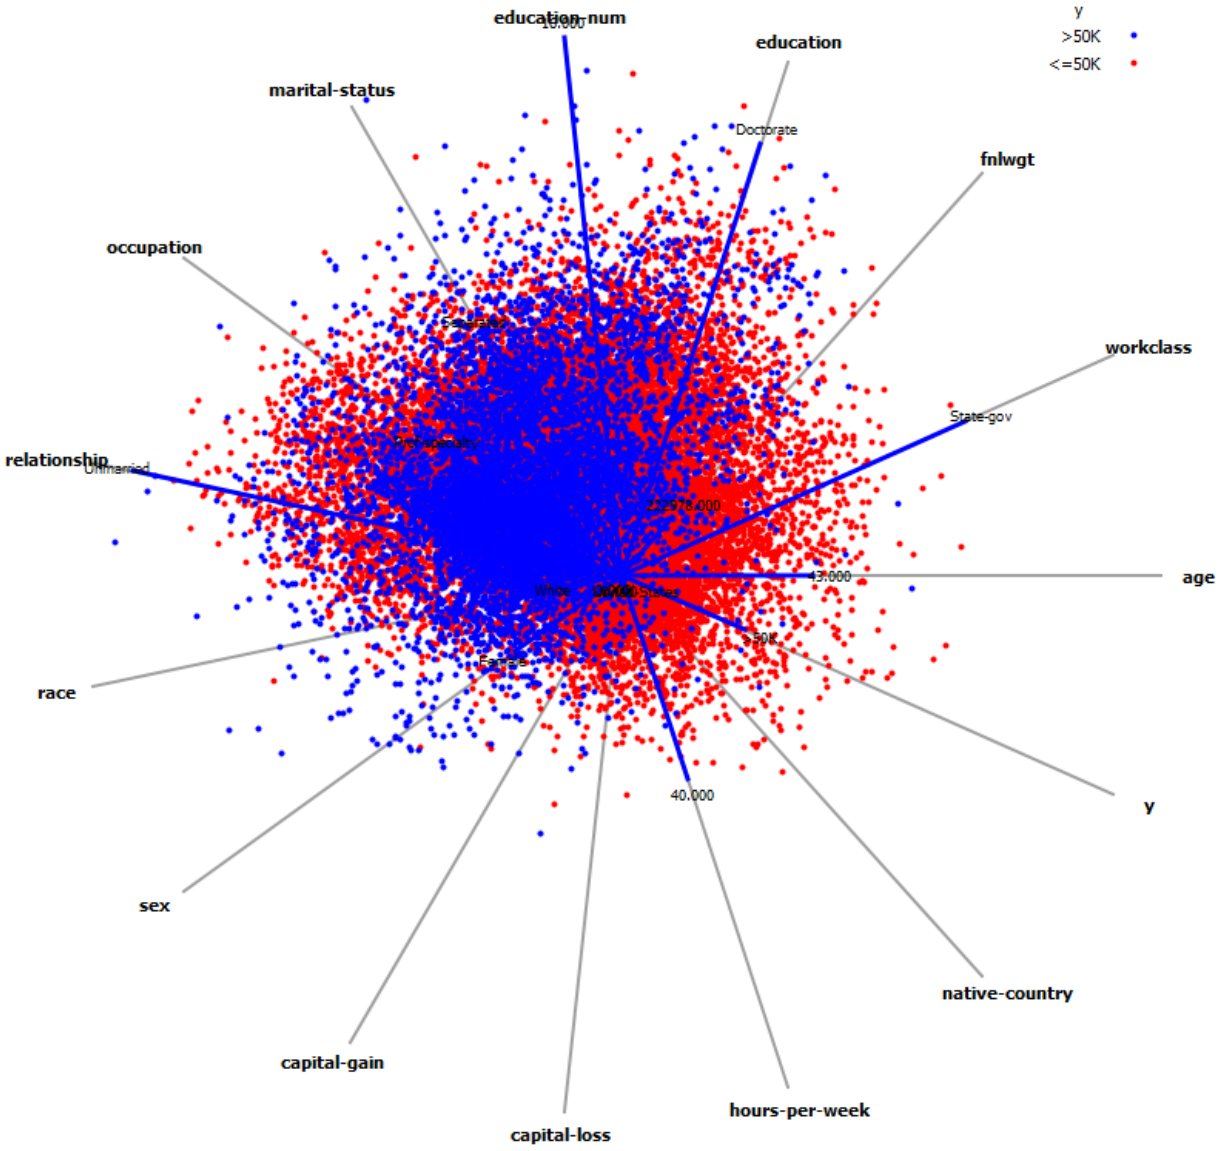
NUAGE DE POINTS

VARIABLES QUANTITATIVES

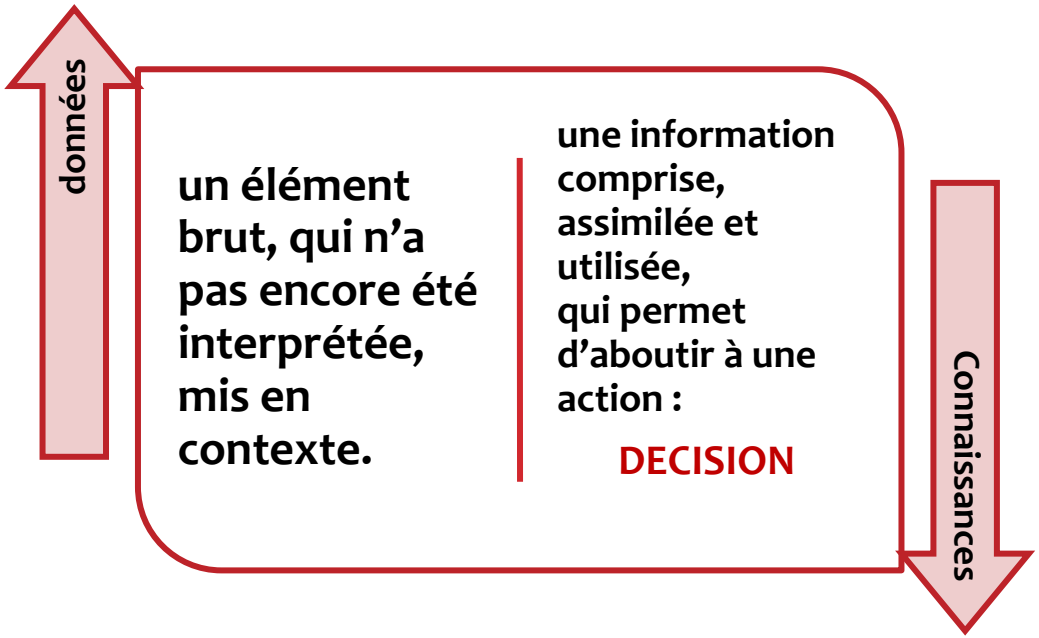


NUAGE DE POINTS

VARIABLES QUALITATIVES



DONNÉES, INFORMATIONS, CONNAISSANCES



client	*M*	*A*	*R*	*E*	*I*
1	moyen	moyen	village	oui	oui
2	élevé	moyen	bourg	non	non
3	faible	âgé	bourg	non	non
4	faible	moyen	bourg	oui	oui
5	moyen	jeune	ville	oui	oui
6	élevé	âgé	ville	oui	non
7	moyen	âgé	ville	oui	non
8	faible	moyen	village	non	non

Donnée :

Client3 : âge = âgé, Niveau d'études = non

Information :

37,5 % des Clients consultent leurs comptes bancaires sur le Web.

Connaissance :

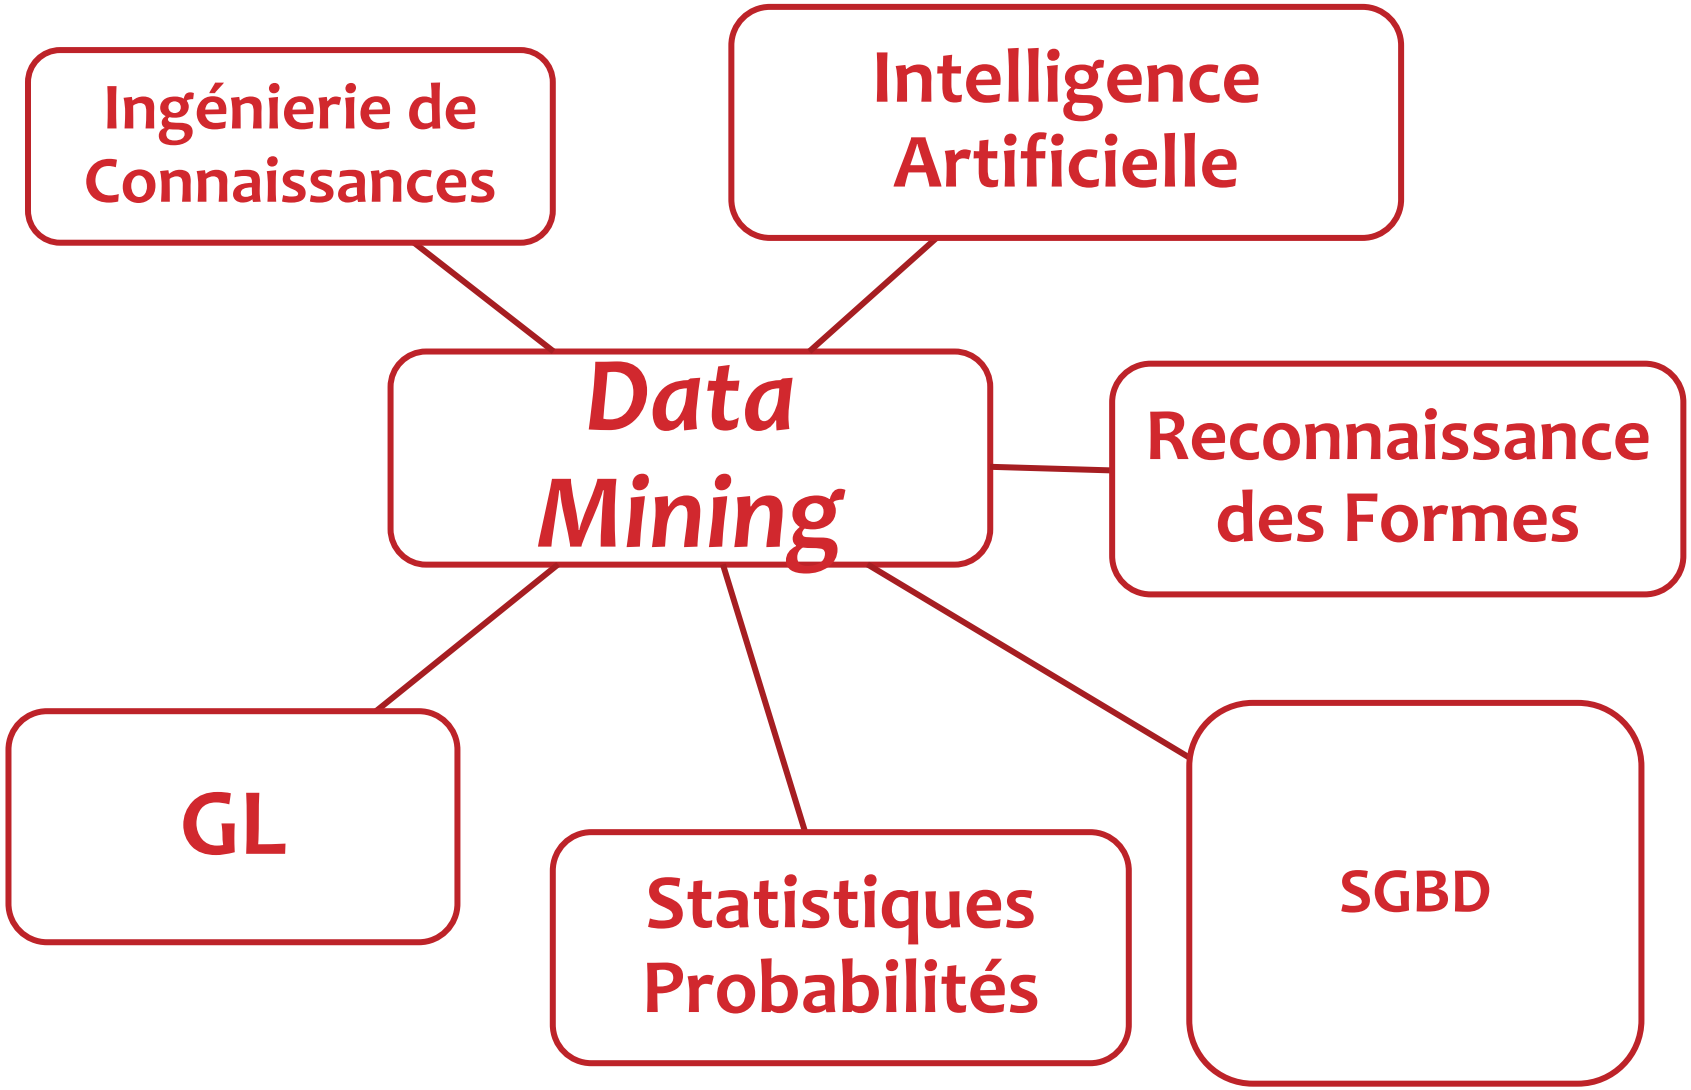
SI E=non **ALORS** I= non

SI E=oui **ET** A=moyen **ALORS** I=oui

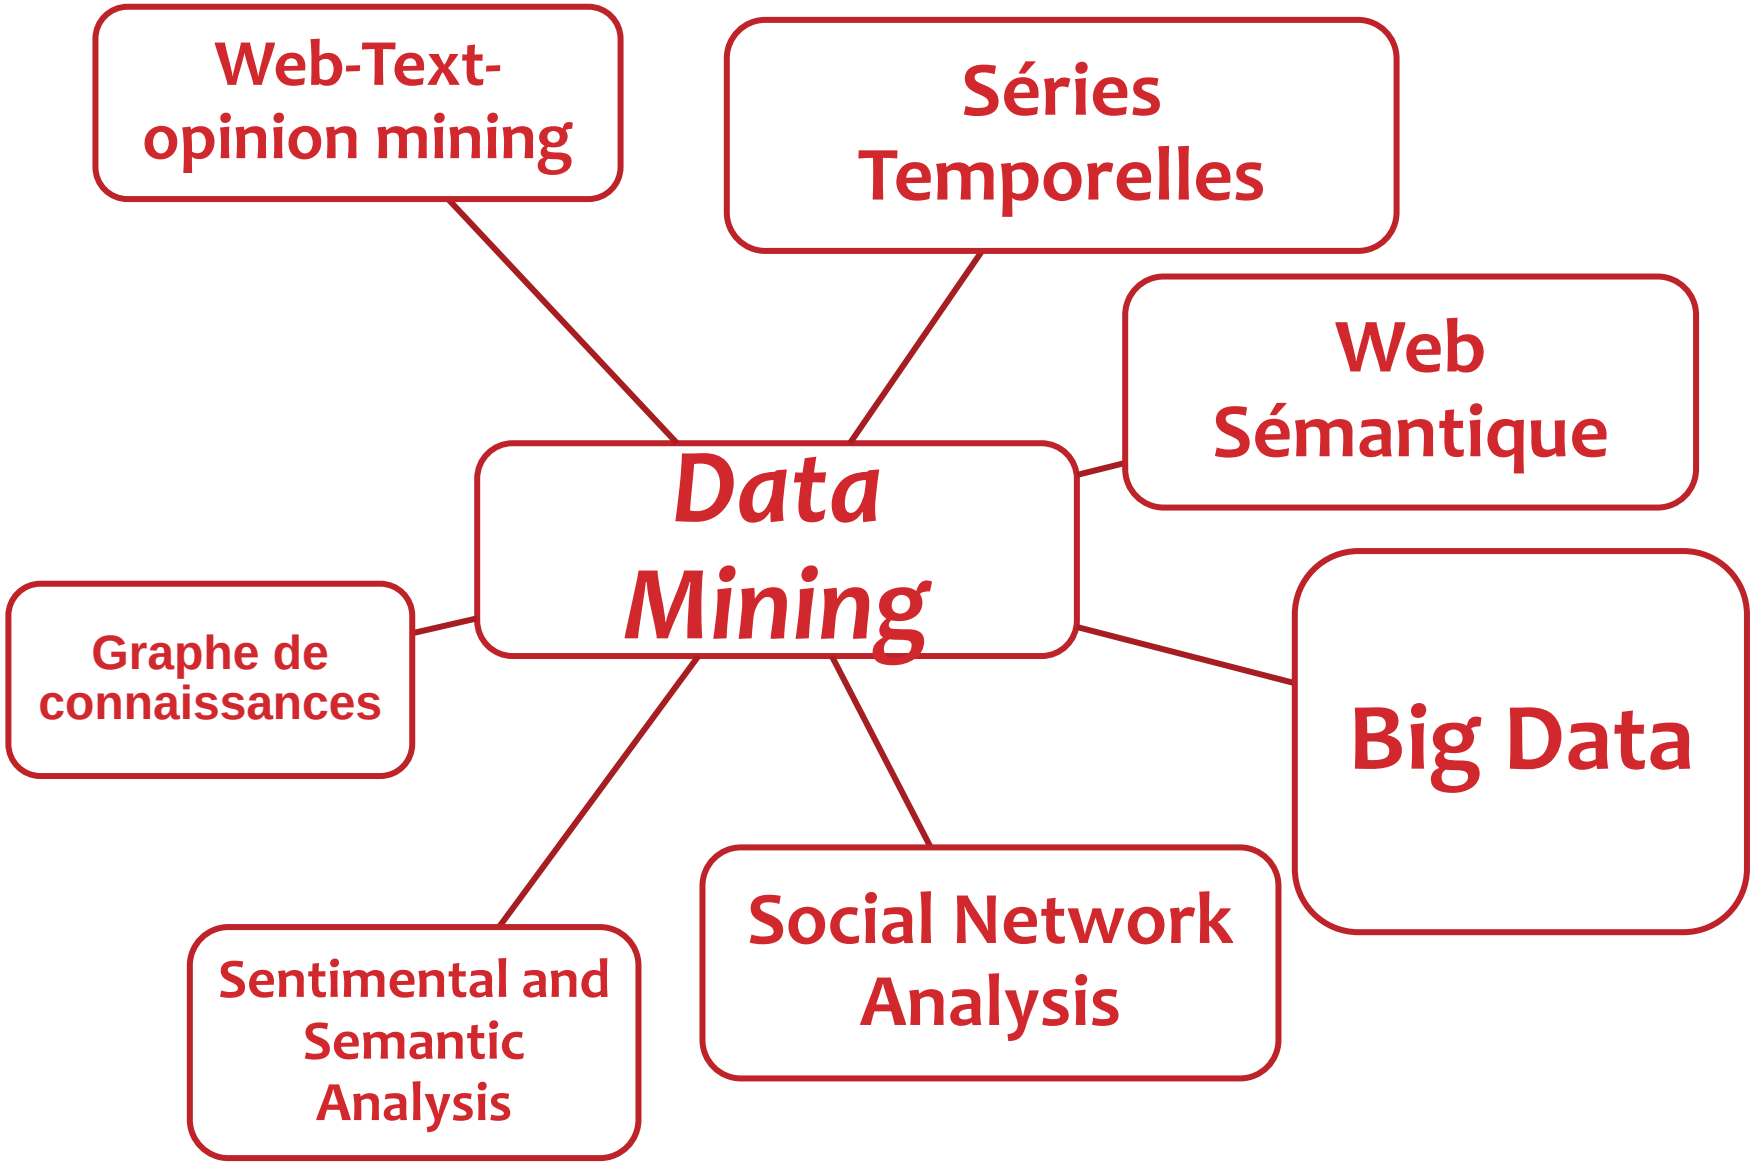
SI E=oui **ET** A=âgé **ALORS** I=non

SI A=oui **ET** A=jeune **ALORS** I=oui

ASPECT PLURIDISCIPLINAIRE



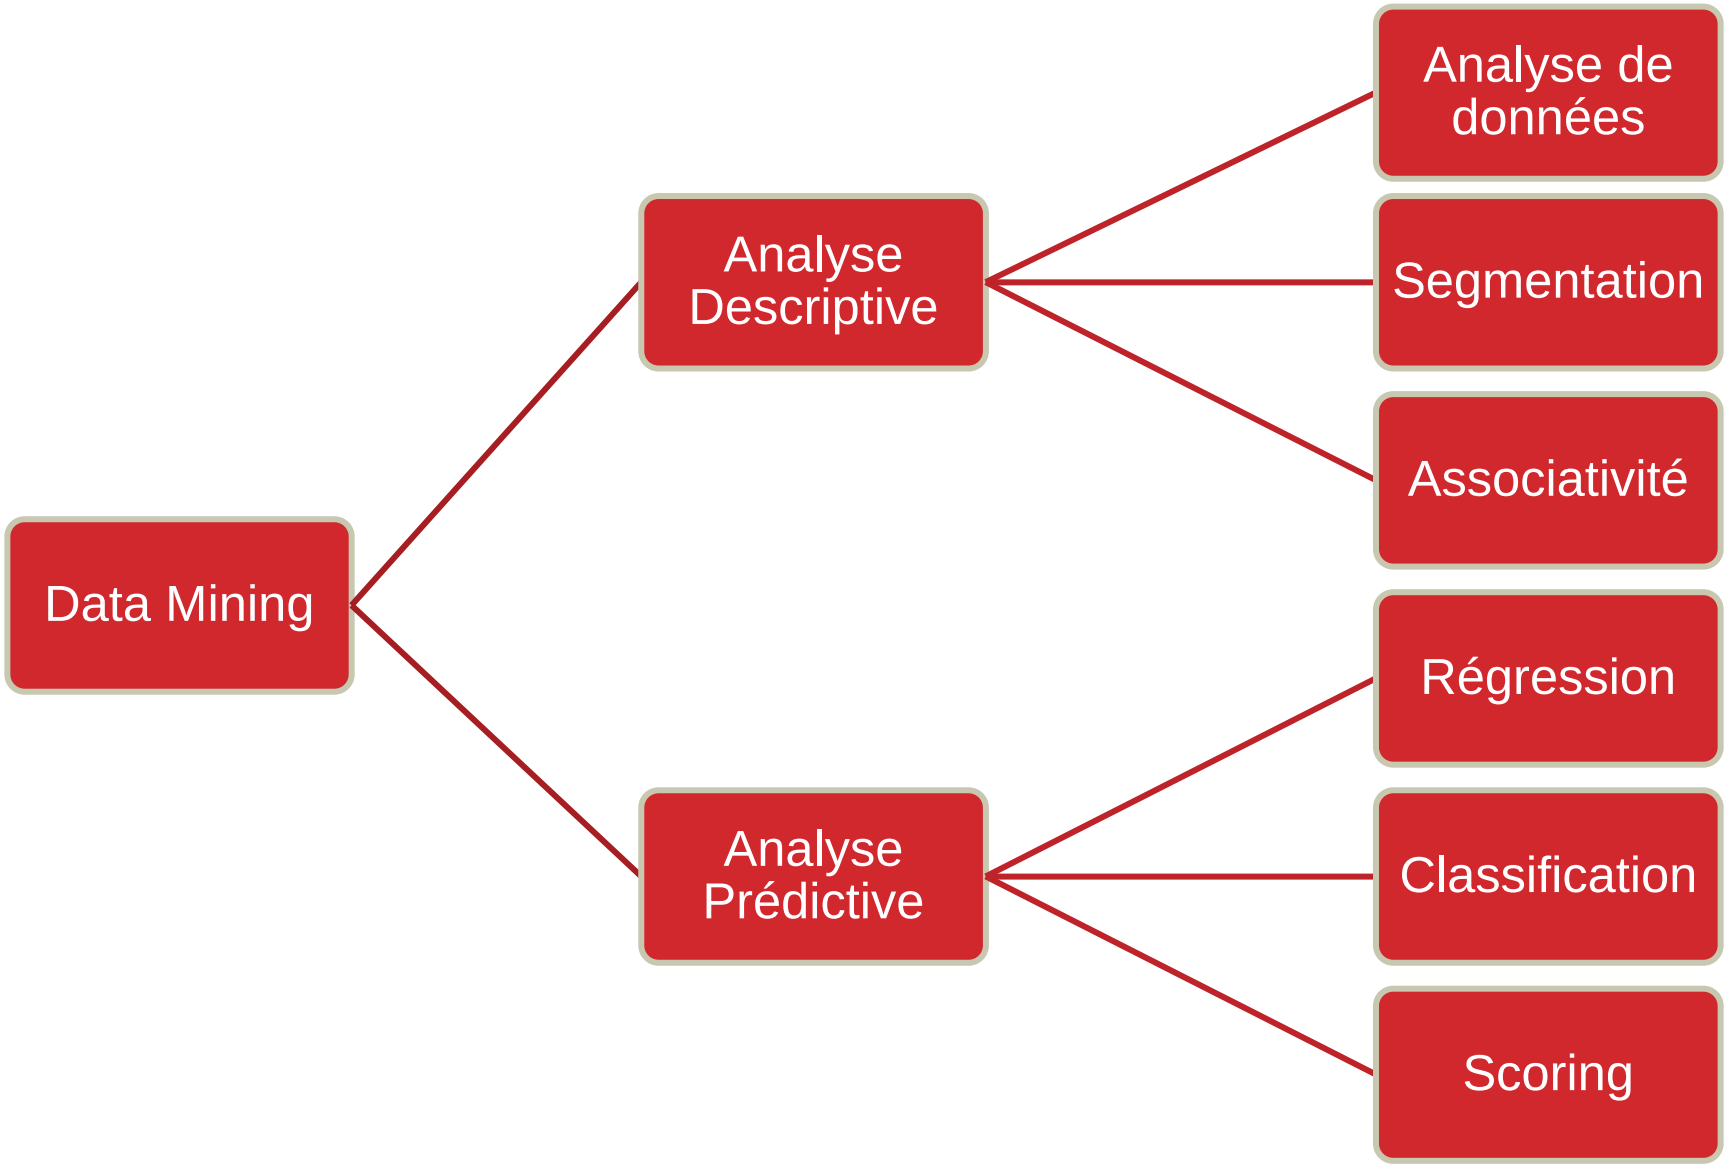
EXTENSION DU DATA MINING



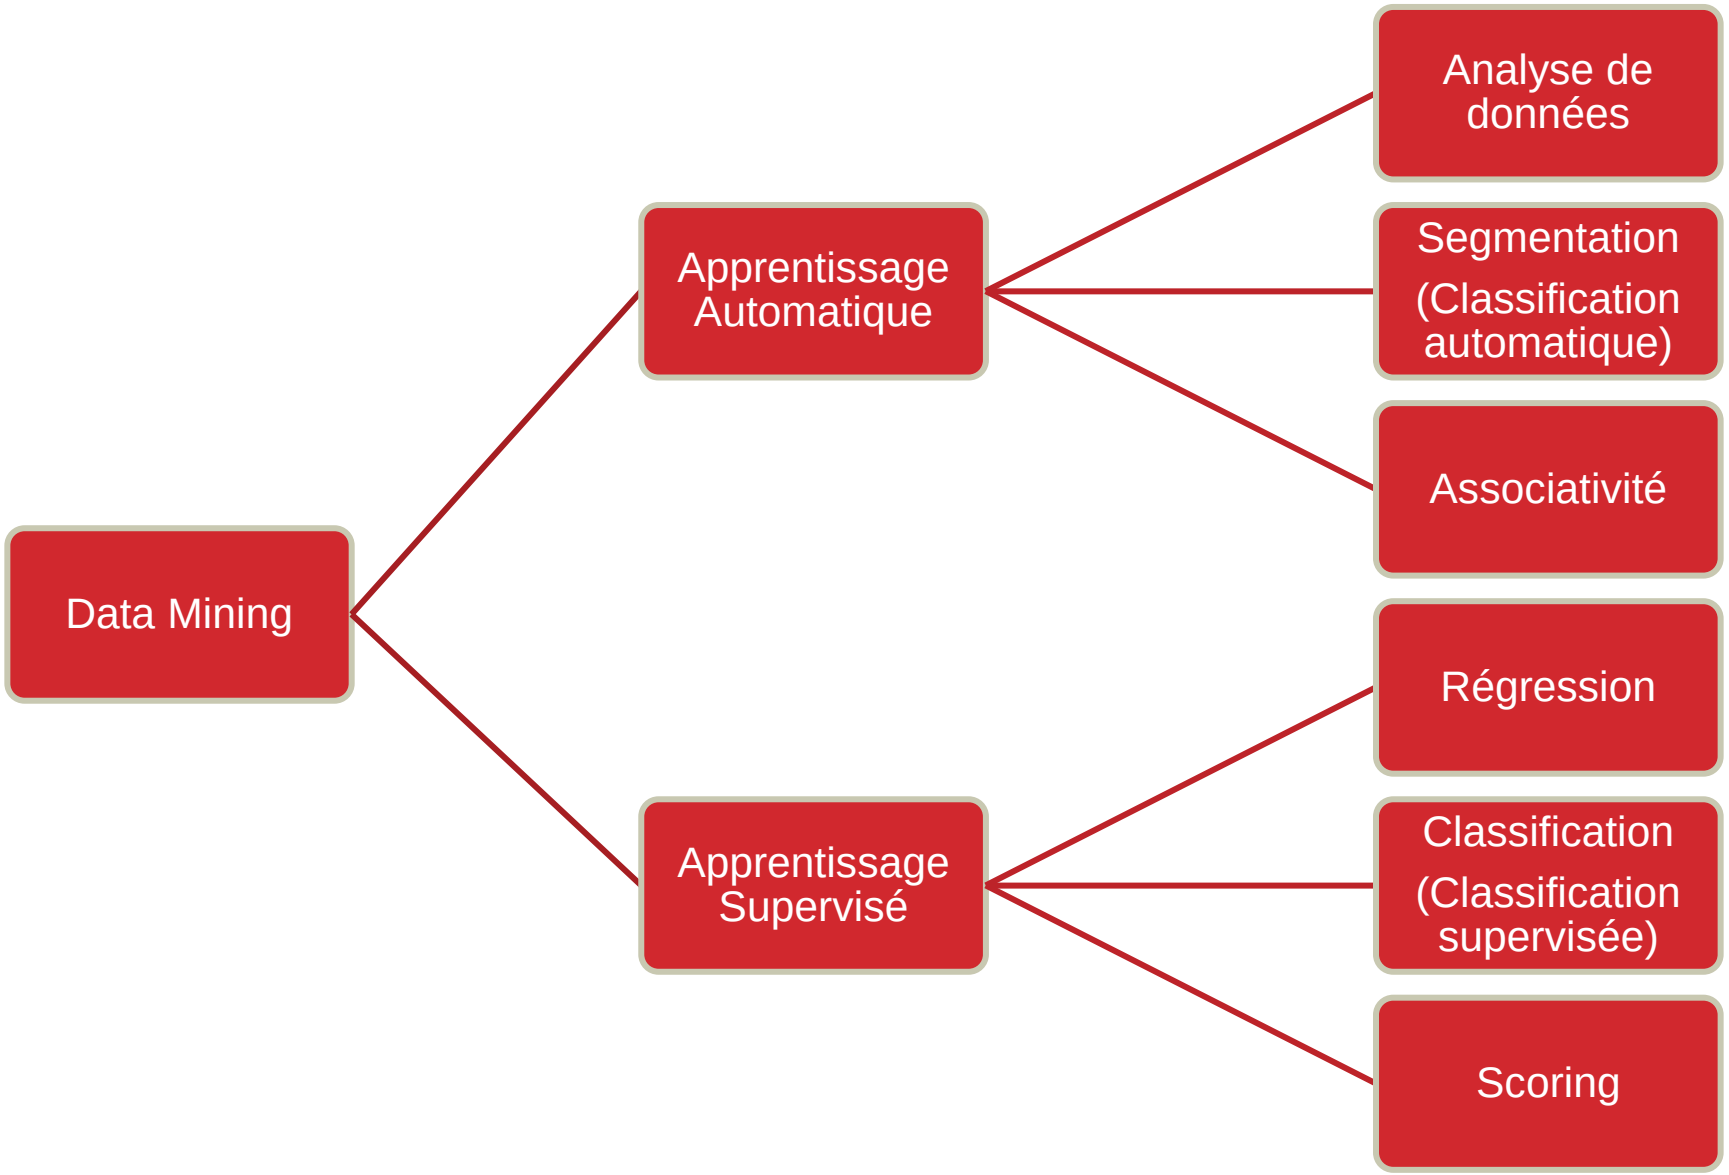
APPLICATIONS DU DATA MINING

esprit
Ecole Supérieure Privée
d'Ingénierie et de Technologies

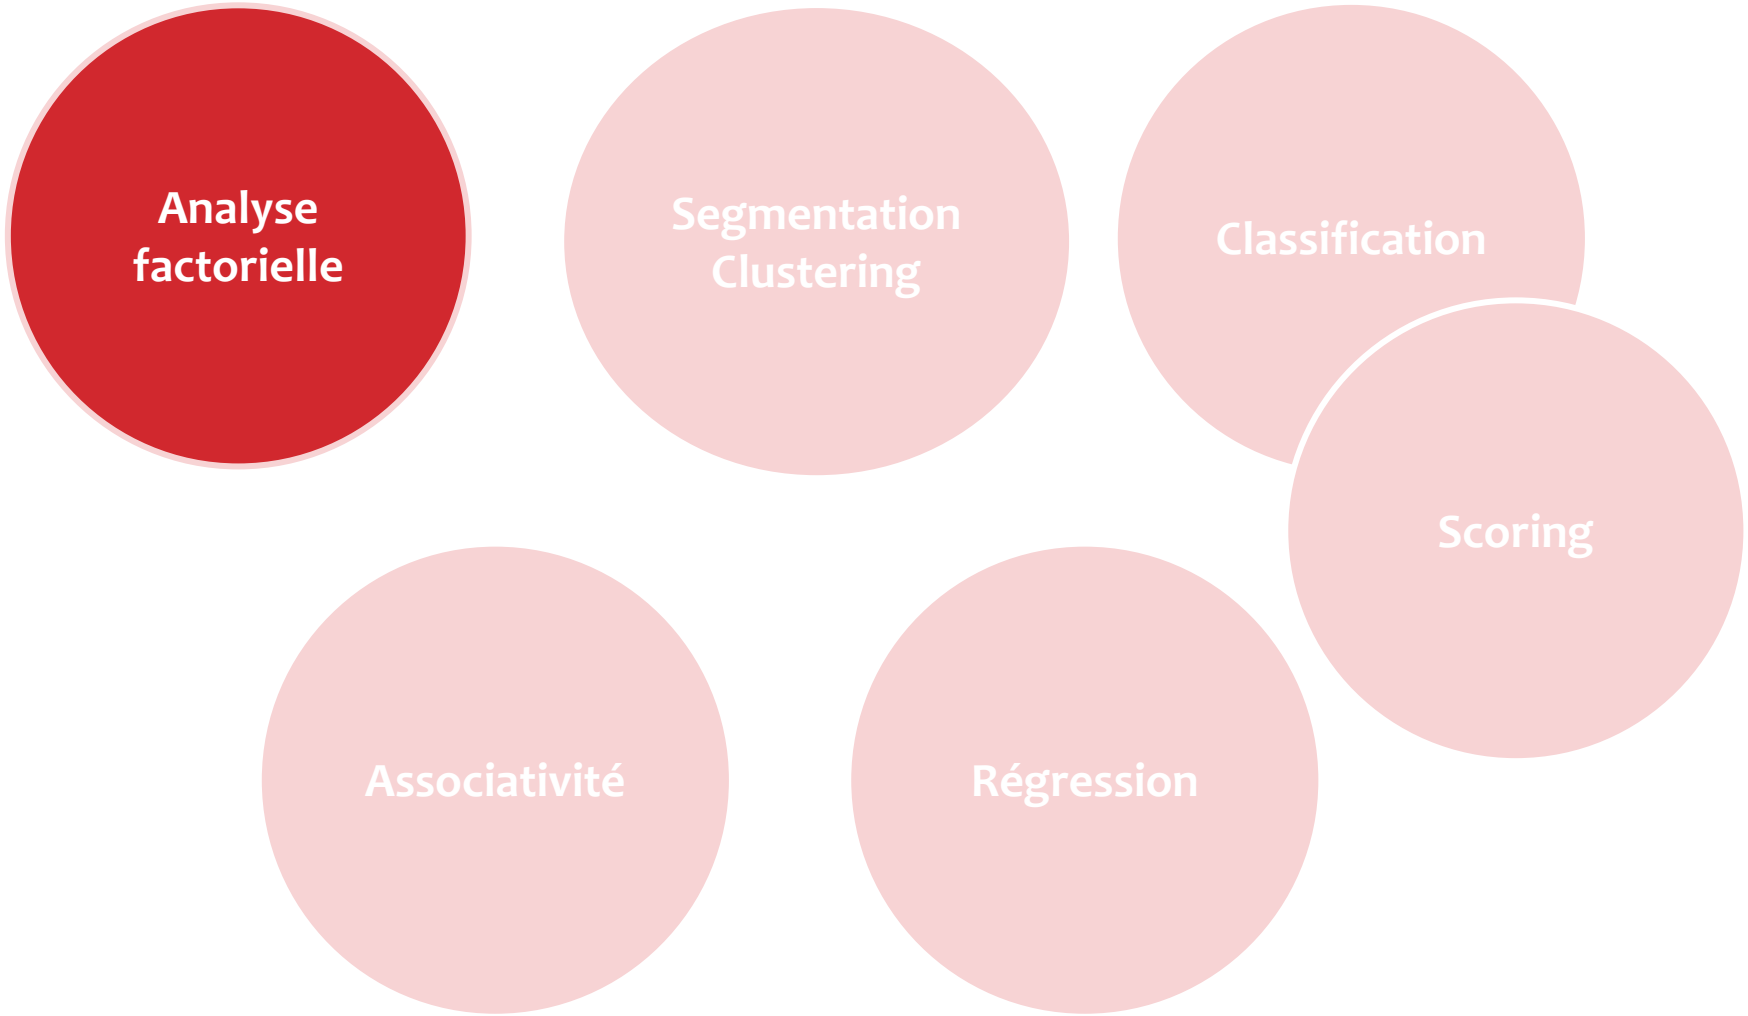
APPLICATIONS DE BASE DU DATA MINING



APPLICATIONS DE BASE DU DATA MINING



APPLICATIONS DE BASE DU DATA MINING

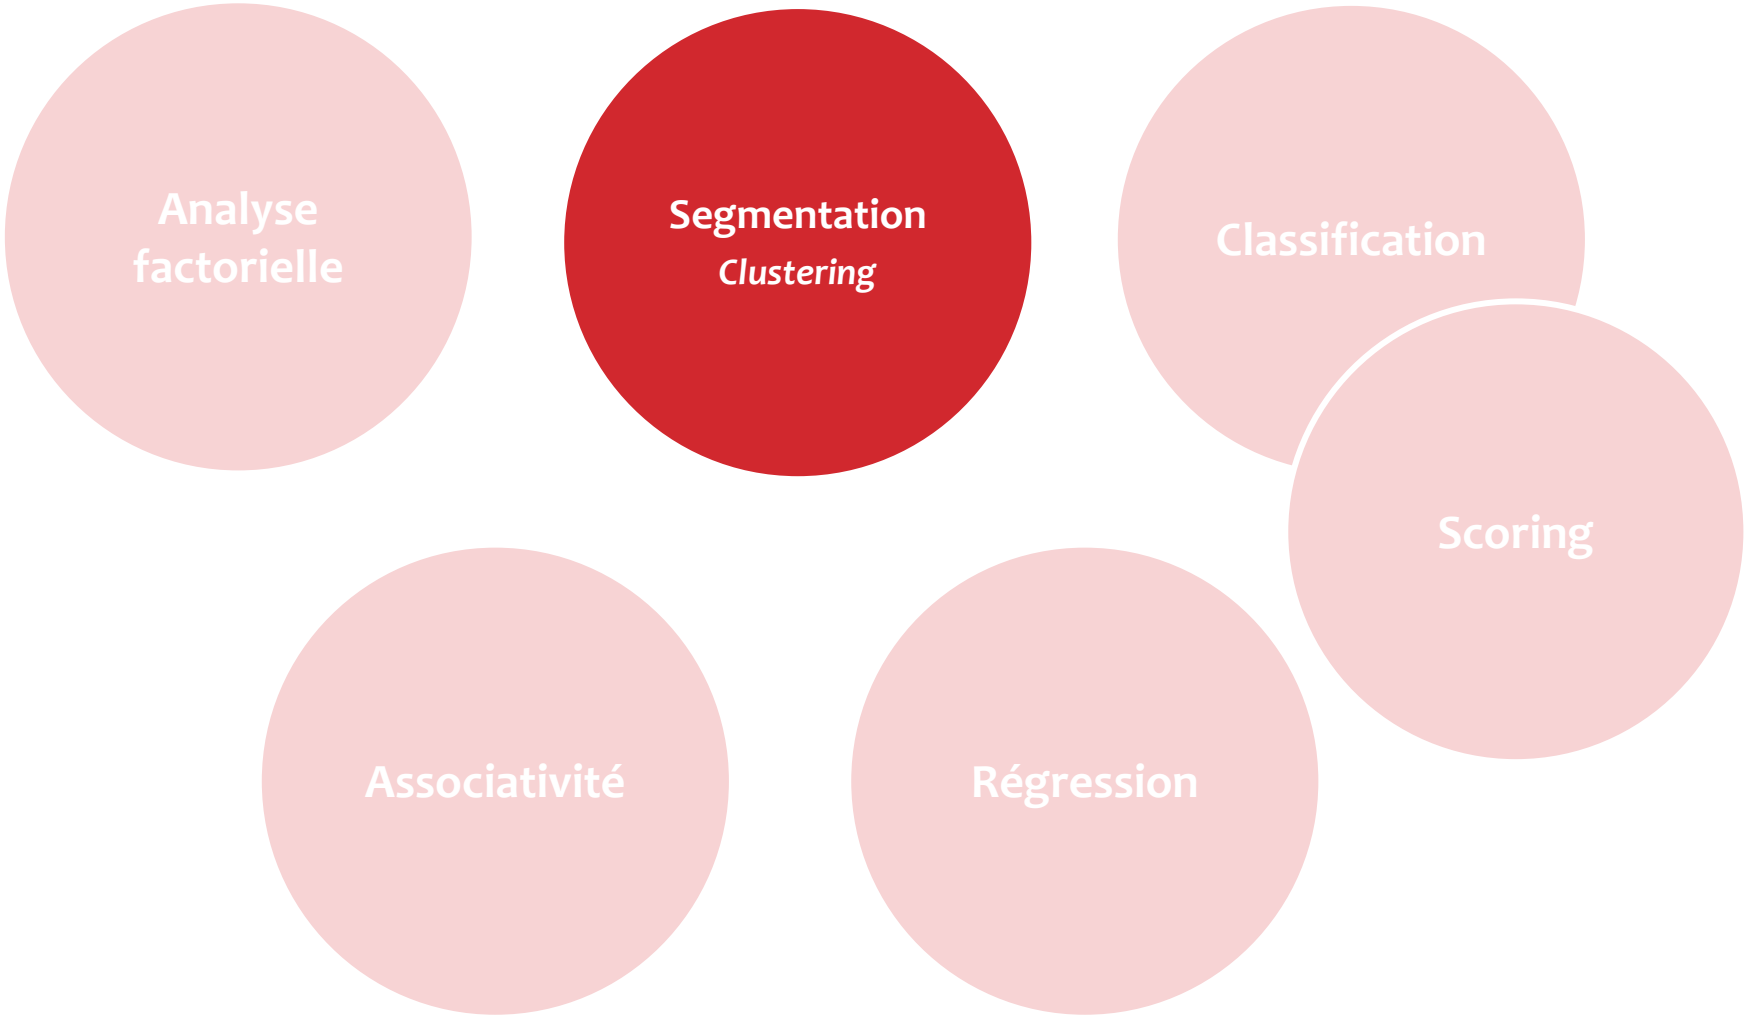


REPORTING ANALYTIQUE

Résumer et visualiser l'activité
de l'entreprise à travers
des ***indicateurs pertinents***



APPLICATIONS DE BASE DU DATA MINING



SEGMENTATION



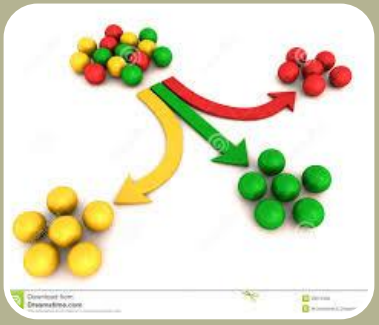
Aucune variable décisionnelle, information quantitative

- Les variables d'entrées servent à créer des groupes homogènes
- Les individus de chaque groupe se ressemblent le plus
- Les groupes d'appartenances obtenus se distinguent le plus



La Segmentation a pour objectifs :

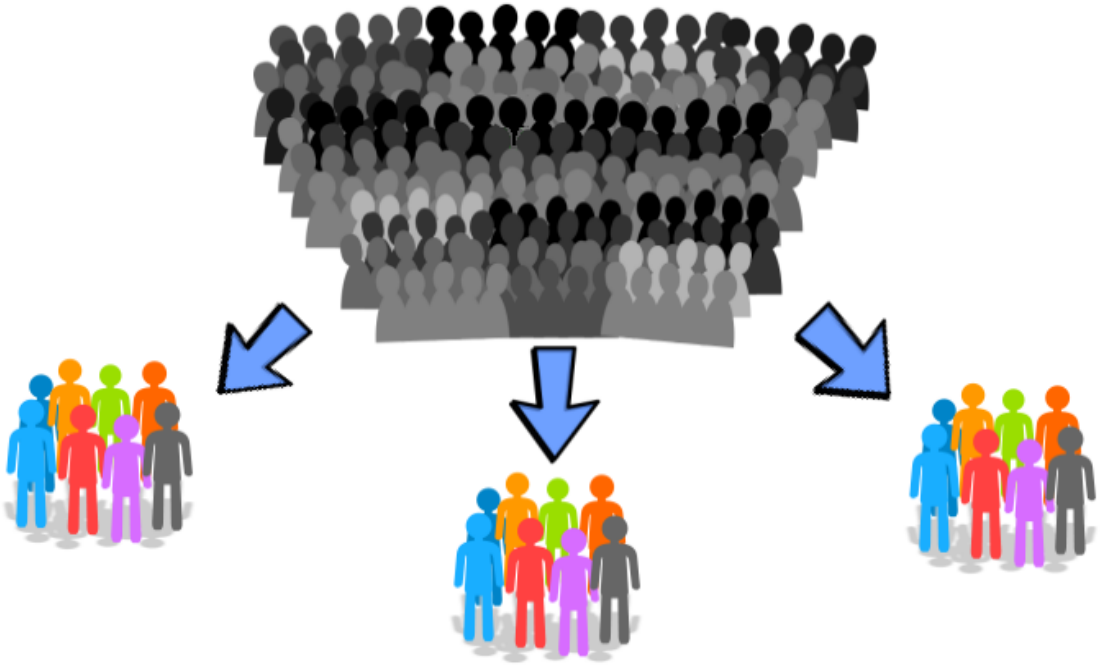
- Trouver les variables métiers influençant la répartition en groupes
- Affecter les individus à leurs nouveaux groupes d'appartenance



Plusieurs méthodes et techniques pour segmenter :

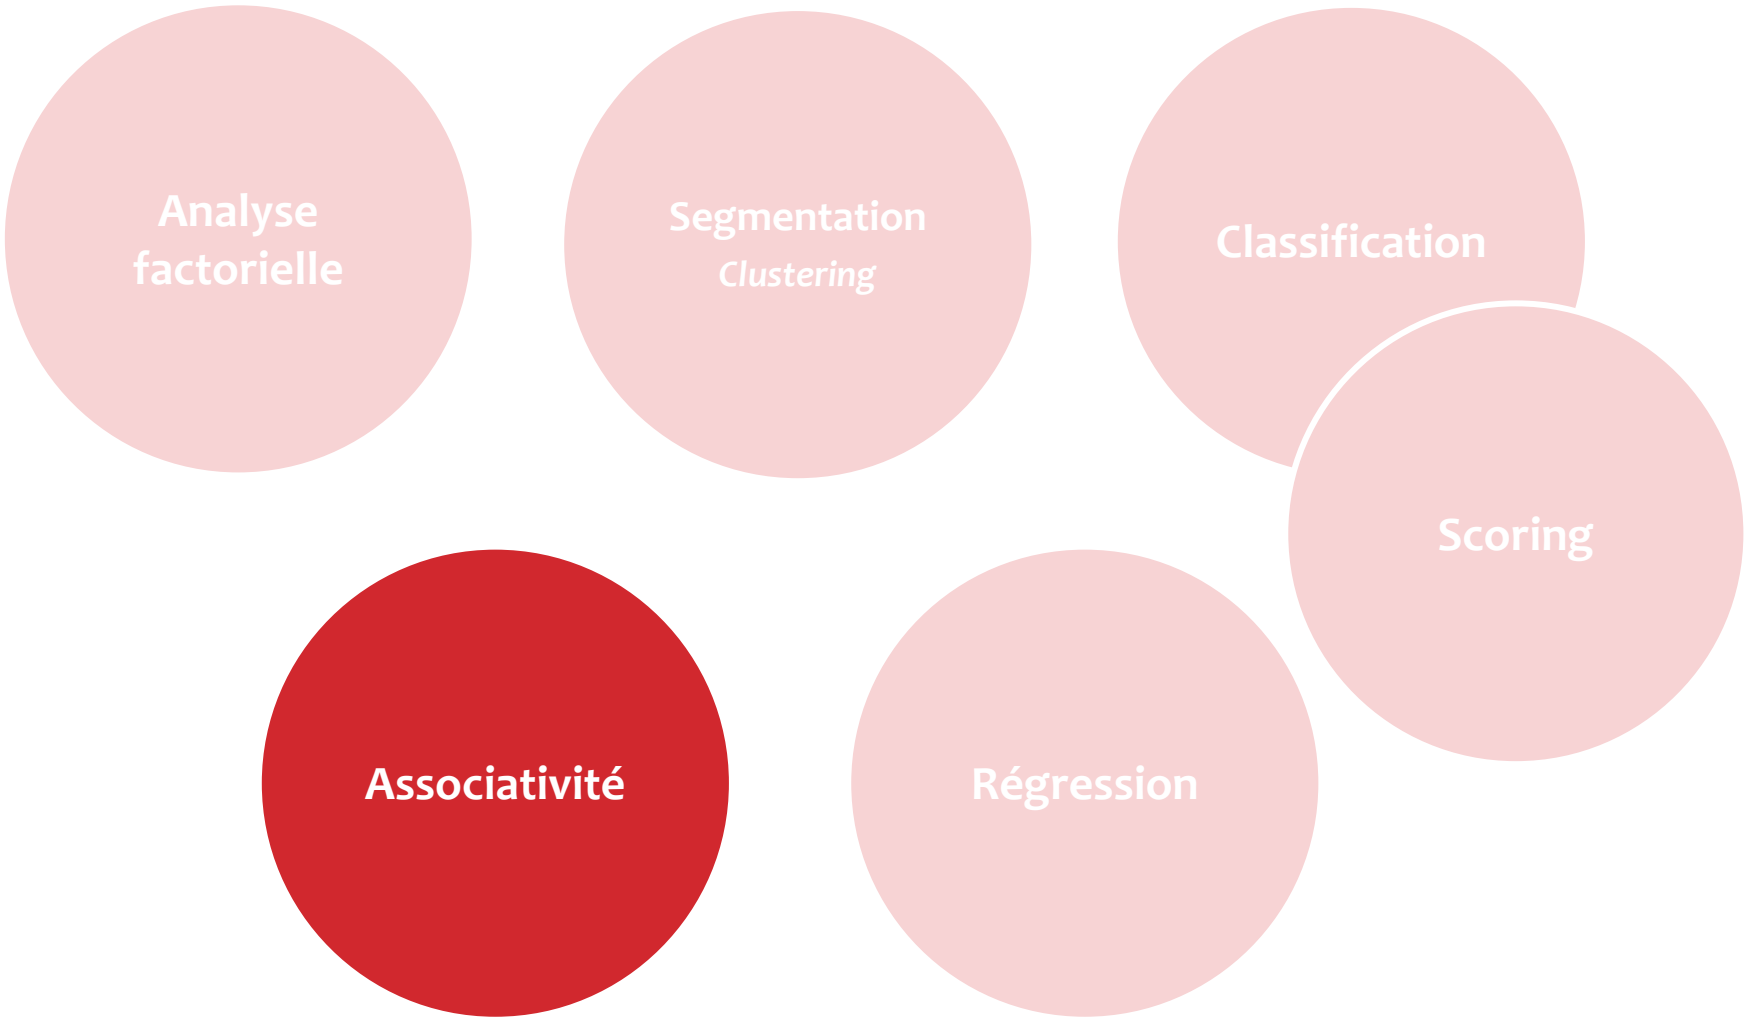
- Partionnement : k-means
- Hiérarchique : CAH

SEGMENTATION – TYPOLOGIE



Trouver les ***comportements typiques*** des clients.

APPLICATIONS DE BASE DU DATA MINING

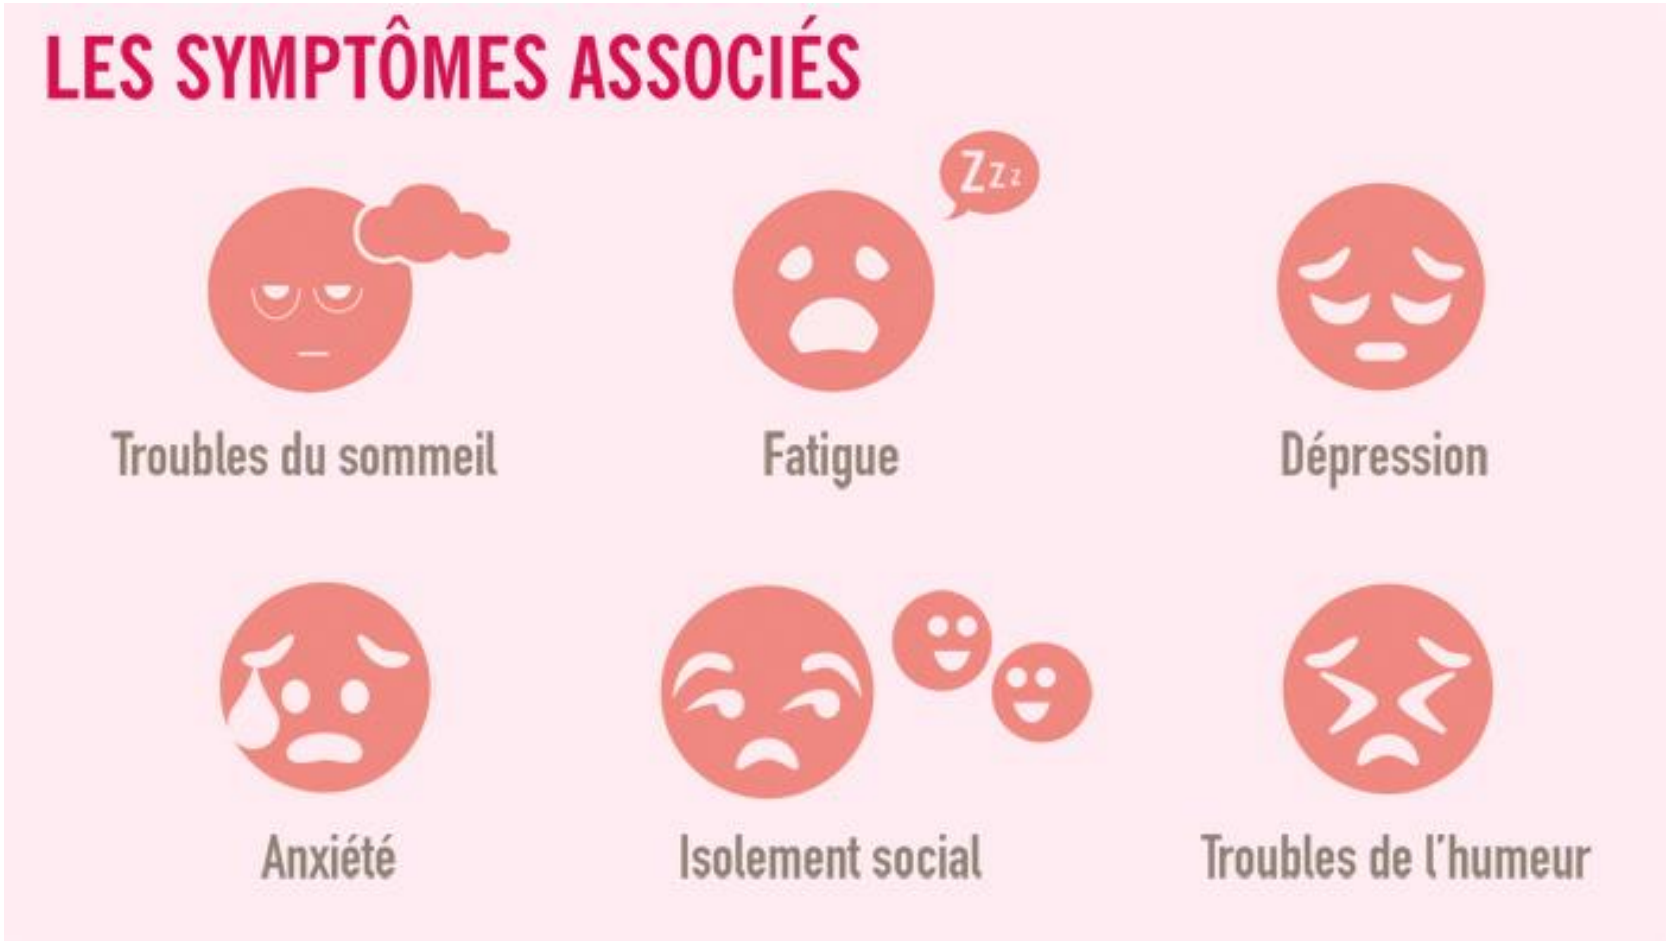


ANALYSE DU CHARIOT

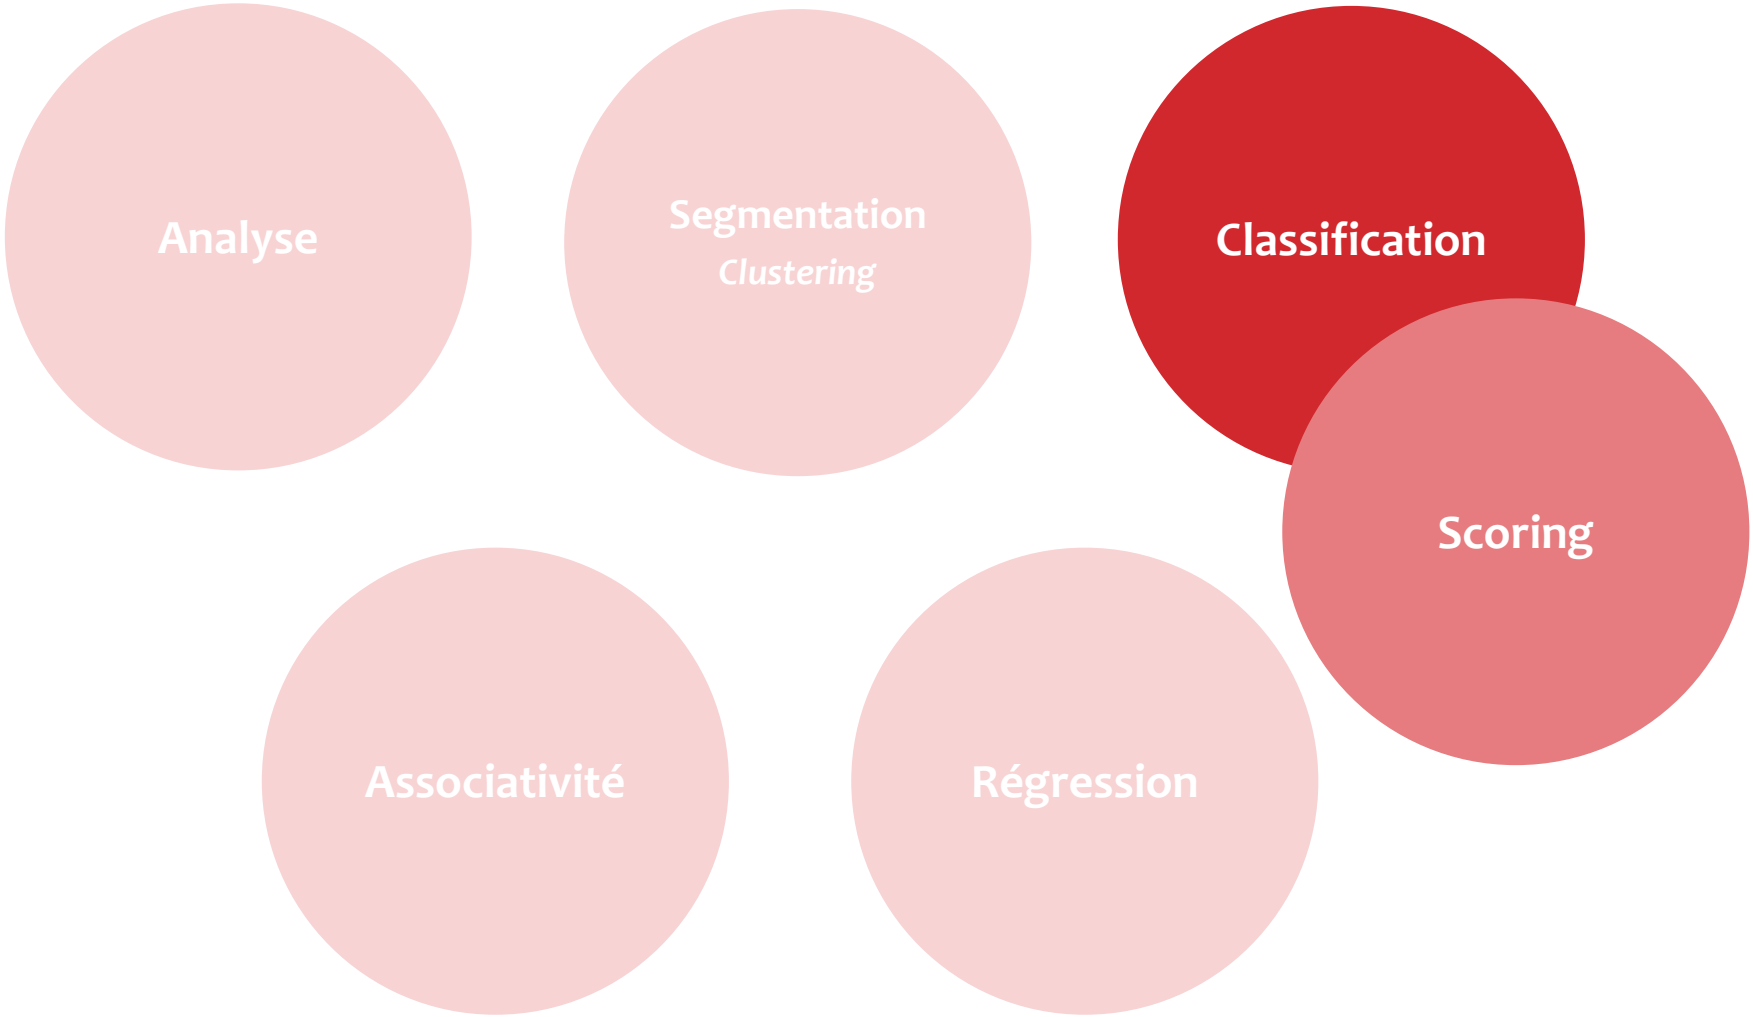


Recherche des articles les plus/moins associés

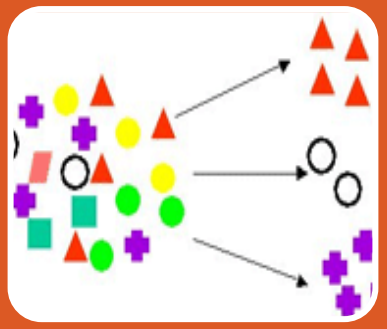
MÉDECINE


LES SYMPTÔMES ASSOCIÉS
Zzz
Troubles du sommeil
Fatigue
Dépression
Anxiété
Isolement social
Troubles de l'humeur

APPLICATIONS DE BASE DU DATA MINING

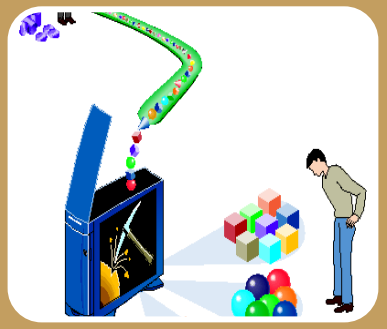


CLASSIFICATION



La variable décisionnelle est **qualitative**

- Un dossier de crédit peut être classifié : BON ou MAUVAIS
- Un patient peut présenter un fort risque de maladie cardiaque
- Un client peut présenter un comportement atypique



La Classification a pour objectifs :

- Détecter les variables possédant un lien fort avec la variable décisionnelle
- Construire un modèle de classification liant ces variables à la décision



Plusieurs méthodes et techniques pour classifier :

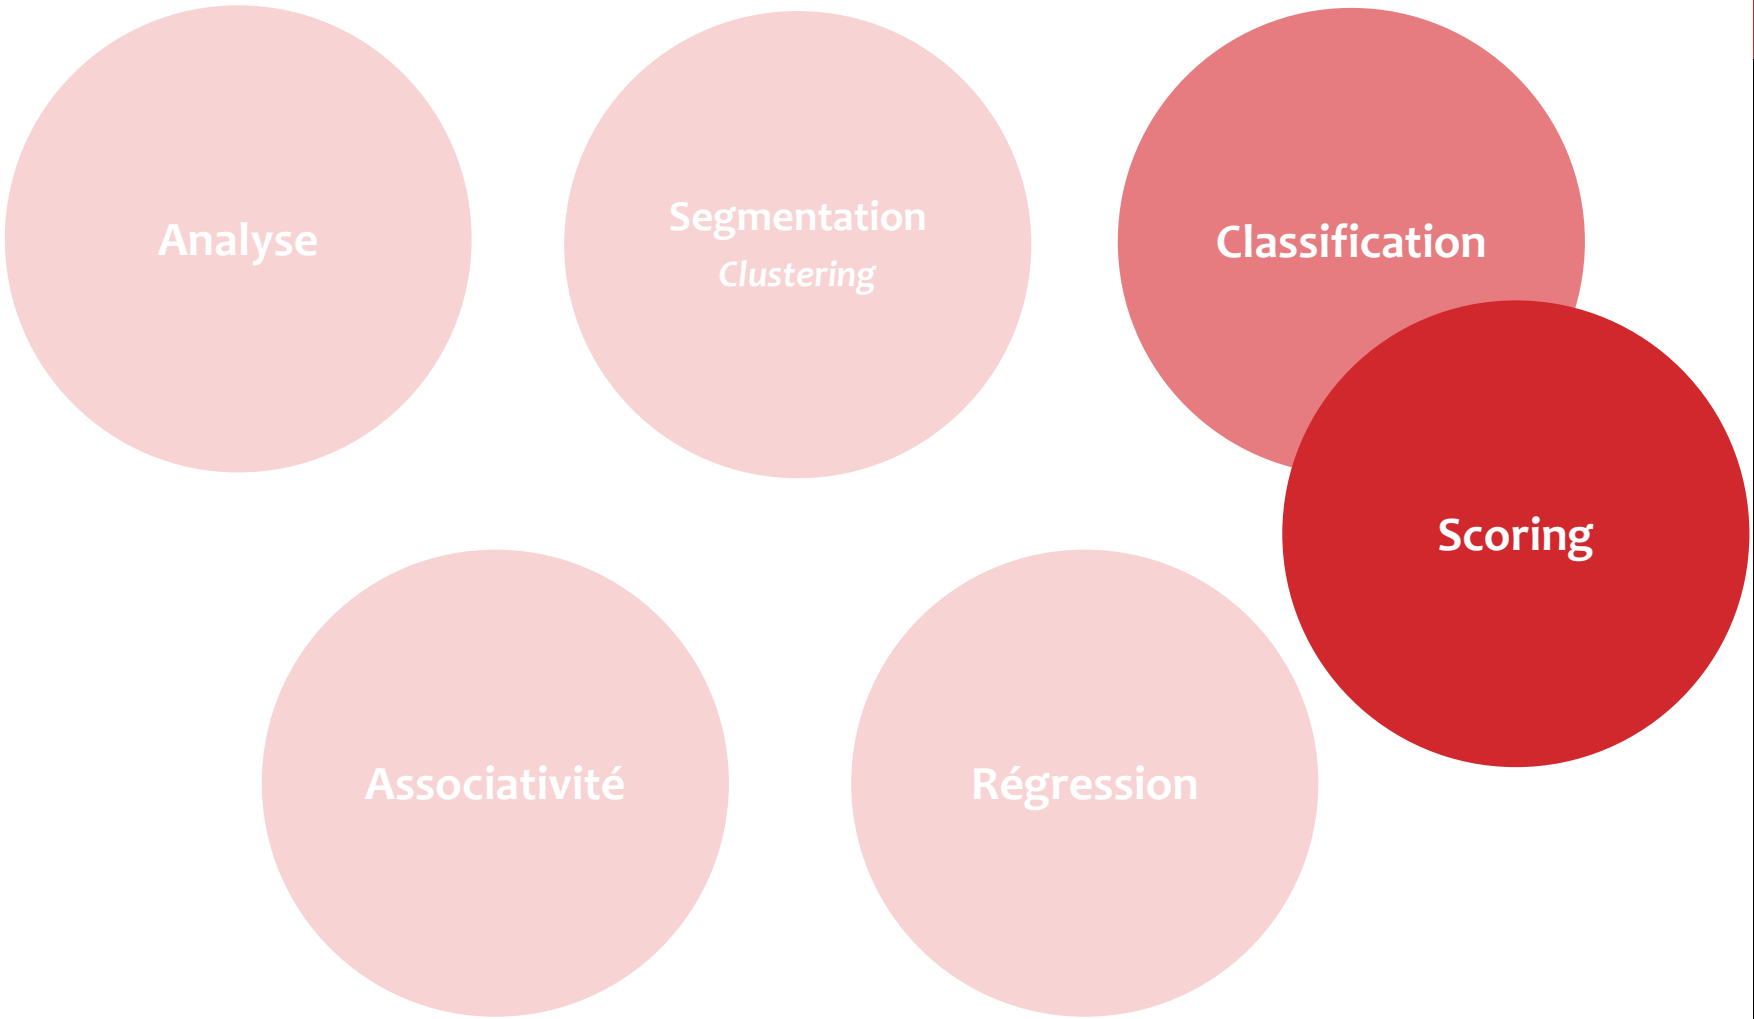
- Arbre de décision
- Forêts Aléatoires
- K-NN *k*-nearest neighbors
- Séparateur à vaste Marge SVM
- Régression Logistique

CLASSIFICATION – PROFILING

Déterminer ce qui ***caractérise*** un groupe ***particulier*** de clients



APPLICATIONS DE BASE DU DATA MINING



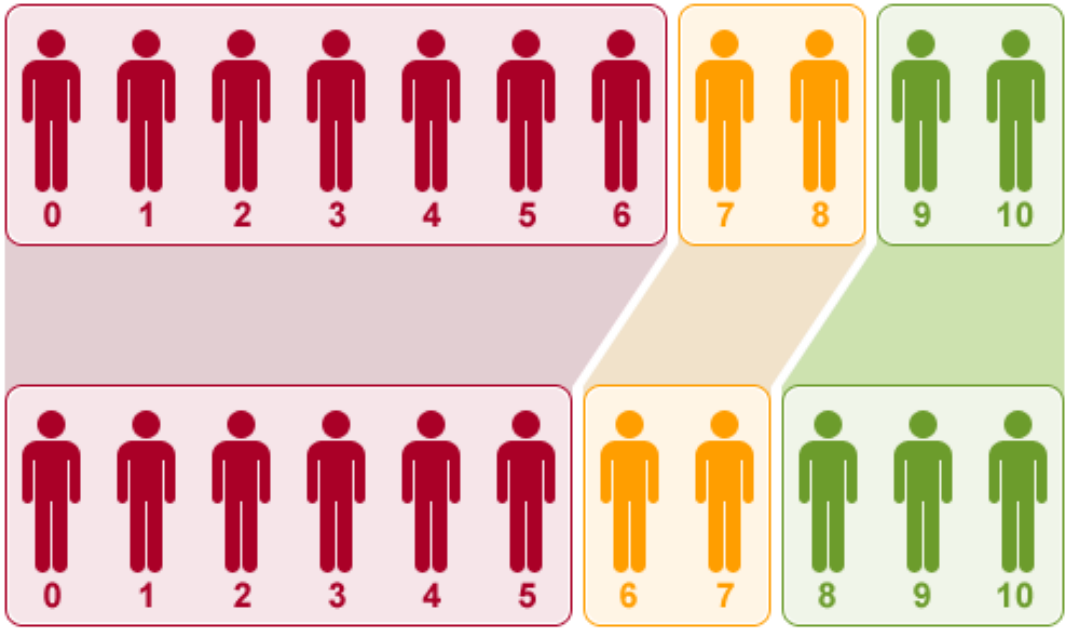
EVALUATION DE CAMPAGNES DE TERRAIN

Déterminer ***l'efficacité de la communication*** avec les clients.



MARKETING CIBLÉ

Optimiser les chances d'obtenir des réponses (positives) de la part des clients à une offre particulière par un ciblage plus précis, mettant en évidence les clients avec une forte probabilité de réponse.



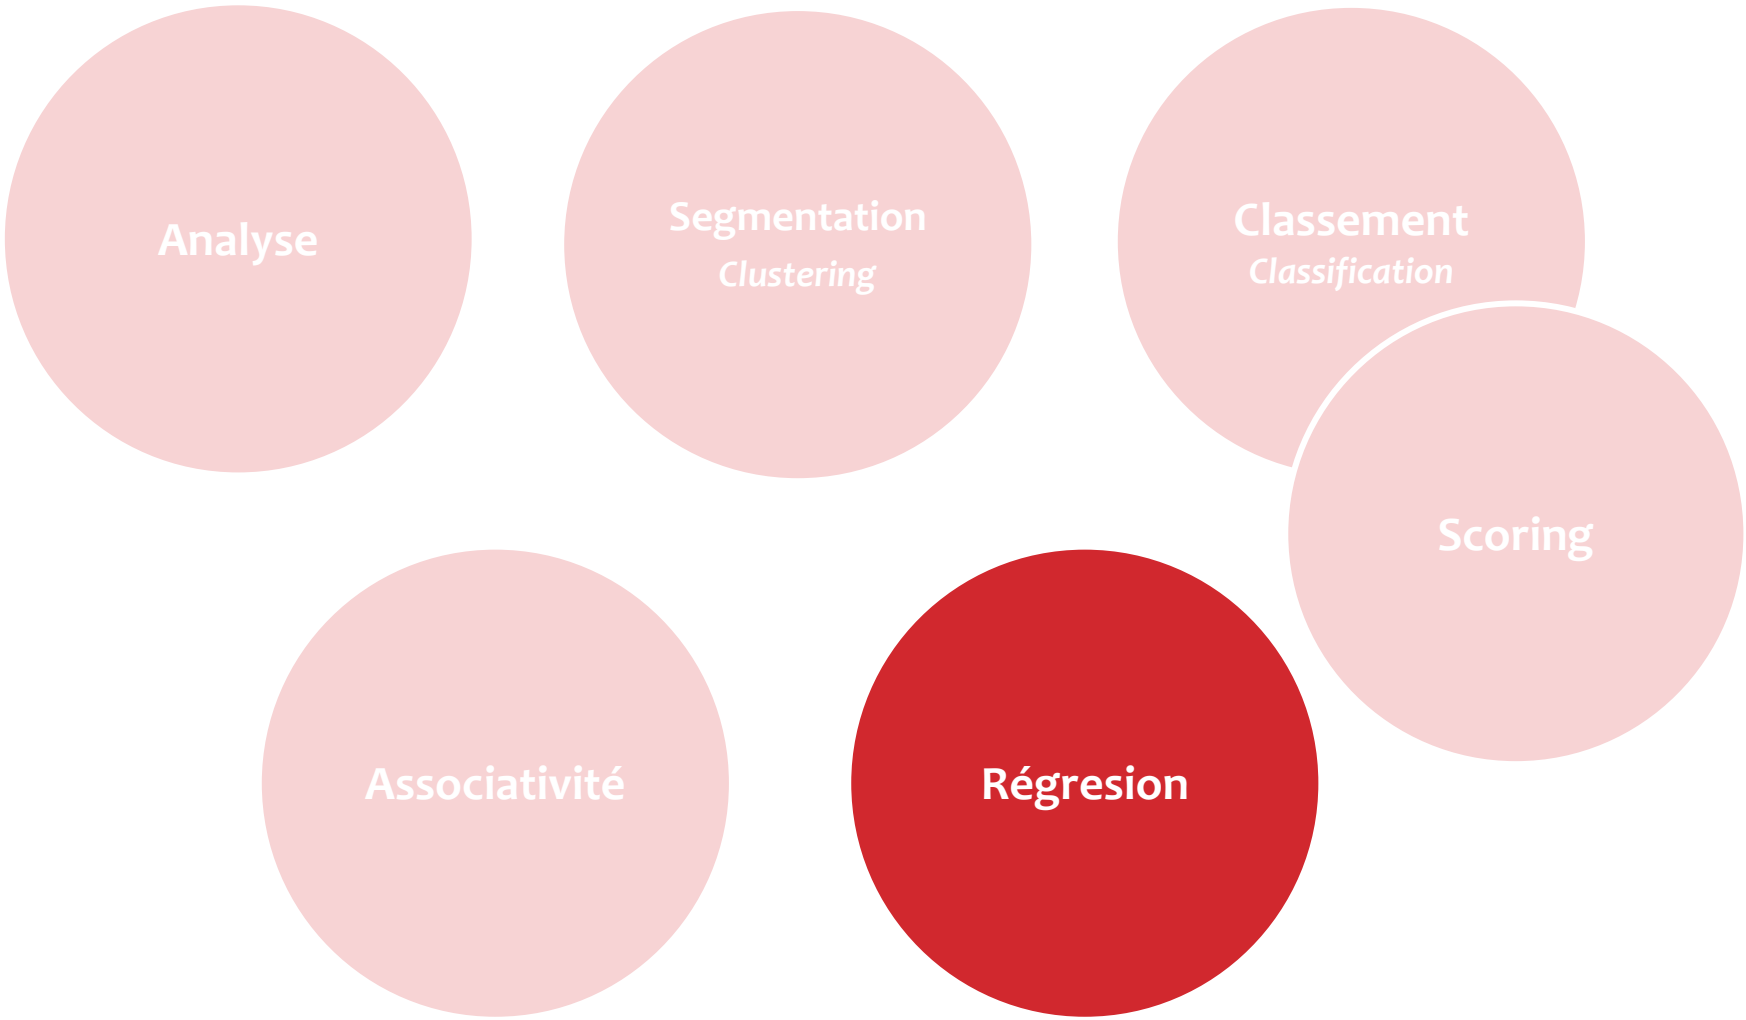
DATA MINING ET CRM

Le datamining a beaucoup d'applications qui peuvent apporter un soutien considérable au marketing et à la gestion de la relation client



- faire correspondre des profils des clients avec des «offres produits» afin d'augmenter le taux de conversion : cross selling

APPLICATIONS DE BASE DU DATA MINING



RÉGRESSION LINÉAIRE



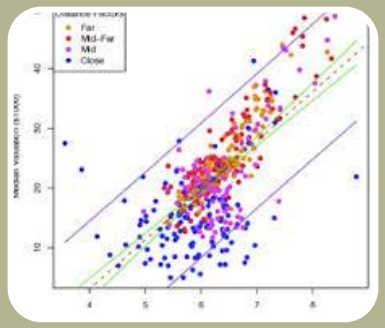
La variable décisionnelle est **quantitative**

- Prédire les tendances salariales la prochaine année
- Prédire le meilleur pourcentage de réduction de coûts
- Construire un modèle générique pour l'estimation de la consommation de carburant



La régression a pour objectifs :

- Détecter les variables possédant un lien fort avec la variable cible
- Construire un modèle prédictif avec l'ensemble des variables pertinentes afin de prédire la variable d'intérêt
- Détecter les individus atypiques ou les aberrances



Régression Linéaire

- Méthode des moindres carrés
- Meilleurs prédicteurs

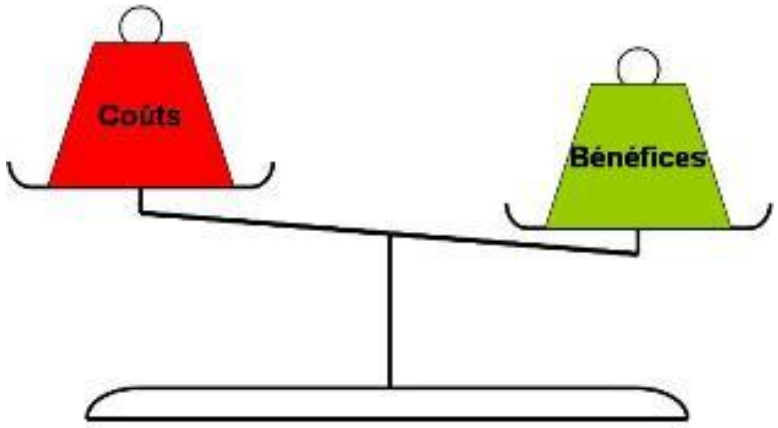
PRICING

Déterminer le ***prix "optimal"*** convenable pour un produit.



ANALYSE COÛTS-BÉNÉFICES

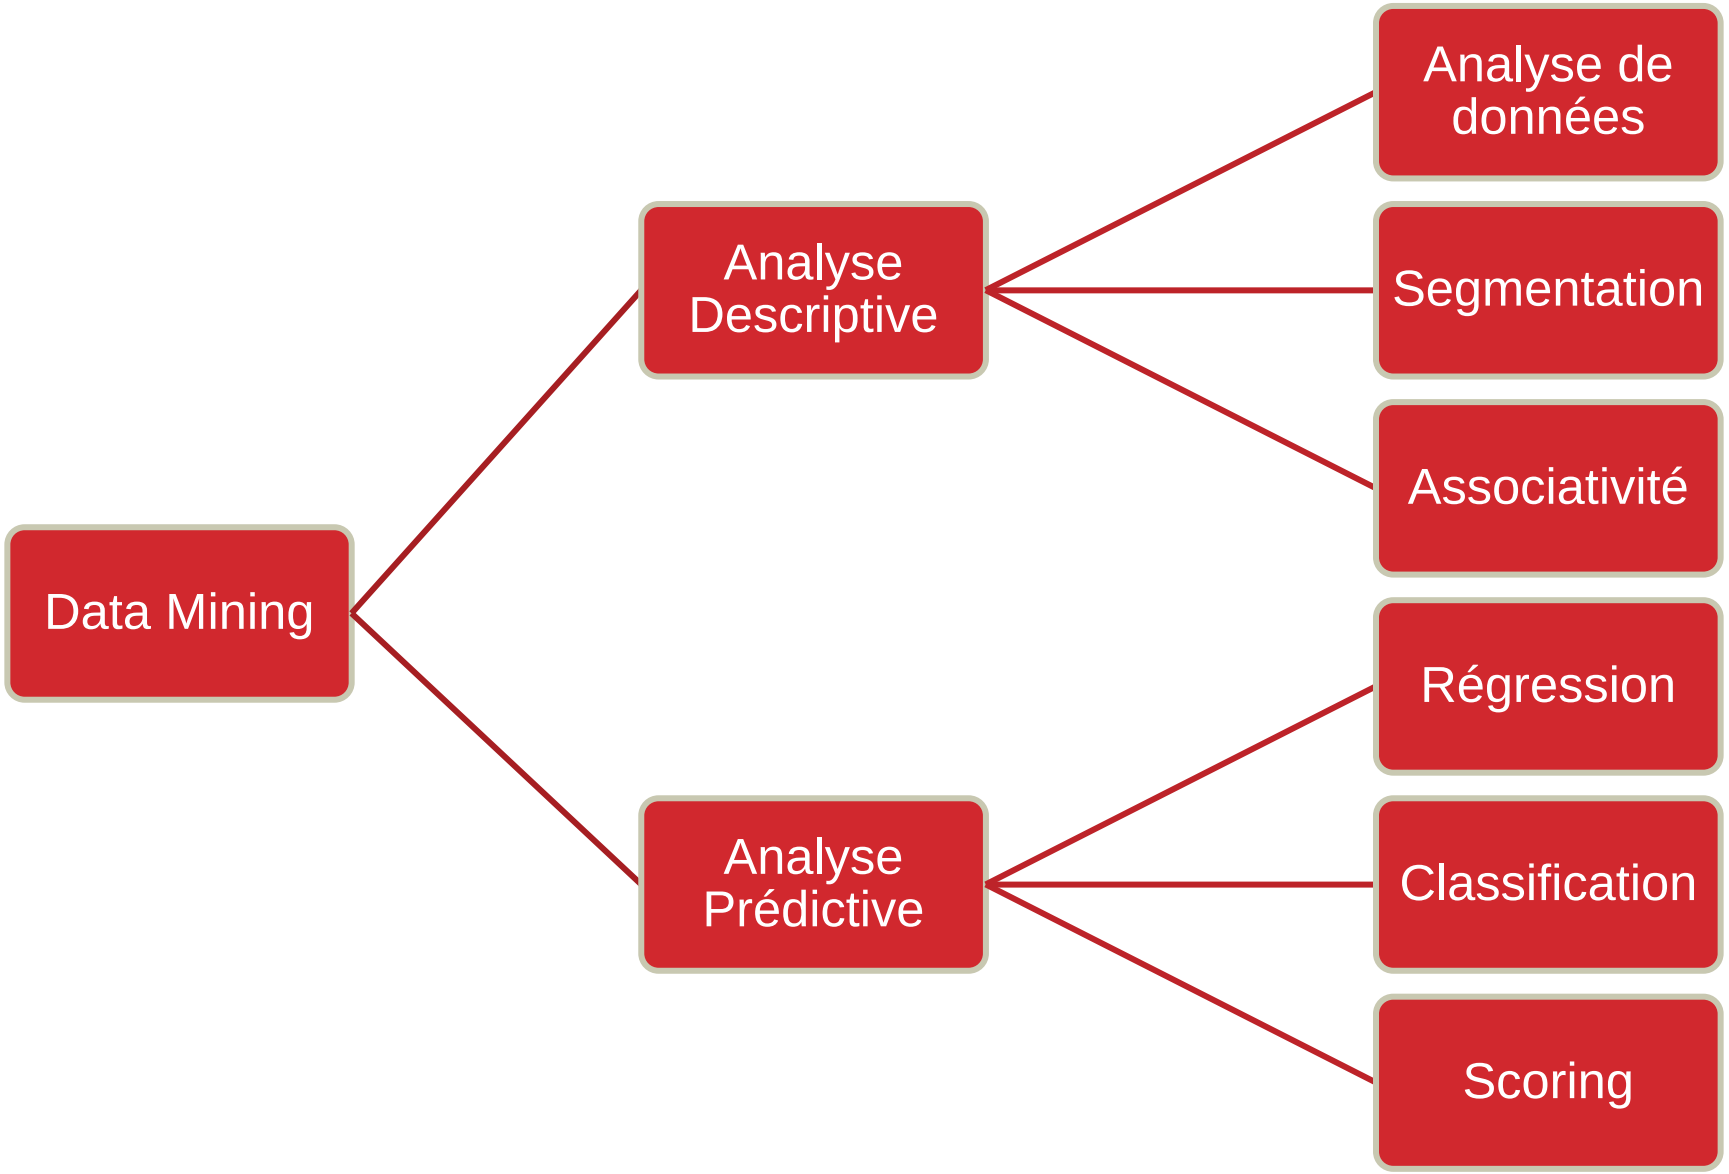
Identifier les produits et les campagnes les ***plus rentables***



LES MÉTHODES DATA MINING

esprit
Ecole Supérieure Privée
d'Ingénierie et de Technologies

APPLICATIONS DE BASE DU DATA MINING



DEUX FAMILLES DE TECHNIQUES

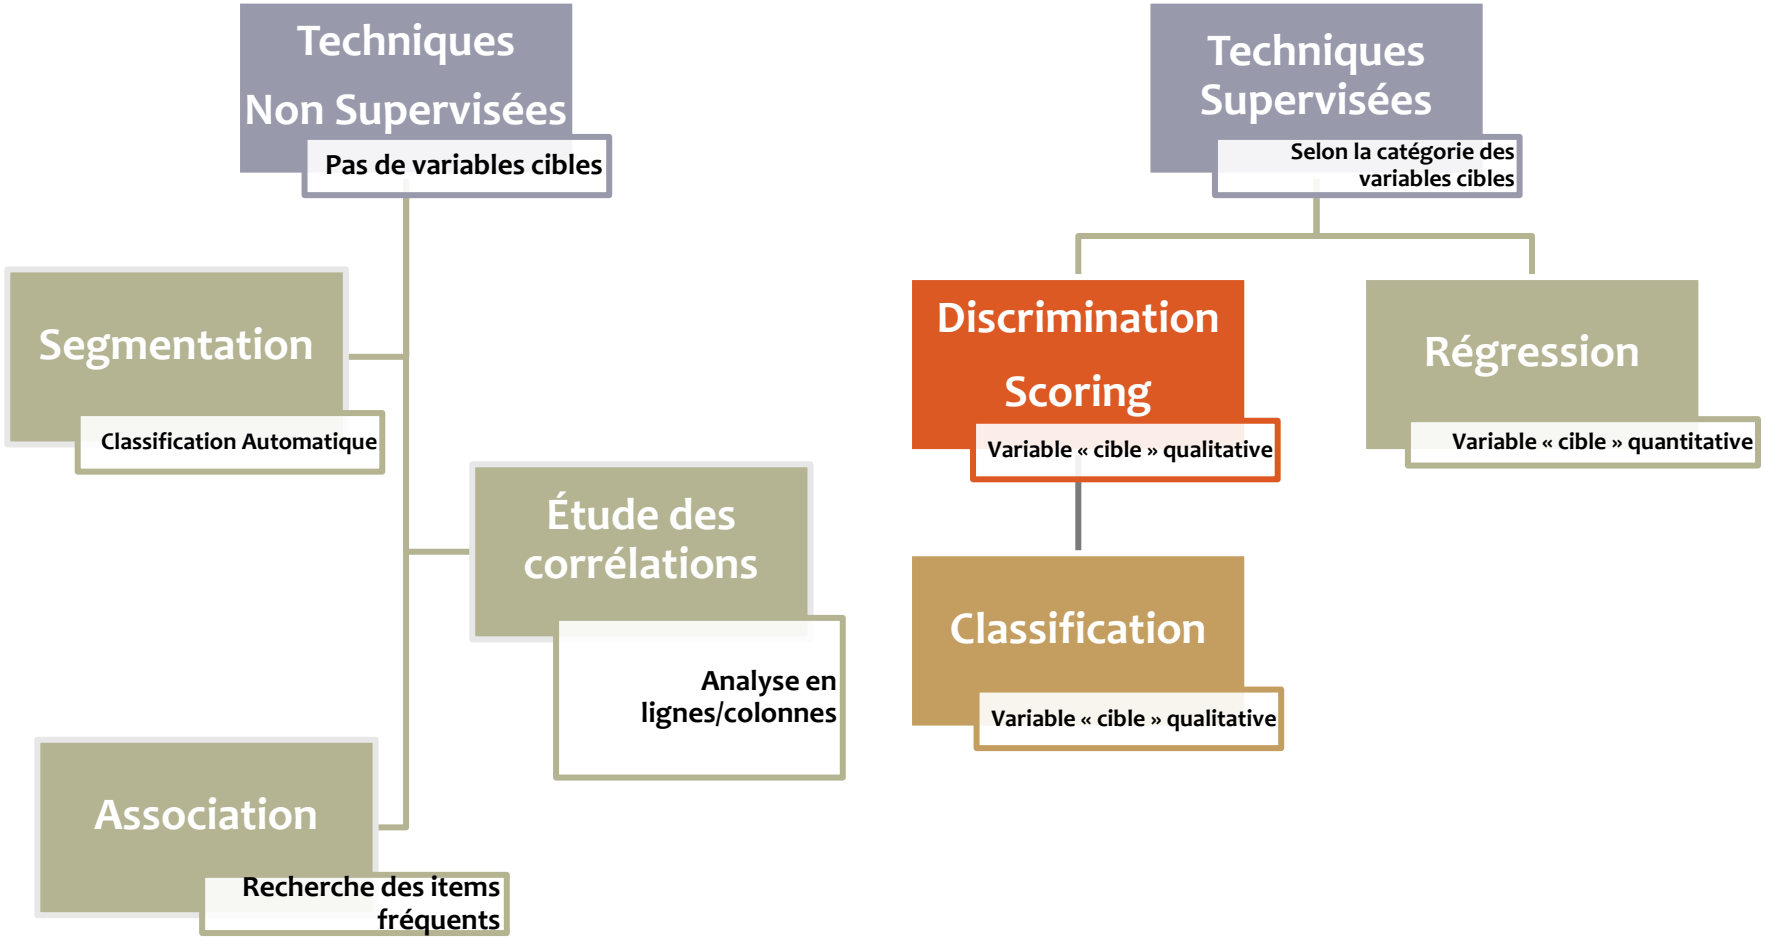
ANALYSE DESCRIPTIVE

- ✓ S'appliquent seulement sur les données quantitatives.
- ✓ Fournissent directement des résultats : à interpréter et à utiliser !
- ✓ visent à mettre en évidence des connaissances **présentes** mais cachées par le volume des données
- ✓ réduisent, résument, synthétisent les masses de données
- ✓ **pas de variable « cible »**

ANALYSE PRÉDICTIVE

- ✓ Fournissent un modèle (et non pas des résultats), créé à partir d'un entrepôt d'apprentissage, testé et validé sur un entrepôt de test, et utilisé dans les problèmes de prise de décision sur des entrepôts de travail
- ✓ visent à découvrir de **nouvelles informations** à partir des informations présentes : connaissances, **décisions**
- ✓ expliquent mieux les données
- ✓ **Une(des) variable(s) « cible(s)»**

TYPES D'APPLICATIONS



DEUX FAMILLES DE TECHNIQUES

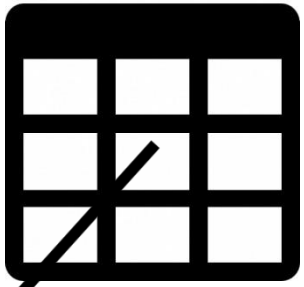
Méthodes *Non Supervisées*

- Analyse en Composantes Principales
  ACP
- Méthodes des Centres Mobiles
  K-means
- Classification Ascendante Hiérarchique
  CAH
- Règles Associatives
  Apriori

Méthodes *Supervisées*

- Arbres de Décisions
- Analyse Linéaire Discriminante
- Régression
- Plus Proche voisin kNN
- Réseaux de Neurones
- Séparateur à Vaste Marge
  SVM

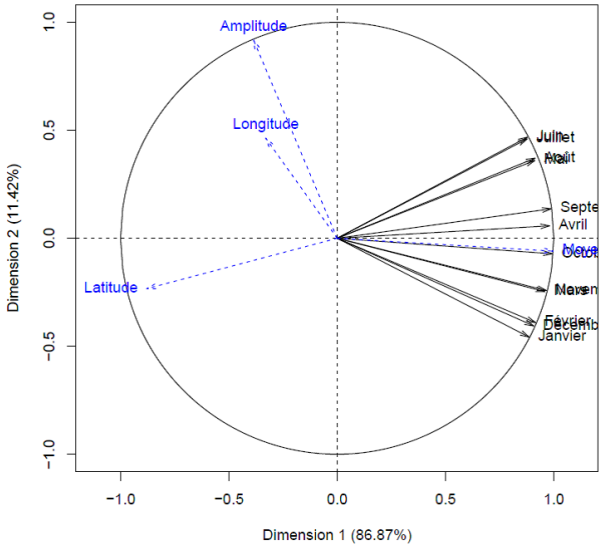
Entrepôt de données

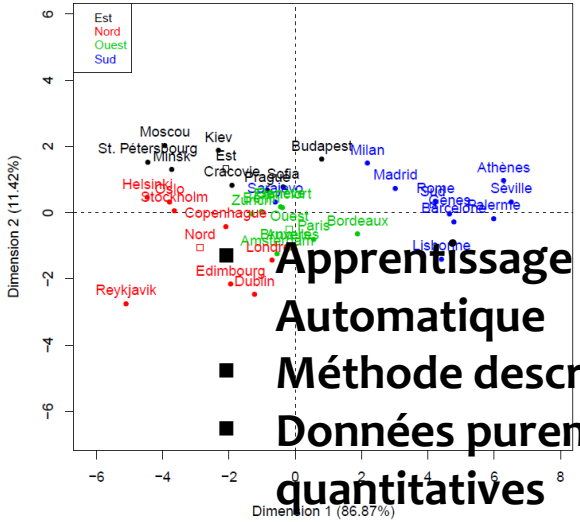


Méthodes Non Supervisées

Méthodes Supervisées

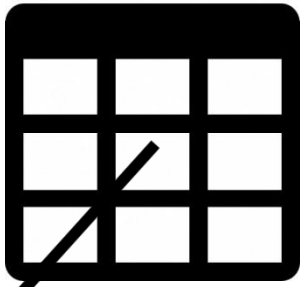
Analyse en Composantes Principales ACP





- Apprentissage Automatique
- Méthode descriptive
- Données purement quantitatives
- Obtention de Corrélations
- Relations :
  i. (I_i, I_j),
  ii. (I_i, X_k),
  iii. (X_k, X_p)

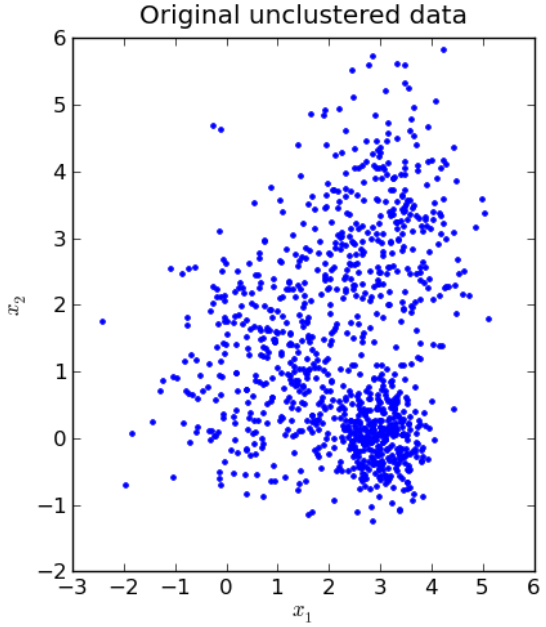
Entrepôt de données

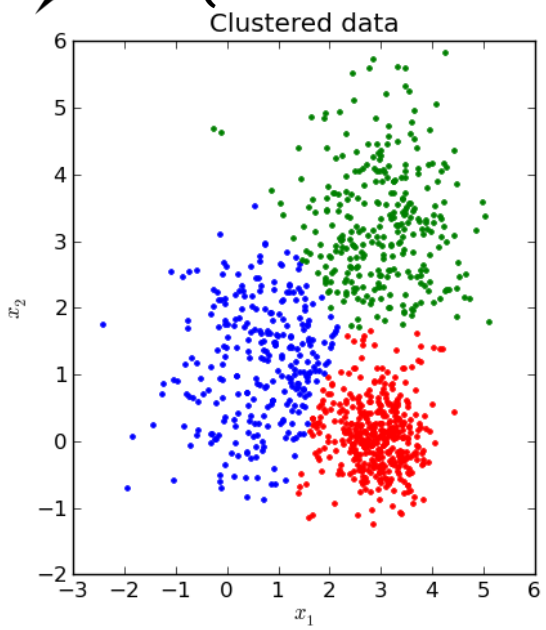


Méthodes Non Supervisées

Méthodes Supervisées

Méthodes de Segmentation (Classification Automatique)



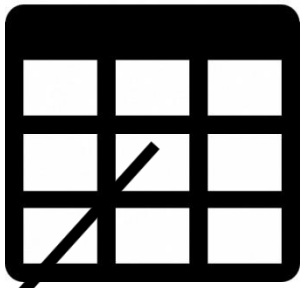


- Apprentissage Automatique
- Méthode descriptive
- Obtention d'une nouvelle affection/appartenance
- Groupes d'individus possédant des caractéristiques semblables : meilleure classification
- Mise à jour de l'entrepôt en Input : ajouter la nouvelle caractéristique des individus

Entrepôt de données

Méthodes Non Supervisées

Méthodes Supervisées



Règles Associatives
(algorithme apriori)

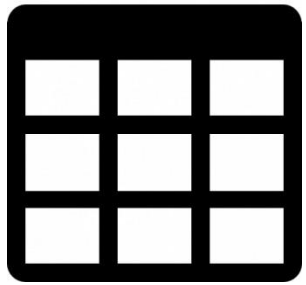
```
> inspect(regles.triees[1 :5])
  lhs                  rhs                  support confidence      lift
1 {Tomatoes,
   Eggs,
   White_Bread}     => {Sugar_Cookies} 0.02130786  0.8055556 14.618148
2 {Sugar_Cookies,
   Eggs,
   White_Bread}     => {Tomatoes}      0.02130786  0.7837838 11.852553
3 {Onions,
   X2pct_Milk,
   Eggs}            => {Wheat_Bread}   0.02130786  0.7631579  9.891980
4 {Eggs,
   White_Bread,
   Sweet_Relish}    => {Toothpaste}    0.02057311  0.7777778  9.801440
5 {Cola,
   Sweet_Relish}    => {Toothpaste}    0.02130786  0.7631579  9.617203
>
```

- Apprentissage Automatique
- Méthode descriptive
- Données Transactionnelles
- Obtention d'un ensemble de règles expliquant l'associativité/correspondance entre les items/produits/profils
- Trier les règles selon des indicateurs de performances

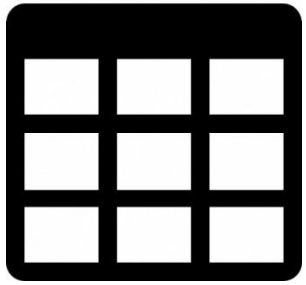
Entrepôts de données

Méthodes Non Supervisées

Méthodes Supervisées



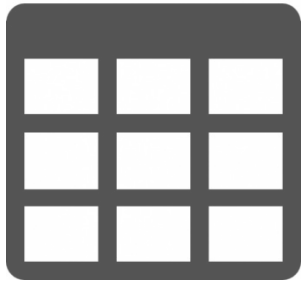
Entrepôt d'apprentissage : présentant *une variable décisionnelle* $Y_{réelle}$



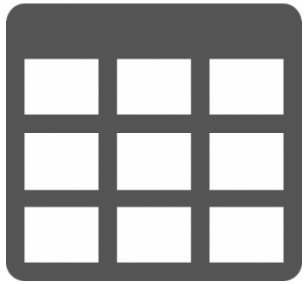




Entrepôt de test



Entrepôt de travail



Méthodes Supervisées :

i. Arbre de Décision
ii. Régression
iii. Analyse Discriminante LDA
iv. Réseaux de Neurones NN
v. Séparateur à vaste marge SVM
vi. Plus proche voisin k-NN

Etc.

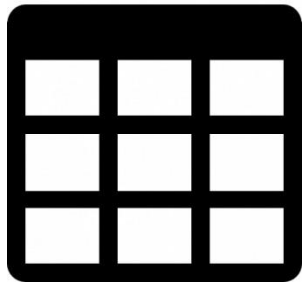
Modèle de Classification ou de Prédiction :

- ✓ Ensemble de règles décisionnelles
- ✓ Formule mathématique / $Y=f(X_i)$
- ✓ Formulations de Score / $Score_A$, $Score_B$, etc.
- ✓ Equation d'un plan séparateur
- ✓ Résultat d'un algorithme itératif

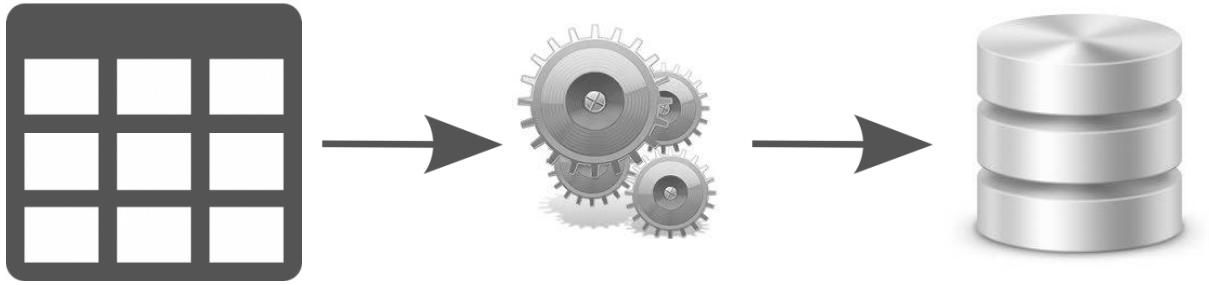
Entrepôts de données

Méthodes Non Supervisées

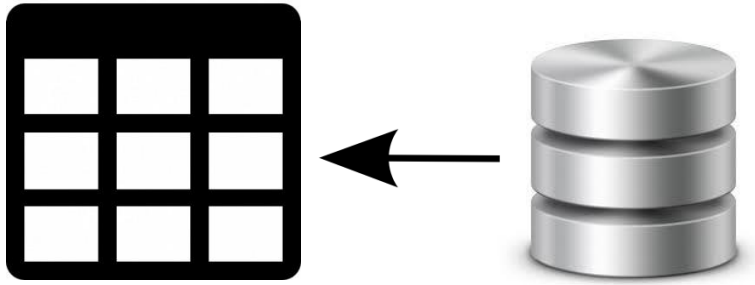
Méthodes Supervisées



Entrepôt d'apprentissage

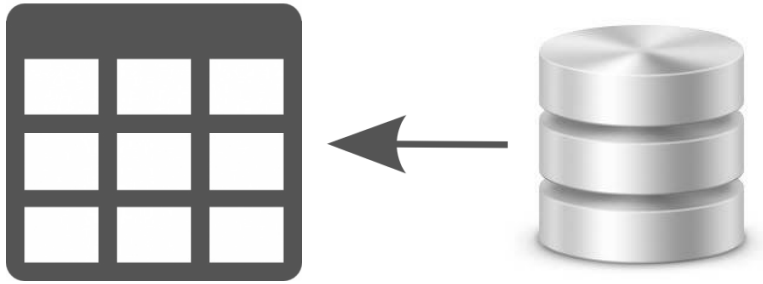


Entrepôt de test : présentant une *variable décisionnelle* $Y_{réelle}$



- ✓ **Appliquer le modèle construit pour obtenir les valeurs de la variable décisionnelle $Y_{prédite}$**
- ✓ **Comparer les deux colonnes $Y_{réelle}$ et $Y_{prédite}$**
- ✓ **Valider le modèle**

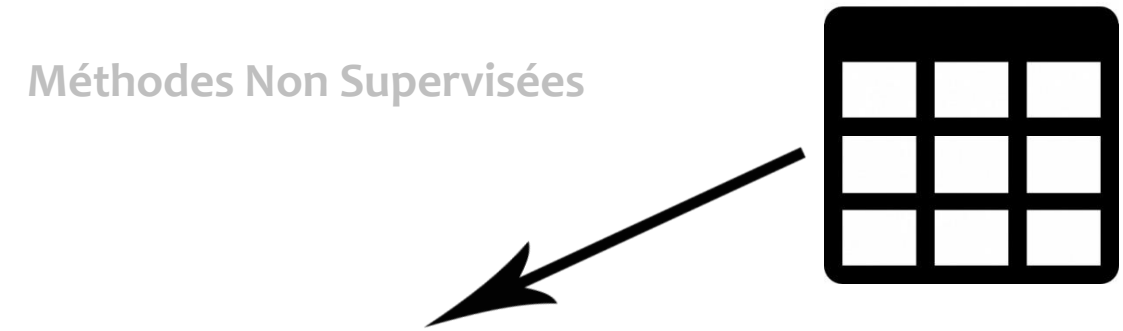
Entrepôt de travail



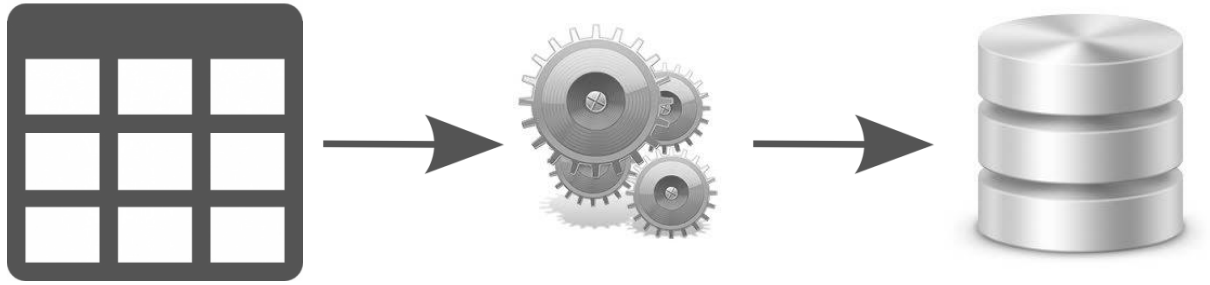
Entrepôts de données

Méthodes Non Supervisées

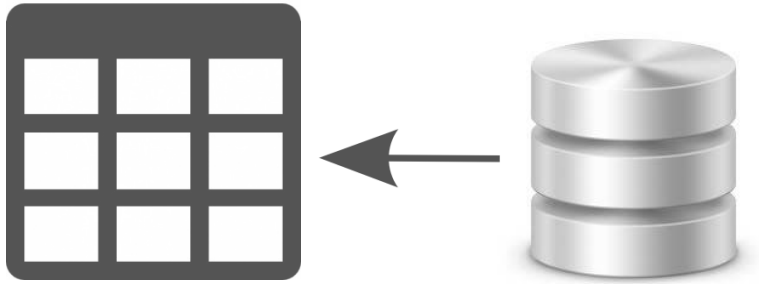
Méthodes Supervisées



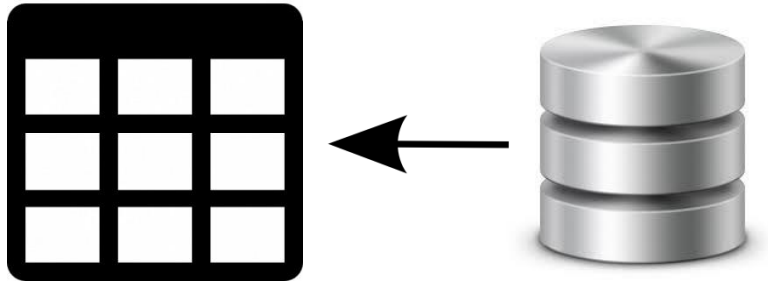
Entrepôt d'apprentissage



Entrepôt de test : présentant une *variable décisionnelle* $Y_{réelle}$



Entrepôt de travail : ne contenant pas les valeurs de la *variable décisionnelle*



- ✓ **Appliquer le modèle construit pour obtenir les valeurs de la variable décisionnelle $Y_{définitive}$**

LES LOGICIELS PROFESSIONNELS

Critères de comparaison :

- ✓ Temps de réponse
- ✓ Payant ou gratuit
- ✓ Extensibilité
- ✓ Richesse en terme de méthodes
- ✓ Souplesse du paramétrage des méthodes appliquées









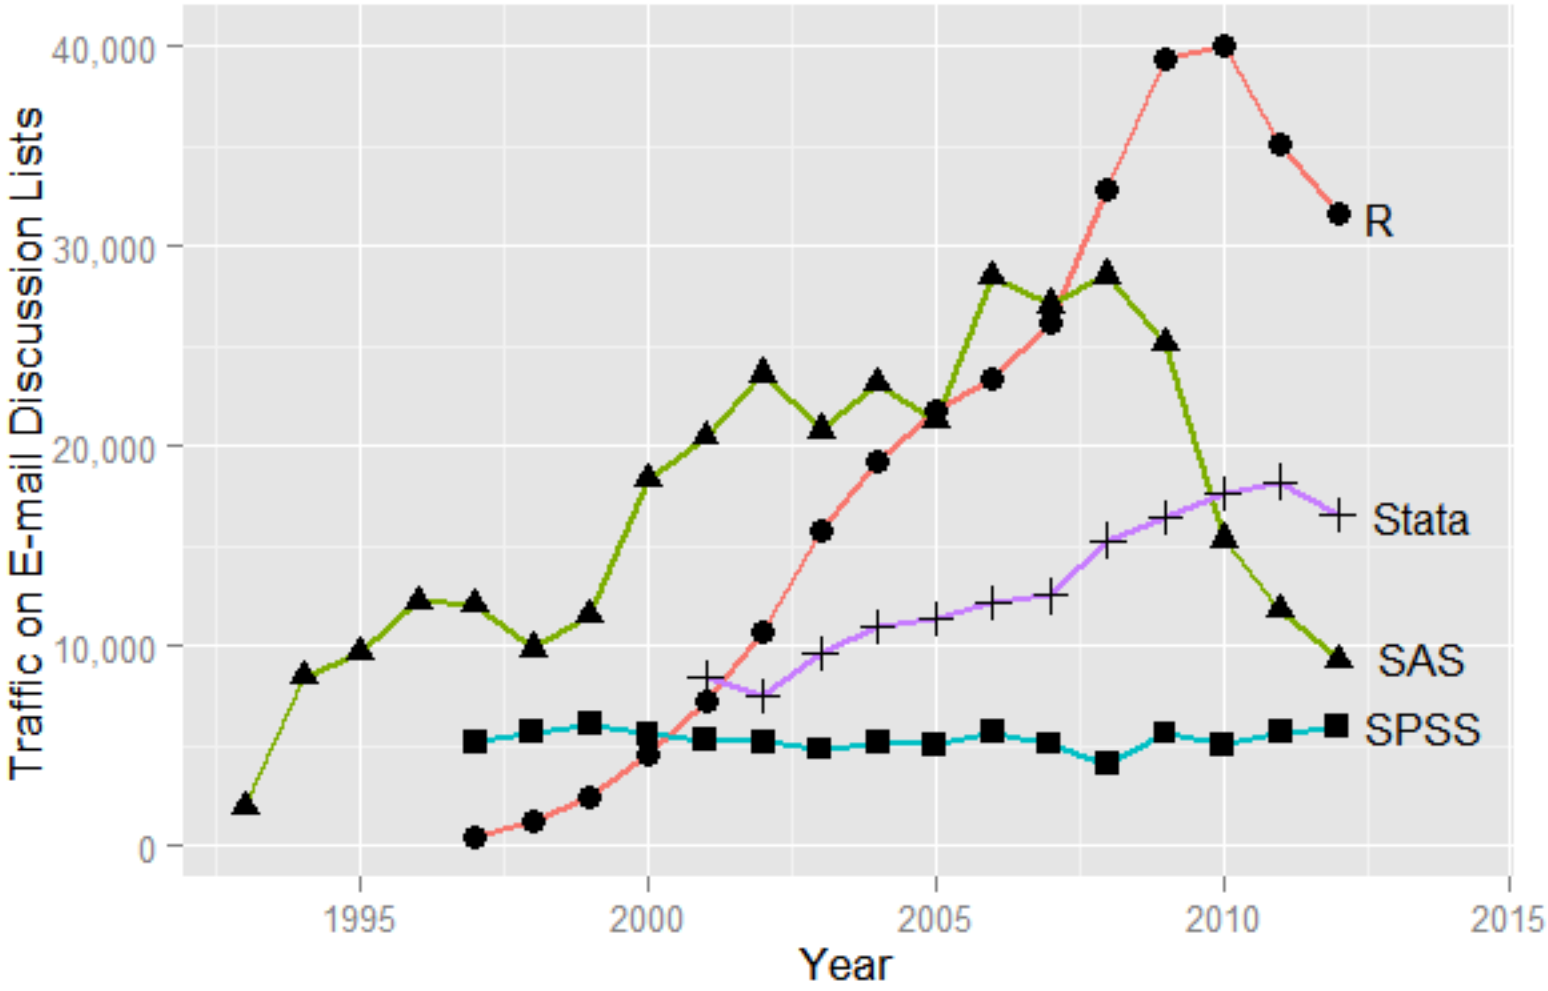








LES LOGICIELS PROFESSIONNELS



CE QU'IL FAUT RETENIR !

SPÉCIALISTES DU MÉTIER



Définition des objectifs

avant l'élaboration d'un score de risque, il

convient de s'entendre sur la définition précise d'un risque

Recensement des données

il est intéressant de connaître les indicateurs considérés comme pertinents par les spécialistes

Analyse des résultats

le spécialiste métier peut dire s'ils

paraissent triviaux, nouveaux et intéressants à creuser, ou

surprenants et très suspects

DATA MINING – STATISTIQUES ?

certaines techniques n'appartiennent qu'au DATA MINIG

le nombre d'individus étudiés est beaucoup plus important en DM, où l'optimisation des algorithmes est très importante

Data Mining fait beaucoup moins d'hypothèses contraignantes sur les lois statistiques suivies

Data Mining recherche plus la compréhensibilité des modèles que leur précision



APPORTS INCROYABLES DU DATA MINING !



Le Data Mining ne permet pas de faire des découvertes incroyables



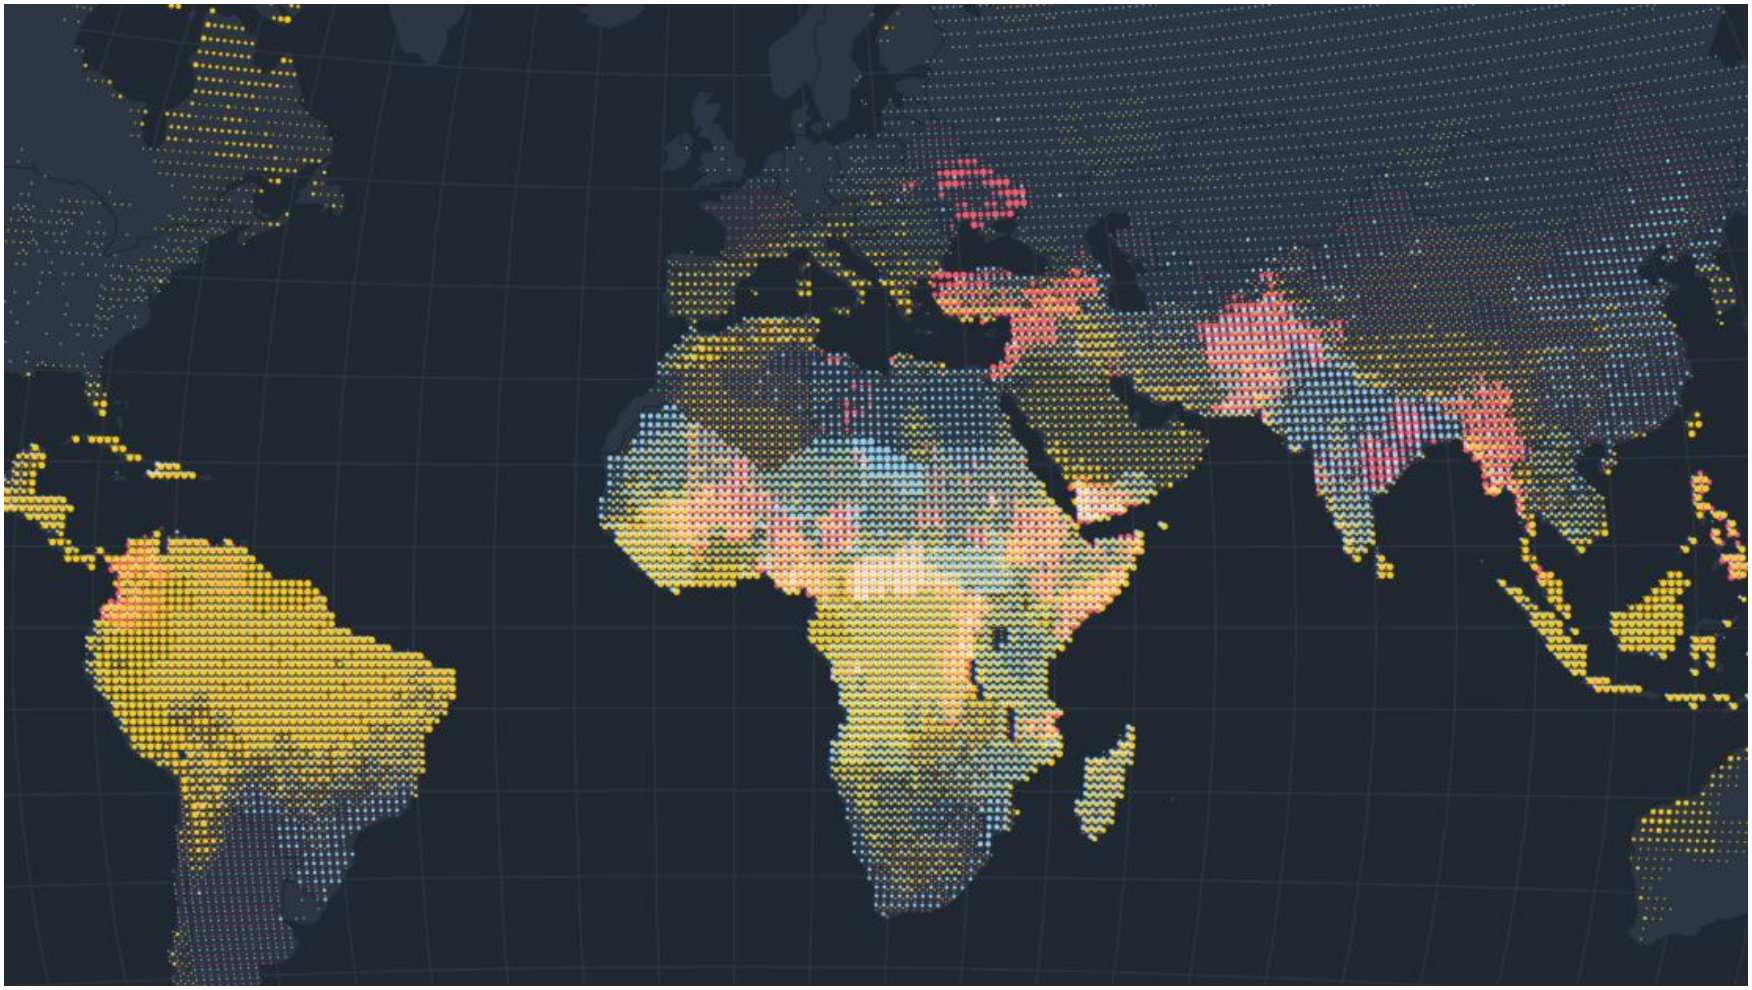
LA meilleur façon de partitionner une masse de données
LA meilleure combinaison possible à détecter
LA meilleure interprétation des Individus, des variables…
LE meilleur apprentissage possible à atteindre
LE meilleur modèle de Classifier
LA meilleure DECISION possible à prendre

DÉROULEMENT DE LA SÉANCE

DATA MINING ;)

esprit
Ecole Supérieure Privée
d'Ingénierie et de Technologies

THE BEAUTY OF DATAVIZ



https://truth-and-beauty.net/

MODÈLE DE PRÉDICTION COUPE DU MONDE FIFA 2014 !

Prediction model for the FIFA World Cup 2014

June 12, 2014

By Christian Groll

Like Share 3.1k Tweet 187

(This article was first published on **Quantifying Information » Rbloggers**, and kindly contributed to R-bloggers)

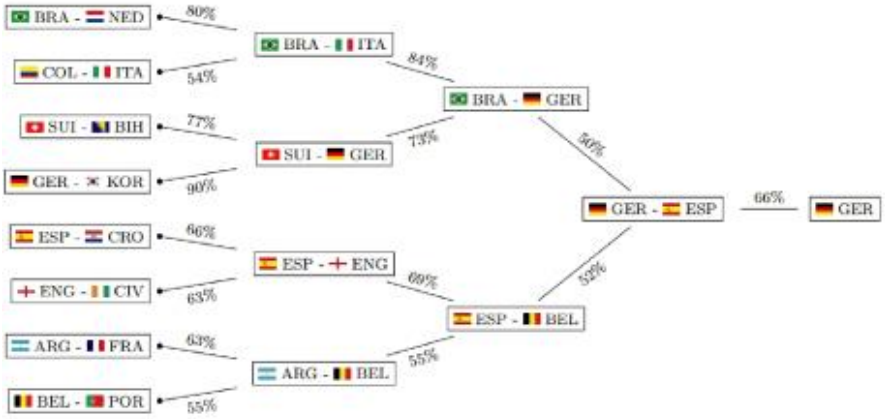
Like a last minute goal, so to speak, Andreas Groll and Gunther Schauberger of Ludwig-Maximilians-University Munich announced their predictions for the FIFA World Cup 2014 in Brazil – just hours before the opening game.

Andreas Groll, with his successful prediction of the European Championship 2012 already experienced in this field, and Gunther Schauberger did set out to predict the 2014 world cup champion based on statistical modeling techniques and R.

A bit surprisingly, Germany is estimated with highest probability of winning the trophy (28.80%), exceeding Brazil's probability (the favorite according to most bookmakers) only marginally (27.65%). You can find all estimated probabilities compared to the respective odds from a German bookmaker in the graphic on their homepage (http://www.statistik.lmu.de/~schauberger/research.html), together with the most likely world cup evolution simulated from their model. The evolution also shows the neck-and-neck race between Germany and Brazil: they are predicted to meet each other in the semi-finals, where Germany's probability of winning the game is a hair's breadth above 50%. Although there does not exist a detailed technical report on the results yet, you still can get some insight into the model as well as the data used through a preliminary summary pdf on their homepage (http://www.statistik.lmu.de/~schauberger/WMGrollSchauberger.pdf).

team	$\hat{p}$ Lasso	$\hat{p}$ Oddset	team	$\hat{p}$ Lasso	$\hat{p}$ Oddset
1. GER	0.2880	0.1420	17. GHA	0.0022	0.0071
2. BRA	0.2765	0.2028	18. KOR	0.0019	0.0024
3. ESP	0.0900	0.1092	19. ALG	0.0018	0.0071
4. BEL	0.0819	0.0592	20. ECU	0.0017	0.0071
5. ARG	0.0582	0.1420	21. USA	0.0016	0.0071
6. POR	0.0522	0.0237	22. MEX	0.0012	0.0071
7. SUI	0.0413	0.0071	23. JPN	0.0010	0.0047
8. CRO	0.0210	0.0071	24. BIH	0.0008	0.0047
9. ENG	0.0193	0.0355	25. GRE	0.0005	0.0071
10. FRA	0.0135	0.0355	26. RUS	0.0004	0.0118
11. NED	0.0129	0.0355	27. NGA	0.0004	0.0035
12. ITA	0.0094	0.0355	28. AUS	0.0003	0.0024
13. URU	0.0071	0.0284	29. HON	0.0002	0.0005
14. CHI	0.0063	0.0203	30. CRC	0	0.0071
15. COL	0.0052	0.0394	31. CMR	0	0.0024
16. CIV	0.0032	0.0071	32. IRN	0	0.0005

Group A 44%	Group B 24%	Group C 16%	Group D 18%	Group E 22%	Group F 36%	Group G 37%	Group H 26%
1. BRA	1. ESP	1. COL	1. ENG	1. SUI	1. ARG	1. GER	1. BEL
2. CRO	2. NED	2. CIV	2. ITA	2. FRA	2. BIH	2. POR	2. KOR
MEX	CHI	JPN	URU	ECU	NGA	GHA	RUS
CMR	AUS	GRE	CRC	HON	IRN	USA	ALG



DATA MINING ET L'ENJEU : DONNÉES !

OBSESSIONS

QUARTZ

DUNNHUMBY

Why an obscure British data-mining company is worth $3 billion



Outlook: grey. (Reuters/Toby Melville)

SHARE

WRITTEN BY

Tesco, the troubled British retail group, is starting over. After an accounting scandal, a series of profit warnings, and plunge in its share price, the beleaguered company has launched a major restructuring plan. It will not pay a dividend at the end of this financial

DATA MINING DANS LE CINÉAMA AMÉRICAIN !



data minin 1 sur 1

MY AMERICAN SCIENTIST email LOG IN REGISTER

SEARCH Search GO

AMERICAN Scientist

THE MAGAZINE OF SIGMA XI THE SCIENTIFIC RESEARCH SOCIETY

Current Issue | Past Issues | Scientists' Nightstand | Multimedia | About | Subscribe | Advertise

HOME > PAST ISSUE > Article Detail

RAISE FONT SIZE A A A

VIEW PRINTER - FRIENDLY

MACROSCOPE

Science Needs More *Moneyball*

Baseball's data-mining methods are starting a similar revolution in research

Frederick M. Cohan

The *Moneyball* story, in book and film, champions a data-mining revolution that changed professional baseball. On the surface, *Moneyball* is about Billy Beane, the general manager of the Oakland A's, who found a way to lead his cash-strapped club to success against teams with much bigger payrolls. Beane used data to challenge what everyone else managing baseball "knew" to be true from intuition, experience and training. He pioneered methods to identify outstanding players he could afford because they were undervalued by the traditional statistics used by the baseball elite.

This film was marketed as a sports movie. When I saw it, I knew right away what *Moneyball* is really about: the thrill and triumph of data mining. It's an instructive tale of how existing data can be examined for meaning in ways that were never intended or imagined when they were originally collected. Beane and his colleagues challenged the time-honored trinity of batting average, home runs and runs batted in (RBIs) as the essence of the offensive value of a player, replacing these statistics with newer measures based on the same data. They worked off theories developed by baseball writer and historian Bill James, who posited in the 1970s that the traditional stats were really imperfect measurements. James's approach didn't just replace one intuition with another. He let the game decide which stats did the best job of predicting offensive output.

This [illegible] would confound the skill of a team's offense with its pitching and fielding. James figured that one could test each offensive stat by trying to predict the total [illegible] eliminating any effects of defense. It turned out that on-base percentage and slugging percentage were far superior to any individual offensive statistics used up to that point. James and others similarly devised statistics for pitching and fielding that were more independent of context.

IN THIS SECTION

Community Guidelines: Disqus Comments
The Art and Science of Communicating Science
American Scientist Classics
Science Online: Women in Science
Purchase a Back Issue
Authors
2014 Annual Index

This Article from Issue
May-June 2012
Volume 100, Number 3
Page: 182
DOI: 10.1511/2012.96.182

PURCHASE PDF
PRINTER - FRIENDLY VERSION
SAVE TO LIBRARY

EMAIL TO A FRIEND :
FRIEND'S EMAIL ADDRESS
YOUR EMAIL ADDRESS

Of Possible Interest
[illegible] Poisons, in Food and Water
Feature Article: Like Hunting a Piece of Sky
Feature Article: Curious Chemistry Guides Hydrangea Colors

AMERICAN Scientist SUBSCRIBE

THE CULTURAL LIVES OF WHALES AND DOLPHINS

Ce film a été commercialisé comme un film de sport. Lorsque je l'ai vu, je ai su tout de suite ce Moneyball est vraiment: le frisson et le triomphe de la fouille de données

DATA MINING ET LES OSCARS !

Decideo·fr

MODÉLISATION PRÉDICTIVE : L'ORACLE DES OSCARS AVAIT-IL RAISON?

PHILIPPE NIEUWBOURG
4 MARS 2014

100 %... oui, c'en est presque inquiétant... mais Farsite avait prédit exactement les gagnants des principaux Oscars de la soirée 2014. En s'appuyant sur des données structurées et non structurées, Farsite a développé un modèle mathématique qui « prédit » les choix artistiques de l'Académie des Oscars. Info ou intox ?



La fameuse "selfie" de la soirée des Oscars qui a fait "exploser" Twitter

Grand jeu à l'occasion de la cérémonie des Oscars qui s'est déroulée il y a 2 jours à Los Angeles, la prédiction des résultats. Comme dans tout bon film de science fiction, la question est de savoir si la machine est capable de modéliser le comportement humain; et de prédire des résultats que l'on imaginait irrationnels. Quoi de plus subjectif que les choix artistiques d'un jury de professionnels du 7eme art... Plusieurs entreprises se sont attachées à démontrer qu'en réalité leurs choix « artistiques » sont parfaitement prévisibles.

22 Tweet | 32 Like | 9 +1 | 56 Share

La société ICC **avait prédit** que :
- Matthew McConaughey remporterait l'Oscar du meilleur acteur pour son rôle dans Dallas Buyers Club... elle avait raison ;
- Alfonso Cuaron remporterait l'Oscar du meilleur réalisateur avec Gravity... elle avait raison ;
- 12 Years a Slave serait récompensé par l'Oscar de la meilleure image... elle avait raison ;
- Jared Leto serait Oscarisé meilleur second rôle masculin dans Dallas Buyers Club... elle avait raison ;
- Cate Blanchett meilleure actrice dans Blue Jasmine... elle avait encore raison;

ABONNEZ-VOUS À LA NEWSLETTER

Votre email:
Votre nom :
Je m'abonne

BIG DATA SUMMIT
NOV 16-18, 2014
PHOENIX, ARIZONA
WWW.BIGDATASUMMIT.US
*Current Decideo Readers
25% RECEIVE DISCOUNT

AGENDA

AUJOURD'HUI
- IEEE VIS 2014 (au 14/11/2014)

MERCREDI 12 NOVEMBRE
- Formation Agile BI (au 14/11/2014)
- "Data analytics" : Des données aux connaissances et à la création de valeur
- Formation en ligne - L'intégration de données d'entreprise pas-à-pas

JEUDI 13 NOVEMBRE
- Talend Roadshow Nantes
- Business Forum Big Data

VENDREDI 14 NOVEMBRE
- BRUSSELS SOFTWARE DAY

Téléchargez l'application gratuite
Disponible sur App Store

100 %... oui, c'en est presque inquiétant... mais Farsite avait prédit exactement les gagnants des principaux Oscars de la soirée 2014. En s'appuyant sur des données structurées et non structurées, Farsite a développé un modèle mathématique qui « prédit » les choix artistiques de l'Académie des Oscars

LES DATA MININERs ?



State CIO Priorities for 2016

November 10, 2015

A. Priority Strategies, Management Processes and Solutions
Top 10 Final Ranking

1. **Security and Risk Management**: governance, budget and resource requirements, security frameworks, data protection, training and awareness, insider threats, third party security practices as outsourcing increases, determining what constitutes "due care" or "reasonable"

2. **Cloud Services**: cloud strategy, proper selection of service and deployment models, scalable and elastic IT-enabled capabilities provided "as a service" using internet technologies, governance, service management, service catalogs, platform, infrastructure, security, privacy, data ownership

3. **Consolidation/Optimization**: centralizing, consolidating services, operations, resources, infrastructure, data centers, communications and marketing "enterprise" thinking, identifying and dealing with barriers

4. **Business Intelligence and Data Analytics**: applying BI/BA within the enterprise, communicating the value, building expertise, delivering shared services, exploring big data, data analytics

5. **Legacy Modernization**: enhancing, renovating, replacing, legacy platforms and applications, business process improvement

6. **Enterprise Vision and Roadmap for IT**: vision and roadmap for IT, recognition by administration that IT is a strategic capability, integrating and influencing strategic planning and visioning with consideration of future IT innovations, aligning with Governor's policy agenda

7. **Budget and Cost Control**: managing budget reduction, strategies for savings, reducing or avoiding costs, dealing with inadequate funding and budget constraints

8. **Human Resources/Talent Management**: human capital/IT workforce, workforce reduction, attracting, developing and retaining IT personnel, retirement wave planning, succession planning, support/training, portal for workforce data and trends

9. **Agile and Incremental Software Delivery**: iterative design and incremental development of software solutions, allows for design modifications, prototyping and addition of new capabilities as part of the development process

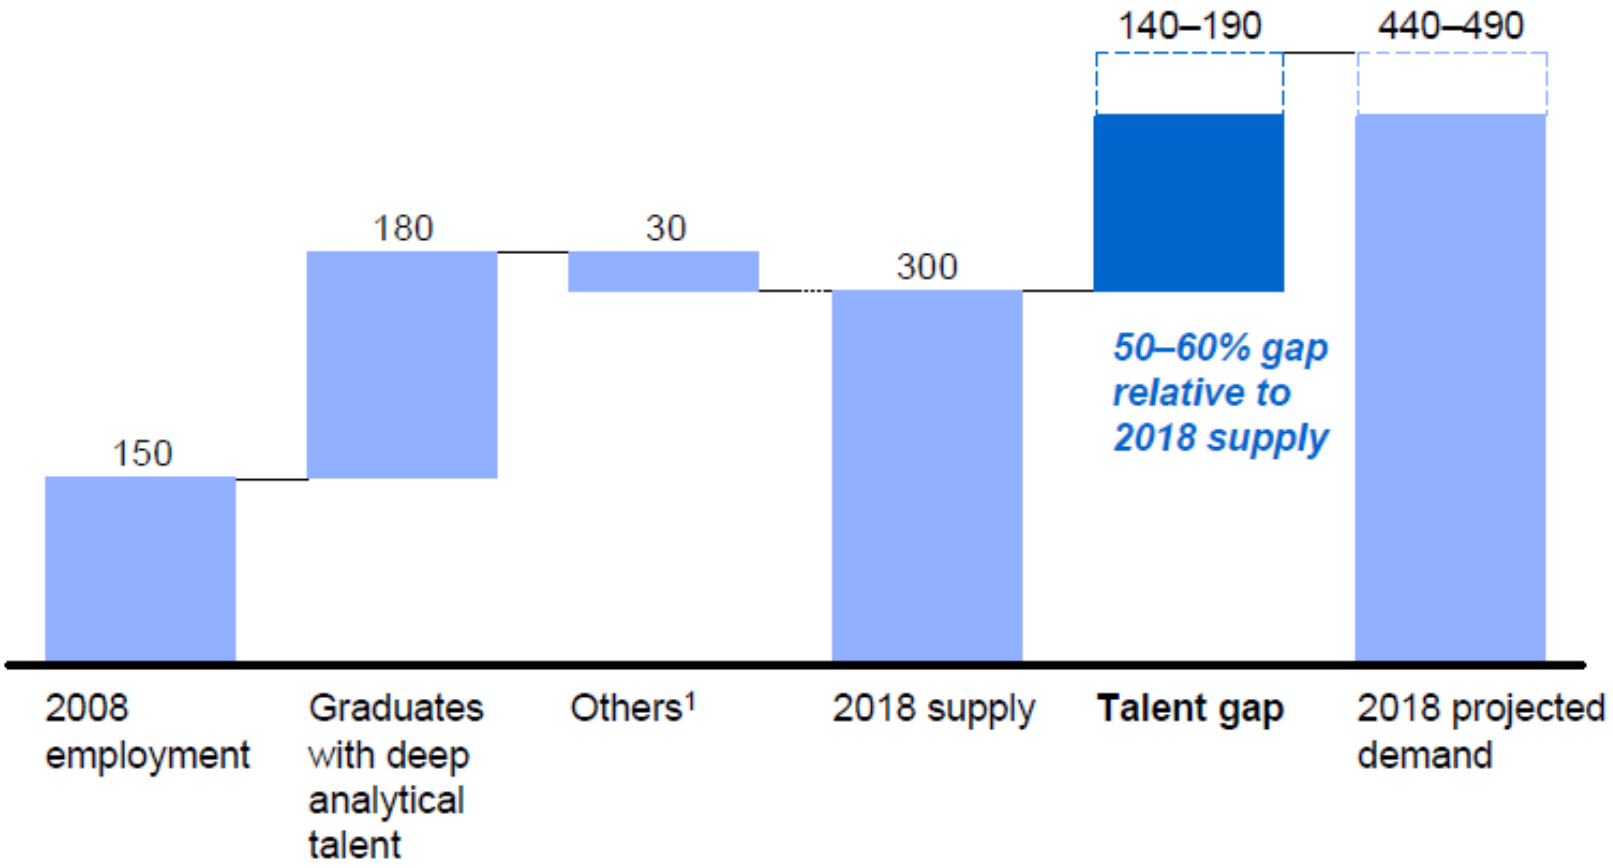
10. **Disaster Recovery/Business Continuity**: improving disaster recovery, business continuity planning and readiness, pandemic/epidemic and IT impact, testing

201 East Main Street, Suite 1405 Lexington, KY 40507 859.514.9153 T: @NASCIO info@NASCIO.org

GOOD NEWS: DEMAND FOR DATA MINING

Demand for deep analytical talent in the United States could be 50 to 60 percent greater than its projected supply by 2018

Supply and demand of deep analytical talent by 2018
Thousand people



1 Other supply drivers include attrition (-), immigration (+), and reemploying previously unemployed deep analytical talent (+).

SOURCE: US Bureau of Labor Statistics; US Census; Dun & Bradstreet; company interviews; McKinsey Global Institute analysis

LES DATA MINERs ?



LES DATA MINERs ?

