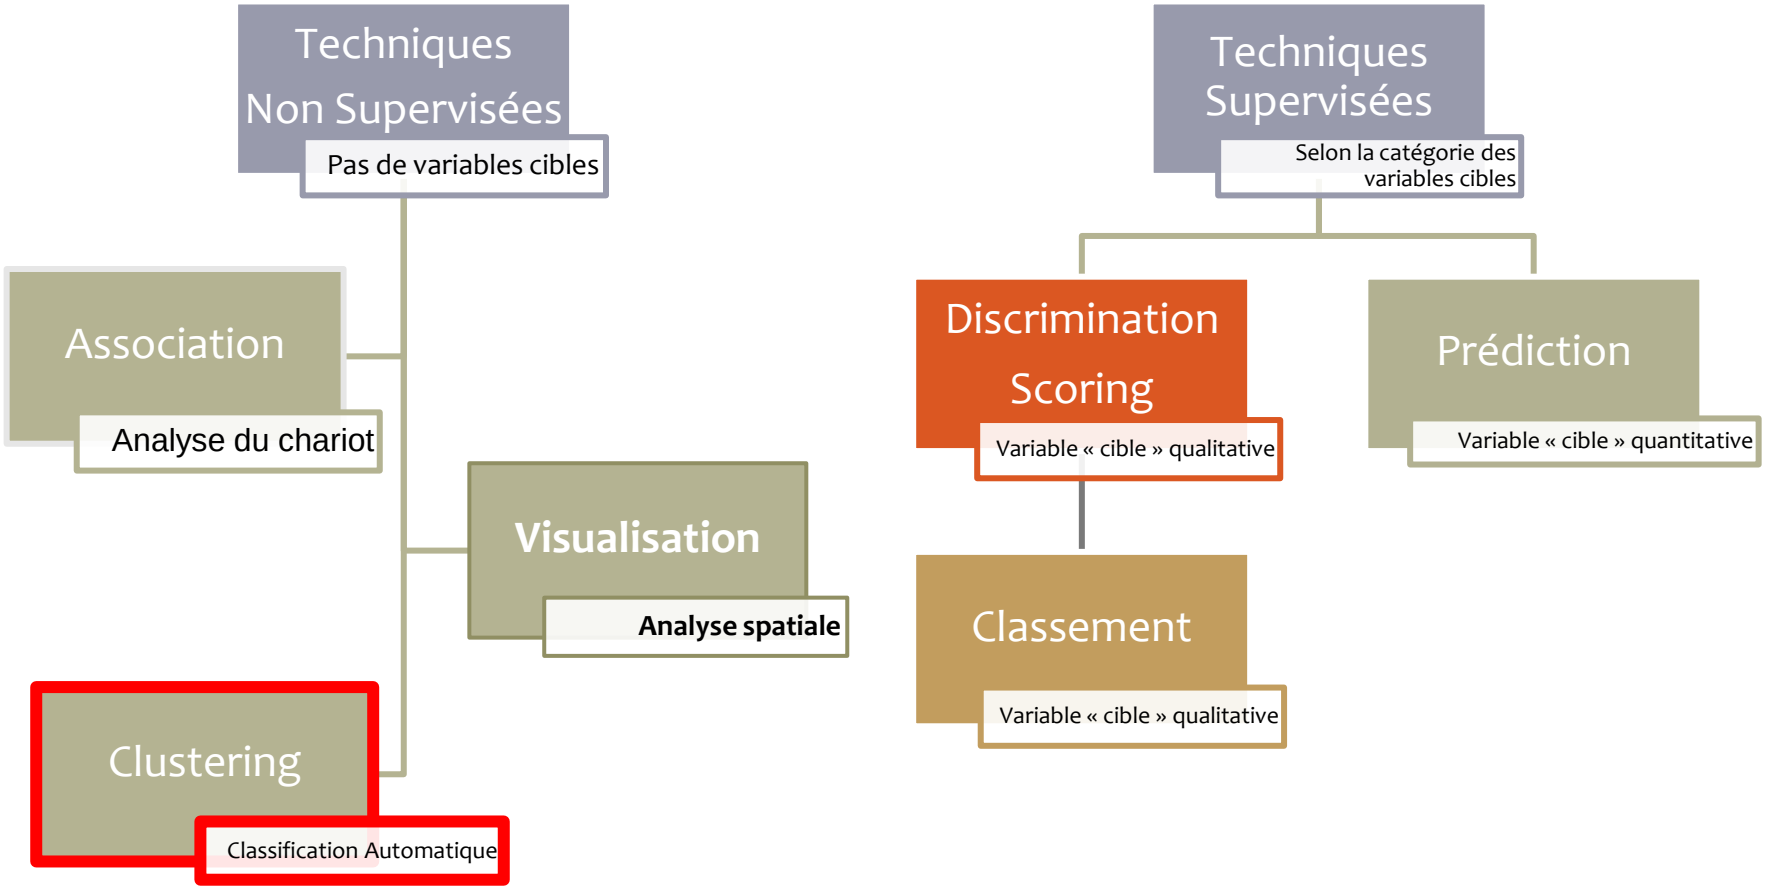
DATA MINING

LES RÈGLES ASSOCIATIVES

Équipe Data Mining

Année Scolaire 2023/2024

TYPES D'APPLICATIONS



MOTIVATIONS et OBJECTIFS

✓ Rechercher les associations consiste à rechercher les règles du type :

« Si pour un individu, la variable A = Xa, la variable B = Xb, etc, alors, dans 80% des cas, la variable Z = Xz, cette configuration se rencontrant pour 30 % des individus »

✓ **Repérer** des règles liant les données avec un bon niveau de probabilité

- découverte de relations fines entre attributs (ou variables)
- généralisation des dépendances fonctionnelles

✓ Mettre en évidence les produits / des articles achetés ensemble

✓ **Transcrire la connaissance** sous forme de règles d'association

✓ Règles du style : < **si** *[P(tid,X) := prémisse]* **alors** *[P(tid,Y) := conséquence]* >

✓ Différents types de règles

- origine « panier de la ménagère »
- étendues aux tables multiples et aux attributs continus

UTILITÉ DES RÈGLES D'ASSOCIATION



Le panier moyen



La course à la fidélisation des clients



Réductions personnalisées à la caisse



Profil-client



Le test des nouveaux produits



Améliorer les systèmes de recommandation



Le parcours magasin



Cartes de fidélité

ANALYSE DES TICKETS DE CAISSE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			



Une observation = un caddie

Ne tenir compte que de la présence des produits : peu importe leur quantité

Dans un caddie : le nombre de produits est variable

La liste des produits est immense et variable

TABLEAU DES TRANSACTIONS

- ✓ Mettre en évidence les produits / des articles achetés ensemble
- ✓ Transcrire la connaissance sous forme de règles d'association

si *[P(tid,X) := prémisse]* **alors** *[P(tid,Y) := conséquence]*

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates

si *Poulet* **et** *Moutarde* **alors** *Œufs* **et** *Pates*

N° Transaction (Caddie)	Contenu du caddie	
6	Œufs	Pain

si *Œufs* **alors** *Pain*

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1								
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture



TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1							
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1						
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1					
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1				
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0			
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0	0		
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0	0	0	
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0	0	0	0
2								
3								
4								
5								
6								
7								

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

N° Transaction (Caddie)	Contenu du caddie			
1	Poulet	Moutarde	Œufs	Pates
2	Moutarde	Œufs		
3	Pain	Beurre	Poulet	
4	Pates			
5	Pain	Lait	Beurre	
6	Œufs	Pain		
7	Confiture			

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0	0	0	0
2	0	1	1	0	0	0	0	0
3	1	0	0	0	1	1	0	0
4	0	0	0	1	0	0	0	0
5	0	0	0	0	1	1	1	0
6	0	0	1	0	1	0	0	0
7	0	0	0	0	0	0	0	1

désignation
P1 = Poulet
P2 = Moutarde
P3 = Œufs
P4 = Pates
P5 = Pain
P6 = Beurre
P7 = Lait
P8 = Confiture

TABLEAU BINAIRE

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0	0	0	0
2	0	1	1	0	0	0	0	0
3	1	0	0	0	1	1	0	0
4	0	0	0	1	0	0	0	0
5	0	0	0	0	1	1	1	0
6	0	0	1	0	1	0	0	0
7	0	0	0	0	0	0	0	1



Dès que l'on peut se ramener à des données 0/1 :

Il est possible de construire des règles d'association

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince



Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1				
2				
3				

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince

Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1				
2				
3				

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince

Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1				
2				
3				

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince

Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1	1			
2				
3				

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince

Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1	1	0		
2				
3				

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince

Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1	1	0	1	
2				
3				

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince

Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1	1	0	1	0
2				
3				

CODAGE DISJONCTIF COMPLET

Observation	Taille	Corpulence
1	Petit	Mince
2	Grand	Enveloppé
3	Grand	Mince



Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1	1	0	1	0
2	0	1	0	1
3	0	1	1	0



Dès que l'on peut se ramener à des données 0/1 :

Il est possible de construire des règles d'association

CODAGE COMPLET

✓ Il s'agit de détecter les cooccurrences des modalités (attribut = valeur)
✓ *Certaines associations sont impossibles par construction*

Observation	Taille = Petit	Taille = Grand	Corpulence = Mince	Corpulence = Enveloppé
1	1	0	1	0
2	0	1	0	1
3	0	1	1	0

	P1	P2	P3	P4	P5	P6	P7	P8
1	1	1	1	1	0	0	0	0
2	0	1	1	0	0	0	0	0
3	1	0	0	0	1	1	0	0
4	0	0	0	1	0	0	0	0
5	0	0	0	0	1	1	1	0
6	0	0	1	0	1	0	0	0
7	0	0	0	0	0	0	0	1

PASSAGE EN FORME DISJONCTIVE COMPLÈTE

- **Catégoriel, qualitatif, discret :** type marché, entreprises, taux, appartenance, …

	Marché
c_1	Part.
c_2	Autre
c_3	Part.
c_4	Part.
c_5	Entr.



	P	E	A
c_1	1		
c_2			1
c_3	1		
c_4	1		
c_5		1	

- **Continu, quantitatif :** virement, âge, température, consommation, pourcentage, …

	Dom
c_1	1100
c_2	0
c_3	2200
c_4	800
c_5	3800



	d0	d1	d2	d3	d4
c_1			1		
c_2	1				
c_3				1	
c_4		1			
c_5					1

CRITÈRES D'ÉVALUATION DES RÈGLES D'ASSOCIATION

SUPPORT

- il représente la fiabilité.
- mesure la fréquence à laquelle une règle associative particulière est vraie dans les données.
- **Sup(F1->F2) =P(F1 ∩ F2).**
- Plus le support est élevé, plus la règle est courante et donc plus fiable.

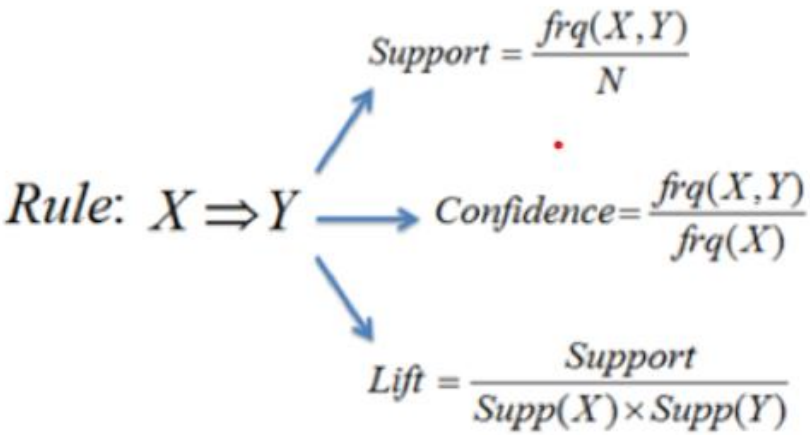
CONFIANCE

- elle représente la précision de la règle et peut être vue comme la probabilité conditionnelle
- **Conf(F1->F2)=P(F2| F1).**
- Plus la confiance est élevée, plus la règle est fiable.

LIFT

- Le lift mesure la force de la relation entre l'antécédent et le conséquent par rapport à leur occurrence indépendante
- **lift(F1 ->F2) =P(F2 | F1) / P(F2) = Conf(F1->F2)/support(F2)**

- Un lift > 1 Indique une corrélation positive
- Un lift de 1 indique une corrélation nulle
- Un lift < 1 Indique une corrélation négative.



CRITÈRES D'ÉVALUATION DES RÈGLES D'ASSOCIATION

SUPPORT

- ✓ indicateur de « fiabilité »
- ✓ probabilité absolue P(X U Y)
- ✓ ||X U Y||/ ||BD|| = % de transactions vérifiant la règle

CONFIANCE

- ✓ Indicateur de « précision »
- ✓ probabilité conditionnelle P(Y/X)
- ✓ ||X U Y||/||X|| = % de transactions vérifiant l'implication

Règle d'association :
(R1): p1 → p2

sup(R1) = 2 : en termes absolus
ou ***sup***(R1) = 2 / 6 = 33% : en termes relatifs

Conf(R1) = ***sup***(R1) / ***sup***(antécédant R1)
= ***sup***(p1 → p2) / ***sup***(p1) = 2 / 4 = 50 %

=(2/6)/ (4/6) = 2/4 = 50%

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

CRITÈRES D'ÉVALUATION DES RÈGLES D'ASSOCIATION

Règle d'association :
p1 → p2

SUPPORT

- ✓ indicateur de « **fiabilité** »
- ✓ probabilité absolue :

  P(X U Y)
- ✓ ||X U Y||/ ||BD|| = %
  de transactions vérifiant la règle

CONFIANCE

- ✓ Indicateur de « **précision** »
- ✓ probabilité conditionnelle :

  P(Y/X)
- ✓ ||X U Y||/||X|| = %
  de transactions vérifiant l'implication

sup(R1) = 2 : en termes absolus
ou ***sup***(R1) = 2 / 6 = 33% : en termes relatifs

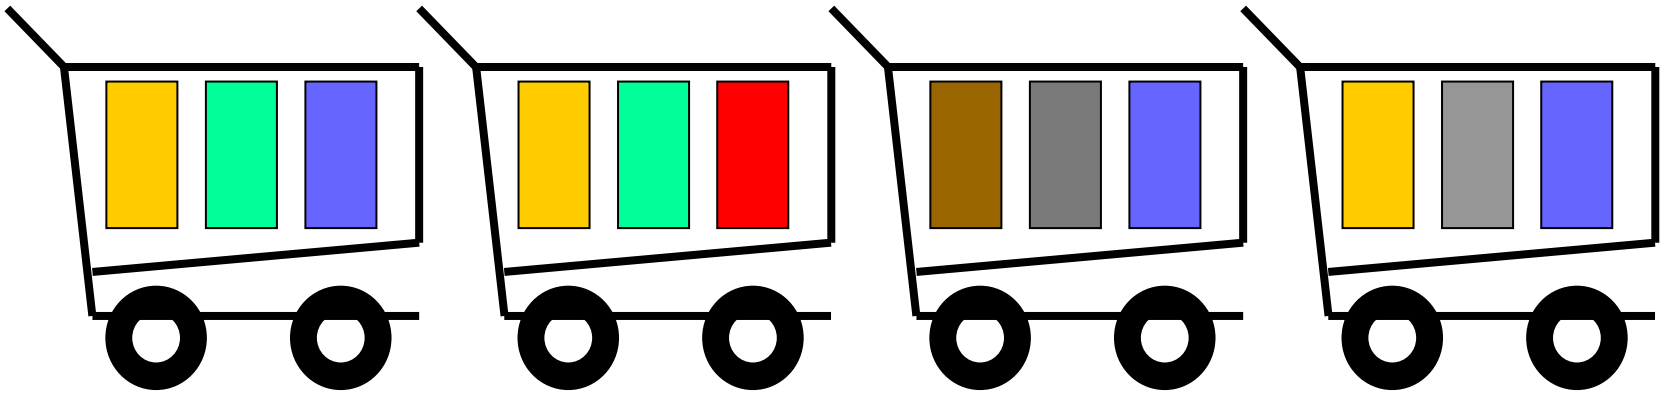
Conf(R1) = ***sup***(R1) / ***sup***(antécédant R1)
= ***sup***(p1 → p2) / ***sup***(p1) = 2 / 4 = 50 %

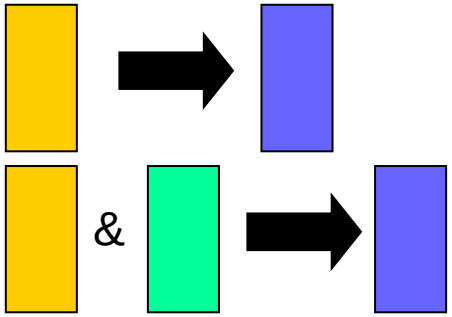
Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



« Bonne » règle = règle avec un support et une confiance élevée

Exemple 1 : ANALYSE DU PANIER DE LA MÉNAGÈRE



Règle	Support	Confiance
	2/4	2/3
	1/4	1/2

Exemple 2: ANALYSE DES TICKETS

{"crème"} ? {"pain"}



ID	PRODUITS
1	pain, crème, eau
2	crème
3	pain, crème, vin
4	eau
5	crème, eau

Support = Prob. (crème et pain) :

$$\text{Sup} = \frac{\text{nom(tran.contenant crème et pain)}}{\text{nom_total(tran.)}} = \frac{2}{5} = 0.4$$

Confiance = Prob(crème et pain / crème) :

$$\text{Conf} = \frac{\text{nom(tran. contenant crème et pain)}}{\text{nom(tran. contenant crème)}} = \frac{2}{4} = 0.5 = \frac{\text{sup(crème et pain)}}{\text{sup(crème)}}$$

Exemple 3: consolidation des notions SUPPORT / CONFIANCE

« **Si** pour un individu, la variable A = X_a, la variable B = X_b, etc, **alors**, dans 80% des cas, la variable Z = X_z, cette configuration se rencontrant pour 30 % des individus »

- *La valeur de 80% est appelée indice de confiance*
- *La valeur de 30% est appelée indice de support*

- l'indice de confiance de B → E : 3 / 4
- l'indice de support de B → E : 3 / 5

T26	A	B	C	D	E
T1245	B	C	E	F	
T156	B	E			
T2356	A	B	D		
T145	C	D			

- Dans l'exemple précédent, on a :

- indice de confiance de l'association C → B est 2/3

- indice de support = 2/5.

- Or, probabilité (B) = 0.8, B est présent dans presque tous les tickets de caisse.
- Cette probabilité est supérieure à l'indice de confiance de

C → B, ce qui fait que l'on ne gagne rien à utiliser la règle

C → B pour prédire B.

- Si l'on suppose aléatoirement qu'un ticket de caisse contient B, on n'a qu'1 chance / 5 de se tromper, contre 1 chance / 3 en appliquant la règle C → B.

DÉMARCHE D'EXTRACTION DES RÈGLES D'ASSOCIATION

Paramètres : Fixer un degré d'exigence sur les règles à extraire

✓ Support min. (exp. 2 transactions)

✓ Confiance min. (exp. 75%)



L'idée est surtout de contrôler (limiter) le nombre de règles produites

Démarche : Construction en deux temps

✓ **recherche des itemsets fréquents (support >= support min.)**

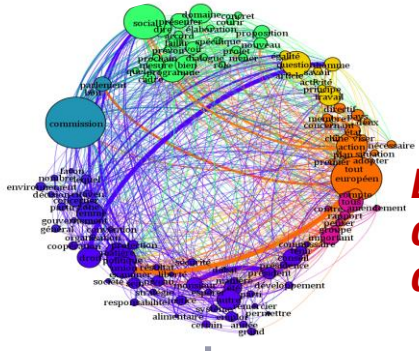
✓ **à partir des itemsets fréquents, produire les règles (conf. >= conf. min.)**

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

Quelques définitions :

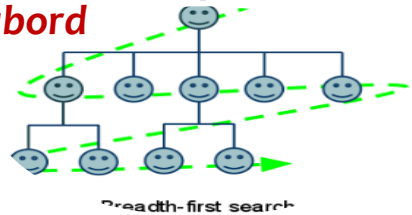
- item = produit
- itemset = ensemble de produits (ex. {p1,p3})
- sup(itemset) = nombre de transactions d'apparition simultanée des produits (ex. sup{p1,p3} = 4)
- card(itemset) = nombre de produits dans l'ensemble (ex. card{p1,p3} = 2)

INDUCTION DE REGLES ASSOCIATIVES

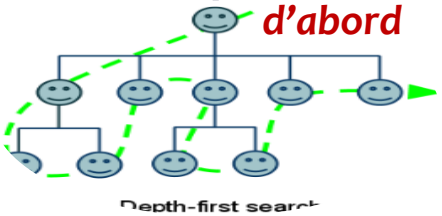


Entrepôts de données

Parcours en Largeur d'abord



Parcours en Profondeur d'abord



- FP-growth
- Eclat
- **Apriori**
- Partition

ALGORITHME APRIORI [AGRAWAL94]

Première passe :

- ✓recherche des 1-ensembles fréquents
- ✓un compteur par produits

L'algorithme génère un candidat de taille k à partir de deux candidats de taille k-1 différents par le dernier élément

- ✓procédure apriori-gen

Passe k :

- ✓comptage des k-ensemble fréquents candidats
- ✓sélection des bons candidats

APRIORI – FRÉQUENTS ITEMSETS

```
L1 = { frequent 1-ensemble } ;
for (k = 2 ; Lk-1 ≠ ∅ ; k++) do
        {
        Ck = apriori-gen(Lk-1); // Generate new candidates
        foreach transactions t ∈ DB do
                { // Counting
                Ct = { subset(Ck, t) }; // get subsets of t candidates
                foreach c ∈ Ct do c.count++;
                }
        Lk = { c ∈ Ck  |c.count >= minsup } ; // Filter candidates
        }
F = {Lk} ;
```

RECHERCHE DES ITEMSETS FRÉQUENTS

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

Combinaisons possibles

$C_4^1 = 4$ ← Itemsets de card = 1

$C_4^2 = 6$ ← Itemsets de card = 2

$C_4^3 = 4$ ← Itemsets de card = 3

$C_4^4 = 1$

$\Sigma = 15 = 2^4 - 1$

...

Cas général : 2^J-1 !!



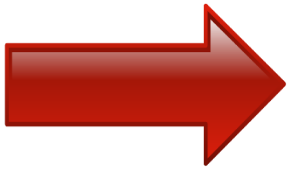
Réduire l'exploration en éliminant certaines pistes

SIMULATION



On va prendre la valeur du Support minimal = **3**

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



1-Itemsets	Support
{p1}	4
{p2}	3
{p3}	5
{p4}	1

L1 = { {p1}, {p2}, {p3} }



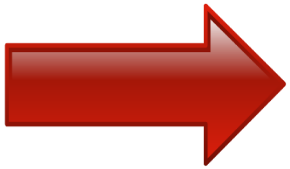
C2 = { {p1,p2}, {p1,p3}, {p2,p3} }

SIMULATION



On va prendre le Support minimal = 3

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



2-Itemsets	Support
{p1,p2}	2
{p1,p3}	4
{p2,p3}	3

L2 = { {p1,p3}, {p2,p3} }

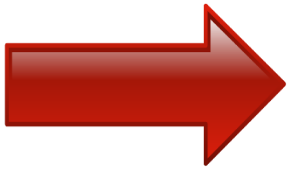
C3 = { {p1,p2 ,p3} }

SIMULATION



On va prendre le Support minimal = 3

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1



3-Itemsets	Support
{p1,p2, p3}	2

$L_3 = \emptyset$

$C_4 = \emptyset$

F = { {p1}, {p2}, {p3}, {p1,p3}, {p2,p3} }

SIMULATION



On va prendre le pourcentage de la confiance minimale = **65%**

Caddie	p1	p2	p3	p4
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	0	1	0
5	0	1	1	0
6	0	0	0	1

{p1,p3}

p1→p3 : confiance = 4/4 = **100 %**

p3→p1 : confiance = 4/5 = **80 %**



{p2,p3}

p2→p3 : confiance = 3/3 = **100 %**

p3→p2 : confiance = 3/5 = **60 %**



MESURE D'INTÉRÊT : *LIFT D'UNE RÈGLE*

- L'amélioration apportée par une règle, par rapport à une réponse au hasard est appelée « **lift** » et vaut :

lift (règle) = confiance (règle) / p (résultat)

= p (condition et résultat) / [p (condition) x p (résultat)]

- Le lift est une bonne mesure de performance de la règle d'association.
- Le lift est la confiance de la règle divisée par la valeur espérée de la confiance.

Interprétation du lift :

- Un lift supérieur à **1** : Indique une corrélation positive
- Un lift de **1** indique une corrélation nulle
- Un lift inférieur à **1** : Indique une corrélation négative

T26	A	B	C	D	E
T1245	B	C	E	F	
T156	B	E			
T2356	A	B	D		
T145	C	D			

lift (C → B) = **5/6 < 1** ✗

lift (B → C) = **6/5 > 1** ✓

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

TICKET 1
Farine
Sucre
Lait



Farine → Sucre	**Sucre → Farine**
Sucre → Lait	**Lait → Sucre**
Lait → Farine	**Farine → Lait**

Les n **items** sont :
I={Farine, Sucre, Lait, Œuf, Chocolat, Thé}

Critère d'extraction des règles
A partir d'un ensemble T de transactions, trouver toutes les règles :
avec un support ***sup > S_{min}*** *et une confiance* ***conf> C_{min}*** *où* S_{min} *et* C_{min} sont des seuils fixés a priori par l'utilisateur

Algorithme proposé par Agrawal et Srikant.



ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

- ✓ Le principe de l'algorithme est de rechercher l'ensemble L_1 de tous les items apparaissant dans au moins **S_{min} x m** transactions.
- ✓ Puis, parmi C_2 qui est le produit cartésien de L_1 avec lui-même, on construit l'ensemble L_2 de tous les couples d'items apparaissant dans au moins **S_{min} x m** transactions.
- ✓ L'algorithme s'arrête quand L_k est vide.

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2
Sucre	3

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2
Sucre	3
Lait	1

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2
Sucre	3
Lait	1
Œuf	3

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2
Sucre	3
Lait	1
Œuf	3
Chocolat	3

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2
Sucre	3
Lait	1
Œuf	3
Chocolat	3
Thé	1

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2
Sucre	3
Lait	1
Œuf	3
Chocolat	3
Thé	1

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C1

item1	nombre
Farine	2 ✓
Sucre	3 ✓
Lait	1 ✗
Œuf	3 ✓
Chocolat	3 ✓
Thé	1 ✗

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre
Farine	Sucre	2
Farine	Œuf	
Farine	Chocolat	
Sucre	Œuf	
sucre	Chocolat	
Œuf	Chocolat	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre
Farine	**Sucre**	**2**
Farine	**Œuf**	
Farine	**Chocolat**	
Sucre	**Œuf**	
sucre	**Chocolat**	
Œuf	**Chocolat**	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre
Farine	Sucre	2
Farine	Œuf	1
Farine	Chocolat	
Sucre	Œuf	
sucre	Chocolat	
Œuf	Chocolat	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre
Farine	Sucre	2
Farine	Œuf	1
Farine	Chocolat	1
Sucre	Œuf	
sucre	Chocolat	
Œuf	Chocolat	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre
Farine	Sucre	2
Farine	Œuf	1
Farine	Chocolat	1
Sucre	Œuf	2
sucre	Chocolat	
Œuf	Chocolat	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre
Farine	Sucre	2
Farine	Œuf	1
Farine	Chocolat	1
Sucre	Œuf	2
sucre	Chocolat	2
Œuf	Chocolat	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre
Farine	Sucre	2
Farine	Œuf	1
Farine	Chocolat	1
Sucre	Œuf	2
Sucre	Chocolat	2
Œuf	Chocolat	3

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

On décide de retenir un taux de support de 30%



Construction de C2

item1	item2	nombre	
Farine	Sucre	2	✓
Farine	Œuf	1	✗
Farine	Chocolat	1	✗
Sucre	Œuf	2	✓
Sucre	Chocolat	2	✓
Œuf	Chocolat	3	✓

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C3

item1	item2	item3	nombre
Farine	**Sucre**	**Œuf**	
Farine	**Sucre**	**Chocolat**	
Sucre	**Œuf**	**Chocolat**	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C3

item1	item2	item3	nombre
Farine	**Sucre**	**Œuf**	**1**
Farine	**Sucre**	**Chocolat**	
Sucre	**Œuf**	**Chocolat**	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de **30%**



Construction de C3

item1	item2	item3	nombre
Farine	Sucre	Œuf	1
Farine	Sucre	Chocolat	1
Sucre	Œuf	Chocolat	

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C3

item1	item2	item3	nombre
Farine	Sucre	Œuf	1
Farine	Sucre	Chocolat	1
Sucre	Œuf	Chocolat	2

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

TICKET 1
Farine
Sucre
Lait

TICKET 2
Œuf
Sucre
Chocolat

TICKET 3
Farine
Œuf
Sucre
Chocolat

TICKET 4
Œuf
Chocolat
Thé

On décide de retenir un taux de support de 30%



Construction de C3

item1	item2	item3	nombre
Farine	Sucre	Œuf	1 ✗
Farine	Sucre	Chocolat	1 ✗
Sucre	Œuf	Chocolat	2 ✓

L'ensemble L des sous-ensembles fréquents est l'union des ensembles $L_1,\dots L_K$:

L1={Farine, Sucre, Oeuf, Chocolat}

L2={(Farine,Sucre), (Sucre,Oeuf), (Sucre,Chocolat), (Oeuf,Chocolat)}

L3={(Sucre, Oeuf, Chocolat)}

ETUDE DE CAS DE RECHERCHE D'ASSOCIATIONS INTÉRESSANTES

- ✓ Pour chaque ensemble fréquent on construit des règles vérifiant la contrainte de seuil de confiance.

- ✓ Un algorithme simple pour produire des règles à partir d'un sous-ensemble fréquent *f* *est de considérer tous les sous ensembles* possibles *g de f et de produire la règle g-> (f-g) si* la condition sur la confiance est vérifiée.

- ✓ Alors on commence par les règles ayant un seul conséquent, puis sur les règles retenues on génère les règles ayant deux conséquents.



L'ensemble L des sous-ensembles fréquents est l'union des ensembles $L_1,\dots L_K$:

L1={Farine, Sucre, Oeuf, Chocolat}
L2={(Farine,Sucre), (Sucre,Oeuf), (Sucre,Chocolat), (Oeuf,Chocolat)}
L3={(Sucre, Oeuf, Chocolat)}

TABLEAU DES RÈGLES

Sous-ensemble	Règle	Support	Confiance
Farine, Sucre	Farine → Sucre	2/4	2/2
	Sucre → Farine	2/4	2/3
Sucre, Œuf	Sucre → Œuf	2/4	2/3
	Œuf → Sucre	2/4	2/3
Sucre, Chocolat	Sucre → Chocolat	2/4	2/3
	Chocolat → Sucre	2/4	2/3
Œuf, Chocolat	Œuf → Chocolat	3/4	3/3
	Chocolat → Œuf	3/4	3/3
Sucre, Œuf, Chocolat	Sucre → Œuf + Chocolat	2/4	2/3
	Œuf + Chocolat → Sucre	2/4	2/3
	Œuf → Sucre + Chocolat	2/4	2/3
	Sucre + Chocolat → Œuf	2/4	2/2
	Chocolat → Sucre + Œuf	2/4	2/3
	Sucre + Œuf → Chocolat	2/4	2/3

TABLEAU DES RÈGLES

Sous-ensemble	Règle	Support	Confiance
Farine, Sucre	Farine → Sucre	2/4	**2/2**
	Sucre → Farine	2/4	2/3
Sucre, Œuf	Sucre → Œuf	2/4	2/3
	Œuf → Sucre	2/4	2/3
Sucre, Chocolat	Sucre → Chocolat	2/4	2/3
	Chocolat → Sucre	2/4	2/3
Œuf, Chocolat	Œuf → Chocolat	3/4	**3/3**
	Chocolat → Œuf	3/4	**3/3**
Sucre, Œuf, Chocolat	Sucre → Œuf + Chocolat	2/4	2/3
	Œuf + Chocolat → Sucre	2/4	2/3
	Œuf → Sucre + Chocolat	2/4	2/3
	Sucre + Chocolat → Œuf	2/4	**2/2**
	Chocolat → Sucre + Œuf	2/4	2/3
	Sucre + Œuf → Chocolat	2/4	2/3

TABLEAU DES RÈGLES INTÉRESSANTES

Sous-ensemble	Règle	Confiance	Lift
Farine, Sucre	Farine → Sucre	2/2	**4/3**
Œuf, Chocolat	Œuf → Chocolat	3/3	**4/3**
Œuf, Chocolat	Chocolat → Œuf	3/3	**4/3**
Sucre, Œuf, Chocolat	Sucre + Chocolat → Œuf	2/4	**2/2**



On a retenu les règles ayant une confiance égale à 1 et un lift supérieur à 1

EXERCICE GUIDÉ

Supposons que vous avez des données de transactions pour un magasin de vêtements et que vous souhaitez trouver des règles associatives pour suggérer des produits connexes à vos clients. Vous avez rassemblé des données pour un mois et vous avez identifié les produits suivants : T-shirts, Jeans, Chaussures et Vestes.

Transaction ID	Articles achetés
1	T-shirt, Jean, Chaussures
2	T-shirt, Chaussures
3	T-shirt, Jean, Chaussures
4	T-shirt, Jean
5	Jean, Chaussures, Veste
6	T-shirt, Jean, Chaussures, Veste
7	T-shirt, Chaussures
8	T-shirt, Jean, Veste
9	T-shirt, Jean, Chaussures
10	T-shirt, Jean

EXERCICE GUIDÉ

Dans un premier temps, nous allons convertir nos données en une forme binaire (plus lisible pour la suite).

Transaction ID	T-shirt	Jean	Chaussures	Veste
1	1	1	1	0
2	1	0	1	0
3	1	1	1	0
4	1	1	0	0
5	0	1	1	1
6	1	1	1	1
7	1	0	1	0
8	1	1	0	1
9	1	1	1	0
10	1	1	0	0

EXERCICE GUIDÉ : Support

Nous pouvons maintenant utiliser l'algorithme Apriori. Nous allons définir un support minimum de 30 % et une confiance de 60 %.

1. La première étape consiste à calculer le support de chaque item. Si le support de certains items est inférieur au seuil minimum, on peut les supprimer dès cette étape pour éviter de faire des calculs sur les itemset qui en découlent.

support(item) = nombre de transactions contenant l'item / nombre total de transactions

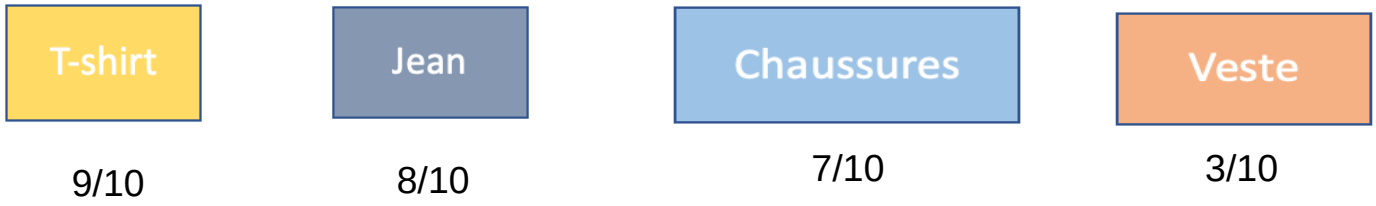
Exemple: support(T-shirt) = nombre de transactions contenant "T-shirt" / nombre total de transactions= 9 / 10 = 0.9

Construction de C1

Article	Support
T-shirt	0.9
Jean	0.8
Chaussures	0.7
Veste	0.3

support minimum 30%

Pas de suppression lors de cette étape de notre exemple

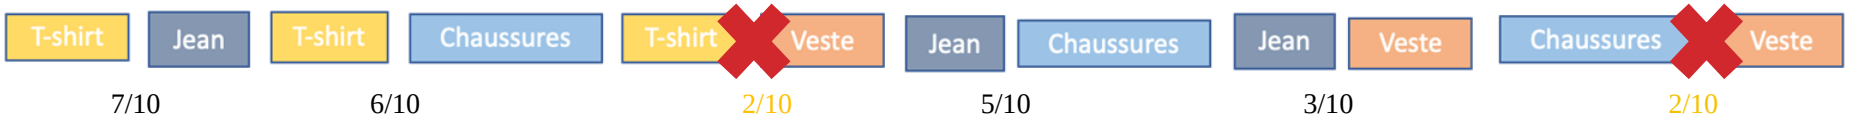


EXERCICE GUIDÉ : Support

Nous pouvons construire les itemsets du niveau suivant et calculer leur support

Construction de C2

2-Itemsets	Support
{T-shirt,Jean}	0,7
{T-shirt,Chaussure}	0,6
{T-shirt,Veste}	0,2
{Jean,Chaussure}	0,5
{Jean,Veste}	0,3
{Chaussure,Veste}	0,2



On constate que deux itemsets n'ont pas atteint un support suffisant, donc nous les supprimons avant de passer à la création des itemsets du niveau suivant

Construction de C3

3-Itemsets	Support
{T-shirt,Jean,Chaussure}	0,4



4/10

support minimum 30%

EXERCICE GUIDÉ : Confiance

La première phase de l'algorithme est terminée, nous avons identifié tous les itemsets fréquents.

2. Nous calculons maintenant la confiance de chaque règle d'association qui en découle et nous ne conservons que celles qui satisfont notre critère de confiance.

Conf(F1->F2)=P(F2| F1)

T-shirt Jean

T-shirt Chaussures

Jean Chaussures

Jean Veste

- conf(T-shir->Jean)=7/9 =0,7 conf(Jean->T-shir)=7/8=0,8
- conf(T-shir->Chaussures)=6/9=0,6 conf(Chaussures->T-shir)=6/7=0,8
- conf(Jean->Chaussures)=5/8 =0,6 conf(Chaussures->Jean)=5/7=0,7
- ✖ conf(Jean->Veste)=3/8 =0.375 conf(Veste->Jean)=3/3=1

T-shirt Jean Chaussures

- ✖ conf(Jean,T-shirt->Chaussures)=4/7 =0.5

conf(Jean,Chaussures->T-shirt)=4/5 0.8

conf(T-shirt,Chaussures->Jean)=4/6=0.66

confiannce minimum 60%

EXERCICE GUIDÉ : lift

L'algorithme apriori a terminé son travail et nous a permis de créer **9 règles** d'association.

Pour apprécier plus finement ces règles, on peut encore calculer le lift , il caractérise l'intérêt de la règle, sa force.

Un **lift supérieur à 1** indique qu'**il existe bien un lien entre les 2 éléments**

On calcule le lift et on classe les règles de décision en fonction de sa valeur

On a : lift(F1 ->F2) =P(F2 | F1) / P(F2) = Conf(F1->F2)/support(F2)

- Lift (T-shir->Jean)=conf(T-shir->Jean)/support(Jean)= 0.7/0.8=0.87
- Lift (Jean->T-shir)=0.8/0.9=0.8
- Lift (Jean->Chaussures)=0.6/0.7=0.8
- Lift (Chaussures->Jean)= 0.7/0.8=0.8
- **Lift(Veste->Jean) = 1/0.8 =1.25 >1**
- Lift(T-shir->Chaussures)=0.6/0.7=0.8
- Lift(Chaussures->T-shir)=0.8/0.9=0.87
- Lift(Jean,Chaussures->T-shirt)=0.8/0.9=0.87
- Lift(T-shirt,Chaussures->Jean)=0.6/0.8=0.75