DATA MINING

RÉGRESSION *LINÉAIRE*

Mohamed Heny SELMI – Wiem Trabelsi

Data mining © esprit 2020-21

DEUX FAMILLES DE TECHNIQUES

Méthodes Non Supervisées

- Analyse en Composantes Principales
  ACP
- Méthodes des Centres Mobiles
  K-means
- Classification Ascendante Hiérarchique
  CAH
- Règles Associatives

Méthodes *Supervisées*

- **Arbres de Décisions**
- **Analyse Linéaire Discriminante**
- **Régression Linéaire**
- **Régression Logistique**
- **Réseaux de Neurones**
- **Séparateur à Vaste Marge**
  SVM

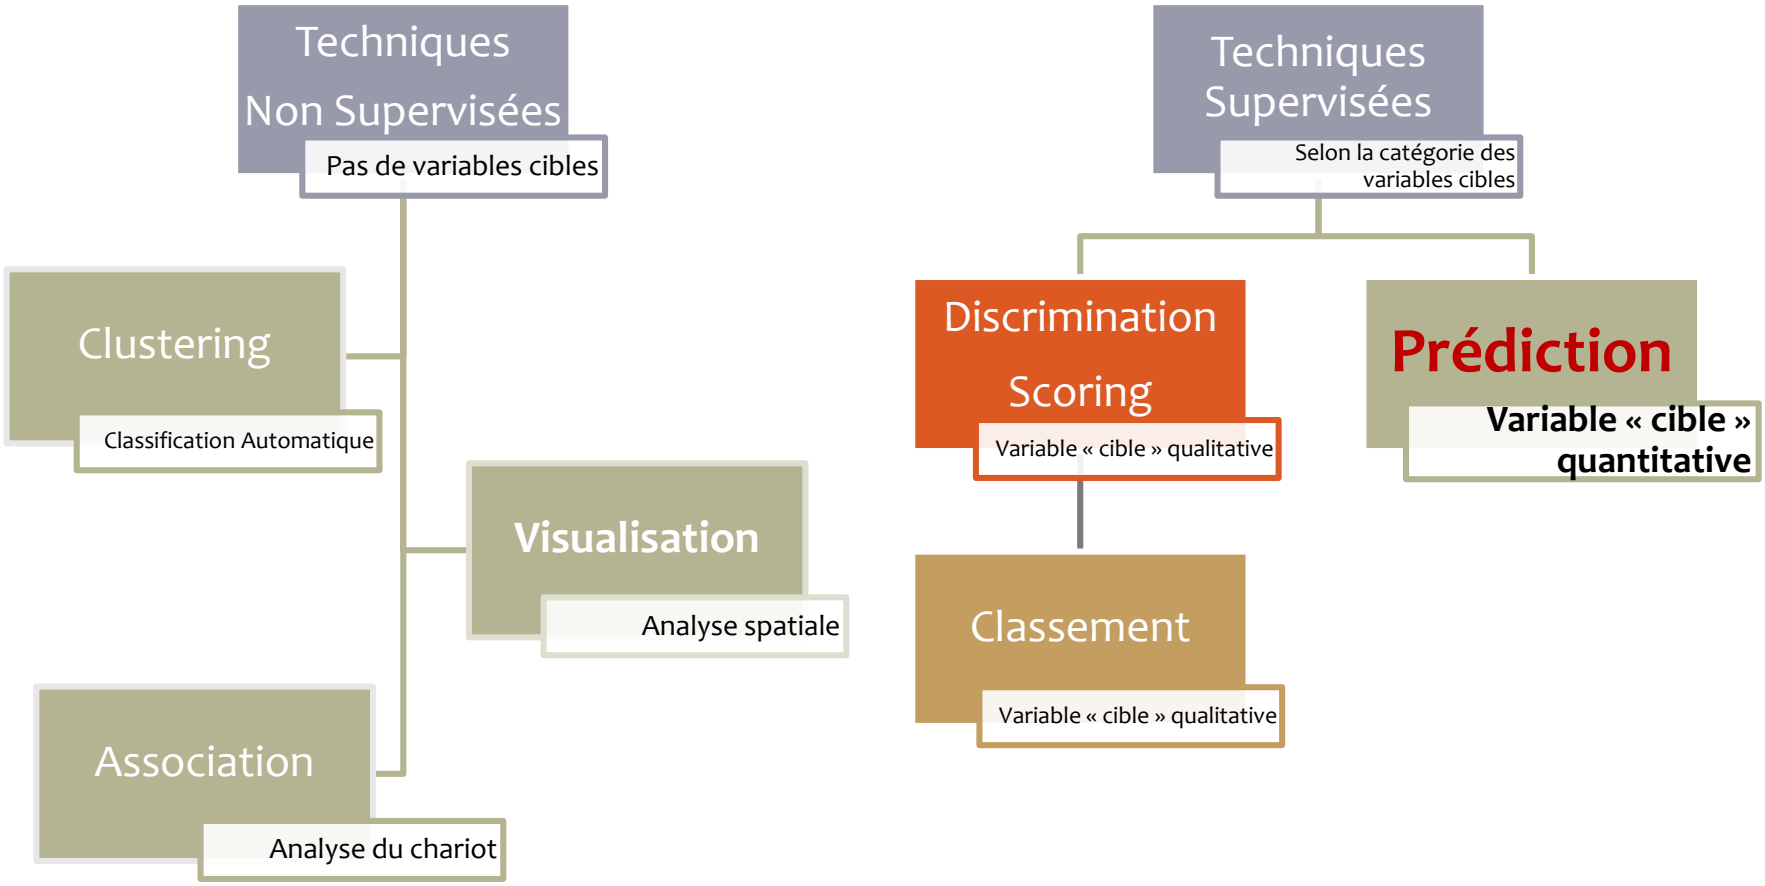
MÉTHODES SUPERVISÉES

$$Y \overset{?}{=} f(X_1, X_2, X_3, \ldots\ldots\ldots\ldots, X_n)$$



Arbre de décision	• Modèle à base de règles logiques • ordre de séparation de données
Régression Linéaire	• **Modèle à base de coefficients estimateurs** • **Modèle complet, avec sélection de variables, individus atypiques**
SVM	• Classifieur Linéaire ou Classifieur Non Linéaire
Régression Logistique	• Modèle à base de coefficients classifieurs
Analyse Linéaire Discriminante	• Modèle de Scoring
Réseaux de Neurones	• Modèle d'Apprentissage Artificielle
KNN	• Modèle de classement informé

TYPES D'APPLICATIONS



OBJECTIFS

- Trouver le meilleur modèle (relation) liant Y et X
- Qualifier la liaison par rapport à chaque X_i
- Raisonner selon un modèle de Prédiction : globale ou réduit

$$R(X_1, X_2, \ldots\ldots\ldots\ldots, X_n) = Y$$

PROBLÉMATIQUE – ENTREPÔT D'APPRENTISSAGE

Modèle Véhicule	X1 (Frs) Prix	X2 (cm3) Cylindrée	X3 (kW) Puissance	X4 (kg) Poids	Y (l/100km) Consommation
Daihatsu Cuore	11600	846	32	650	5,7
Suzuki Swift 1.0 GLS	12490	993	39	790	5,8
Fiat Panda Mambo L	10450	899	29	730	6,1
VW Polo 1.4 60	17140	1390	44	955	6,5
Opel Corsa 1.2i Eco	14825	1195	33	895	6,8
Subaru Vivio 4WD	13730	658	32	740	6,8
Toyota Corolla	19490	1331	55	1010	7,1
Ferrari 456 GT	285000	5474	325	1690	21,3
Mercedes S[illegible]0	183900	5987	300	2250	18,7
Maserati G[illegible]li GT	92500	2789	209	1485	[illegible]5
Opel Ast[illegible].6i 16	25[illegible]00	1597	74	10[illegible]0	7,4
Peuge[illegible]6 X[illegible]108	223[illegible]	1761	74	[illegible]00	9,0
Renau[illegible]2.2 V	36[illegible]00	2[illegible]65	10[illegible]	1[illegible]0	11,7
Seat I[illegible]a[illegible]0 GTI	22500	1983	85	1075	9,5
VW G[illegible].0 GTI	31580	1984	85	1155	9,5
Citroen ZX Volcane	28750	1998	89	1140	8,8
Fiat Tempra 1.6 Liberty	22600	1580	65	1080	9,3
Fort Escort 1.4i PT	20300	1390	54	1110	8,6
Honda Civic Joker 1.4	19900	1396	66	1140	7,7
Volvo 850 2.5	39800	2435	106	1370	10,8
Ford Fiesta 1.2 Zetec	19740	1242	55	940	6,6
Hyundai Sonata 3000	38990	2972	107	1400	11,7
Lancia K 3.[illegible] LS	50800	2958	150	1[illegible]	11,9
Mazda Ha[illegible]back V	36200	2497	122	1330	10,8
Mitsubishi Galant	31990	1998	66	1300	7,6
Opel Omega 2.5i V6	47700	2496	125	1670	11,3
Peugeot 806 2.0	36950	1998	89	1560	10,8
Nissan Primera 2.0	26950	1997	92	1240	9,2
Seat Alhambra 2.0	36400	1984	85	1635	11,6
Toyota Previa salon	50900	2438	97	1800	12,8
Volvo 960 Kombi aut	49300	2473	125	1570	12,7

$f(X_1, X_2, X_3, \ldots, X_n) = Y$



f(Prix, Cylindrée, Puissance, Poids) = Consommation

PROBLÉMATIQUE - ENTREPÔT D'APPRENTISSAGE

$f(X_1, X_2, X_3, \ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots\ldots, X_n) = Y$

	MT	RG	PRIX	BR	INV	PUB	FV	TPUB	VENTES
2	369	118	59	9	17	89	177	225	5439
3	476	138	71	18	4	63	279	206	5149
4	432	152	73	16	-50	16	245	309	4704
5	418	135	79	35		74	270	83	5036
6	383	104	60	21	-4	32	201	298	4110
7	554	138	81	20		93	324	161	6180
8	320	147	66	15	0	48	154	305	4888
9	268	129	57	29		51	166	263	4290
10	359	106	69	27	71	74	196	414	5397
11	461	132	82	27	-18	91	267	170	5272
12	420	136	70	10	8	91	213	429	4989
13	536	111	73	27	128	74	296	273	5927
14	311	143	67	22	-25	27	181	60	4033
15	511	142	74	21	27	75	301	345	6124
16	332	140	60	11	61	21	180	247	4708
17	336	136	60	25	-30	40	213	328	4627
18	394	146	59	13	143	52	209	407	4872
19	415	148	69	8	47	29	207	80	5151



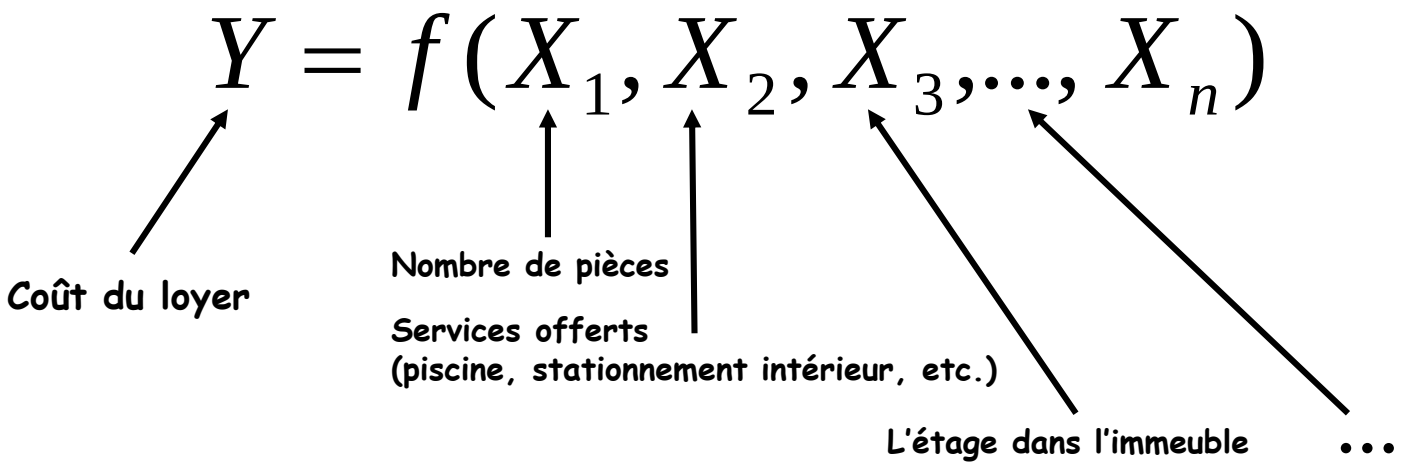
$f(MT, RG, PRIX, BR, INV, PIB, FV, TPUB) = VENTES$

OBJECTIFS DE LA RÉGRESSION LINÉAIRE

- ✓ Le modèle de prédiction ***LINEAIRE*** consiste à estimer la valeur d'une variable **continue** (dite « à expliquer »,« cible », en fonction de la valeur **d'un certain nombre d'autres variables** (dites « explicatives », « de contrôle », ou « indépendantes »)

- ✓ Cette variable « cible » peut être par exemple :
  - le poids : en fonction de la taille
  - le prix d'un appartement : en fonction de sa superficie, de l'étage et du quartier
  - la consommation d'électricité : en fonction de la température extérieure et de l'épaisseur de l'isolation

EXEMPLE DE RÉGRESSION LINÉAIRE



Estimer le coût du loyer en fonction :

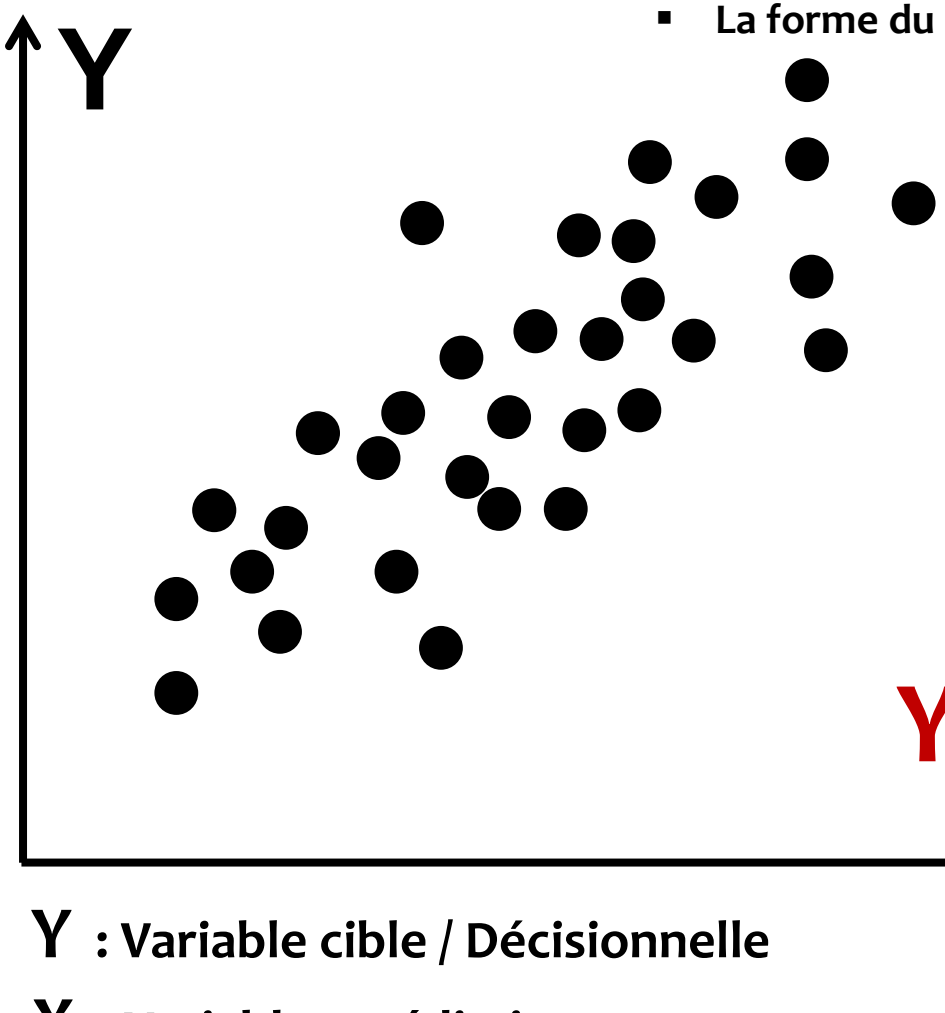
du nombre de pièces,

du niveau d'étage dans l'immeuble,

des services offerts ...

REPRÉSENTATION PAR UN NUAGE DE POINTS

- N couples de points (x_i, y_i)
- X_i : quantitatives
- Y : quantitative
- La forme du nuage de points suit la nature des variables





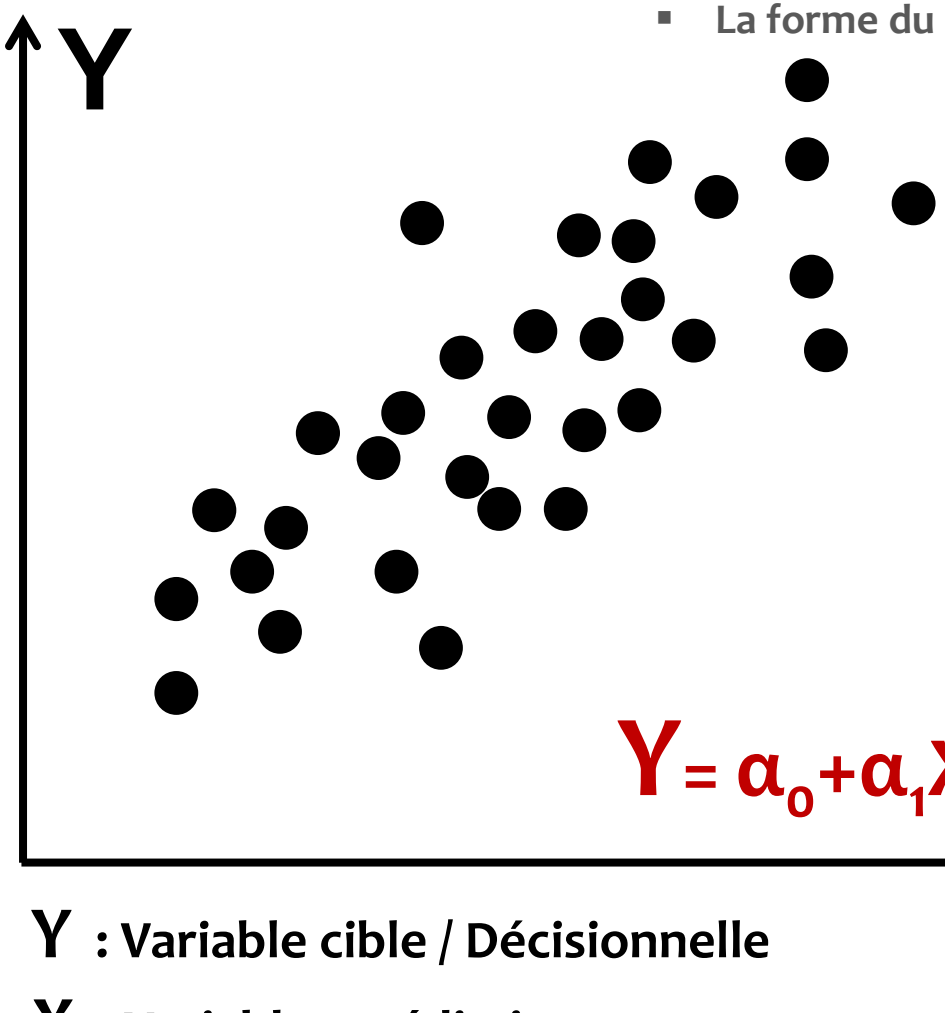
$$Y = f(X_1, X_2, \ldots\ldots, X_n)$$

Y : Variable cible / Décisionnelle

X_i : Variables prédictives

REPRÉSENTATION PAR UN NUAGE DE POINTS

- N couples de points (X_i, y_i)
- Xi : quantitatives
- Y : quantitative
- La forme du nuage de points suit la nature des variables





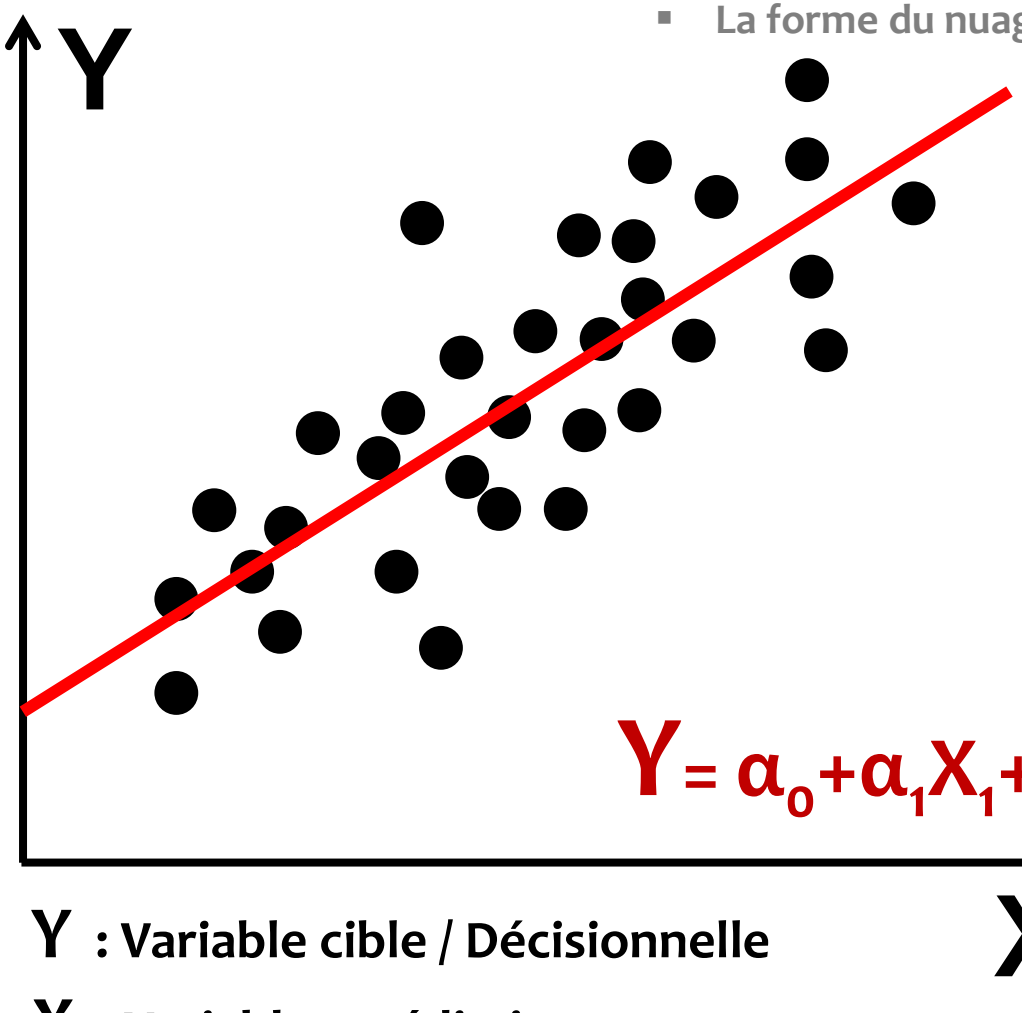
$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n$$

Y : Variable cible / Décisionnelle

X_i : Variables prédictives

REPRÉSENTATION PAR UN NUAGE DE POINTS

- N couples de points (X_i, y_i)
- Xi : quantitatives
- Y : quantitative
- La forme du nuage de points suit la nature des variables





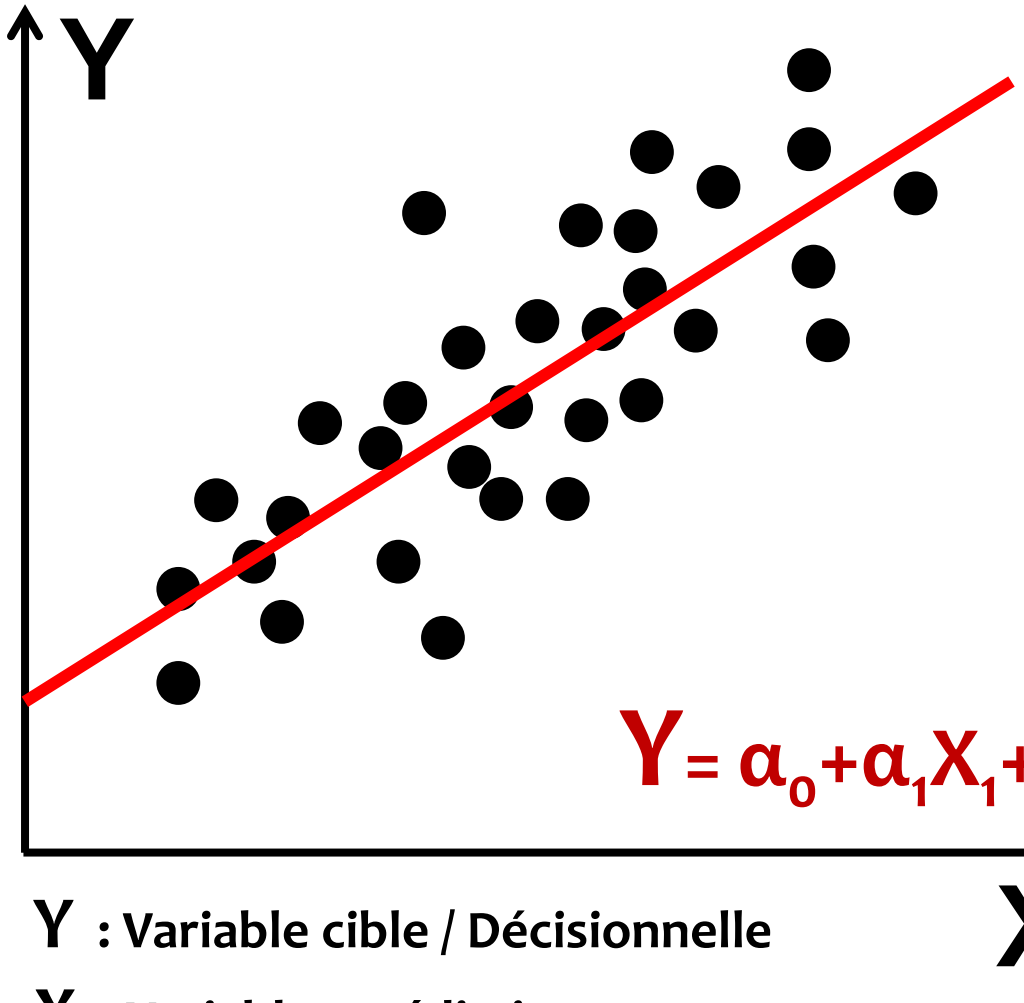
$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n$$

Y : Variable cible / Décisionnelle

X_i : Variables prédictives

REPRÉSENTATION PAR UN NUAGE DE POINTS

- La droite qui représente mieux les données
- La droite qui résume le mieux le nuage des points
- La droite qui explique mieux les Y en fonctions des X_i





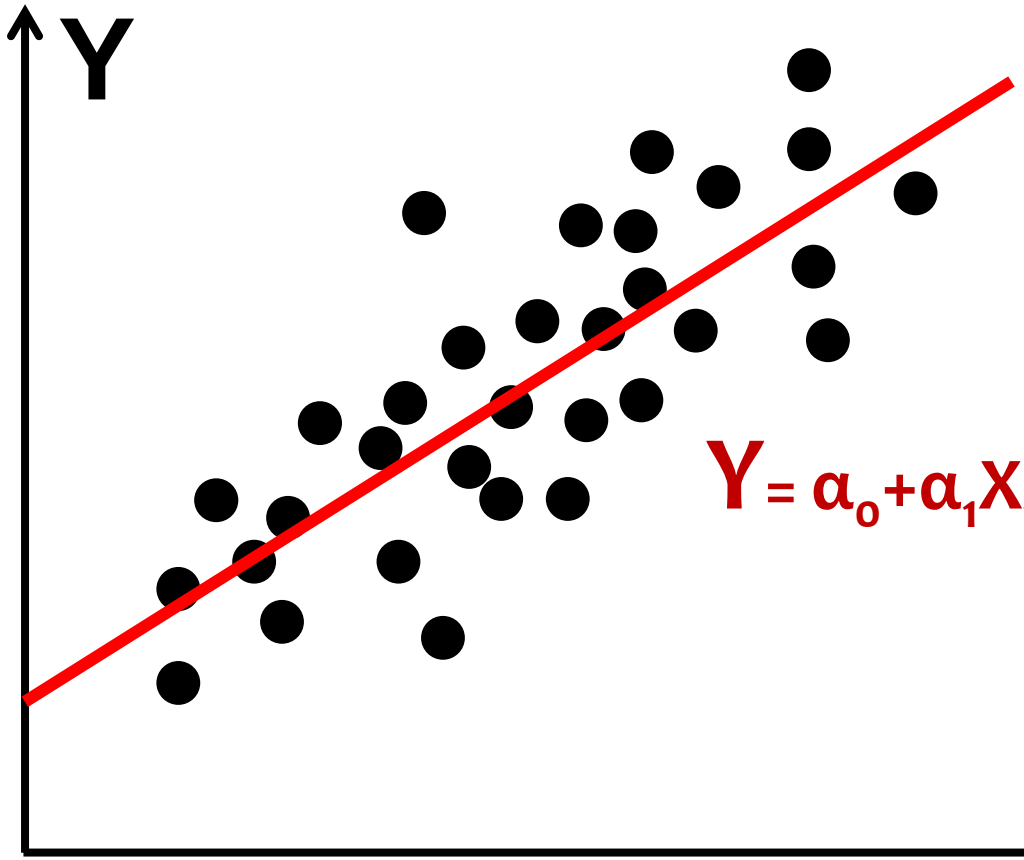
$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n$$

Y : Variable cible / Décisionnelle

X_i : Variables prédictives

MÉTHODES DES MOINDRES CARRÉS

- La droite qui représente mieux les données
- La droite qui résume le mieux le nuage des points
- La droite qui explique mieux les Y en fonctions des X_i



$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n + \varepsilon$$



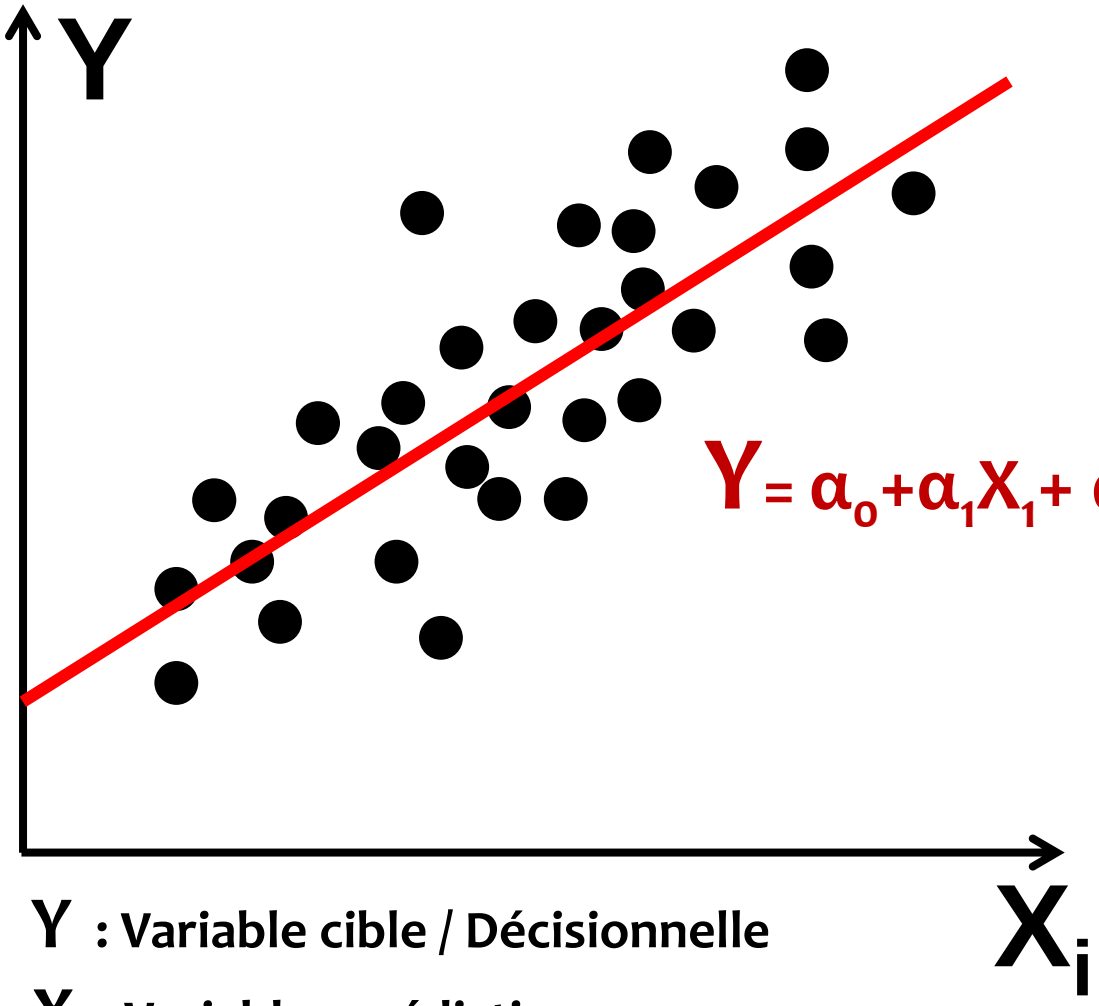
Y : Variable cible / Décisionnelle

X_i : Variables prédictives

MÉTHODES DES MOINDRES CARRÉS



- la droite dont les points du nuage sont en moyenne les plus proches
- la droite qui passe à la plus faible distance de chaque point du nuage



$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n + \varepsilon$$



Y : Variable cible / Décisionnelle

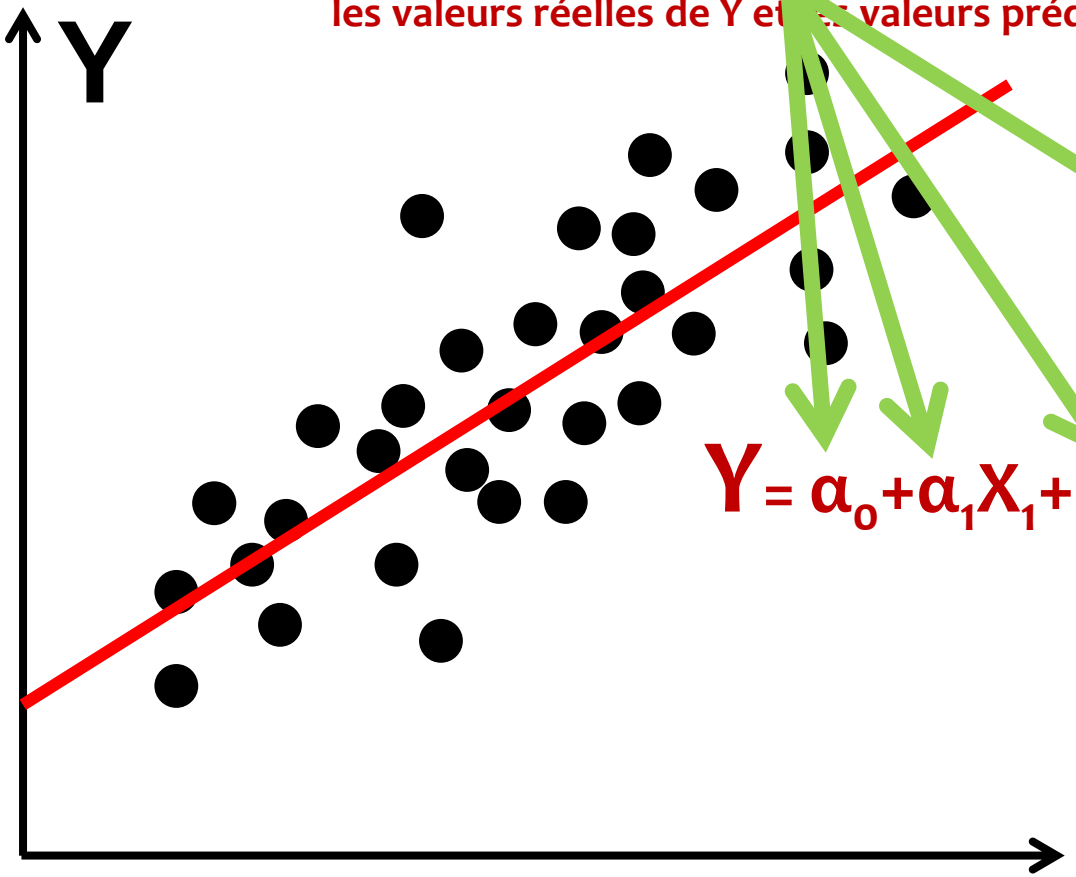
X_i : Variables prédictives

MÉTHODES DES MOINDRES CARRÉS



- la droite dont les points du nuage sont en moyenne les plus proches
- la droite qui passe à la plus faible distance de chaque point du nuage

- Trouver les valeurs des α_i qui minimise la somme des carrés des écarts entre les valeurs réelles de Y et les valeurs prédites avec le modèle de prédiction



$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n + \varepsilon$$



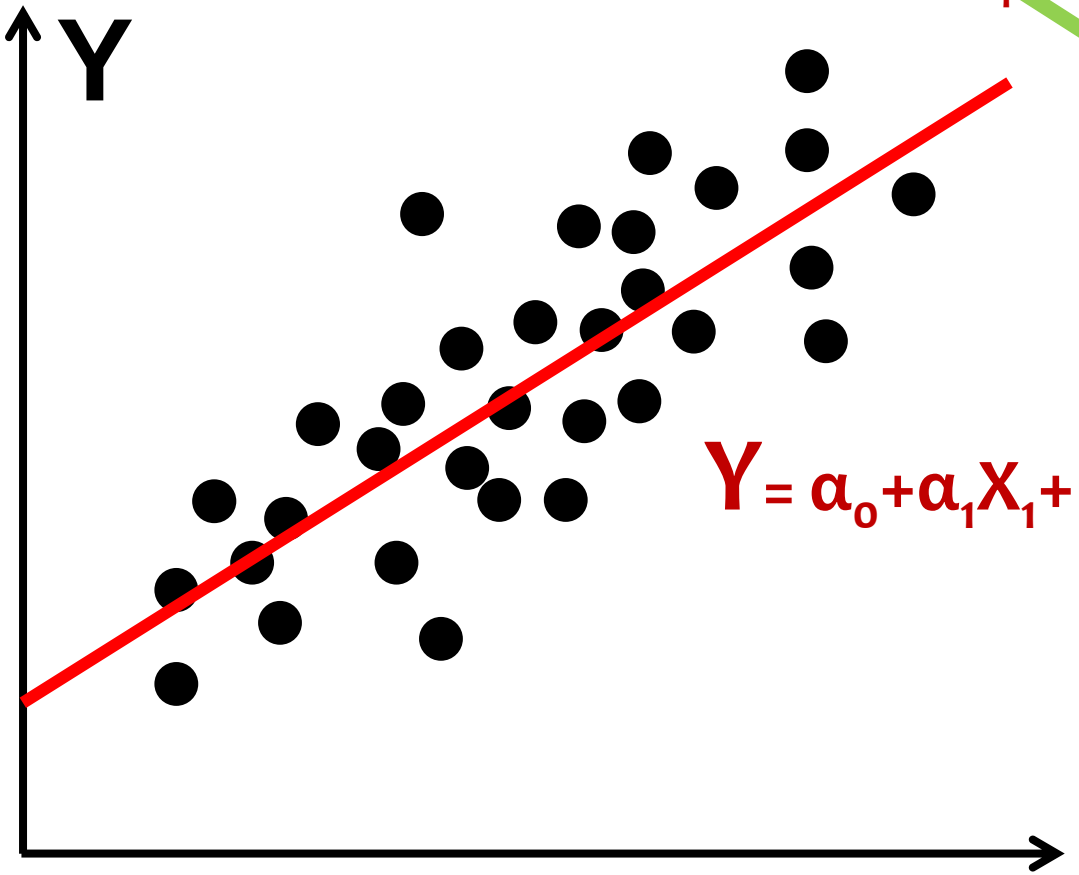
Y : Variable cible / Décisionnelle

X_i : Variables prédictives

MÉTHODES DES MOINDRES CARRÉS



- la droite dont les points du nuage sont en moyenne les plus proches
- la droite qui passe à la plus faible distance de chaque point du nuage
- **Trouver les valeurs des α_i qui minimise la somme des carrés des écarts entre les valeurs réelles de Y et les valeurs prédites avec le modèle de prédiction**



$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n + \varepsilon$$

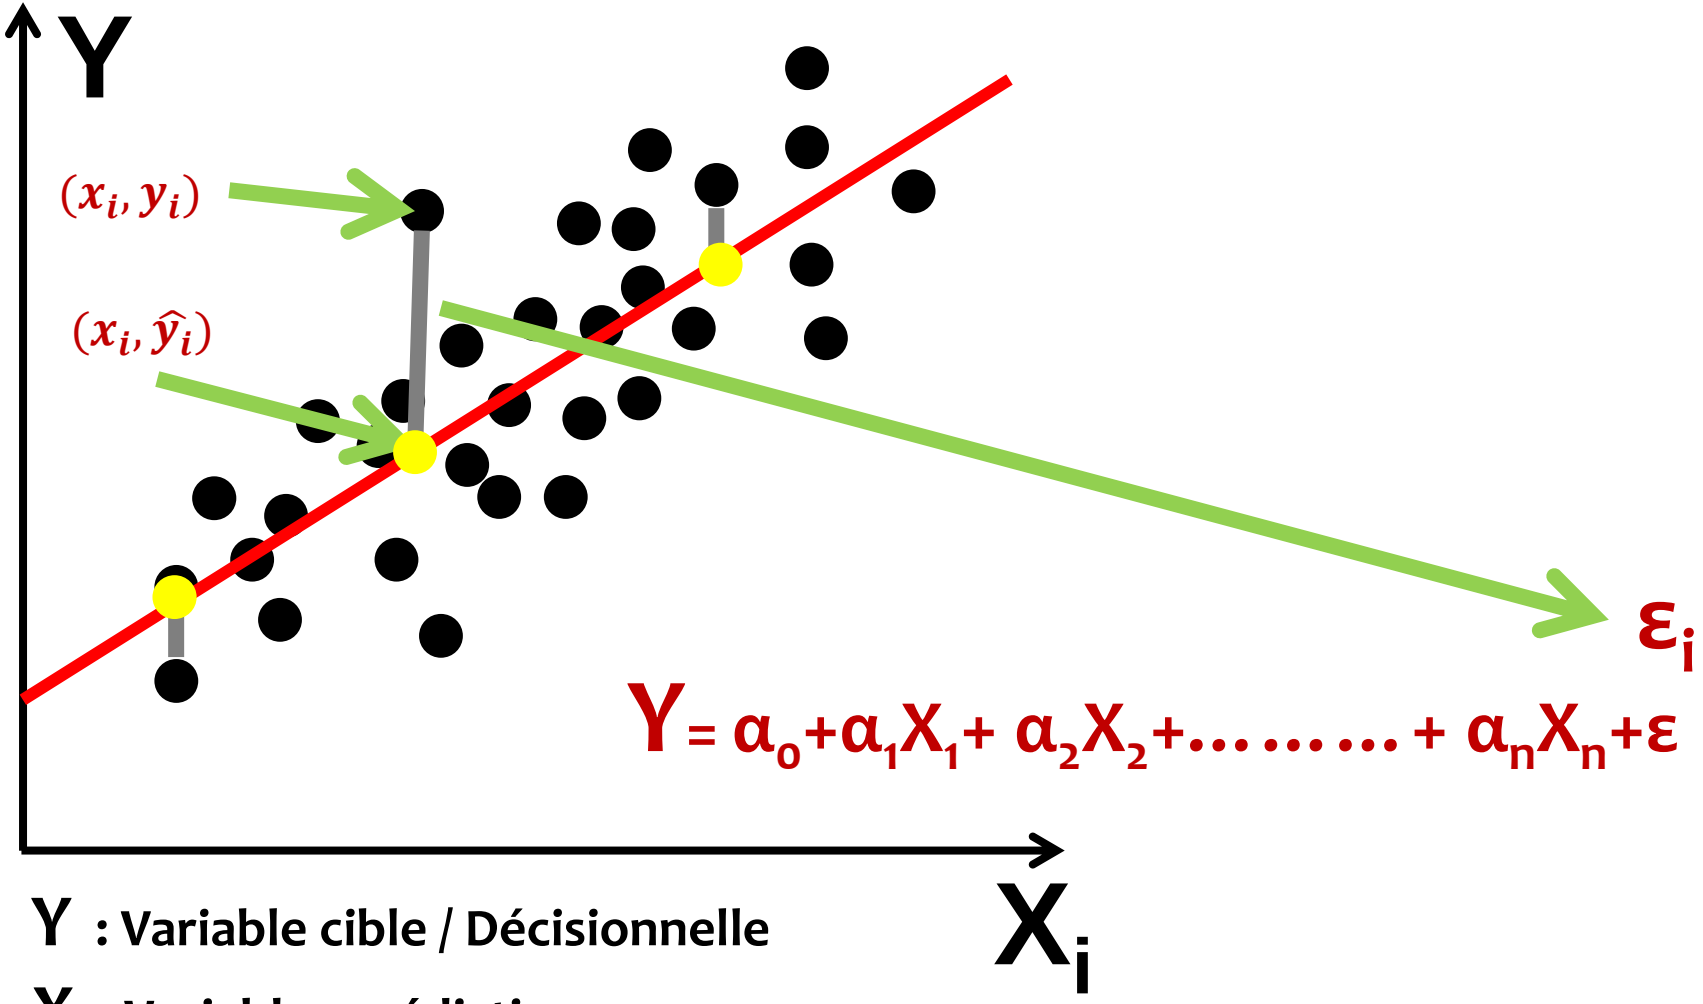


Y : Variable cible / Décisionnelle

X_i : Variables prédictives

ESTIMATION PAR LA MÉTHODE DES MOINDRES CARRÉS

- **La distance d'un point à la droite est la distance verticale entre l'ordonnée du point observé (x_i, y_i) et l'ordonnée du point correspondant sur la droite $(x_i, \hat{y}_i)$**
- Trouver les valeurs des α_i qui minimise la somme des carrés des écarts entre les valeurs réelles de Y et les valeurs prédites avec le modèle de prédiction



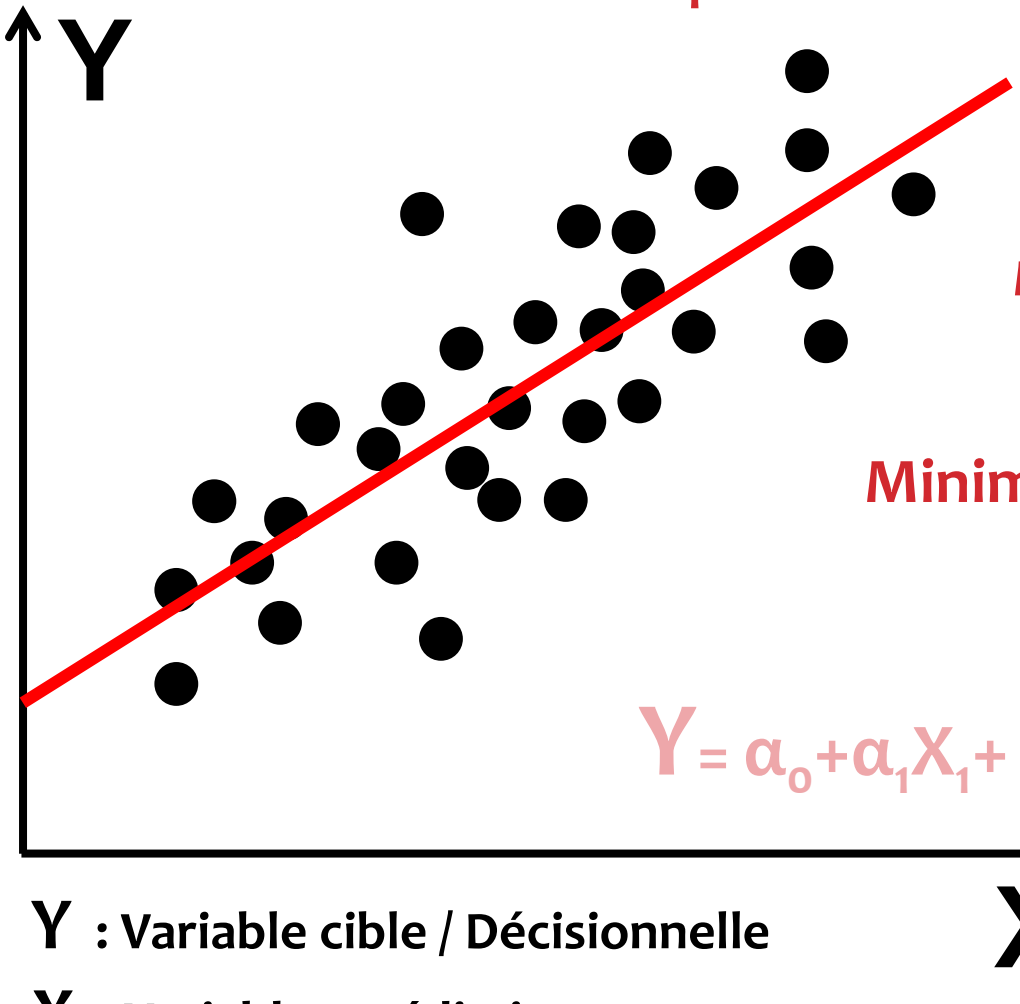
Y : Variable cible / Décisionnelle

X_i : Variables prédictives

OBJECTIFS DE LA MÉTHODE DES MOINDRES CARRÉS



- La distance d'un point à la droite est la distance verticale entre l'ordonnée du point observé (x_i, y_i) et l'ordonnée du point correspondant sur la droite $(x_i, \hat{y}_i)$
- **Minimiser les ε_i**



Minimiser $\varepsilon_i = y_i - \hat{y}_i$

Minimiser $\sum \varepsilon_i^2 = \sum (y_i - \hat{y}_i)^2$

$$Y = \alpha_0 + \alpha_1 X_1 + \alpha_2 X_2 + \ldots\ldots\ldots + \alpha_n X_n + \varepsilon$$

Y : Variable cible / Décisionnelle

X_i : Variables prédictives

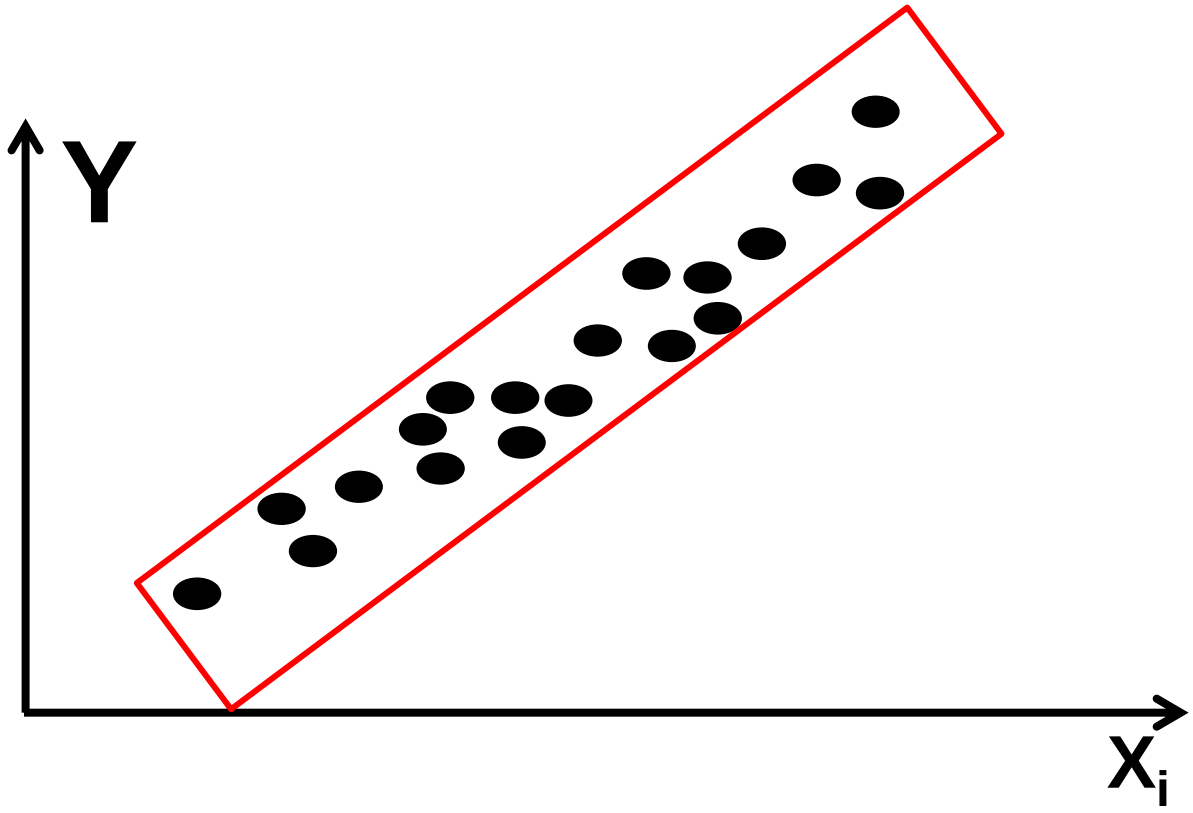
DIAGRAMME QUANTILE-QUANTILE QQ-PLOT

le diagramme Quantile-Quantile ou diagramme Q-Q ou Q-Q plot est un outil graphique permettant d'évaluer la pertinence de l'ajustement d'une distribution donnée à un modèle théorique.

Le terme de quantile-quantile provient du fait que l'on compare la position de certains quantiles dans la population observée avec leur position dans la population théorique.

Le diagramme quantile-quantile permet également de comparer deux distributions que l'on estime semblables.

DIAGRAMME QUANTILE-QUANTILE QQ-PLOT



RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

VENTES
5439
5149
4704
5036
4110
6180
4888
4290
5397
5272
4989
5927
4033
6124
4708
4627
4872
5151

	MT	RG	PRIX	BR	INV	PUB	FV	TPUB
2	369	118	59	9	17	89	177	225
3	476	138	71	18	4	63	279	206
4	432	152	73	16	-50	16	245	309
5	418	135	79	35	142	74	270	83
6	383	104	60	21	-45	32	201	298
7	554	138	81	20	42	93	324	161
8	320	147	66	15	10	48	154	305
9	268	129	57	29	89	51	166	263
10	359	106	69	27	71	74	196	414
11	461	132	82	27	-18	91	267	170
12	420	136	70	10	8	91	213	429
13	536	111	73	27	128	74	296	273
14	311	143	67	22	-25	27	181	60
15	517	142	74	27	27	75	307	345
16	332	140	60	11	61	21	180	247
17	336	136	60	25	-30	40	213	328
18	394	146	59	13	143	52	209	407
19	415	148	69	8	47	29	207	80

LES TERMES DE L'ÉQUATION

$$y_i = \alpha_0 + \alpha_1 x_{1i} + \alpha_2 x_{2i} + \ldots + \alpha_p x_{pi} + \varepsilon_i$$

$i^{\text{ème}}$ observation de Y

Terme constant

Influence de la variable X_1

Influence de la variable X_p

Résidu de la $i^{\text{ème}}$ observation

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

1

$$s = \sum \varepsilon_i^2 = \sum (y_i - \hat{y}_i)^2$$

$$= \sum (y_i - \alpha x_i - \alpha_0)^2$$

$$\frac{\partial s}{\partial \alpha} = 0 \; et \; \frac{\partial s}{\partial \alpha_0} = 0$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

1

$$\frac{\partial s}{\partial \alpha} = 0 \; et \; \frac{\partial s}{\partial \alpha_0} = 0$$

$$\sum x_i y_i - \alpha \sum x_i^{\,2} - \alpha_0 \, \bar{x} = 0$$

$$et \; \bar{y} - \alpha \bar{x} - \alpha_0 = 0$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

1

$$\sum x_i y_i - \alpha \sum x_i^{\,2} - \alpha_0 \bar{x} = 0$$

$$et\ \bar{y} - \alpha\bar{x} - \alpha_0 = 0$$

$$\hat{\alpha} = \frac{\sum (y_i - \bar{y})(x_i - \bar{x})}{\sum (x_i - \bar{x})^2}$$

$$\widehat{\alpha_0} = \bar{y} - \hat{\alpha}\bar{x}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

2

$$Y = X\,\alpha$$

$$X^t Y = X^t X\,\alpha$$

$$X^t Y = [X^t X]\,\alpha$$

$$[X^t X]^{-1} X^t Y = [X^t X]^{-1}\,[X^t X]\,\alpha$$

$$[X^t X]^{-1} X^t Y = \alpha$$

$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

2

$$Y = X\alpha$$
$$X^t Y = X^t X \alpha$$
$$X^t Y = [X^t X]\,\alpha$$
$$[X^t X]^{-1} X^t Y = [X^t X]^{-1}\,[X^t X]\,\alpha$$
$$[X^t X]^{-1} X^t Y = \alpha$$
$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

2

$$\begin{aligned} \boldsymbol{Y} &= \boldsymbol{X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= \boldsymbol{X^t X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= [\boldsymbol{X^t X}]\,\boldsymbol{\alpha} \\ [X^tX]^{-1}X^tY &= [X^tX]^{-1}\,[X^tX]\,\alpha \\ [X^tX]^{-1}X^tY &= \alpha \\ [X^tX]^{-1}X^tY &= \hat{\alpha} \end{aligned}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

2

$$Y = X\,\alpha$$
$$X^t Y = [\quad]\,\alpha$$
$$X^t Y = [\quad]\,\alpha$$
$$[X^t X]^{-1} X^t Y = [X^t X]^{-1}\,[X^t X]\,\alpha$$
$$[X^t X]^{-1} X^t Y = \alpha$$
$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

2

$$\begin{aligned} \boldsymbol{Y} &= \boldsymbol{X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= \boldsymbol{X^t X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= [\boldsymbol{X^t X}]\,\boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= [\boldsymbol{X^t X}]^{-1}\,[\boldsymbol{X^t X}]\,\boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= \boldsymbol{\alpha} \\ [X^t X]^{-1} X^t Y &= \hat{\alpha} \end{aligned}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

2

$$\begin{aligned} \boldsymbol{Y} &= \boldsymbol{X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= \boldsymbol{X^t X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= [\boldsymbol{X^t X}]\,\boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= [\boldsymbol{X^t X}]^{-1}\,[\boldsymbol{X^t X}]\,\boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= \boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= \hat{\boldsymbol{\alpha}} \end{aligned}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

2

$$\begin{aligned} \boldsymbol{Y} &= \boldsymbol{X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= \boldsymbol{X^t X}\,\boldsymbol{\alpha} \\ \boldsymbol{X^t Y} &= [\boldsymbol{X^t X}]\,\boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= [\boldsymbol{X^t X}]^{-1}\,[\boldsymbol{X^t X}]\,\boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= \boldsymbol{\alpha} \\ [\boldsymbol{X^t X}]^{-1}\boldsymbol{X^t Y} &= \hat{\boldsymbol{\alpha}} \end{aligned}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

3

Si on exige que ε ne contient plus de l'information X

$Y - X\alpha$ a pu absorber l'information des X contenue dans Y

Inter – Indépendance entre X et $Y - X\alpha$

X *et* $Y - X\alpha$ sont géométriquement orthogonaux

$$\langle X | Y - X\alpha \rangle = 0$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

3

- **Si on exige que ε ne contient plus de l'information X**
- **$Y - X\alpha$ a pu absorber l'information des X contenue dans Y**
- Inter – Indépendance entre X et $Y - X\alpha$
- X et $Y - X\alpha$ sont géométriquement orthogonaux
- $\langle X | Y - X\alpha \rangle = 0$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

3

- Si on exige que ε ne contient plus de l'information X
- $Y - X\alpha$ a pu absorber l'information des X contenue dans Y
- Inter – Indépendance entre X et $Y - X\alpha$
- X et $Y - X\alpha$ sont géométriquement orthogonaux
- $\langle X | Y - X\alpha \rangle = 0$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

3

- Si on exige que ε ne contient plus de l'information X
- $Y - X\alpha$ a pu absorber l'information des X contenue dans Y
- Inter – Indépendance entre X et $Y - X\alpha$
- X et $Y - X\alpha$ sont géométriquement orthogonaux

$$\langle X | Y - X\alpha \rangle = 0$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



- Si on exige que ε ne contient plus de l'information X
- $Y - X\alpha$ a pu absorber l'information des X contenue dans Y
- Inter – Indépendance entre X et $Y - X\alpha$
- X et $Y - X\alpha$ sont géométriquement orthogonaux
- $\langle X | Y - X\alpha \rangle = 0$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



$$\langle X | Y - X\alpha \rangle = 0$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

3

$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}[X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

3

$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**



$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$[X^tX]^{-1}X^tY = \hat{\alpha}$$

RECOURS À L' ÉCRITURE MATRICIELLE

$$\begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & x_{1,1} & \cdots & x_{1,p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1,n} & \cdots & x_{n,p} \end{bmatrix} \begin{bmatrix} \alpha_0 \\ \alpha_1 \\ \vdots \\ \alpha_p \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Entrepôt d'apprentissage

SI $\begin{bmatrix} \varepsilon_1 \\ \vdots \\ \varepsilon_n \end{bmatrix} \to 0$ **ALORS**

3

$$\langle X | Y - X\alpha \rangle = 0$$
$$X^t(Y - X\alpha) = 0$$
$$X^tY - X^tX\alpha = 0$$
$$X^tY = X^tX\alpha$$
$$X^tY = [X^tX]\alpha$$
$$[X^tX]^{-1}X^tY = [X^tX]^{-1}\,[X^tX]\,\alpha$$
$$[X^tX]^{-1}X^tY = \alpha$$
$$\boxed{[X^tX]^{-1}X^tY = \hat{\alpha}}$$

CARACTÉRISTIQUES DES COEFFICIENTS ESTIMATEURS

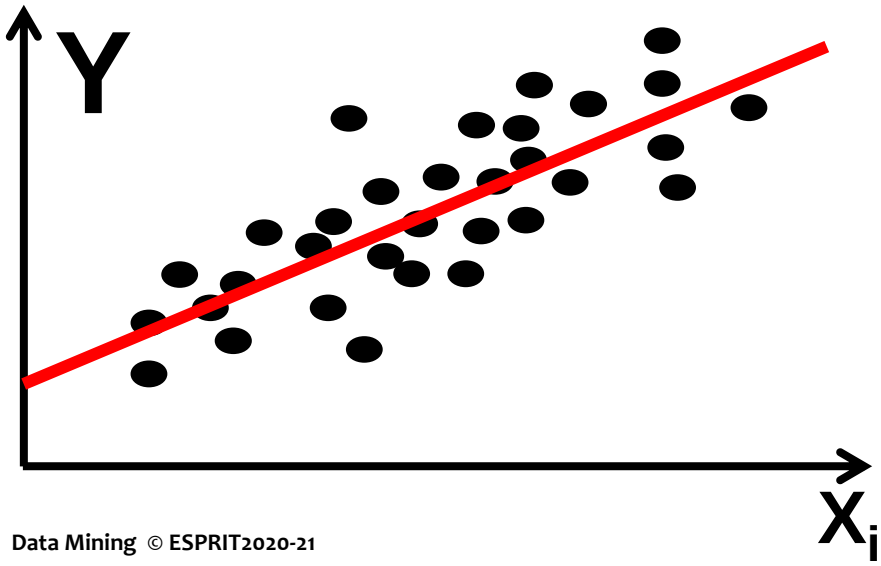
$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$

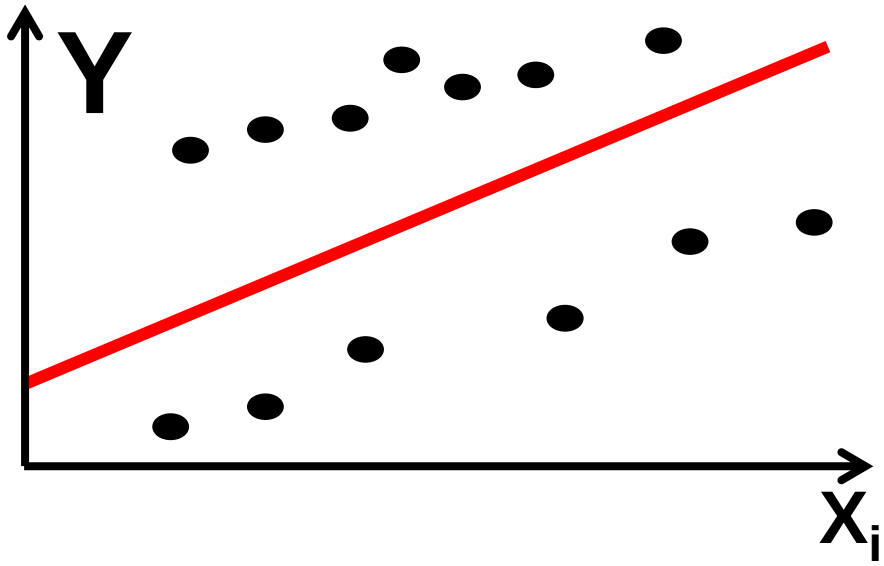
Les coefficients estimateurs sont d'autant plus précis que :

i. **La variance de l'erreur est faible :**
la droite de régression passe bien au milieu des points

ii. **La dispersion des X est forte :**
les X couvrent bien l'espace de représentation

$\sum \varepsilon_i^2 = \sum (y_i - \hat{y}_i)^2$ **est élevé !**





CARACTÉRISTIQUES DES COEFFICIENTS ESTIMATEURS

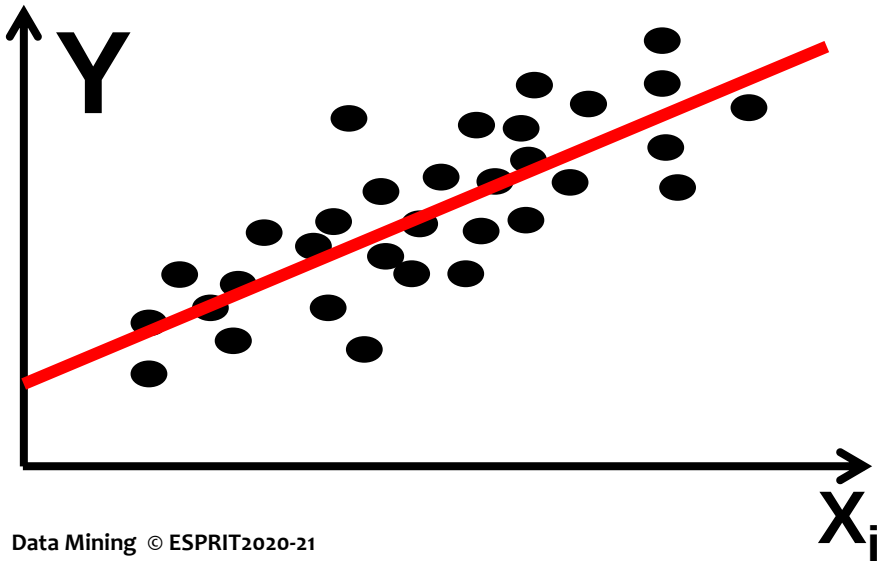
$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$

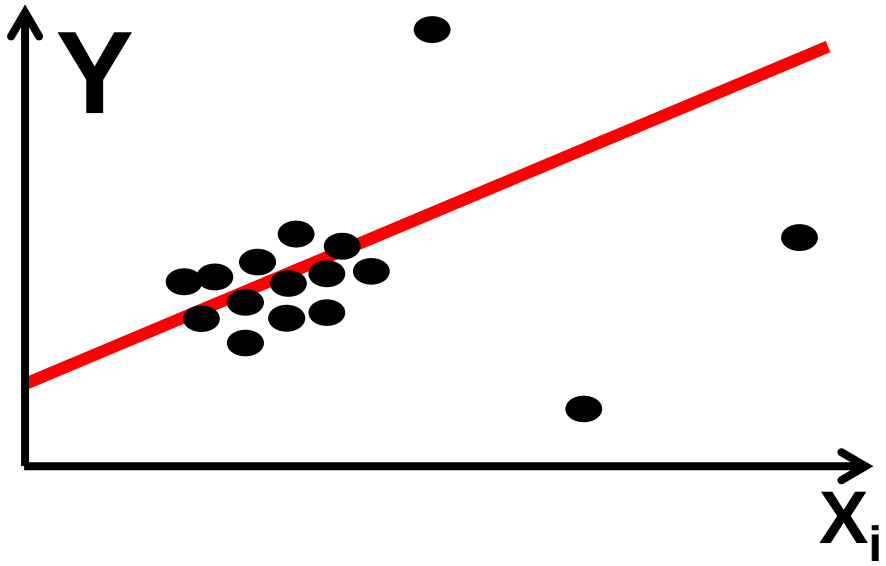
Les coefficients estimateurs sont d'autant plus précis que :

i. **La variance de l'erreur est faible :**
la droite de régression passe bien au milieu des points

ii. **La dispersion des X est forte :**
les X couvrent bien l'espace de représentation

$\sum(x_i - \bar{x})^2$ **est faible !**





MODÈLE GLOBAL À BASE DE COEFFICIENTS ESTIMATEURS

$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$

Y (l/100km) Consommation
5,7
5,8
6,1
6,5
6,8
6,8
7,1
21,3
18,7
14,5
7,4
9,0
11,7
9,5
9,5
8,8
9,3
8,6
7,7
10,8
6,6
11,7
11,9
10,8
7,6
11,3
10,8
9,2
11,6
12,8
12,7

=

X1 (Frs) Prix	X2 (cm3) Cylindrée	X3 (kW) Puissance	X4 (kg) Poids
11600	846	32	650
12490	993	39	790
10450	899	29	730
17140	1390	44	955
14825	1195	33	895
13730	658	32	740
19490	1331	55	1010
285000	5474	325	1690
183900	5987	300	2250
92500	2789	209	1485
25000	1597	74	1080
22350	1761	74	1100
36600	2165	101	1500
22500	1983	85	1075
31580	1984	85	1155
28750	1998	89	1140
22600	1580	65	1080
20300	1390	54	1110
19900	1396	66	1140
39800	2435	106	1370
19740	1242	55	940
38990	2972	107	1400
50800	2958	150	1550
36200	2497	122	1330
31990	1998	66	1300
47700	2496	125	1670
36950	1998	89	1560
26950	1997	92	1240
36400	1984	85	1635
50900	2438	97	1800
49300	2473	125	1570

×

$$\widehat{\alpha_1}$$
$$\widehat{\alpha_2}$$
$$\widehat{\alpha_3}$$
$$\widehat{\alpha_4}$$

MODÈLE GLOBAL À BASE DE COEFFICIENTS ESTIMATEURS

$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$

VENTES
5439
5149
4704
5036
4110
6180
4888
4290
5397
5272
4989
5927
4033
6124
4708
4627
4872
5151

=

	MT	RG	PRIX	BR	INV	PUB	FV	TPUB
1								
2	369	118	59	9	17	89	177	225
3	476	138	71	18	4	63	279	206
4	432	152	73	16	-50	16	245	309
5	418	135	79	35	142	74	270	83
6	383	104	60	21	-45	32	201	298
7	554	138	81	20	42	93	324	161
8	320	147	66	15	10	48	154	305
9	268	129	57	29	89	51	166	263
10	359	106	69	27	71	74	196	414
11	461	132	82	27	-18	91	267	170
12	420	136	70	10	8	91	213	429
13	536	111	73	27	128	74	296	273
14	311	143	67	22	-25	27	181	60
15	517	142	74	27	27	75	307	345
16	332	140	60	11	61	21	180	247
17	336	136	60	25	-30	40	213	328
18	394	146	59	13	143	52	209	407
19	415	148	69	8	47	29	207	80

×

$\widehat{\alpha_1}$
$\widehat{\alpha_2}$
$\widehat{\alpha_3}$

$\widehat{\alpha_8}$

MODÈLE GLOBAL À BASE DE COEFFICIENTS ESTIMATEURS

$$[X^t X]^{-1} X^t Y = \hat{\alpha}$$



VENTES
5439
5149
4704
5036
4110
6180
4888
4290
5397
5272
4989
5927
4033
6124
4708
4627
4872
5151

=

	MT	RG	PRIX	BR	INV	PUB	FV	TPUB
2	369	118	59	9	17	89	177	225
3	476	138	71	18	4	63	279	206
4	432	152	73	16	-50	16	245	309
5	418	135	79	35	142	74	270	83
6	383	104	60	21	-45	32	201	298
7	554	138	81	20	42	93	324	161
8	320	147	66	15	10	48	154	305
9	268	129	57	29	89	51	166	263
10	359	106	69	27	71	74	196	414
11	461	132	82	27	-18	91	267	170
12	420	136	70	10	8	91	213	429
13	536	111	73	27	128	74	296	273
14	311	143	67	22	-25	27	181	60
15	517	142	74	27	27	75	307	345
16	332	140	60	11	61	21	180	247
17	336	136	60	25	-30	40	213	328
18	394	146	59	13	143	52	209	407
19	415	148	69	8	47	29	207	80

×

$\widehat{\alpha_1}$
$\widehat{\alpha_2}$
$\widehat{\alpha_3}$

$\widehat{\alpha_8}$

CRITÈRES DE SÉLECTION DE VARIABLES PERTINENTES

AIC

Critère d'information d'Akaike

- la différence entre 2 fois le nombre de paramètres (k) deux fois la log-vraisemblance du modèle estimé.
- $$AIC = 2k - 2 \ln L$$

BIC

critère d'information Bayésien

- pénalité dépend de la taille de l'échantillon et pas seulement du nombre de paramètres
- $$AIB = -2 \ln L + k \ln N$$

EXEMPLE : CAS DE VENTES SEMESTRIELLES

Variable à expliquer :

VENTES = Ventes semestrielles

Variables explicatives :

MT = Marché total

RG = Remises aux grossistes

PRIX = Prix

BR = Budget de Recherche

INV = Investissement

PUB = Publicité

FV = Frais de ventes

TPUB = Total budget publicité de la branche

	A	B	C	D	E	F	G	H	I
1	MT	RG	PRIX	BR	INV	PUB	FV	TPUB	VENTES
2	369	118	59	9	17	89	177	225	5439
3	476	138	71	18	4	63	279	206	5149
4	432	152	73	16	-50	16	245	309	4704
5	418	135	79	35	142	74	270	83	5036
6	383	104	60	21	-45	32	201	298	4110
7	554	138	81	20	42	93	324	161	6180
8	320	147	66	15	10	48	154	305	4888
9	268	129	57	29	89	51	166	263	4290
10	359	106	69	27	71	74	196	414	5397
11	461	132	82	27	-18	91	267	170	5272
12	420	136	70	10	8	91	213	429	4989
13	536	111	73	27	128	74	296	273	5927
14	311	143	67	22	-25	27	181	60	4033
15	517	142	74	27	27	75	307	345	6124
16	332	140	60	11	61	21	180	247	4708
17	336	136	60	25	-30	40	213	328	4627
18	394	146	59	13	143	52	209	407	4872
19	415	148	69	8	47	29	207	80	5151

PREMIÈRE ÉTAPE

Model Summary

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.898[a]	.806	.752	256.29

a. Predictors: (Constant), Total publicité de la branche, Marché total, Remises aux grossistes, Budget de recherche, Investissements, Publicité, Prix, Frais de ventes

TPUB = Total budget publicité de la branche

Coefficients[a]

Model		Unstandardized Coefficients		t	Sig.
		B	Std. Error		
1	(Constant)	3129.231	641.355	4.879	.000
	MT	4.423	1.588	2.785	.009
	RG	1.676	3.291	.509	.614
	PRIX	-13.526	8.305	-1.629	.114
	BR	-3.410	6.569	-.519	.608
	INV	1.924	.778	2.474	.019
	PUB	8.547	1.826	4.679	.000
	FV	1.497	2.771	.540	.593
	TPUB	-2.15E-02	.401	-.054	.958

a. Dependent Variable: VENTES

MODÈLE COMPLET (SANS RESTRICTION DE VARIABLES)

Coefficients[a]

Model		Unstandardized Coefficients		t	Sig.
		B	Std. Error		
1	(Constant)	3129.231	641.355	4.879	.000
	MT	4.423	1.588	2.785	.009
	RG	1.676	3.291	.509	.614
	PRIX	-13.526	8.305	-1.629	.114
	BR	-3.410	6.569	-.519	.608
	INV	1.924	.778	2.474	.019
	PUB	8.547	1.826	4.679	.000
	FV	1.497	2.771	.540	.593
	TPUB	-2.15E-02	.401	-.054	.958

a. Dependent Variable: VENTES

VENTE 1 = 3129,231 + 4,423 X MT + 1,676 X RG - 13,526 X PRIX – 3,410 X BR +1,924 X INV + 8,328 X PUB + 1,497 X FV – 0,00215 X TPUB



DEUXIÈME ÉTAPE

Model Summary[b]

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.898[a]	.806	.760	251.99

a. Predictors: (Constant), Frais de ventes, Remises aux grossistes, Publicité, Investissements, Budget de recherche, Prix, Marché total

b. Dependent Variable: Ventes

BR = Budget de Recherche

Coefficients[a]

Model		Unstandardized Coefficients		t	Sig.
		B	Std. Error		
1	(Constant)	3115.648	579.517	5.376	.000
	MT	4.426	1.561	2.836	.008
	RG	1.706	3.191	.535	.597
	PRIX	-13.445	8.029	-1.675	.104
	BR	-3.392	6.451	-.526	.603
	INV	1.931	.756	2.554	.016
	PUB	8.558	1.784	4.798	.000
	FV	1.482	2.710	.547	.588

a. Dependent Variable: VENTES

TROIXIÈME ÉTAPE

Model Summary[b]

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.897[a]	.804	.766	249.04

a. Predictors: (Constant), Frais de ventes, Remises aux grossistes, Publicité, Investissements, Prix, Marché total

b. Dependent Variable: Ventes

FV = Frais de ventes

Coefficients[a]

Model		Unstandardized Coefficients		t	Sig.
		B	Std. Error		
1	(Constant)	3137.547	571.233	5.493	.000
	MT	4.756	1.412	3.368	.002
	RG	1.705	3.153	.541	.593
	PRIX	-14.790	7.521	-1.966	.058
	INV	1.885	.742	2.539	.016
	PUB	8.519	1.761	4.837	.000
	FV	.950	2.484	.382	.705

a. Dependent Variable: VENTES

QUATRIÈME ÉTAPE

Model Summary[b]

Model	R	R Square	Adjusted R Square	Std. Error of the Estimate
1	.896[a]	.803	.772	245.69

a. Predictors: (Constant), Publicité, Remises aux grossistes, Marché total, Investissements, Prix

b. Dependent Variable: Ventes

RG = Remises aux grossistes

Coefficients[a]

Model		Unstandardized Coefficients		t	Sig.
		B	Std. Error		
1	(Constant)	3084.009	546.374	5.645	.000
	MT	5.222	.704	7.415	.000
	RG	1.700	3.111	.546	.589
	PRIX	-13.467	6.589	-2.044	.049
	INV	1.984	.686	2.893	.007
	PUB	8.328	1.666	4.998	.000

a. Dependent Variable: VENTES

MODÈLE AVEC SÉLECTION DE VARIABLES

Coefficients[a]

Model		Unstandardized Coefficients		t	Sig.
		B	Std. Error		
1	(Constant)	3084.009	546.374	5.645	.000
	MT	5.222	.704	7.415	.000
	PRIX	-13.467	6.589	-2.044	.049
	INV	1.984	.686	2.893	.007
	PUB	8.328	1.666	4.998	.000

a. Dependent Variable: VENTES

$VENTE_2 = 3084{,}009 + 5{,}222 \times MT - 13{,}467 \times PRIX + +1{,}984 \times INV + 8{,}328 \times PUB$



PRÉDICTION ET ÉVALUATION SUR UN ENTREPÔT DE TEST



Modèle global

	MT	RG	PRIX	BR	INV	PUB	FV	TPUB	VENTES	pred.full
2	328	123	77	20	59	88	211	141	4787	4722,93
3	285	105	63	8	-28	12	176	218	4123	3646,53
4	441	120	80	16	-22	50	267	405	4801	4847,31
5	462	112	73	15	68	93	283	212	5712	5406,63
6	417	120	81	35	148	83	257	111	5512	5330,98
7	408	131	66	13	120	62	235	141	5313	5138,27
8	362	145	67	23	117	73	220	239	4942	5092,38
9	436	123	73	32	100	43	276	280	5366	5004,36
10	456	128	65	22	144	52	253	93	5741	5401,29
11	364	120	64	14	128	96	195	107	5383	5269,58
12	433	124	68	8	122	25	258	291	5140	4839,73
13	277	135	62	11	76	68	175	410	4842	4476,9
14	455	126	78	22	18	95	233	118	5316	5626,29
15	398	138	56	12	50	77	229	98	5540	5175,03
16	412	149	78	36	30	26	258	124	4647	4752,77
17	415	119	75	20	-40	41	211	315	4630	4844,78
18	484	111	58	13	107	40	258	321	5502	5358,06
19	515	120	77	23	126	21	328	398	5288	5139,33
20	429	125	74	11	88	83	218	118	5095	5452,81
21	355	131	65	24	113	77	208	307	5094	5082,23

PRÉDICTION ET ÉVALUATION SUR UN ENTREPÔT DE TEST



Modèle global



Modèle réduit

	MT	RG	PRIX	BR	INV	PUB	FV	TPUB	VENTES	pred.full	pred.sel
2	328	123	77	20	59	88	211	141	4787	4722,93	4976,03
3	285	105	63	8	-28	12	176	218	4123	3646,53	4070,95
4	441	120	80	16	-22	50	267	405	4801	4847,31	5139,34
5	462	112	73	15	68	93	283	212	5712	5406,63	5636,19
6	417	120	81	35	148	83	257	111	5512	5330,98	5336,96
7	408	131	66	13	120	62	235	141	5313	5138,27	5100,06
8	362	145	67	23	117	73	220	239	4942	5092,38	4991,94
9	436	123	73	32	100	43	276	280	5366	5004,36	5051,22
10	456	128	65	22	144	52	253	93	5741	5401,29	5226,66
11	364	120	64	14	128	96	195	107	5383	5269,58	5215,42
12	433	124	68	8	122	25	258	291	5140	4839,73	4869,75
13	277	135	62	11	76	68	175	410	4842	4476,9	4556,15
14	455	126	78	22	18	95	233	118	5316	5626,29	5622,77
15	398	138	56	12	50	77	229	98	5540	5175,03	5194,05
16	412	149	78	36	30	26	258	124	4647	4752,77	4782,91
17	415	119	75	20	-40	41	211	315	4630	4844,78	4936,43
18	484	111	58	13	107	40	258	321	5502	5358,06	5243,04
19	515	120	77	23	126	21	328	398	5288	5139,33	5207,94
20	429	125	74	11	88	83	218	118	5095	5452,81	5391,9
21	355	131	65	24	113	77	208	307	5094	5082,23	4997,16

PRÉDICTION ET ÉVALUATION SUR UN ENTREPÔT DE TEST



Modèle global



Modèle réduit

1	MT	RG	PRIX	BR	INV	PUB	FV	TPUB	VENTES	pred.full	pred.sel
2	328	123	77	20	59	88	211	141	4787	4722,93	4976,03
3	285	105	63	8	-28	12	176	218	4123	3646,53	4070,95
4	441	120	80	16	-22	50	267	405	4801	4847,31	5139,34
5	462	112	73	15	68	93	283	212	5712	5406,63	5636,19
6	417	120	81	35	148	83	257	111	5512	5330,98	5336,96
7	408	131	66	13	120	62	235	141	5313	5138,27	5100,06
8	362	145	67	23	117	73	220	239	4942	5092,38	4991,94
9	436	123	73	32	100	43	276	280	5366	5004,36	5051,22
10	456	128	65	22	144	52	253	93	5741	5401,29	5226,66
11	364	120	64	14	128	96	195	107	5383	5269,58	5215,42
12	433	124	68	8	122	25	258	291	5140	4839,73	4869,75
13	277	135	62	11	76	68	175	410	4842	4476,9	4556,15
14	455	126	78	22	18	95	233	118	5316	5626,29	5622,77
15	398	138	56	12	50	77	229	98	5540	5175,03	5194,05
16	412	149	78	36	30	26	258	124	4647	4752,77	4782,91
17	415	119	75	20	-40	41	211	315	4630	4844,78	4936,43
18	484	111	58	13	107	40	258	321	5502	5358,06	5243,04
19	515	120	77	23	126	21	328	398	5288	5139,33	5207,94
20	429	125	74	11	88	83	218	118	5095	5452,81	5391,9
21	355	131	65	24	113	77	208	307	5094	5082,23	4997,16



COMPARAISON DES MODÈLES DE PRÉDICTION

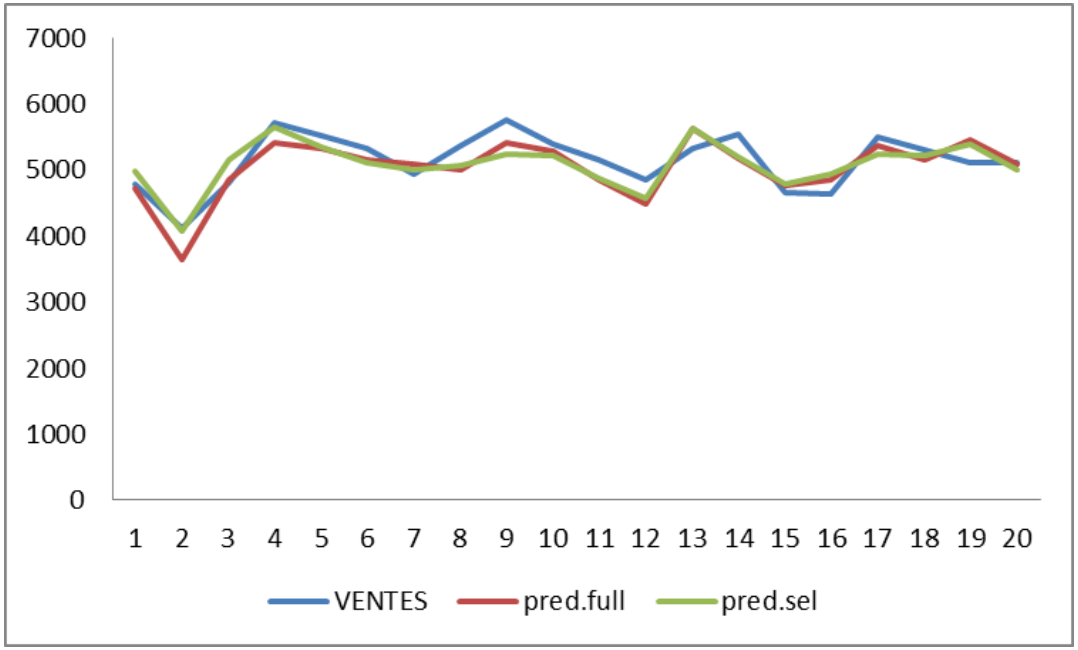


Modèle global



Modèle réduit

VENTES	pred.full	pred.sel
4787	4722,93	4976,03
4123	3646,53	4070,95
4801	4847,31	5139,34
5712	5406,63	5636,19
5512	5330,98	5336,96
5313	5138,27	5100,06
4942	5092,38	4991,94
5366	5004,36	5051,22
5741	5401,29	5226,66
5383	5269,58	5215,42
5140	4839,73	4869,75
4842	4476,9	4556,15
5316	5626,29	5622,77
5540	5175,03	5194,05
4647	4752,77	4782,91
4630	4844,78	4936,43
5502	5358,06	5243,04
5288	5139,33	5207,94
5095	5452,81	5391,9
5094	5082,23	4997,16



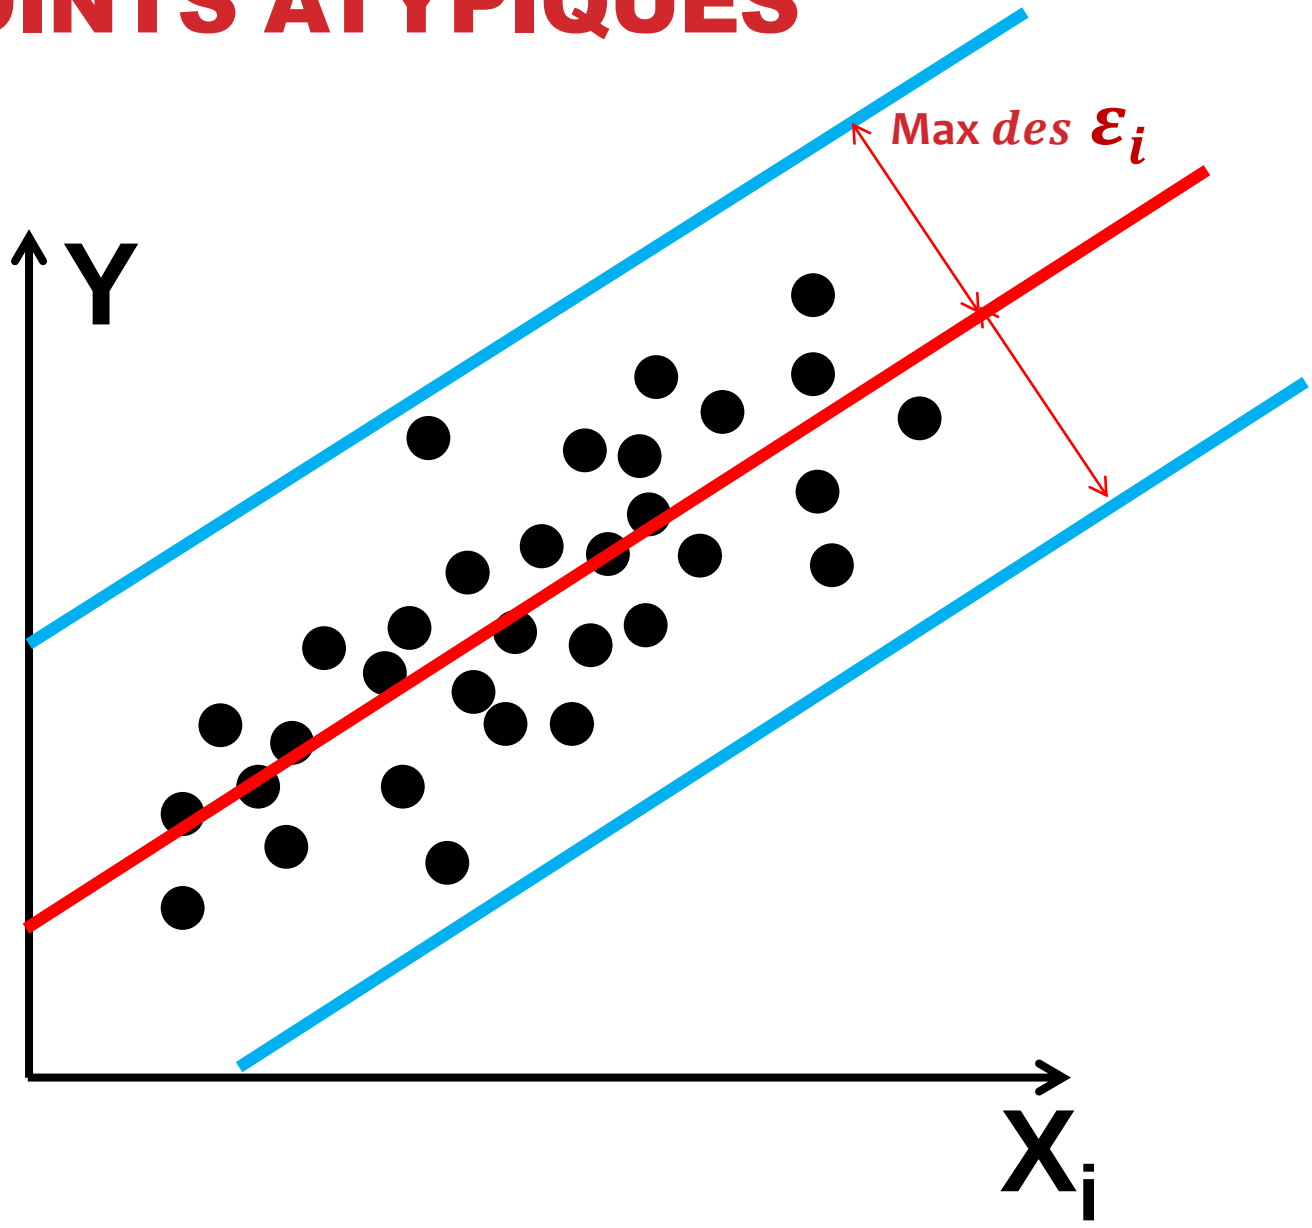
LES POINTS ATYPIQUES

Repérer les observations qui jouent un rôle anormal dans la régression

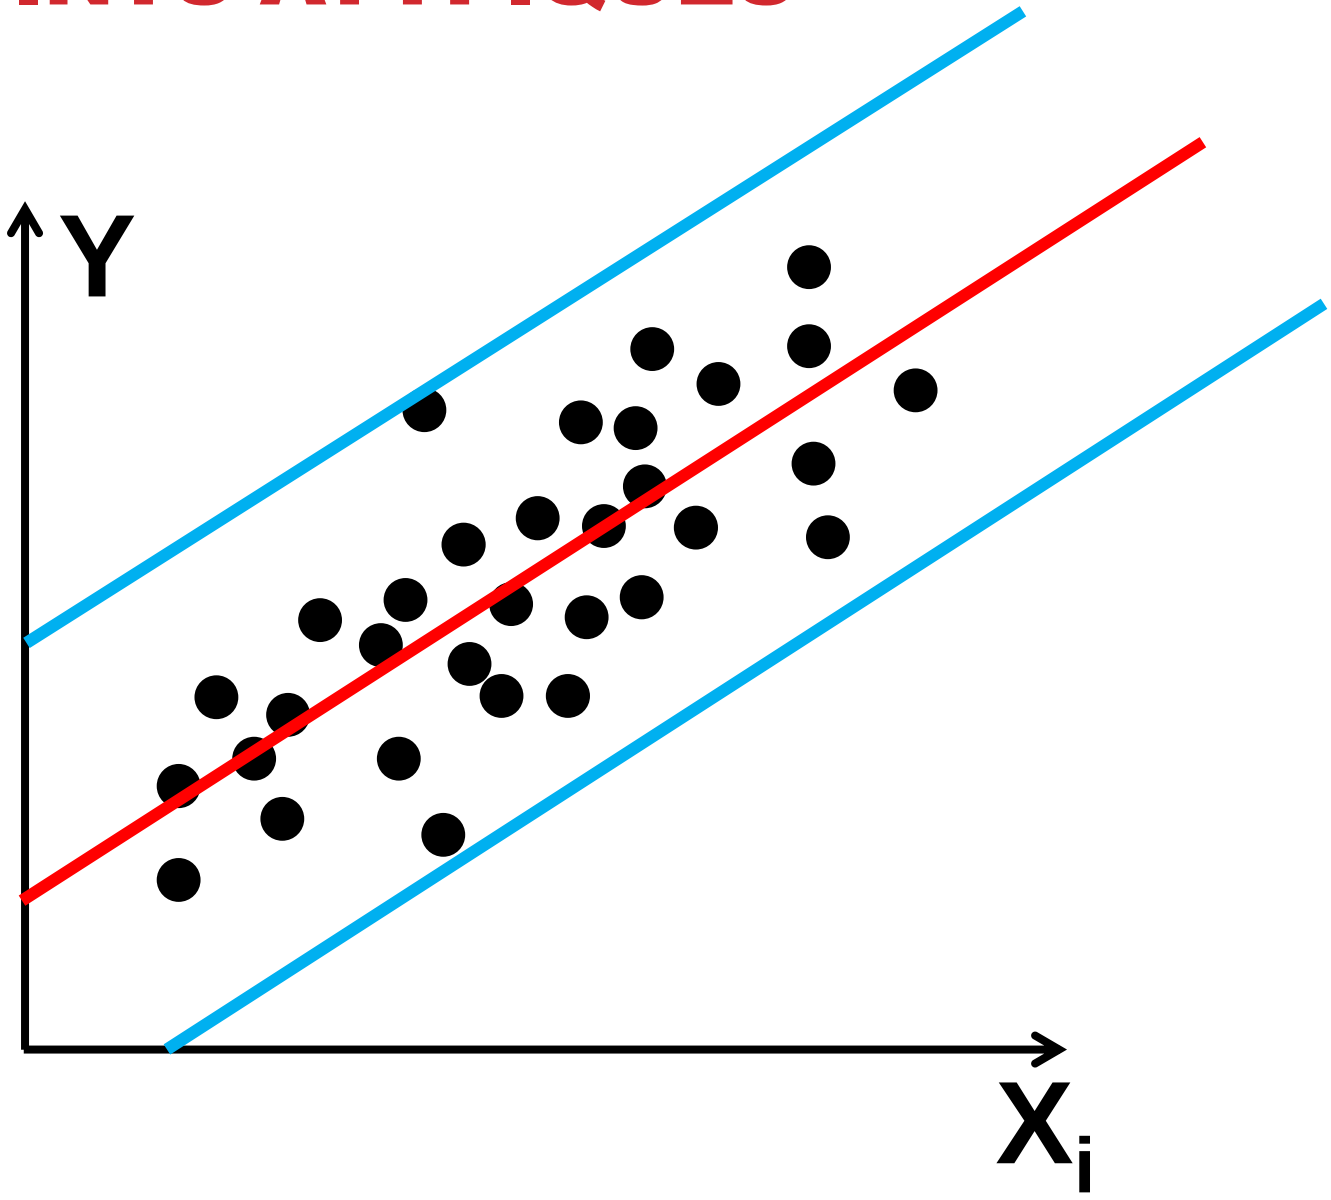


Atypique (aberrant)	• Elle prend une valeur inhabituelle sur une variable • Elle prend une combinaison de valeurs inhabituelles sur plusieurs variables
Influent	• Elle pèse de manière exagérée dans la régression • les résultats sont très différents selon que le point est pris en compte ou pas dans la régression
Atypique (régression)	• Elle est très mal reconstituée (expliquée) par la régression • le résidu observé est très (trop) élevé, le point n'obéit pas à la relation qui a été établie par la régression

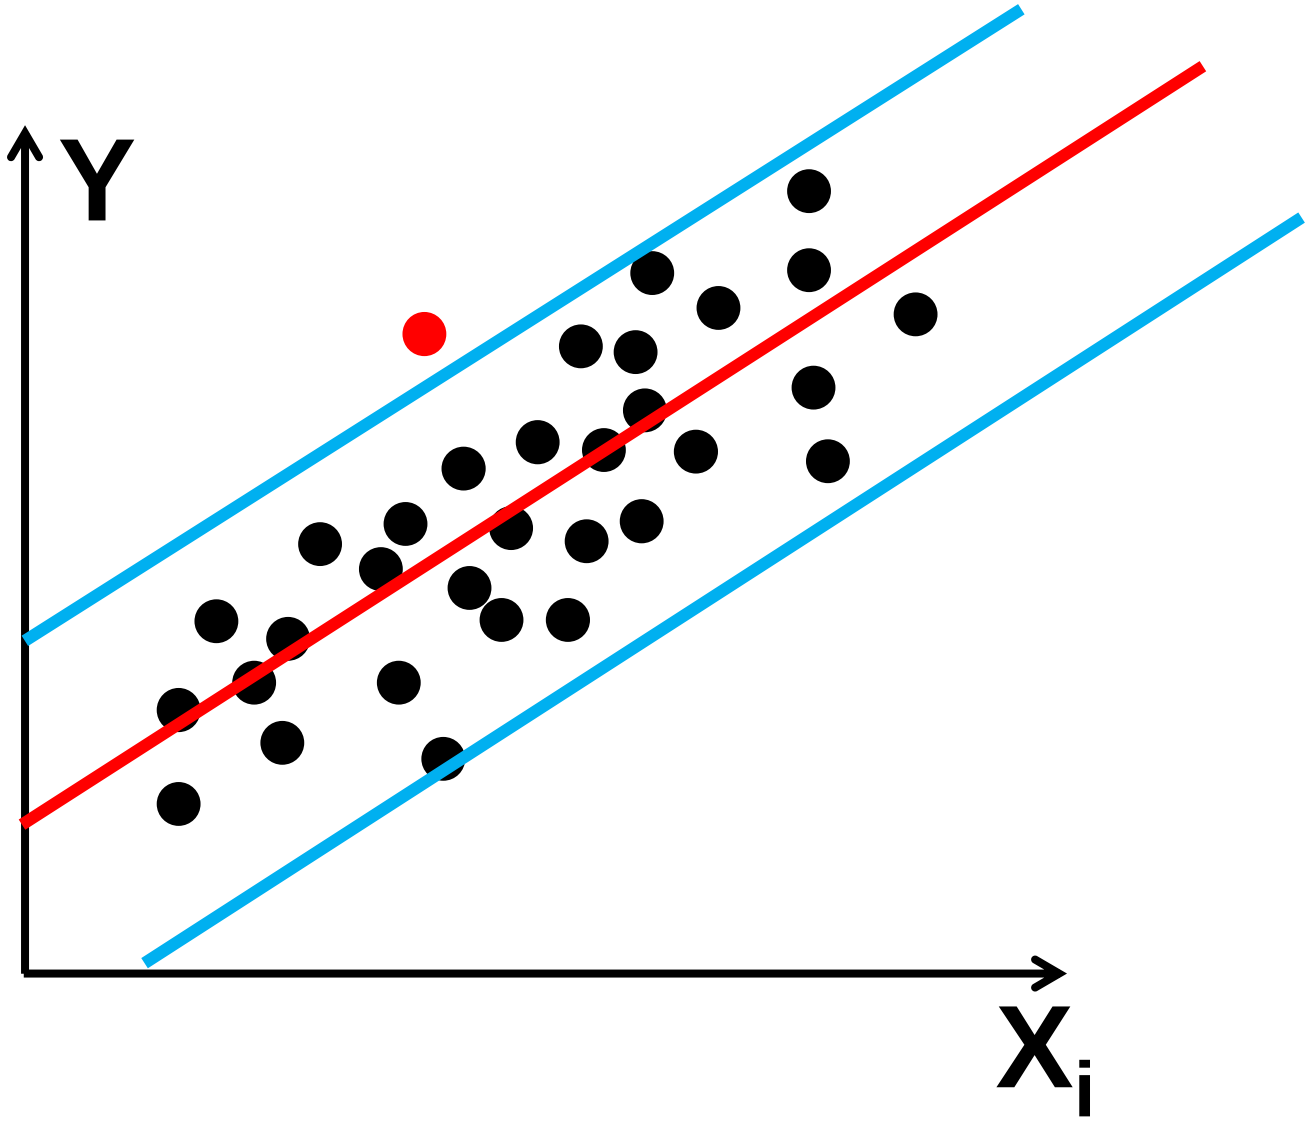
LES POINTS ATYPIQUES



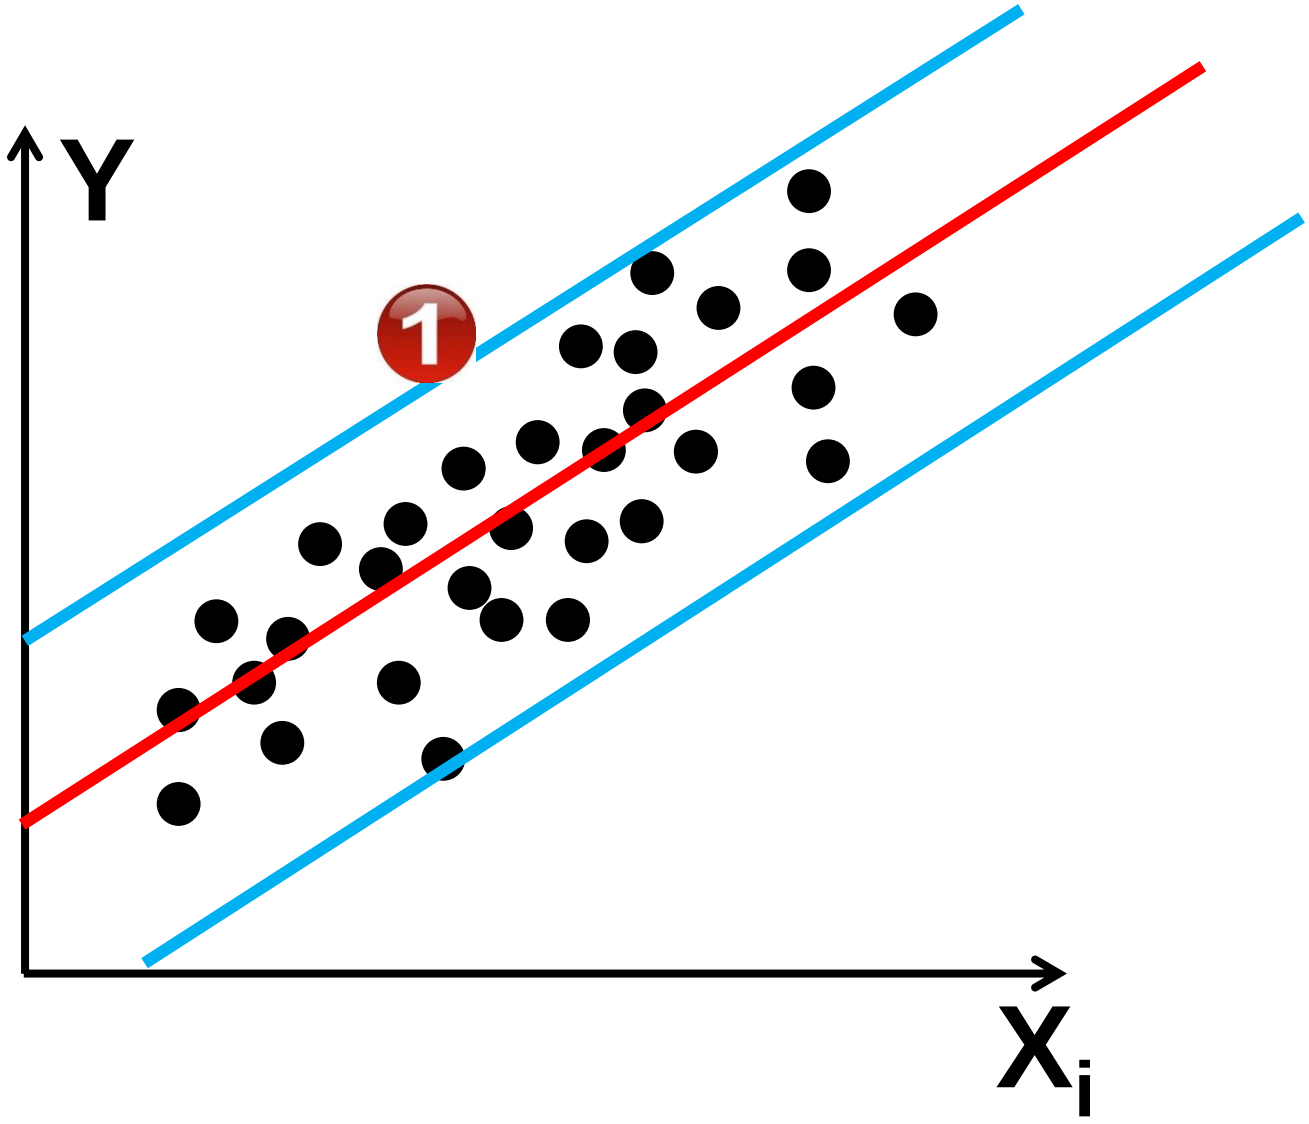
LES POINTS ATYPIQUES



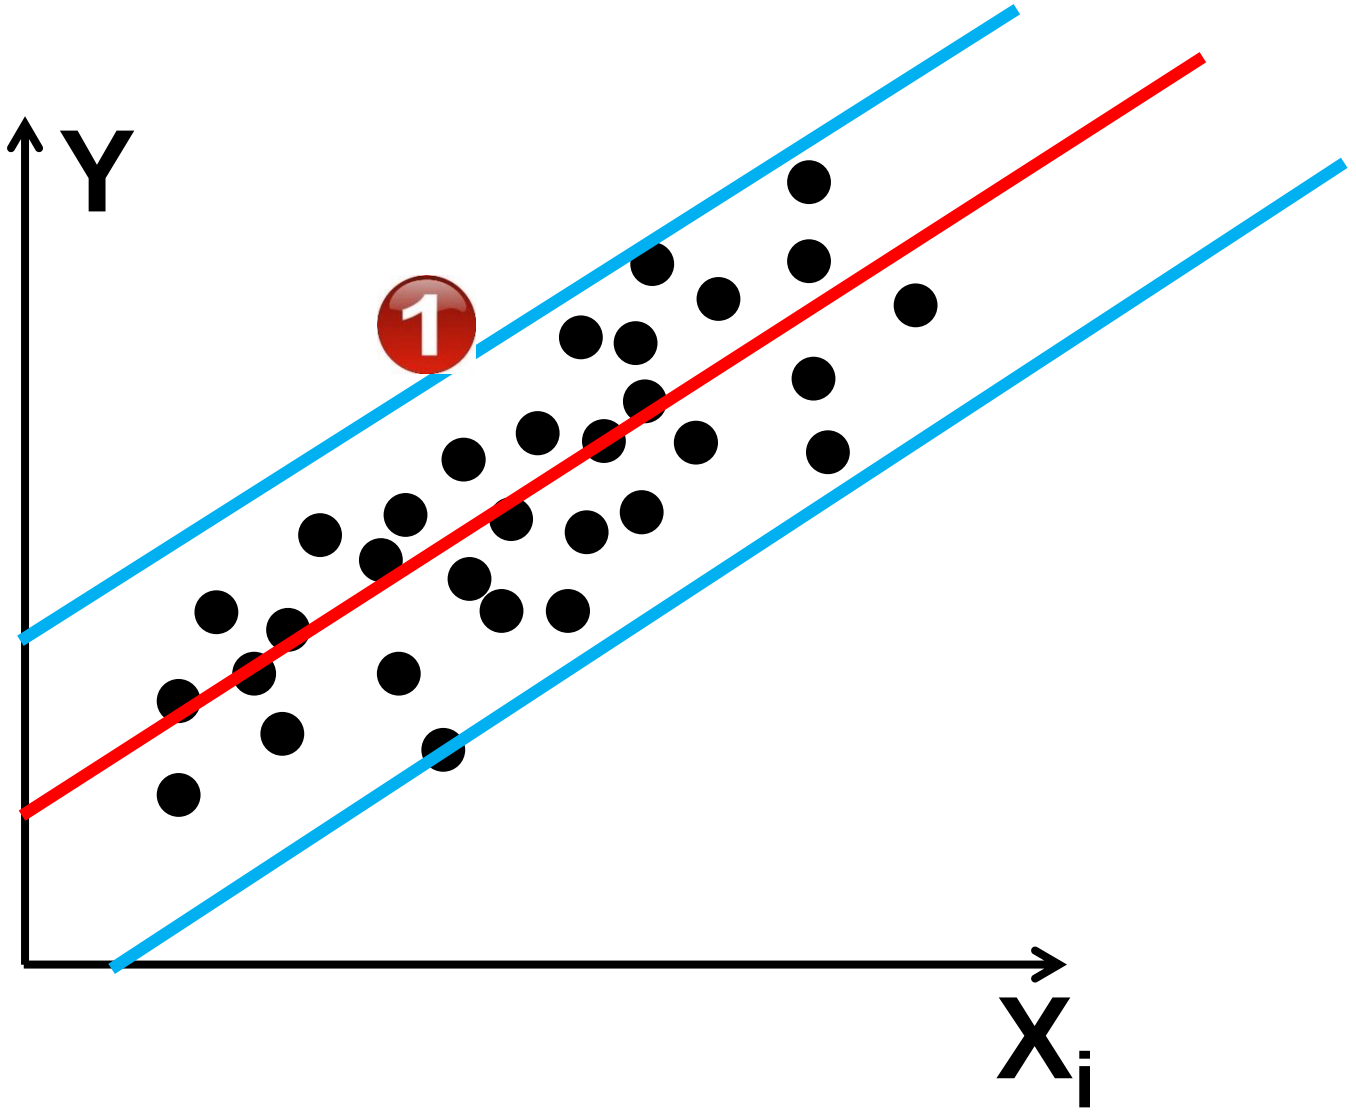
LES POINTS ATYPIQUES



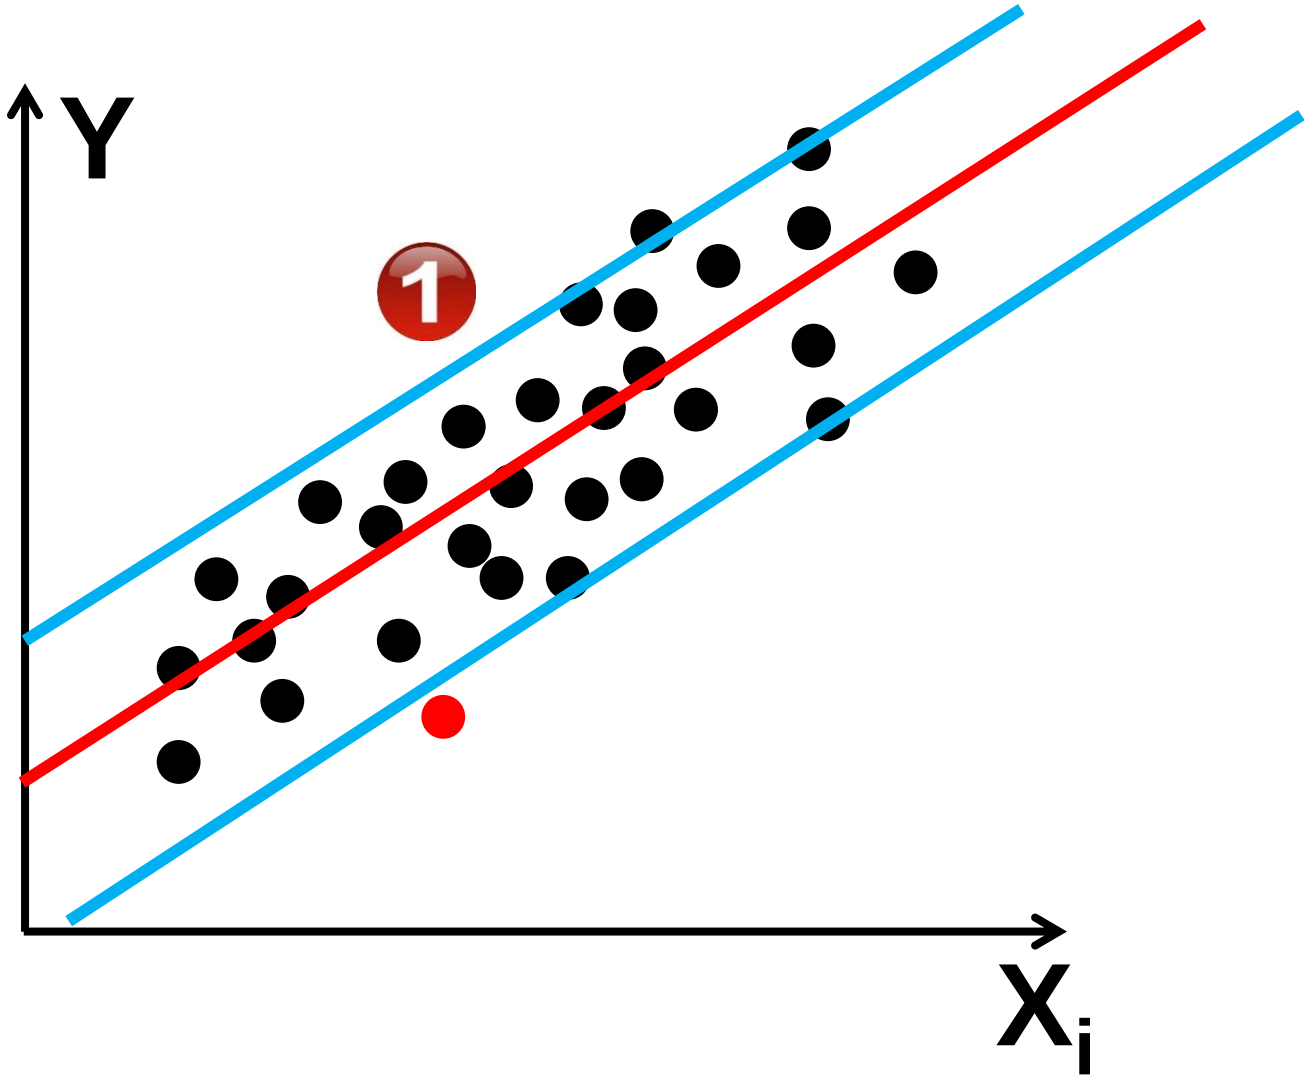
LES POINTS ATYPIQUES



LES POINTS ATYPIQUES



LES POINTS ATYPIQUES



LES POINTS ATYPIQUES

