Exercice 1: Analyse en composantes principales [6 points]

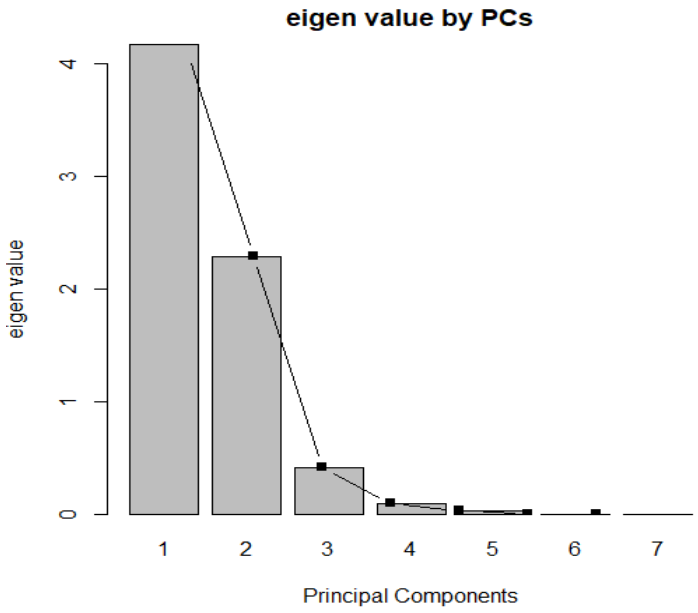
Une équipe de nutritionnistes souhaite étudier les pizzas surgelées. Une partie de cette analyse vise à mettre en évidence les relations qui existent entre leurs composants en utilisant l'ACP. Un aperçu de la data est donné par la figure 1 annexe 1.

Les variables de la data sont illustrées comme suit:

- **brand - Pizza brand (class label):['A' 'B' 'C' 'D']**
- **id - Sample analyzed.**
- **mois - Amount of water per 100 grams in the sample.**
- **prot - Amount of protein per 100 grams in the sample.**
- **fat - Amount of fat per 100 grams in the sample.**
- **ash - Amount of ash (cendre) per 100 grams in the sample**
- **sodium - Amount of sodium per 100 grams in the sample**
- **carb - Amount of carbohydrates per 100 grams in the sample**
- **cal - Amount of calories per 100 grams in the sample**

1- D'après cet aperçu, quelles sont les variables à éliminer avant de commencer le traitement de l'ACP, justifier votre réponse. [0.5 pt]

2-L'application de l'ACP a permis d'avoir le graphique suivant:



A- Combien de composantes doit-on choisir pour avoir une bonne représentation? Donner le critère de référence.[0.5 pt]

B- Donner une estimation du taux de la variance expliquée sur le meilleur plan factoriel. interpréter ce résultat en expliquant l'impact des données sur ce dernier. [1 pt]

3- La carte des individus est illustrée par l'annexe 1 figure 2.

a- Donner une analyse métier visant à mettre en évidence des groupes homogènes en se référant à la variable ***brand.*** [0.75 pt]

B - Donner la liste des six individus les mieux représentés sur le plan factoriel. [0.75 pt]

C- Etudier les corrélations entre les observations de cette liste sur les deux composantes principales PC1 et PC2. [0.5 pt]

4- L'analyse des variables est essentielle pour nos nutritionnistes qui ont généré le graphique illustré par la figure 3 annexe 1.

A- Interpréter la corrélation entre les variables bien représentées par la composante PC2.[0.5 pt]

B- Y-a-t-il une optimisation à faire en ce qui concerne les variables corrélées positivement avec PC1? [0.5 pt]

C- Donner une segmentation des variables. [0.5 pt]

5- Proposer un profiling des individus sélectionnés dans la question (3-B) en se basant sur la segmentation des variables précédentes. [1 pt]

Exercice 2: Régression Linéaire Simple et Multiple [4 points]

On dispose d'un ensemble de données traduisant les dépenses publicitaires mensuelles (en dinars) en fonction de trois canaux de marketing : télévision, radio et journaux, ainsi que le montant total des ventes mensuelles (en dinars).
On se propose de prédire les ventes mensuelles en fonction des dépenses publicitaires.
Les données sont disponibles sur ***l'annexe 2.***
Les résultats de l'application de la méthode régression linéaire sont donnés par le tableau suivant:

Coefficients:

	Estimate	Std. Error	t-value	P-value	
Intercept	**1500**	**500**	**3.0**	**0.012**	*****
TV	**200**	**50**	**4.0**	**0.002**	******
Radio	**100**	**30**	**3.3**	**0.021**	*****
Newspaper	**50**	**20**	**1.6**	**0.052**	**.**

Residual standard error: 500 on 96 degrees of freedom
Multiple R-squared: 0.85, Adjusted R-squared: 0.83
F-statistic: 60.8, p-value: 0.001

1. **En se référant au tableau précédent, donner un ordre de pertinence des variables illustratives. [0.5]**
2. **Quelle est la signification du coefficient d'interception dans le modèle de régression linéaire? [0.25]**

3. Après avoir essayer plusieurs modèles de régression linéaire en utilisant différentes combinaisons de variables indépendantes, le calcul du critère AIC pour chaque modèle donne les valeurs suivantes

Modèle 1 (Dépenses TV et Dépenses Radio) : AIC = 560
Modèle 2 (Dépenses TV uniquement) : AIC = 600

Quel est le modèle à retenir. Justifier votre réponse.[0.75]

3- Supposons que nous disposions ces deux modèles :

Modèle 1 : Régression linéaire simple (avec seulement les dépenses publicitaires en télévision)
$Y = \beta0 + \beta1*X1$
Supposons que les coefficients estimés pour le modèle soient :

- **β0 (interception) = 300**
- **β1 (coefficient pour les dépenses publicitaires en télévision) = 2**

Modèle 2 : Régression linéaire multiple (avec les dépenses publicitaires en télévision, radio et journaux)
$Y= \beta0 + \beta1X1 + \beta2X2 + \beta3*X3$
Supposons que les coefficients estimés pour le modèle soient :

- **β0 (interception) = 200**
- **β1 (coefficient pour les dépenses publicitaires en télévision) =1.5 dinar**
- **β2 (coefficient pour les dépenses publicitaires en radio) = 2 dinars**
- **β3 (coefficient pour les dépenses publicitaires en journaux) = 0.5 dinar**

Calculer les valeurs prédites des ventes mensuelles (Y) en utilisant les deux modèles précédents pour une situation où les dépenses publicitaires sont les suivantes : [1 pt]

- **Télévision (X1) : 300 dinars**

- **Radio (X2) : 150 dinars**
- **Journaux (X3) : 40 dinars**

4- Sachant que Y réelle = 61370 **. Quel est le meilleur modèle à retenir. [0.5]**

Exercice 3: Problème [10 points]

On se propose d'analyser des données relatives aux résultats d'admission des étudiants ayant postulé pour accéder à des universités pour des études supérieures. Un extrait des données est disponible sur la figure 1 de l'annexe 3.

Les variables descriptives sont explicitées par le tableau suivant:

GRE	General Test Scores
SOP	Statement of purpose
University rating	Rating of the university.
LOR	Letter of recommendation
CGPA	Cumulative grade point average
Research	1 for research, 0 for none.
TOEFL SCORE	Score of TOEFL
Chance of admission	Score of the access to the chosen university.

Partie 1: Analyse préliminaire [2.5 pts]

Votre client, ne disposant pas de connaissances approfondies dans le domaine de la Data Science, souhaite avoir un cahier de charges détaillant les objectifs métiers possibles à réaliser.

1. Proposer deux méthodologies de travail susceptibles de répondre aux exigences d'un tel projet. Justifier votre réponse. [0.5]
2. Par référence aux données précédemment présentées, proposer:
   A- Un objectif métier descriptif et une méthode qui peut le résoudre convenablement.[0.5]
   B- Un objectif métier prédictif et deux méthodes qui peuvent le résoudre convenablement.[0.75]
3. En se référant à la figure 2 annexe 3, donner une interprétation du résultat de la fonction summary.[0.5]

4. Afin de mieux comprendre les données, proposer une méthode qui permet de détecter les valeurs aberrantes. [0.25]

Partie 2: Clustering [2 pts]

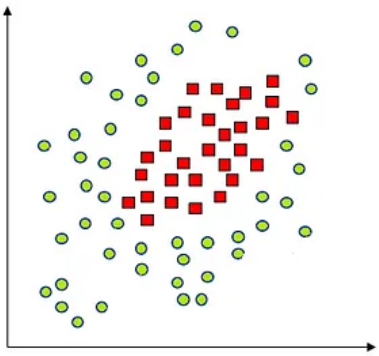
Pour mener à terme l'objectif métier descriptif de votre client, vous avez opté pour des méthodes de segmentation.

1. Deux méthodes sont candidates: la méthode des centres mobiles mobiles (K-means) et la classification ascendante hiérarchique (CAH). Donner un ordre d'application adéquat. [0.5 pt]
2. Citer deux étapes de préparation de données nécessaires avant l'application des algorithmes de segmentation. [0.5 pt]
3. On donne le dendrogramme illustré par la figure3 annexe3. Comment peut-on obtenir la meilleure segmentation. Donner votre proposition du nombre de groupes à retenir. Justifier votre choix. [0.75 pt]
4. Par référence à la figure4 annexe3, vérifier le choix du nombre de groupes précédents. Qu'en est-il pour le compromis entre inertie inter-classes et intra-classes? [0.25]

Partie 3: Classification Supervisée [5.5 pts]

Dans cette partie, votre client souhaite réaliser une classification bimodale des étudiants ayant postulé pour accéder aux grandes écoles.

1. Une étape de préparation de données concernant la variable cible s'avère primordiale . Expliciter-la. Proposer un seuil pour chaque classe. [0.5]
2. Dans un premier temps, on applique un modèle à base d'arbre de décisions.
   A- Donner la particularité de l'indice de Gini.[0.25]
   B- Donner la signification de chaque paramètre de la commande suivante: [0.5]
   m1<-rpart(Chance.of.Admit~., newdata, control =rpart.control(minsplit=20))
   C- La description textuelle de l'arbre obtenue est donnée par la figure 5 annexe 3. Donner le nombre de décisions obtenues ainsi qu'une règle obtenue à partir d'un nœud pur. [0.75]
   D- Donner la représentation graphique de l'arbre de décisions. [1 pt]
3. Dans un deuxième temps, on applique un modèle à base de séparateur à vastes marges.
   A- Le nuage de point de la population étudiée est illustré par la figure suivante. Proposer un noyau adapté pour l'éventuelle classification. Justifier votre choix.[0.5 pt]



   B- Lors de la présence d'individus mal placés, comment serait-il possible d'ajuster leurs classes d'appartenance? [0.5 pt]

4- Avant de passer à la phase de déploiement, il est indispensable d'évaluer chacun des modèles précédents.

A- On donne les deux matrices de confusion suivantes. Calculer les taux de mauvaise classification. Donner une interprétation des résultats obtenus.[1 pt]

SVM	0	1
0	200	12
1	15	179

ADD	0	1
0	199	17
1	16	168

B- On s'intéresse maintenant aux courbes suivantes. Affiner votre interprétation des performances des deux modèles. [0.5]

