SALMA DAMAK
MED. AZYZ NGUIRA

DATA SANTE

1/ Compréhension de métier:

- Objectifs Métiers (Détecter les caractéristiques):
  - **Améliorer la qualité des soins médicaux fournis par l'hôpital.**
  - Optimiser les processus médicaux
  - Personnaliser les traitements des patients
  - Réduire les risques de maladies cardiovasculaires
- Objectif Data Mining:
  - Optimiser les processus médicaux
    - Grouper les patients en segments en fonction de leurs caractéristiques (K-MEANS)
    - Réduire la dimensionnalité des données et identifier les variables cibles (ACP)
  - Personnaliser les traitements des patients
    - Identifier les variables les plus importantes dans la personnalisation des traitements (ACP)
    - Développer des modèles prédictifs personnalisés basés sur les caractéristiques individuelles des patients (KNN)
  - Réduire les risques de maladies cardiovasculaires
    - Prédire le risque des maladies, TenYearCHD (KNN)
    - Créer une relation entre les facteurs de risque quanti. (Reg.Lin)
    - Modéliser les facteurs de risque et prédire les risques cardiovasculaires (ADD)

2/Compréhension des données:

```
> dim(sante)
[1] 4240   16
```

On a un dataset avec 4240 observations, et 16 variables.

EXPLICATION DES ABRÉVIATIONS:

PrevalentStroke : Accident vasculaire cérébral prévalent
PrevalentHyp : Hypertension prévalente
BPMeds : Médicaments pour la pression artérielle
totChol : Cholestérol total
sysBP : Pression artérielle systolique
diaBP : Pression artérielle diastolique
BMI : Indice de masse corporelle
heartRate : Fréquence cardiaque
cigsPerDay : Nombre de cigarettes par jour
TenYearCHD : probabilité de maladie coronarienne dans les 10 ans à venir

```
> summary(hopital)
      male             age          education     currentSmoker      cigsPerDay         BPMeds
 Min.   :0.0000   Min.   :32.00   Min.   :1.000   Min.   :0.0000   Min.   : 0.000   Min.   :0.00000
 1st Qu.:0.0000   1st Qu.:42.00   1st Qu.:1.000   1st Qu.:0.0000   1st Qu.: 0.000   1st Qu.:0.00000
 Median :0.0000   Median :49.00   Median :2.000   Median :0.0000   Median : 0.000   Median :0.00000
 Mean   :0.4292   Mean   :49.58   Mean   :1.979   Mean   :0.4941   Mean   : 9.006   Mean   :0.02962
 3rd Qu.:1.0000   3rd Qu.:56.00   3rd Qu.:3.000   3rd Qu.:1.0000   3rd Qu.:20.000   3rd Qu.:0.00000
 Max.   :1.0000   Max.   :70.00   Max.   :4.000   Max.   :1.0000   Max.   :70.000   Max.   :1.00000
                                  NA's   :105                      NA's   :29       NA's   :53
 prevalentStroke     prevalentHyp       diabetes          totChol          sysBP           diaBP
 Min.   :0.000000   Min.   :0.0000   Min.   :0.00000   Min.   :107.0   Min.   : 83.5   Min.   : 48.0
 1st Qu.:0.000000   1st Qu.:0.0000   1st Qu.:0.00000   1st Qu.:206.0   1st Qu.:117.0   1st Qu.: 75.0
 Median :0.000000   Median :0.0000   Median :0.00000   Median :234.0   Median :128.0   Median : 82.0
 Mean   :0.005896   Mean   :0.3106   Mean   :0.02571   Mean   :236.7   Mean   :132.4   Mean   : 82.9
 3rd Qu.:0.000000   3rd Qu.:1.0000   3rd Qu.:0.00000   3rd Qu.:263.0   3rd Qu.:144.0   3rd Qu.: 90.0
 Max.   :1.000000   Max.   :1.0000   Max.   :1.00000   Max.   :696.0   Max.   :295.0   Max.   :142.5
                                                      NA's   :50
      BMI          heartRate         glucose         TenYearCHD
 Min.   :15.54   Min.   : 44.00   Min.   : 40.00   Min.   :0.0000
 1st Qu.:23.07   1st Qu.: 68.00   1st Qu.: 71.00   1st Qu.:0.0000
 Median :25.40   Median : 75.00   Median : 78.00   Median :0.0000
 Mean   :25.80   Mean   : 75.88   Mean   : 81.96   Mean   :0.1519
 3rd Qu.:28.04   3rd Qu.: 83.00   3rd Qu.: 87.00   3rd Qu.:0.0000
 Max.   :56.80   Max.   :143.00   Max.   :394.00   Max.   :1.0000
 NA's   :19      NA's   :1        NA's   :388
>
```

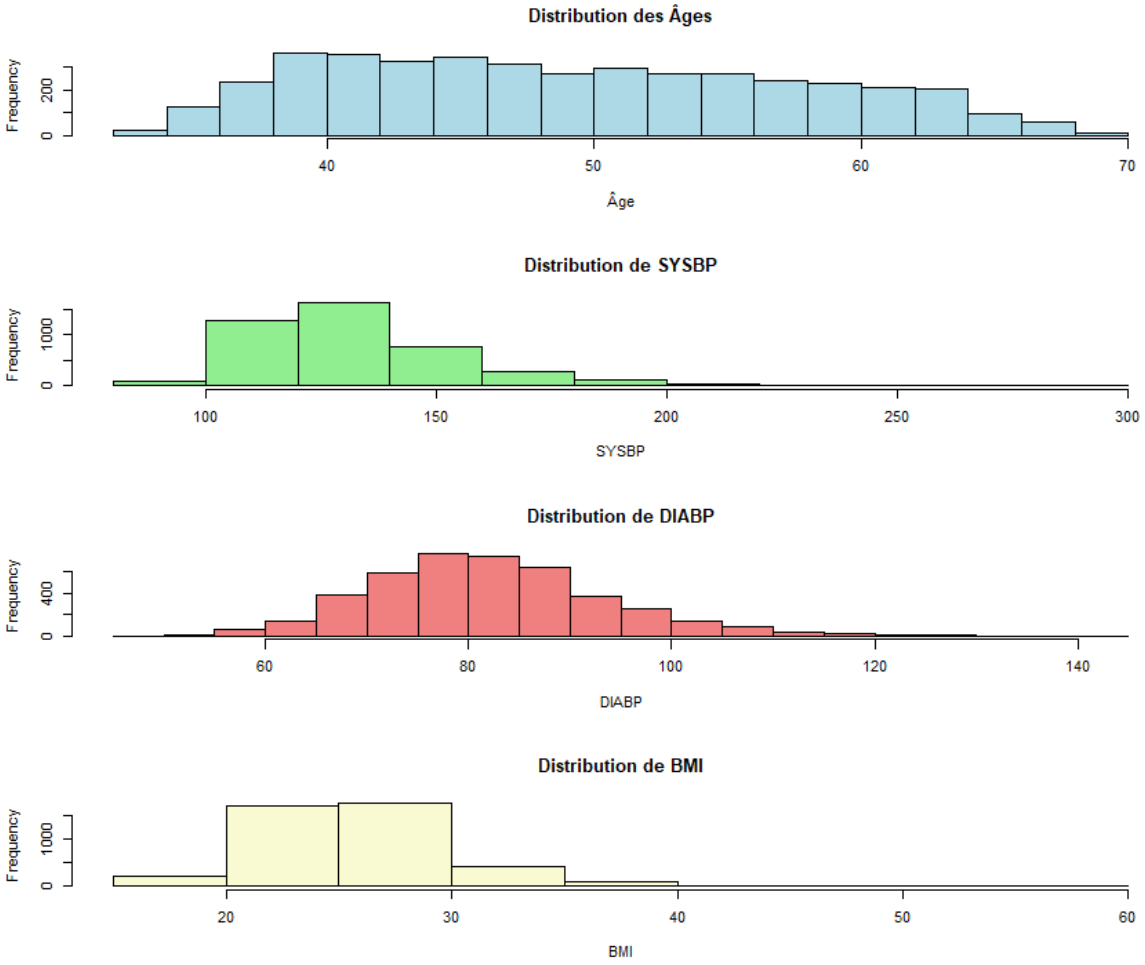
On a des variables quantitatives et qualitatives, les variables qualitatives sont sous la forme binaire (male, currentSmoker, BPMeds,prevalentStroke, prevalentHyp, diabetes, TenYeaCHD).

On a des valeurs manquantes dans les variables : éducation, cigsPerDay, BPMeds, totChol, BMI, hearRate et glucose.

Variable cible de classification: TenYearCHD
Prédire si l'individu présente un risque élevé de développer une maladie coronarienne dans les dix prochaines années.
Variable cible de régression: cigsPerDay
Comprendre comment le nombre de cigarettes fumées par jour est lié à d'autres caractéristiques. On va identifier la relation entre cigsPerDay et les autres variables.

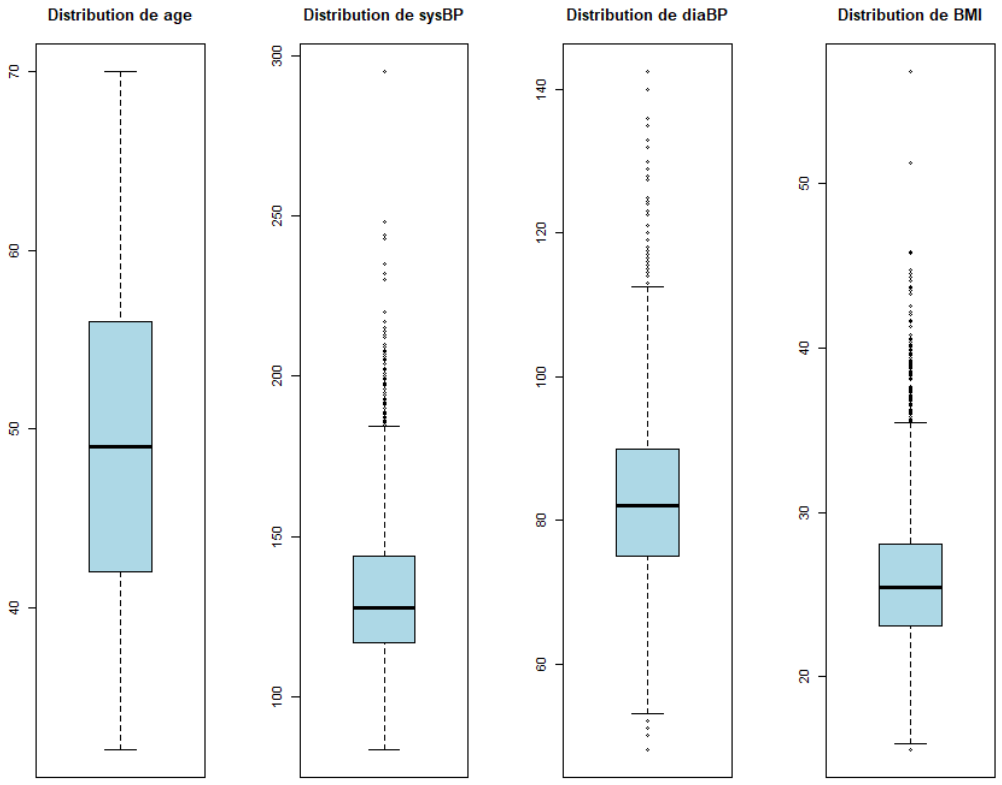
Pour les variables quantitatives: on va visualiser la distribution des données de (AGE, SysBP,DiaBP et BMI) dans des histogrammes de distribution et des boxplot
Pour les variables qualitatives: on va utiliser un diagramme en barres pour les données de (SEXE, CurrentSmoker, diabetes et prevalentHyp)

Histogrammes pour les distributions ("age", "sysBP", "diaBP", "BMI")



ÂGE: La valeur la plus fréquente est 60 ans.
Il y a plus de personnes âgées plus que de personnes jeunes.
SysBP: Les deux modes se situent à 120 mmHg et 160 mmHg.
Il y a plus de personnes avec une pression artérielle élevée que de personnes avec une pression artérielle basse.
DiaBP: La valeur la plus fréquente est 80 mmHg.
Il y a plus de personnes avec une pression artérielle élevée que de personnes avec une pression artérielle basse.
BMI: La valeur la plus fréquente est 25 kg/m².
Il y a plus de personnes en surpoids ou obèses que de personnes de poids normal.

BOXPLOTS pour les variables ("age", "sysBP", "diaBP", "BMI")

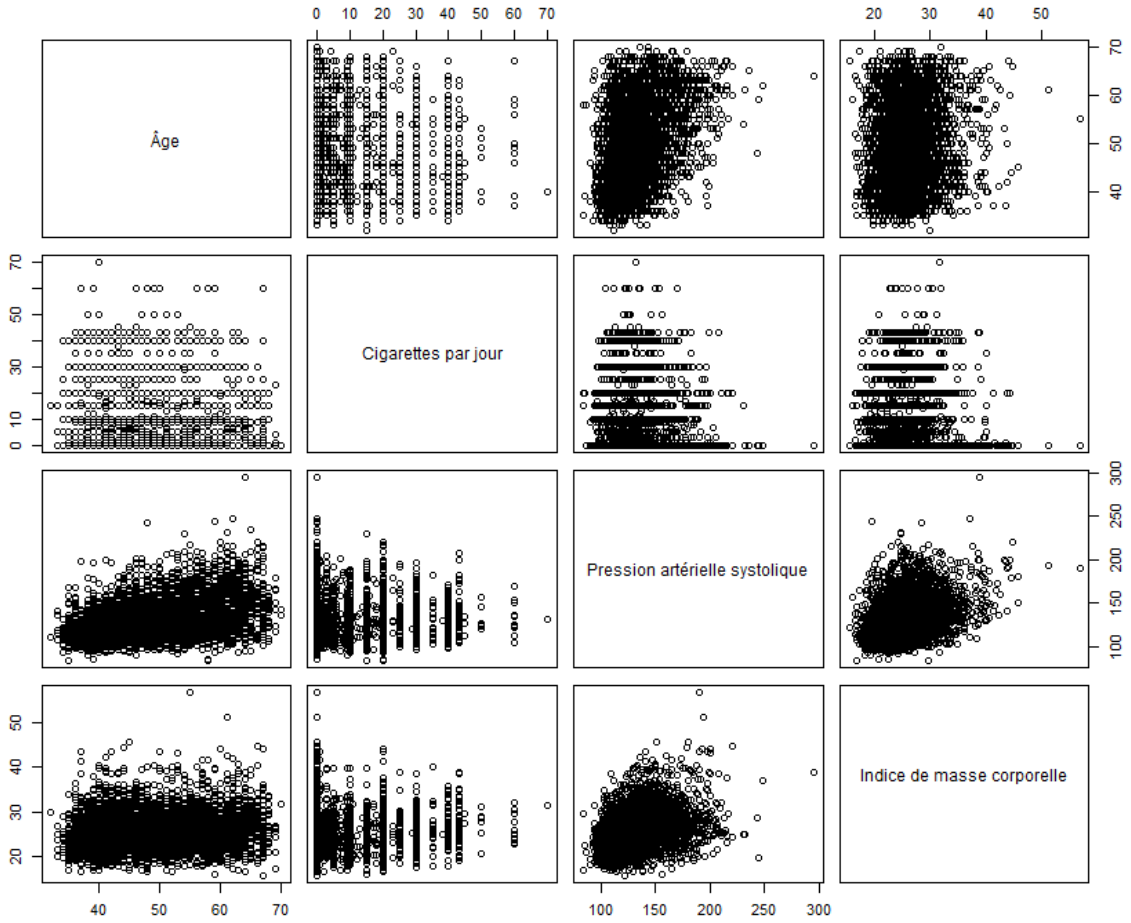


Âge: La médiane est de 50 ans.
La distribution est asymétrique vers la droite, ce qui signifie qu'il y a plus de personnes âgées que de personnes plus jeunes.
SysBP: La médiane est de 120 mmHg.
La distribution est bimodale, avec les deux modes se situant à 120 mmHg et 160 mmHg.
DiaBP: La médiane est de 80 mmHg.
La distribution est asymétrique vers la droite, ce qui signifie qu'il y a plus de personnes avec une pression artérielle élevée que de personnes avec une pression artérielle basse.
BMI: La médiane est de 25 kg/m².
La distribution est asymétrique vers la droite, ce qui signifie qu'il y a plus de personnes en surpoids ou obèses que de personnes de poids normal.

CONCLUSION VARIABLES QUANTITATIVES:

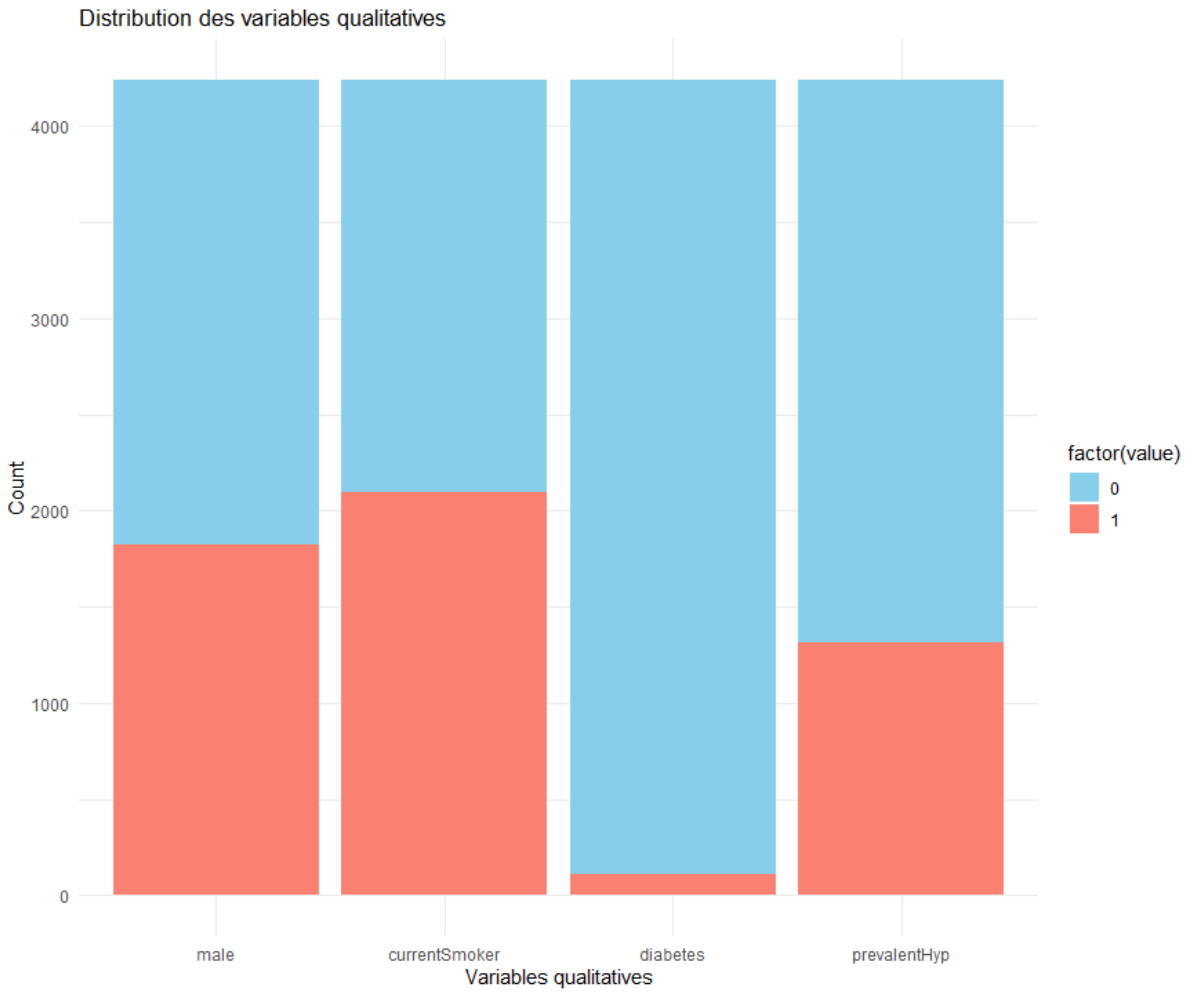
- La plage des valeurs pour l'âge est de 20 à 70 ans.
- La plage des valeurs pour la pression artérielle systolique est de 100 à 250 mmHg.
- La plage des valeurs pour la pression artérielle diastolique est de 60 à 140 mmHg.
- La plage des valeurs pour l'indice de masse corporelle est de 10 à 40 kg/m².

Matrice de nuages de points (scatterplot)



- Les personnes plus âgées fument moins que les personnes plus jeunes.
- Les personnes plus âgées ont une pression artérielle systolique plus élevée que les personnes plus jeunes.
- Les personnes qui fument moins ont une pression artérielle systolique plus basse que les personnes qui fument plus.
- Les personnes avec un indice de masse corporelle plus élevé ont une pression artérielle systolique plus élevée que les personnes avec un indice de masse corporelle plus bas.

Barplot pour les variables qualitatives ("SEXE", "CurrentSmoker", "diabetes", et "prevalentHyp")

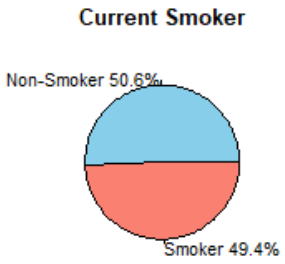


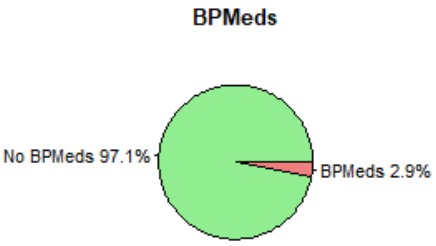
- 0 (femme) 1 (homme)
- 0 (ne fume pas) 1 (fume)
- 0 (diabète-non) 1 (diabète-oui)
- 0 (tension-non) et 1 (tension-oui).

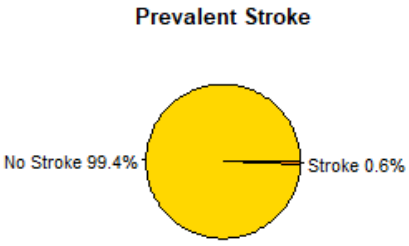
- Les hommes sont plus susceptibles d'être fumeurs et d'avoir une maladie cardiaque.
- Les fumeurs sont plus susceptibles d'avoir une maladie cardiaque.
- Les personnes atteintes de diabète sont plus susceptibles d'avoir une maladie cardiaque.
- Les personnes atteintes d'hypertension artérielle sont plus susceptibles d'avoir une maladie cardiaque.

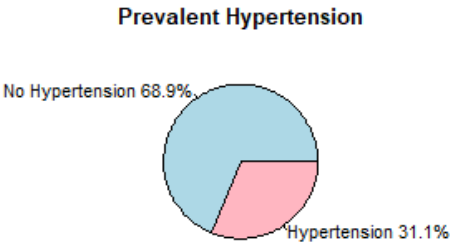
Conclusion: Les personnes âgées, les hommes, les fumeurs, les personnes atteintes de diabète et les personnes atteintes d'hypertension artérielle sont plus susceptibles d'avoir une maladie cardiaque

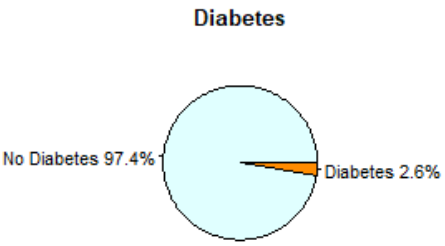
Pie Chart des variables qualitatives

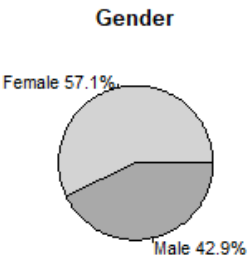












Conclusion: Les hommes, les fumeurs, les personnes ayant déjà eu un accident vasculaire cérébral et les personnes atteintes d'hypertension artérielle sont plus susceptibles d'avoir une maladie cardiaque.

3/Préparation des données:

- **Nettoyage des données :** Identifier et traiter les valeurs manquantes, les valeurs aberrantes …
- **Préparation des données :** Normalisation, encodage des variables …

On a des valeurs manquantes dans les variables :
éducation :**105**
cigsPerDay :**29**
BPMeds :**53**
totChol :**50**
BMI :**19**
hearRate :**1**
glucose :**338**

- On va remplacer ces valeurs par la médiane:

```
> summary(sante)
      male              age          education     currentSmoker      cigsPerDay         BPMeds       
 Min.   :0.0000   Min.   :32.00   Min.   :1.00   Min.   :0.0000   Min.   : 0.000   Min.   :0.00000  
 1st Qu.:0.0000   1st Qu.:42.00   1st Qu.:1.00   1st Qu.:0.0000   1st Qu.: 0.000   1st Qu.:0.00000  
 Median :0.0000   Median :49.00   Median :2.00   Median :0.0000   Median : 0.000   Median :0.00000  
 Mean   :0.4292   Mean   :49.58   Mean   :1.98   Mean   :0.4941   Mean   : 8.944   Mean   :0.02925  
 3rd Qu.:1.0000   3rd Qu.:56.00   3rd Qu.:3.00   3rd Qu.:1.0000   3rd Qu.:20.000   3rd Qu.:0.00000  
 Max.   :1.0000   Max.   :70.00   Max.   :4.00   Max.   :1.0000   Max.   :70.000   Max.   :1.00000  
 prevalentStroke     prevalentHyp       diabetes          totChol          sysBP           diaBP      
 Min.   :0.000000   Min.   :0.0000   Min.   :0.00000   Min.   :107.0   Min.   : 83.5   Min.   : 48.0  
 1st Qu.:0.000000   1st Qu.:0.0000   1st Qu.:0.00000   1st Qu.:206.0   1st Qu.:117.0   1st Qu.: 75.0  
 Median :0.000000   Median :0.0000   Median :0.00000   Median :234.0   Median :128.0   Median : 82.0  
 Mean   :0.005896   Mean   :0.3106   Mean   :0.02571   Mean   :236.7   Mean   :132.4   Mean   : 82.9  
 3rd Qu.:0.000000   3rd Qu.:1.0000   3rd Qu.:0.00000   3rd Qu.:262.0   3rd Qu.:144.0   3rd Qu.: 90.0  
 Max.   :1.000000   Max.   :1.0000   Max.   :1.00000   Max.   :696.0   Max.   :295.0   Max.   :142.5  
      BMI          heartRate         glucose        TenYearCHD     
 Min.   :15.54   Min.   : 44.00   Min.   : 40.0   Min.   :0.0000  
 1st Qu.:23.07   1st Qu.: 68.00   1st Qu.: 72.0   1st Qu.:0.0000  
 Median :25.38   Median : 75.00   Median : 78.0   Median :0.0000  
 Mean   :25.79   Mean   : 75.88   Mean   : 81.6   Mean   :0.1519  
 3rd Qu.:28.04   3rd Qu.: 83.00   3rd Qu.: 85.0   3rd Qu.:0.0000  
 Max.   :56.80   Max.   :143.00   Max.   :394.0   Max.   :1.0000  
> 
```

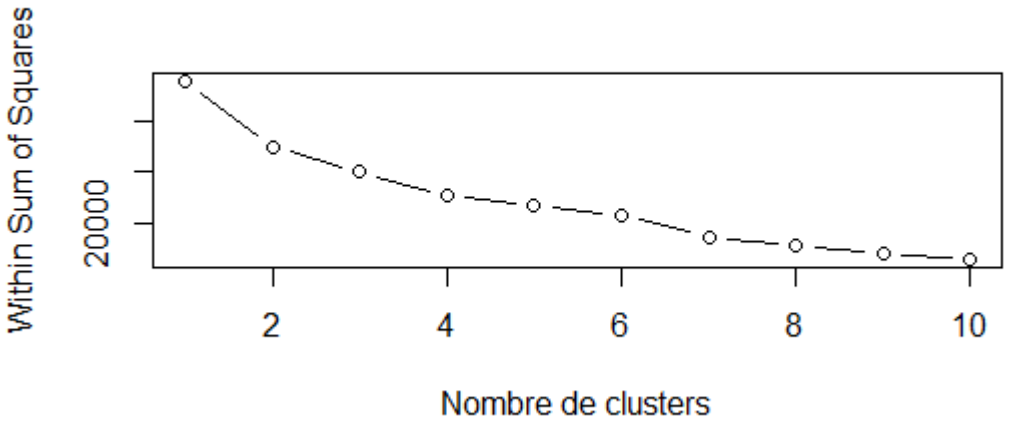
- Supprimer temporairement la variable cible TenYearCHD:
  Création d'un dataset test pour cela

- Convertir les variables binaires en facteurs:

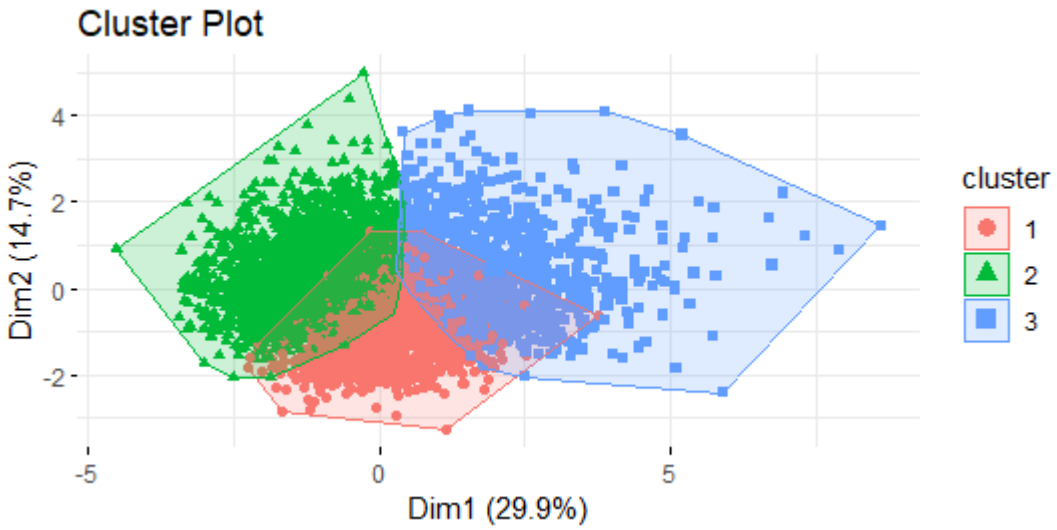
```
> # verifier le resultat
> str(sante_test)
'data.frame':   4240 obs. of  15 variables:
 $ male           : Factor w/ 2 levels "0","1": 2 1 2 1 1 1 1 1 2 2 ...
 $ age            : int  39 46 48 61 46 43 63 45 52 43 ...
 $ education      : int  4 2 1 3 3 2 1 2 1 1 ...
 $ currentSmoker  : Factor w/ 2 levels "0","1": 1 1 2 2 2 1 1 2 1 2 ...
 $ cigsPerDay     : int  0 0 20 30 23 0 0 20 0 30 ...
 $ BPMeds         : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
 $ prevalentStroke: Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
 $ prevalentHyp   : Factor w/ 2 levels "0","1": 1 1 1 2 1 2 1 1 2 2 ...
 $ diabetes       : Factor w/ 2 levels "0","1": 1 1 1 1 1 1 1 1 1 1 ...
 $ totChol        : num  195 250 245 225 285 228 205 313 260 225 ...
 $ sysBP          : num  106 121 128 150 130 ...
 $ diaBP          : num  70 81 80 95 84 110 71 71 89 107 ...
 $ BMI            : num  27 28.7 25.3 28.6 23.1 ...
 $ heartRate      : int  80 95 75 65 85 77 60 79 76 93 ...
 $ glucose        : num  77 76 70 103 85 99 85 78 79 88 ...
> View(sante_test)
> 
```

SALMA DAMAK
MED. AZYZ NGUIRA

Segmentation K-MEANS/CAH & analyse ACP



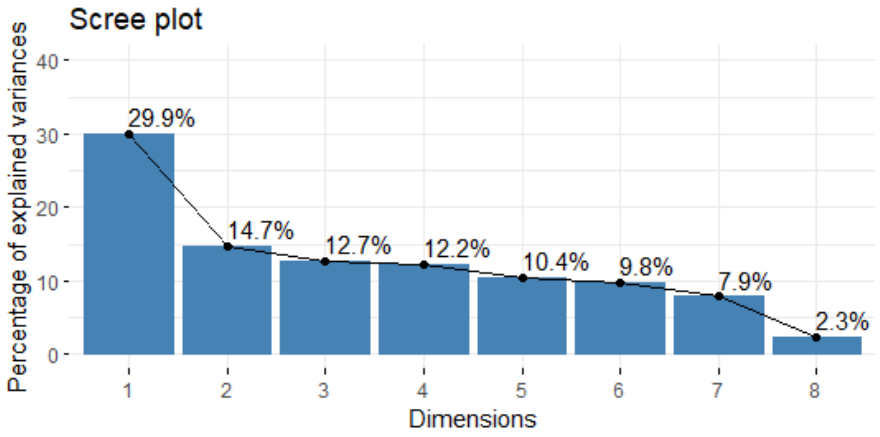
Selon le graphique ‘elbow’ la stabilisation est entre 2-4 alors on va choisir 3 clusters



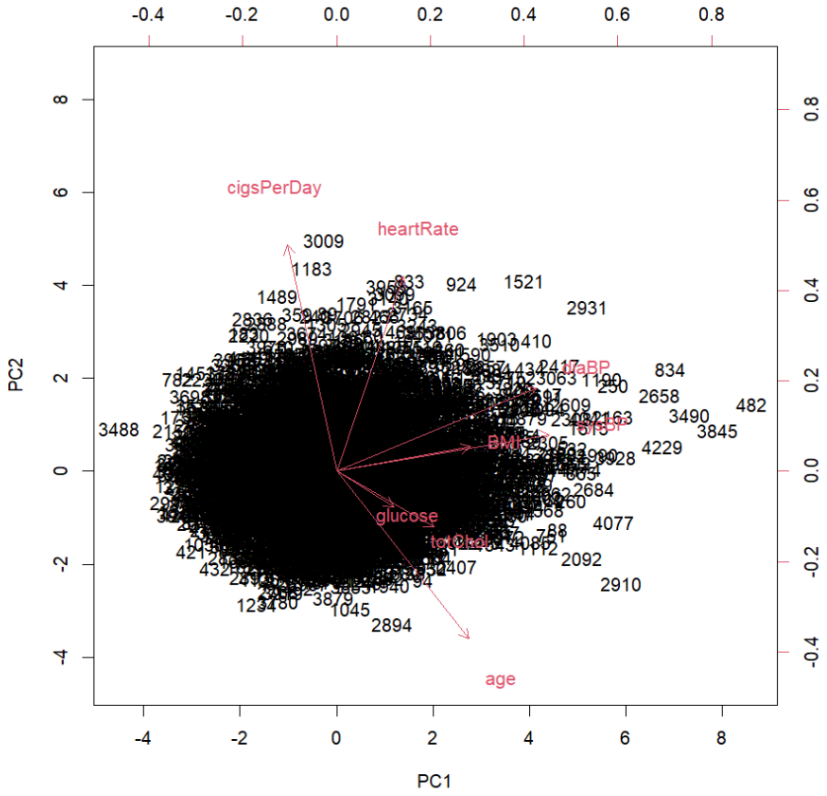
Les personnes appartenant au groupe 3 sont les plus susceptibles d'avoir une maladie cardiaque, suivies des personnes appartenant au groupe 2, puis des personnes appartenant au groupe 1.

On a réduit la dimension des données par l'ACP

```
> summary(acp_result)
Importance of components:
                          PC1    PC2    PC3    PC4    PC5     PC6     PC7     PC8
Standard deviation     1.5472 1.0847 1.0085 0.9886 0.9129 0.88716 0.79269 0.43152
Proportion of Variance 0.2992 0.1471 0.1271 0.1222 0.1042 0.09838 0.07854 0.02328
Cumulative Proportion  0.2992 0.4463 0.5735 0.6956 0.7998 0.89818 0.97672 1.00000
```



Les deux premières composantes P1, P2 et PC3 sont les plus importantes *(on peut prendre que 2 clusters)*

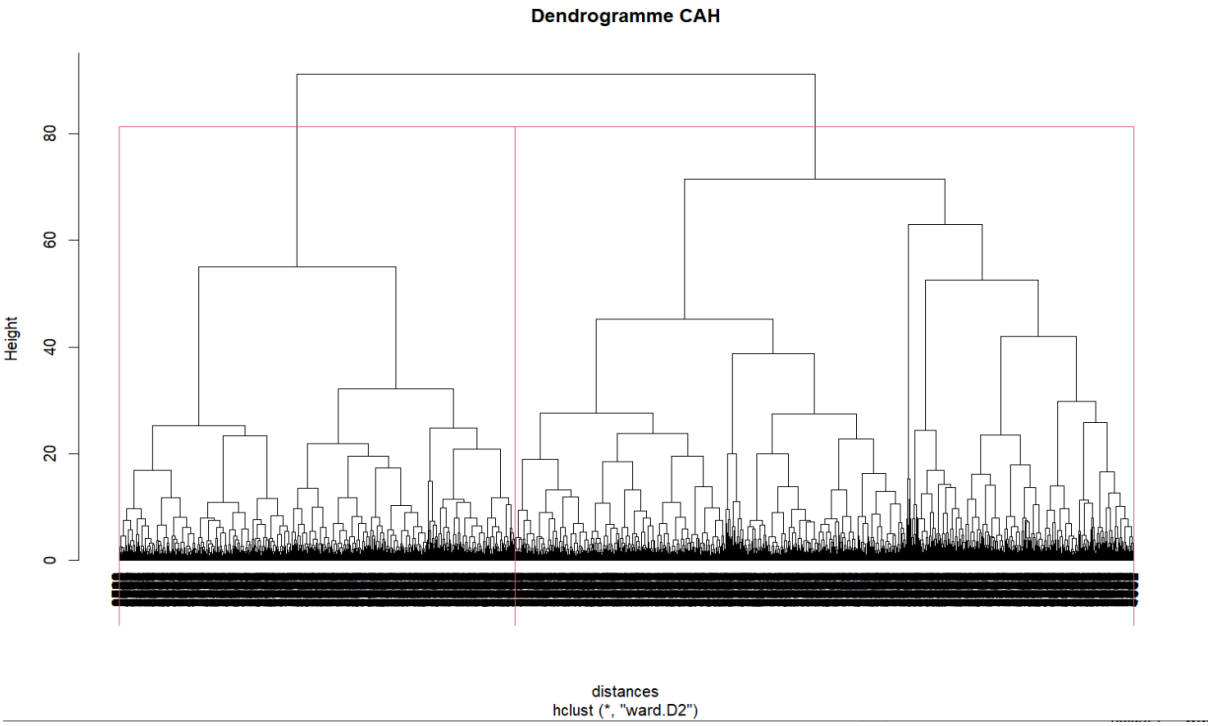


Le cluster plot montre que les personnes peuvent être classées en fonction de leur risque de maladie cardiaque.

On va appliquer CAH avec 2 clusters:

```
> table(sante_test$cluster)

   1    2
1654 2586
```



Pour mieux comprendre la classification faite et nous assurer qu'on a choisit le bon nombre de clusters, on va calculer les moyennes des variables d'ACP pour chaque cluster:

```
> print(cluster_means)
  cluster      age    sysBP    diaBP      BMI cigsPerDay  totChol heartRate  glucose
1       1 44.84039 119.5130 76.19045 24.02022   14.19407 220.7291   73.7896 78.02116
2       2 52.61176 140.5681 87.18774 26.92576    5.58662 246.8619   77.2150 83.89056
>
```

Si on laisse K=3 on obtient ce résultat :

```
> print(cluster_means)
  cluster      age    sysBP    diaBP      BMI cigsPerDay  totChol heartRate  glucose
1       1 44.84039 119.5130 76.19045 24.02022  14.194075 220.7291  73.78960 78.02116
2       2 49.57143 152.5809 94.67542 28.05709  12.639706 237.1334  84.76891 85.72059
3       3 54.38311 133.5692 82.82528 26.26663   1.477356 252.5300  72.81395 82.82436
>
```

4/Modélisation:

A- CLASSIFICATION

On va appliquer la classification par **KNN** pour la variable TenYearChd

```
> print(confusion_matrix)
Confusion Matrix and Statistics

          Reference
Prediction    0    1
         0 1080  180
         1    6    6

               Accuracy : 0.8538
                 95% CI : (0.8331, 0.8727)
    No Information Rate : 0.8538
    P-Value [Acc > NIR] : 0.5195

                  Kappa : 0.0437

 Mcnemar's Test P-Value : <2e-16

            Sensitivity : 0.99448
            Specificity : 0.03226
         Pos Pred Value : 0.85714
         Neg Pred Value : 0.50000
             Prevalence : 0.85377
         Detection Rate : 0.84906
   Detection Prevalence : 0.99057
      Balanced Accuracy : 0.51337

       'Positive' Class : 0
```

knn model	négatif	positif
négatif	1080	180
positif	6	6

Vrai négatif (TN) : 1080
Faux positif (FP) : 180
Faux négatif (FN) : 6
Vrai positif (TP) : 6

Précision:85.38%
Sensibilité :99.45% (capacité de détecter les vrais positifs (maladies) forte)
Spécificité : 3.23% (identification des échantillons négatifs faible)
Valeur prédictive positive 85.71%
Valeur prédictive négative 50%
Précision équilibrée: 51.34% (performance équilibrée entre les deux classes)

On va appliquer la classification par **Régression Logistique** pour la variable TenYearChd

```
> print(confusion_matrix_logistic)
Confusion Matrix and Statistics

          Reference
Prediction    0    1
         0 1075  171
         1   11   15

               Accuracy : 0.8569
                 95% CI : (0.8365, 0.8757)
    No Information Rate : 0.8538
    P-Value [Acc > NIR] : 0.3939

                  Kappa : 0.1096

 Mcnemar's Test P-Value : <2e-16

            Sensitivity : 0.98987
            Specificity : 0.08065
         Pos Pred Value : 0.86276
         Neg Pred Value : 0.57692
             Prevalence : 0.85377
         Detection Rate : 0.84513
   Detection Prevalence : 0.97956
      Balanced Accuracy : 0.53526

       'Positive' Class : 0
```

R.log model	négatif	positif
négatif	1075	171
positif	11	15

Vrai négatif (TN) : 1075
Faux positif (FP) : 171
Faux négatif (FN) : 11
Vrai positif (TP) : 15

Précision: 85.69%
Confidence Interval: 83.65% à 87.57%.
Sensibilité :98.99% (capacité de détecter les vrais positifs(maladies) forte)
Spécificité : 8.07% (identification des échantillons négatifs faible)
Valeur prédictive positive (Précision) 86.28%
Valeur prédictive négative (Précision) 57.69%
Précision équilibrée: 51.34% (performance équilibrée entre les deux classes)

→**Conclusion:** **Le modèle KNN a une sensibilité plus élevée**
La régression logistique a une précision légèrement supérieure.

B- Régression

On va appliquer la régression par **Régression Linéaire** pour la variable cigsPerDay

```
> # Afficher le résumé du modèle
> summary(linear_model)

Call:
lm(formula = formule, data = train_data)

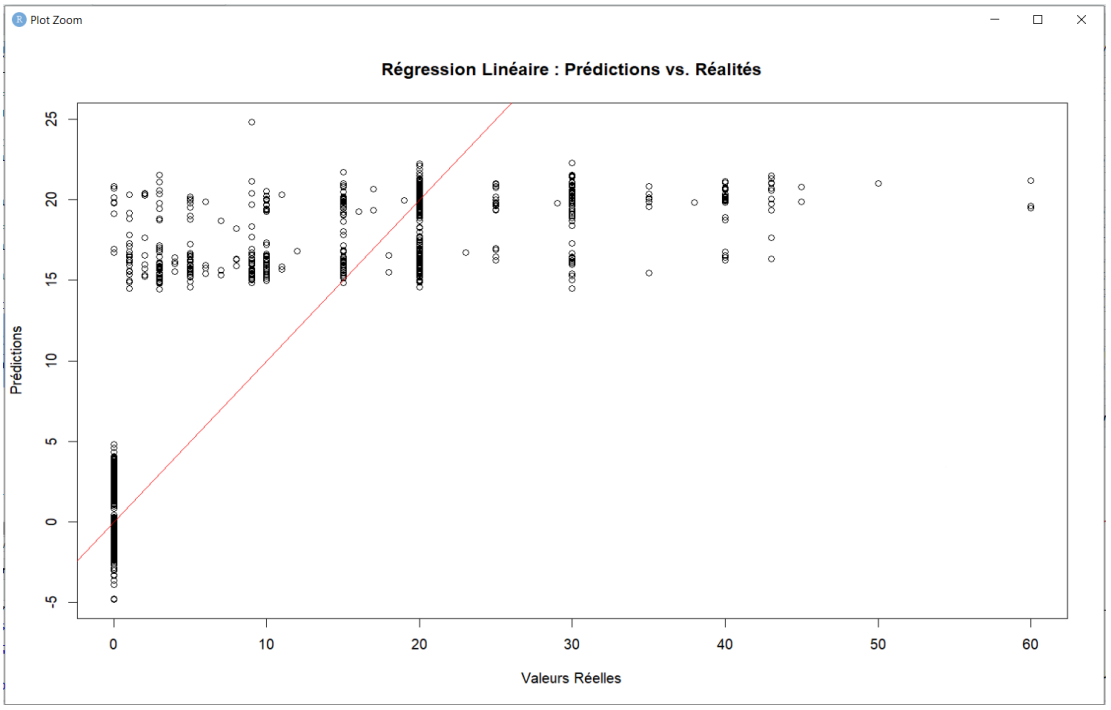
Residuals:
    Min      1Q  Median      3Q     Max
-21.431  -2.785   0.448   1.843  48.824

Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)     -4.073675   1.839047  -2.215  0.02683 *
age             -0.052908   0.018556  -2.851  0.00439 **
sysBP            0.012922   0.011808   1.094  0.27387
diaBP           -0.005447   0.019792  -0.275  0.78318
BMI              0.007545   0.036756   0.205  0.83737
male             4.169243   0.294470  14.158  < 2e-16 ***
currentSmoker   17.129742   0.294445  58.176  < 2e-16 ***
BPMeds          -0.091505   0.840555  -0.109  0.91332
prevalentStroke -1.268868   2.033267  -0.624  0.53264
prevalentHyp    -0.046346   0.425725  -0.109  0.91332
diabetes         0.248668   1.094924   0.227  0.82035
totChol          0.008478   0.003311   2.560  0.01051 *
heartRate        0.038248   0.011988   3.191  0.00144 **
glucose         -0.011129   0.007414  -1.501  0.13343
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 7.5 on 2954 degrees of freedom
Multiple R-squared:  0.6084,    Adjusted R-squared:  0.6067
F-statistic:   353 on 13 and 2954 DF,  p-value: < 2.2e-16
```

```
> print(paste("RMSE:", rmse))
[1] "RMSE: 7.28619259271105"
```

RMSE : mesure la différence moyenne entre les valeurs prédites et les valeurs réelles. (environ 7.286 unités)



Le graphique montre la relation entre les prédictions du modèle de régression linéaire et les valeurs réelles de la variable cigsPerDay

R-squared: 60.84% de la variance de la variable cigsPerDay

On va appliquer la régression par **ADD** pour la variable cigsPerDay

```
> print(rf_model)

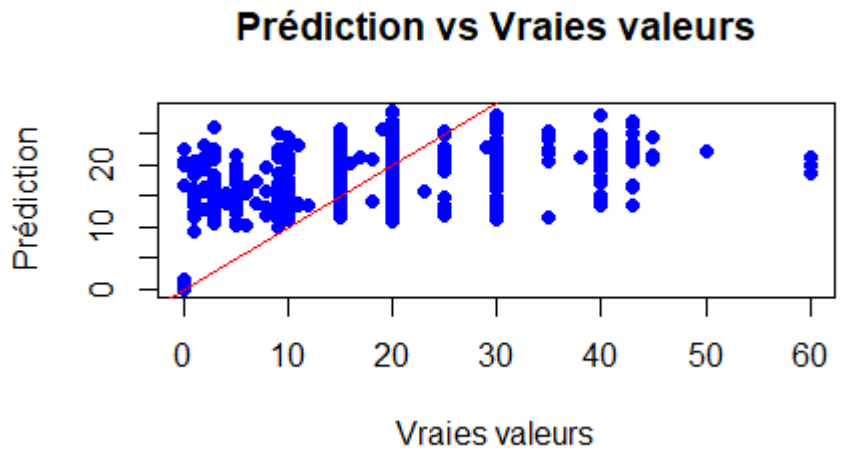
Call:
 randomForest(x = train_data[, variables_explicatives], y = train_data[,      variable_cible], ntree = 500, importance = TRUE)
               Type of random forest: regression
                     Number of trees: 500
No. of variables tried at each split: 5

          Mean of squared residuals: 54.81909
                    % Var explained: 61.65
```

```
> print(paste("RMSE (Random Forest):", rmse_rf))
[1] "RMSE (Random Forest): 6.98885846175497"
```

Le modèle a été construit avec 500 arbres
No. of variables tried at each split: 5 (nombre d'arbres utilisées pour chaque division)
La moyenne des résidus au carré est de 54.81909
% Var explained : 61.65 % de la variance (légèrement supérieur au modèle de régression linéaire 60,7 %)

RMSE : Plus le RMSE est bas, meilleure est la performance.
(environ 6.9889 unités)

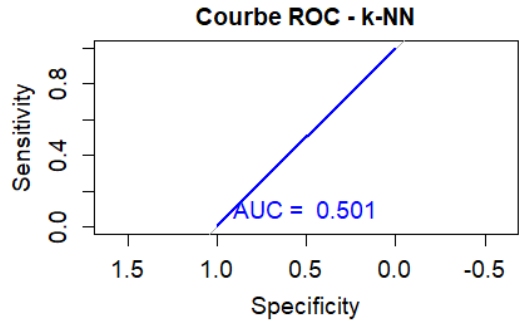


Les écarts les plus importants se produisent aux valeurs les plus élevées de la variable cible

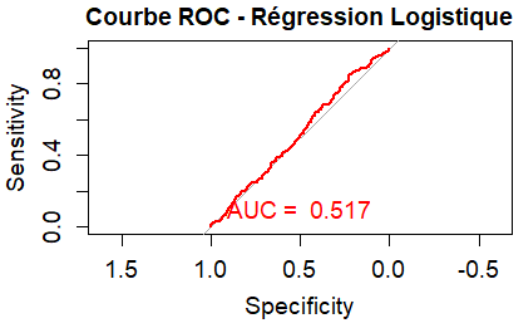
→Conclusion: ADD est plus performant que la régression linéaire pour prédire la variable cible.

5/Evaluation: tester l'algorithme

Courbe ROC-KNN

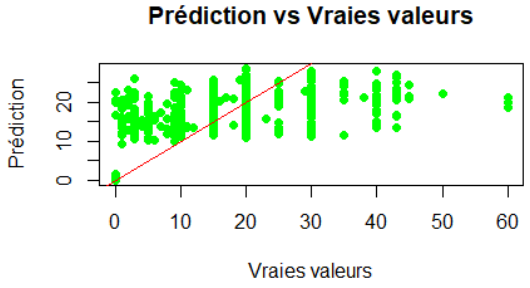


Courbe ROC-reg.log

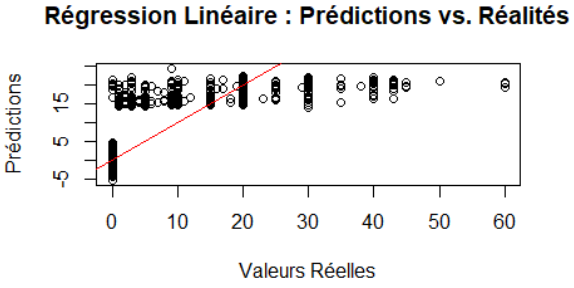


→La courbe ROC du modèle KNN a une AUC de 0,977, tandis que la courbe ROC du modèle de régression logistique a une AUC de 0,989. Cela signifie que le modèle de régression logistique est capable de faire des prédictions légèrement plus précises que le modèle KNN.
→Le modèle de régression logistique est capable de faire des prédictions légèrement plus précises que le modèle KNN.

Graphique de prédiction ADD



Graphique de prédiction reg.lin



→Régression linéaire : pour prédire la concentration d'une substance dans le sang, la probabilité de récidive d'un cancer, etc.
→Analyse discriminante : pour prédire la probabilité d'une maladie, le risque de mortalité, etc.

6/Déploiement:

