DATA FROMAGES

1/ Compréhension des métiers:

- Objectif Métier : réaliser une étude statistique sur les indicateurs financiers (FD, RA, AD, AV) des 46 entreprises fournies dans le fichier entreprise.txt.
- Objectif Data Mining:

Utiliser les techniques avancées de data mining pour analyser les données financières des entreprises (indicateurs FD, RA, AD, AV) contenues dans le fichier entreprise.txt. L'objectif est de découvrir des modèles, des tendances ou des informations cachées dans ces données, qui ne seraient pas évidentes à observer de manière traditionnelle. Ces informations peuvent être utilisées pour prendre des décisions commerciales plus éclairées, identifier les entreprises à haut risque ou potentiellement performantes, et formuler des recommandations précises pour améliorer la santé financière des entreprises clientes de R.E.F.S.

2/Compréhension des données:

On a deux possibilités:

- *Éliminer la variable descriptive qualitative (ET)*
- *Spécifier la première colonne en tant que l'indice de ce dataset*

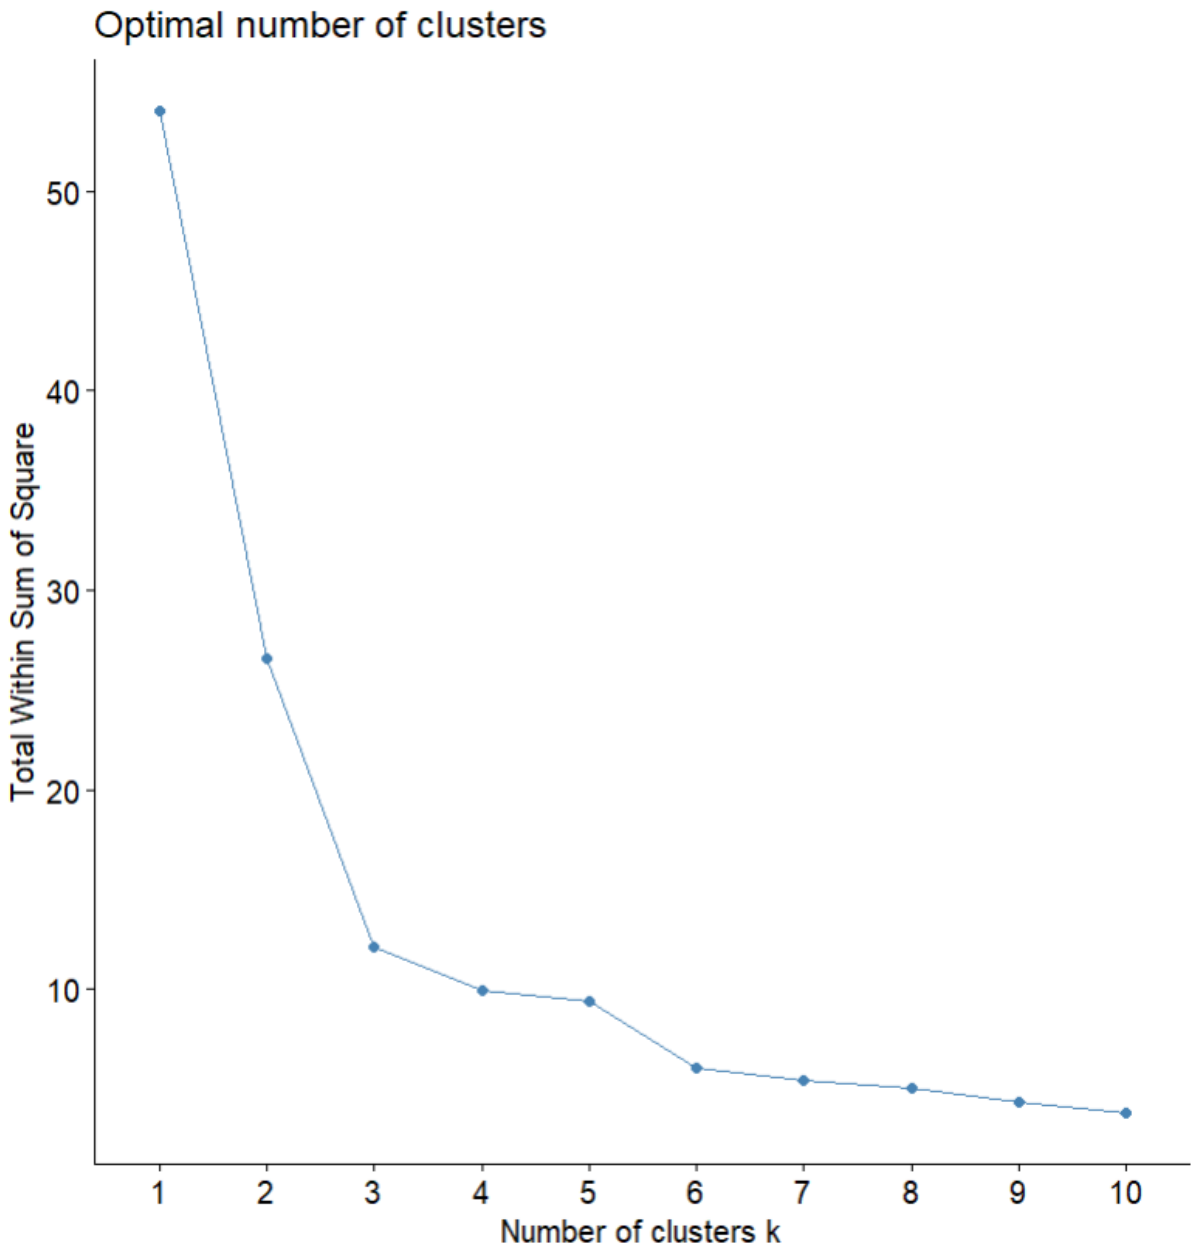
	FD	RA	AD	AV	ET
1	-0.45	-0.41	1.09	0.45	F
2	-0.56	-0.31	1.51	0.16	F
3	0.06	0.02	1.01	0.40	F
4	-0.07	-0.09	1.45	0.26	F
5	-0.10	-0.09	1.45	0.26	F
6	-0.14	-0.07	0.71	0.28	F
7	0.04	0.01	1.50	0.71	F
8	-0.07	-0.06	1.37	0.40	F
9	0.07	-0.01	1.37	0.40	F
10	-1.14	-1.14	1.42	0.43	F
11	-0.23	-0.30	0.33	0.18	F
12	0.07	0.02	1.31	0.25	F
13	0.01	0.00	2.15	0.70	F
14	-0.28	-0.23	1.19	0.66	F
15	0.15	0.05	1.88	0.27	F

```
> summary(entreprise)
       FD                  RA                  AD              AV              ET
 Min.   :-1.14000   Min.   :-1.14000   Min.   :0.330   Min.   :0.1300   Length:46
 1st Qu.:-0.07000   1st Qu.:-0.05250   1st Qu.:1.370   1st Qu.:0.2725   Class :character
 Median : 0.12000   Median : 0.03500   Median :1.935   Median :0.4100   Mode  :character
 Mean   : 0.07457   Mean   :-0.01696   Mean   :2.031   Mean   :0.4241
 3rd Qu.: 0.21500   3rd Qu.: 0.07000   3rd Qu.:2.425   3rd Qu.:0.5375
 Max.   : 0.58000   Max.   : 0.60000   Max.   :5.060   Max.   :0.9500
> #renvoie les noms des colonnes (variables)
> names(entreprise)
[1] "FD" "RA" "AD" "AV" "ET"
> #affiche la structure de la bd
> str(entreprise)
'data.frame':   46 obs. of  5 variables:
 $ FD: num  -0.45 -0.56 0.06 -0.07 -0.1 -0.14 0.04 -0.07 0.07 -1.14 ...
 $ RA: num  -0.41 -0.31 0.02 -0.09 -0.09 -0.07 0.01 -0.06 -0.01 -1.14 ...
 $ AD: num  1.09 1.51 1.01 1.45 1.45 0.71 1.5 1.37 1.37 1.42 ...
 $ AV: num  0.45 0.16 0.4 0.26 0.26 0.28 0.71 0.4 0.4 0.43 ...
 $ ET: chr  "F" "F" "F" "F" ...
> dim(entreprise)
[1] 46  5
```

3/Préparation des données:

K-MEANS

Choix du nombre des clusters: (on remarque que la stabilisation de l' "elbow" entre 2 et 3 (donc on va choisir soit 2 ou 3 clusters)


Optimal number of clusters
Total Within Sum of Square
50
40
30
20
10
1
2
3
4
5
6
7
8
9
10
Number of clusters k

utiliser K-means pour la segmentation des données (3 clusters)

```
> k<-kmeans(entreprise.seg,3) #3 c'est le nombre de classes
> k
K-means clustering with 3 clusters of sizes 20, 4, 22

Cluster means:
          FD      RA       AD        AV
1 -0.1180000 -0.1405 1.213500 0.3965000
2  0.4425000  0.0675 4.510000 0.4725000
3  0.1827273  0.0800 2.323636 0.4404545

Clustering vector:
 1  2  3  4  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29 30 31 32 33 34
 1  1  1  1  1  1  1  1  1  1  1  1  3  1  3  3  1  1  1  1  1  3  3  3  3  2  2  3  3  3  3  3  3  1
35 36 37 38 39 40 41 42 43 44 45 46
 3  3  3  3  3  3  1  2  3  3  3  2

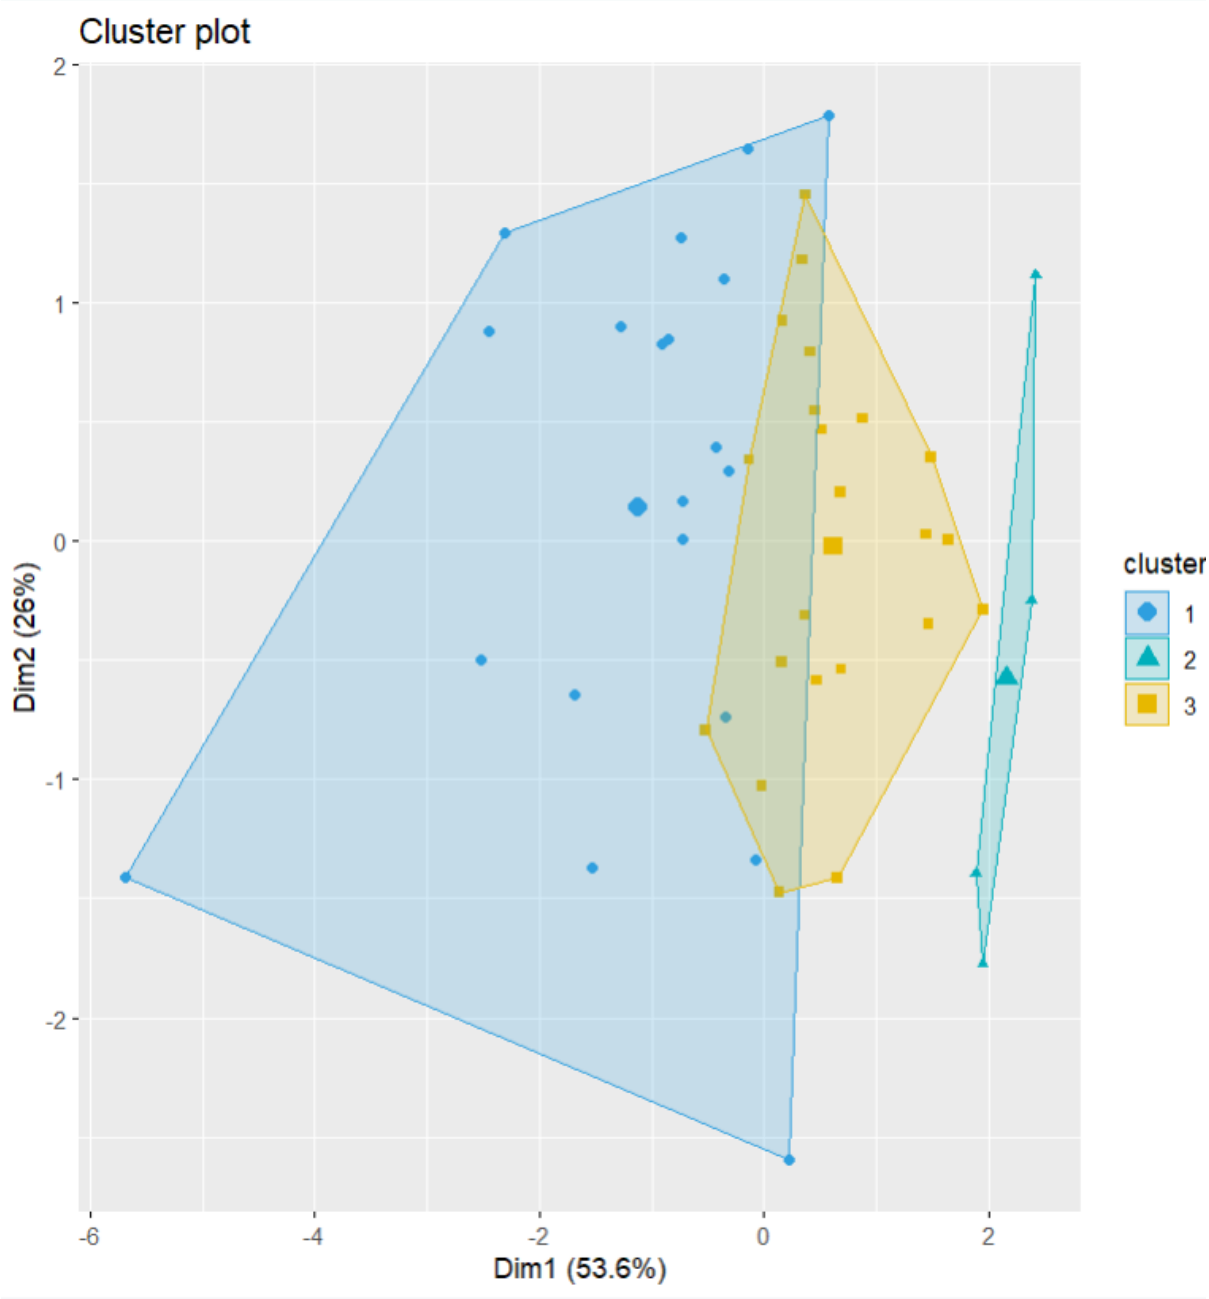
Within cluster sum of squares by cluster:
[1] 6.697325 0.686025 4.703241
 (between_SS / total_SS =  77.6 %)

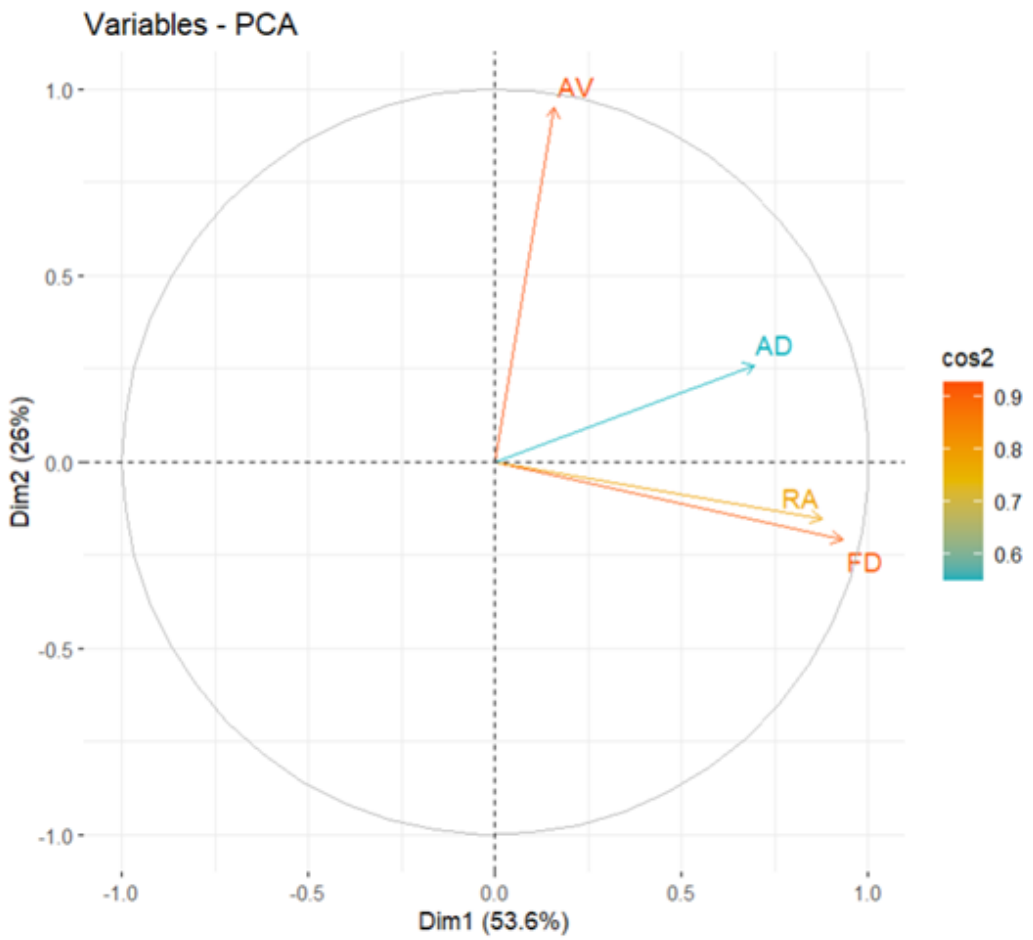
Available components:

[1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss" "betweenss"
[7] "size"         "iter"         "ifault"
> k$centers
          FD      RA       AD        AV
1 -0.1180000 -0.1405 1.213500 0.3965000
2  0.4425000  0.0675 4.510000 0.4725000
3  0.1827273  0.0800 2.323636 0.4404545
> library(cluster)
```

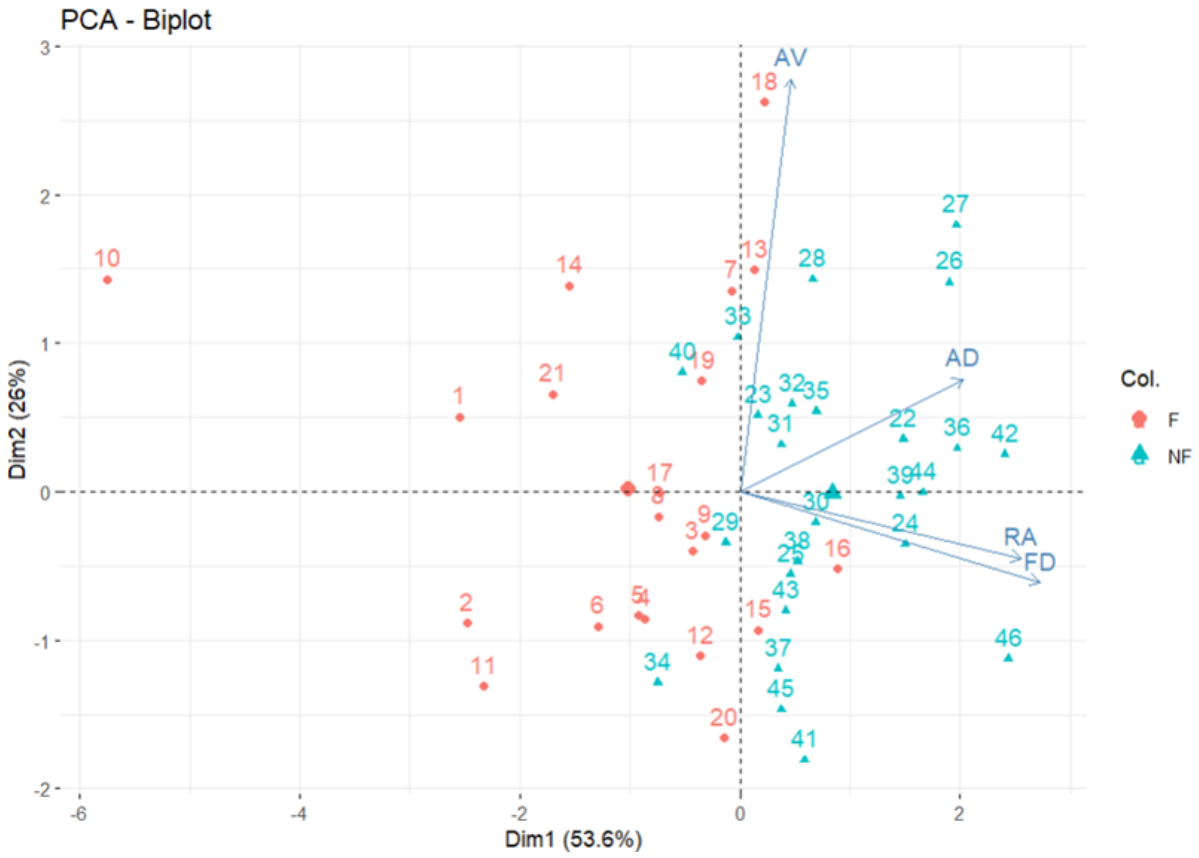
4/Modélisation:

Visualisation des clusters choisis

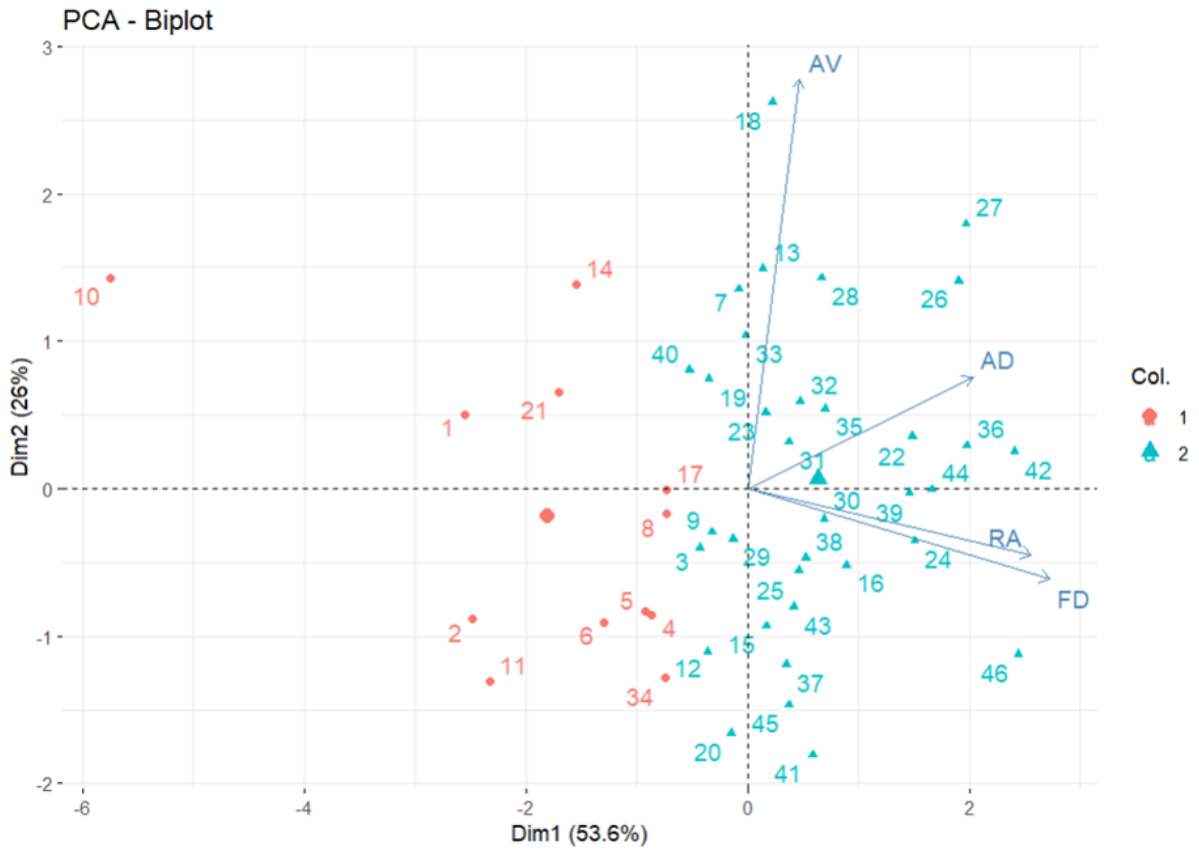

Cluster plot
Dim2 (26%)
Dim1 (53.6%)
2
1
0
-1
-2
-6
-4
-2
0
2
cluster
1
2
3



On observe que les angles sont proche à 0 c'est-à-dire l'individu est bien représenté



les entreprises de la partie droite de l'axe de dim1 est NF ou les individus sont corrélés positivement(même sens) .



Après avoir effectué le clustering en utilisant 2 classes, nous observons que les entreprises sont segmentées de manière similaire à la segmentation basée sur la variable cible. Cette cohérence dans les résultats indique une forte corrélation entre les clusters identifiés par l'algorithme de clustering et les catégories définies par la variable cible. Cela suggère que le modèle de clustering a réussi à capturer les schémas sous-jacents dans les données qui sont pertinents pour la variable cible, renforçant ainsi la validité de notre approche de clustering.

Afin de vérifier notre choix de nombre de classes est optimal on va calculer l'inertie (L'inertie est une mesure de la similarité des clusters)

