DATA BREAST

1/ Compréhension des métiers:

- Objectif Métier (Détecter les caractéristiques):
  - Identifier les caractéristiques clés associées à la détection du cancer du sein.
  - Comprendre les facteurs qui contribuent à la classification des tumeurs bénignes ou malignes.
  - Améliorer la capacité à diagnostiquer le cancer du sein en se basant sur des caractéristiques spécifiques.

- Objectif Data Mining:

Construire un modèle de data mining pour prédire la nature d'une tumeur (bénigne ou maligne) en fonction de ses caractéristiques.

2/Compréhension des données:

Fromages.R | TD3.R | tennis.R | automobiles.R | VENTE.R | breast.R | breast

Filter

	clump	ucellsize	ucellshape	mgadhesion	sepics	bnuclei	bchromatin	normnucl	mitoses	classe
1	2	1	1	1	2	1	1	1	1	begnin
2	1	2	2	1	2	1	1	1	1	begnin
3	1	1	1	1	1	1	2	1	1	begnin
4	2	1	1	1	2	1	1	1	1	begnin
5	1	1	1	1	2	1	2	1	1	begnin
6	3	1	1	1	2	1	2	1	1	begnin
7	5	10	6	1	10	4	4	10	10	malignant
8	1	1	1	1	1	1	3	1	1	begnin
9	1	1	1	1	2	1	1	1	1	begnin
10	10	10	10	10	6	10	8	1	5	malignant
11	7	9	4	10	10	3	5	3	3	malignant
12	8	8	9	6	6	3	10	10	1	malignant
13	1	1	1	1	2	3	3	1	1	begnin
14	3	1	4	1	2	4	3	1	1	begnin
15	1	1	1	1	2	1	1	1	8	begnin
16	1	1	1	1	2	4	2	1	1	begnin
17	3	7	7	4	4	9	4	8	1	malignant
18	3	1	1	3	2	1	1	1	1	begnin
19	1	1	1	1	2	1	2	1	1	begnin

```
> View(breast)
> summary(breast)
     clump          ucellsize        ucellshape      mgadhesion        sepics         bnuclei
 Min.   : 1.000   Min.   : 1.000   Min.   : 1.000   Min.   : 1.000   Min.   : 1.000   Min.   : 1.000
 1st Qu.: 2.000   1st Qu.: 1.000   1st Qu.: 1.000   1st Qu.: 1.000   1st Qu.: 2.000   1st Qu.: 1.000
 Median : 4.000   Median : 1.000   Median : 2.000   Median : 1.000   Median : 2.000   Median : 1.000
 Mean   : 4.404   Mean   : 3.195   Mean   : 3.201   Mean   : 2.922   Mean   : 3.201   Mean   : 3.619
 3rd Qu.: 6.000   3rd Qu.: 5.000   3rd Qu.: 5.000   3rd Qu.: 4.000   3rd Qu.: 4.000   3rd Qu.: 6.000
 Max.   :10.000   Max.   :10.000   Max.   :10.000   Max.   :10.000   Max.   :10.000   Max.   :10.000
   bchromatin       normnucl         mitoses           classe
 Min.   : 1.000   Min.   : 1.000   Min.   : 1.000   Length:399
 1st Qu.: 2.000   1st Qu.: 1.000   1st Qu.: 1.000   Class :character
 Median : 3.000   Median : 1.000   Median : 1.000   Mode  :character
 Mean   : 3.496   Mean   : 2.872   Mean   : 1.569
 3rd Qu.: 5.000   3rd Qu.: 4.000   3rd Qu.: 1.000
 Max.   :10.000   Max.   :10.000   Max.   :10.000
> head(breast)
# A tibble: 6 × 10
  clump ucellsize ucellshape mgadhesion sepics bnuclei bchromatin normnucl mitoses classe
  <dbl>     <dbl>      <dbl>       <dbl>  <dbl>   <dbl>      <dbl>    <dbl>   <dbl> <chr>
1     2         1          1           1      2       1          1        1       1 begnin
2     1         2          2           1      2       1          1        1       1 begnin
3     1         1          1           1      1       1          2        1       1 begnin
4     2         1          1           1      2       1          1        1       1 begnin
5     1         1          1           1      2       1          2        1       1 begnin
6     3         1          1           1      2       1          2        1       1 begnin
> seuil.hat <- qnorm(1 - 0.1 / 2) / sqrt(nrow(autos))
```

3/Préparation des données:

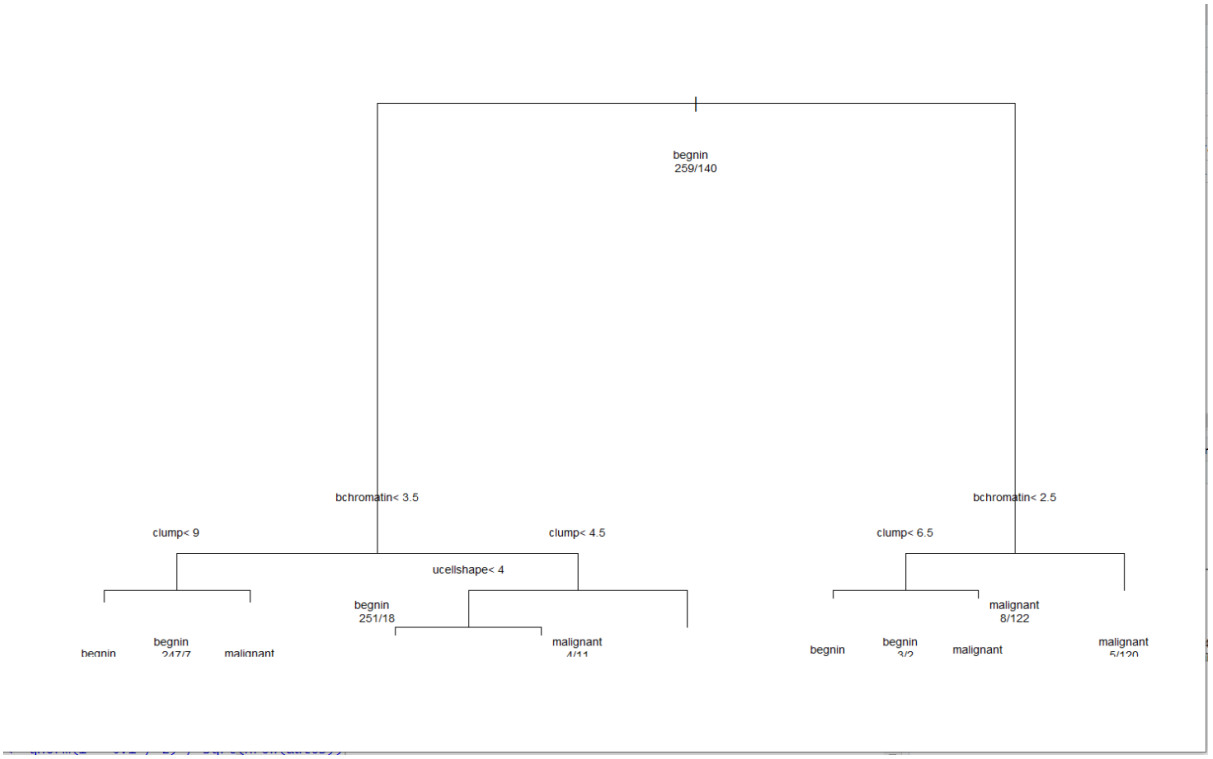
[data = breast.app] - Construction de l'arbre sur l'échantillon « breast.app ».

[classe ~.] - Prédire « classe » à partir des autres variables de la base.

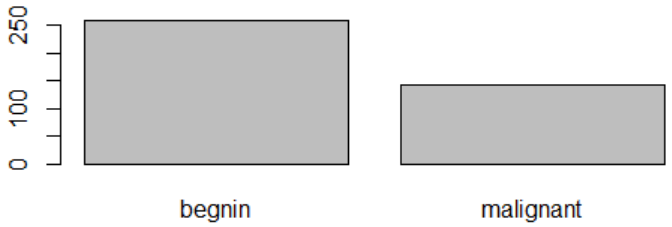
[method = « class »] - On construit un arbre de décision c.-à-d. apprentissage supervisé.

4/Modélisation des données:

- **Construction de l'arbre de décision sur l'échantillon breast**



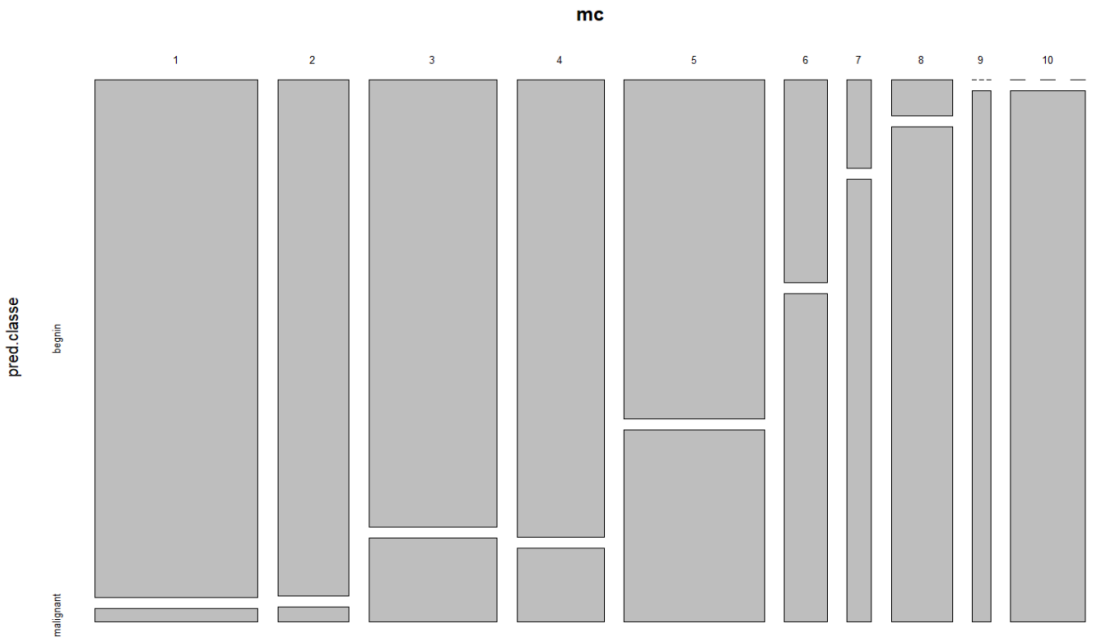
- **Evaluation de l'arbre sur un échantillon test**



begnin malignant
258 141

- **Matrice de de Confusion (Table de Contingence)**

Les Classes de Prédiction		
	Bénigne	Maligne
Bégnine	254	5
Maligne	4	136



5/Evaluation: tester l'algorithme

- **Calcul du taux de l'erreur :**

$$E = 0.09022556$$

E: représente la proportion d'observations mal classées par rapport au total des observations dans votre échantillon de test.
En d'autres termes, environ 9% des prédictions du modèle ne correspondent pas aux vraies classes.

Cela signifie que le modèle a une performance globalement bonne, car le taux d'erreur est relativement bas.