DATA FROMAGES

1/ Compréhension des métiers:

- Objectif Métier (Détecter les caractéristiques):

Classification des Fromages en Fonction de Leurs Caractéristiques Nutritionnelles

L'objectif principal est de classer 29 fromages en catégories distinctes en utilisant leurs caractéristiques nutritionnelles.

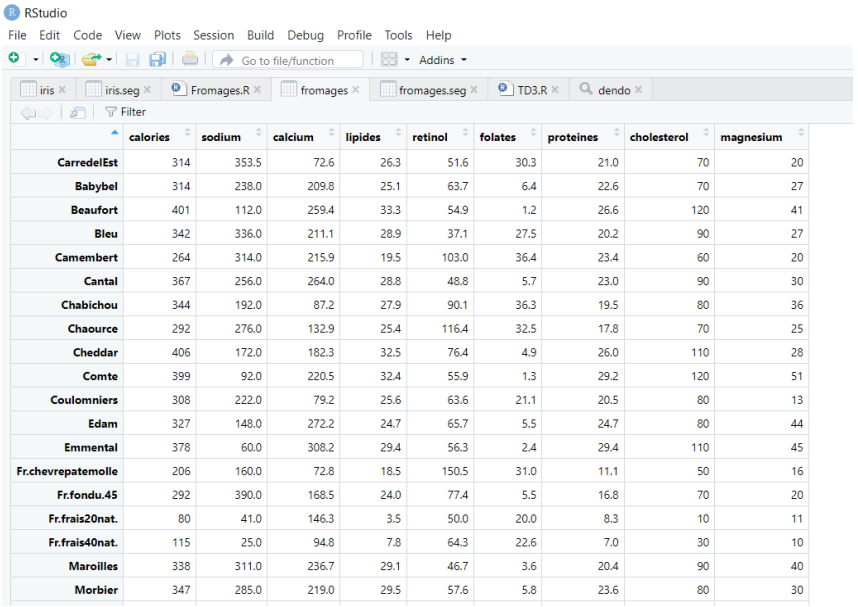
- Objectif Data Mining:

L'objectif du data mining est d'extraire à partir des données des fromages des relations nutritionnelles entre les fromages et créer des clusters qui nous aideront dans la classification des fromages.

2/Compréhension des données:

On a deux possibilités:

- *Éliminer les données qualitatives (les noms des fromages)*
- *Spécifier la première colonne en tant que nom des lignes*



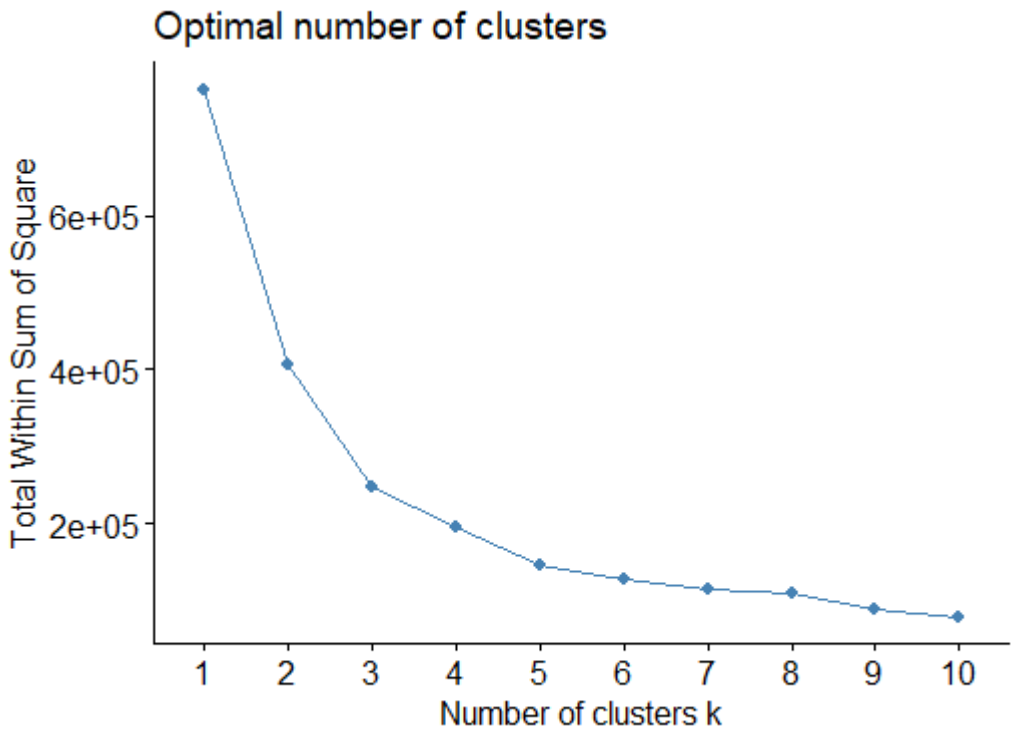
	calories	sodium	calcium	lipides	retinol	folates	proteines	cholesterol	magnesium
CarredelEst	314	353.5	72.6	26.3	51.6	30.3	21.0	70	20
Babybel	314	238.0	209.8	25.1	63.7	6.4	22.6	70	27
Beaufort	401	112.0	259.4	33.3	54.9	1.2	26.6	120	41
Bleu	342	336.0	211.1	28.9	37.1	27.5	20.2	90	27
Camembert	264	314.0	215.9	19.5	103.0	36.4	23.4	60	20
Cantal	367	256.0	264.0	28.8	48.8	5.7	23.0	90	30
Chabichou	344	192.0	87.2	27.9	90.1	36.3	19.5	80	36
Chaource	292	276.0	132.9	25.4	116.4	32.5	17.8	70	25
Cheddar	406	172.0	182.3	32.5	76.4	4.9	26.0	110	28
Comte	399	92.0	220.5	32.4	55.9	1.3	29.2	120	51
Coulomniers	308	222.0	79.2	25.6	63.6	21.1	20.5	80	13
Edam	327	148.0	272.2	24.7	65.7	5.5	24.7	80	44
Emmental	378	60.0	308.2	29.4	56.3	2.4	29.4	110	45
Fr.chevrepatemolle	206	160.0	72.8	18.5	150.5	31.0	11.1	50	16
Fr.fondu.45	292	390.0	168.5	24.0	77.4	5.5	16.8	70	20
Fr.frais20nat.	80	41.0	146.3	3.5	50.0	20.0	8.3	10	11
Fr.frais40nat.	115	25.0	94.8	7.8	64.3	22.6	7.0	30	10
Maroilles	338	311.0	236.7	29.1	46.7	3.6	20.4	90	40
Morbier	347	285.0	219.0	29.5	57.6	5.8	23.6	80	30

```
> #génère un résumé statistique des variables contenues dans fromages
> summary(fromages)
    calories        sodium          calcium          lipides          retinol          folates         proteines
 Min.   : 70   Min.   : 22.0   Min.   : 72.6   Min.   : 3.40   Min.   : 37.10   Min.   : 1.20   Min.   : 4.10
 1st Qu.:292   1st Qu.:140.0   1st Qu.:132.9   1st Qu.:23.40   1st Qu.: 51.60   1st Qu.: 4.90   1st Qu.:17.80
 Median :321   Median :223.0   Median :202.3   Median :26.30   Median : 62.30   Median : 6.40   Median :21.00
 Mean   :300   Mean   :210.1   Mean   :185.7   Mean   :24.16   Mean   : 67.56   Mean   :13.01   Mean   :20.17
 3rd Qu.:355   3rd Qu.:276.0   3rd Qu.:220.5   3rd Qu.:29.10   3rd Qu.: 76.40   3rd Qu.:21.10   3rd Qu.:23.40
 Max.   :406   Max.   :432.0   Max.   :334.6   Max.   :33.30   Max.   :150.50   Max.   :36.40   Max.   :35.70
  cholesterol       magnesium
 Min.   : 10.00   Min.   :10.00
 1st Qu.: 70.00   1st Qu.:20.00
 Median : 80.00   Median :26.00
 Mean   : 74.59   Mean   :26.97
 3rd Qu.: 90.00   3rd Qu.:30.00
 Max.   :120.00   Max.   :51.00
> #renvoie les noms des colonnes (variables) de fromages
> names(fromages)
[1] "calories"    "sodium"      "calcium"     "lipides"     "retinol"     "folates"     "proteines"   "cholesterol"
[9] "magnesium"
> #affiche la structure de fromages
> str(fromages)
'data.frame':   29 obs. of  9 variables:
 $ calories   : int  314 314 401 342 264 367 344 292 406 399 ...
 $ sodium     : num  354 238 112 336 314 ...
 $ calcium    : num  72.6 209.8 259.4 211.1 215.9 ...
 $ lipides    : num  26.3 25.1 33.3 28.9 19.5 28.8 27.9 25.4 32.5 32.4 ...
 $ retinol    : num  51.6 63.7 54.9 37.1 103 ...
 $ folates    : num  30.3 6.4 1.2 27.5 36.4 5.7 36.3 32.5 4.9 1.3 ...
 $ proteines  : num  21 22.6 26.6 20.2 23.4 23 19.5 17.8 26 29.2 ...
 $ cholesterol: int  70 70 120 90 60 90 80 70 110 120 ...
 $ magnesium  : int  20 27 41 27 20 30 36 25 28 51 ...
> dim(fromages)
[1] 29  9
```

3/Préparation des données:

K-MEANS

Choix du nombre des clusters: (on remarque que la stabilisation de l' "elbow" entre 3 et 4 (donc on va choisir soit 3 ou 4 clusters)



utiliser K-means pour la segmentation des données (4 clusters)

```
Console  Terminal  Background Jobs
R 4.3.1 · ~/
> fviz_nbclust(fromages.seg,kmeans,method="wss")
> k<-kmeans(fromages.seg,4) #4 c'est le nombre de classes
> k
K-means clustering with 4 clusters of sizes 8, 8, 4, 9

Cluster means:
  calories   sodium  calcium  lipides  retinol   folates proteines cholesterol magnesium
1 322.0000 336.6875 186.0125 26.63750 66.25000 16.312500  20.47500    80.00000  26.50000
2 305.0000 224.3750 130.3750 25.15000 81.38750 18.037500  19.60000    73.75000  23.00000
3 101.7500  44.7500 133.7500  6.27500 55.15000 16.475000   7.20000    18.25000  11.25000
4 364.2222 158.3333 257.8000 29.02222 61.95556  4.066667  26.16667    95.55556  37.88889

Clustering vector:
 [1] 1 2 4 1 1 4 2 2 4 4 2 4 4 2 1 3 3 1 1 4 3 2 2 1 1 4 2 4 3

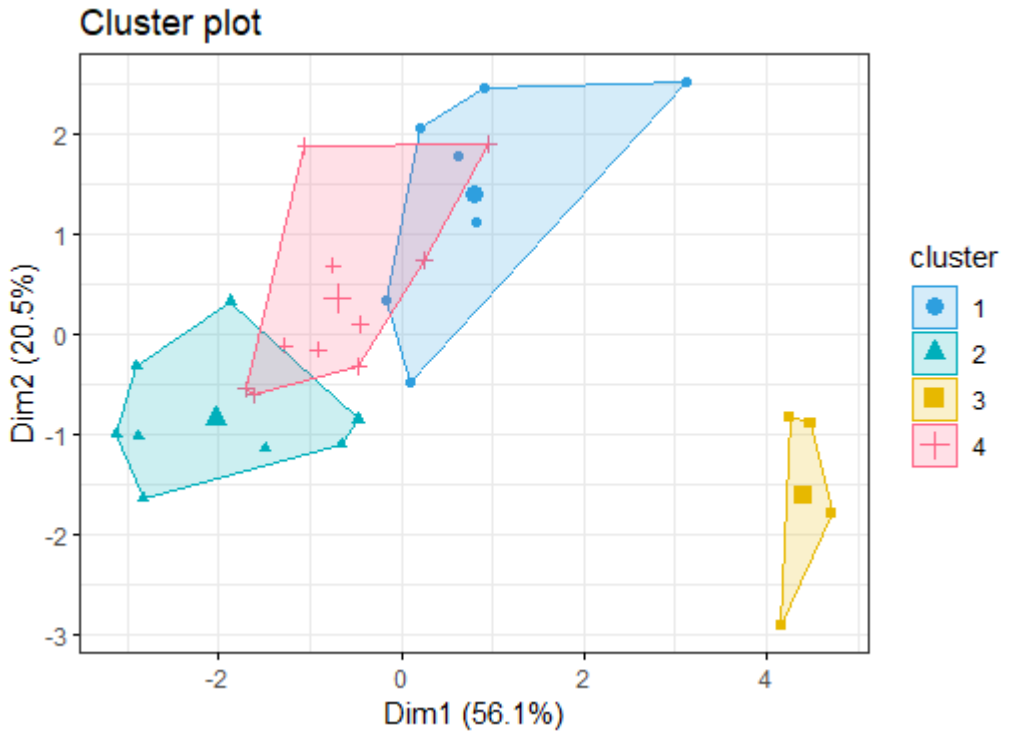
Within cluster sum of squares by cluster:
[1] 53718.38 52015.46 18690.22 70549.80
 (between_SS / total_SS =  74.5 %)

Available components:

[1] "cluster"      "centers"      "totss"        "withinss"     "tot.withinss" "betweenss"    "size"
[8] "iter"         "ifault"
> k$centers
  calories   sodium  calcium  lipides  retinol   folates proteines cholesterol magnesium
1 322.0000 336.6875 186.0125 26.63750 66.25000 16.312500  20.47500    80.00000  26.50000
2 305.0000 224.3750 130.3750 25.15000 81.38750 18.037500  19.60000    73.75000  23.00000
3 101.7500  44.7500 133.7500  6.27500 55.15000 16.475000   7.20000    18.25000  11.25000
4 364.2222 158.3333 257.8000 29.02222 61.95556  4.066667  26.16667    95.55556  37.88889
>
```

4/Modélisation:

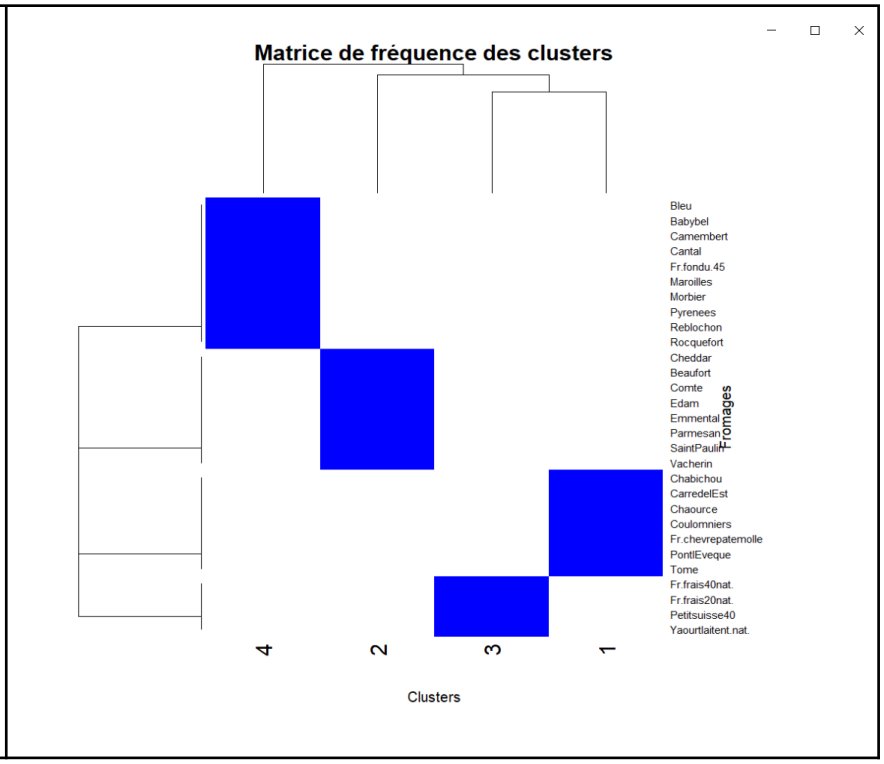
Visualisation des clusters choisis



5/Evaluation: tester l'algorithme

```
> table(fromages$Fromages,k$cluster)

                  1 2 3 4
  Babybel         0 0 0 1
  Beaufort        0 1 0 0
  Bleu            0 0 0 1
  Camembert       0 0 0 1
  Cantal          0 0 0 1
  CarredelEst     1 0 0 0
  Chabichou       1 0 0 0
  Chaource        1 0 0 0
  Cheddar         0 1 0 0
  Comte           0 1 0 0
  Coulomniers     1 0 0 0
  Edam            0 1 0 0
  Emmental        0 1 0 0
  Fr.chevrepatemolle 1 0 0 0
  Fr.fondu.45     0 0 0 1
  Fr.frais20nat.  0 0 1 0
  Fr.frais40nat.  0 0 1 0
  Maroilles       0 0 0 1
  Morbier         0 0 0 1
  Parmesan        0 1 0 0
  Petitsuisse40   0 0 1 0
  PontlEveque     1 0 0 0
  Pyrenees        0 0 0 1
  Reblochon       0 0 0 1
  Rocquefort      0 0 0 1
  SaintPaulin     0 1 0 0
  Tome            1 0 0 0
  Vacherin        0 1 0 0
  Yaourtlaitent.nat. 0 0 1 0
>
```

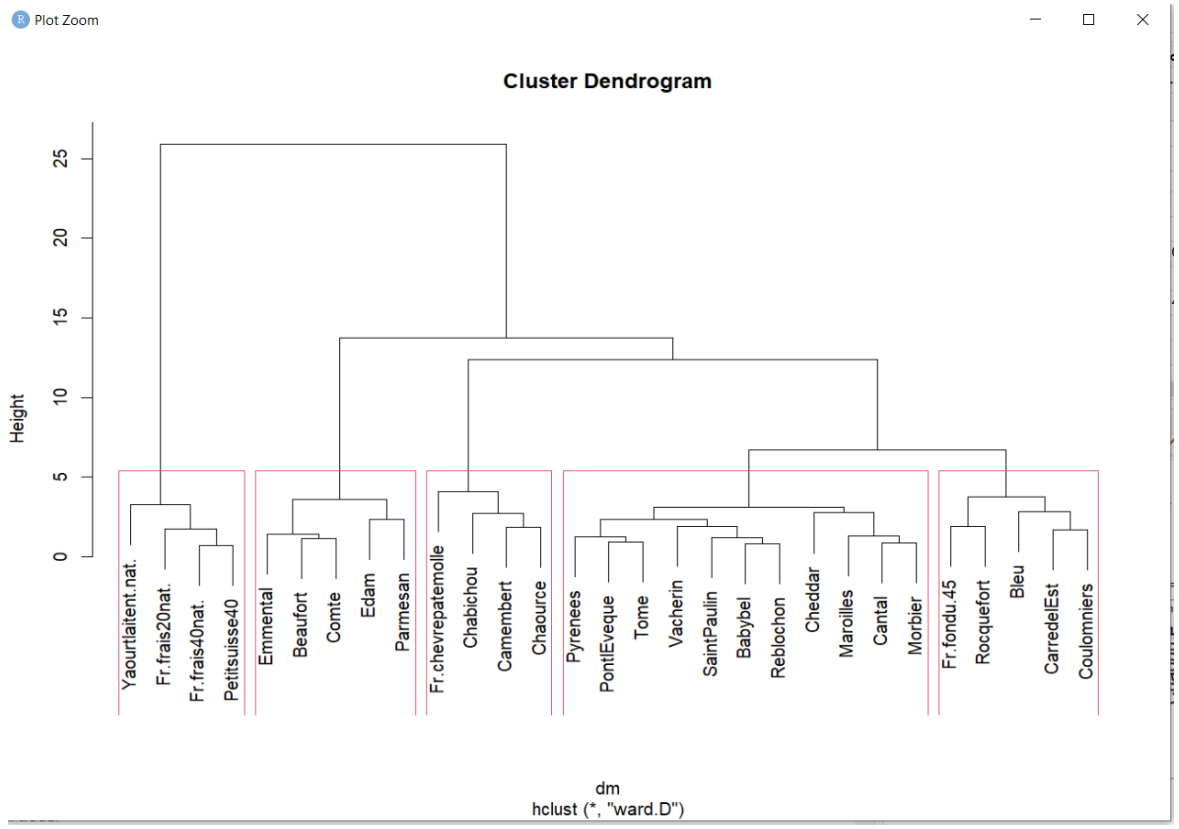


6/Déploiement : un dataset labellisé

CAH

```
> dm<-dist(fromages.cr)
> dendo<-hclust(dm,method = "ward.D")
> summary(dendo)
            Length Class  Mode
merge       56     -none- numeric
height      28     -none- numeric
order       29     -none- numeric
labels      29     -none- character
method       1     -none- character
call         3     -none- call
dist.method  1     -none- character
> plot(dendo)
> rect.hclust(dendo,k=5)
>
```

On va afficher dendrogramme avec matérialisation des groupes (5 groupes)



A travers cette modélisation, on va classifier les fromages sous 5 types:

FROMAGE	TYPE
Fr.frais20nat. Fr.frais40nat. Petitsuis se40 Yaourtlaitent.nat.	Fromages frais et yaourts naturels
Beaufort Comte Emmental Parmesan	Fromages à pâte dure
Camembert Chabichou Chaource Fr.chevrepatemolle	Fromages à pâte molle et de chèvre
Babybel Cantal Cheddar Edam Maroilles Morbier PontlEveque Pyrénées Reblochon SaintPaulin Tome Vacherin	Fromages variés à pâte dure et molle
Fr.fondu.45 Bleu Rocquefort CarredelEs t Coulomniers	Fromages à pâte fondu et fromages bleus

Afin de vérifier notre choix de nombre de classes est optimal on va calculer l'inertie (L'inertie est une mesure de la similarité des clusters)

