TD Régression

Exercice 1 :

L'objectif de cette étude est d'expliquer le total des ventes semestrielles d'un ensemble d'entreprises, en fonction des mesures suivantes : Marché total, Remises aux grossistes, Prix, Budget de Recherche, Investissement, Publicité, Frais de ventes, et Total budget publicité de la branche.

1. Une première étude a mis en place une régression linéaire multiple avec R, et elle a donné le résultat suivant :

```
> lm(VENTES ~. , ventes)

Call:
lm(formula = VENTES ~ ., data = ventes)

Coefficients:
(Intercept)           MT           RG         PRIX           BR          INV          PUB           FV         TPUB
  1862.5771       7.8966       5.2537      -3.8941       5.6258       1.6171       9.0311      -5.2378       0.1875
```

Donner la formule complète de la régression.

2. En déduire une interprétation de la pertinence des variables prises en considération.
3. Proposer une méthode pour la construction d'un deuxième modèle qui prendra en considération un ordre de pertinence des variables explicatives, décrire les différentes approches de cette méthode.

Exercice 2 :

Peut-on appliquer le même principe d'une régression linéaire, sur une analyse prédictive ciblant une variable qualitative ayant deux attributs ? Justifier votre réponse en donnant votre **preuve mathématique** pour ce faire.

Exercice 3 :

Cet exercice porte sur les données observées sur un échantillon de 31 véhicules, décrites par leurs prix, leurs cylindrées, leurs puissances et leurs poids.

On souhaite expliquer la consommation moyenne en fonction de toutes les autres variables à l'aide de la méthode de la régression linéaire multiple.

1. Donner brièvement le principe de la méthode des moindres carrées. (Possibilité de s'appuyer sur un schéma)
2. Monter que le calcul des coefficients estimateurs donne la formule suivante : $[X^t X]^{-1} X^t Y = \hat{\alpha}$
3. Expliquer l'utilité de chaque paramètre dans ***lm*** (fonction prédéfinie de R réalisant une régression linéaire)

```
> reg.lin = lm(conso ~., voitures )
> reg.lin

Call:
lm(formula = conso ~ ., data = voitures)

Coefficients:
(Intercept)         prix    cylindree    puissance        poids
  2.456e+00    2.042e-05   -5.006e-04    2.499e-02    4.161e-03
```

4. En se basant sur les valeurs des coefficients estimateurs obtenus, donner l'équation de la régression linéaire multiple.
5. En déduire une première interprétation de leurs pertinences sur l'aspect décisif mis en jeu.
6. Donner une deuxième interprétation à partir du résultat suivant :

```
> summary(reg.lin)

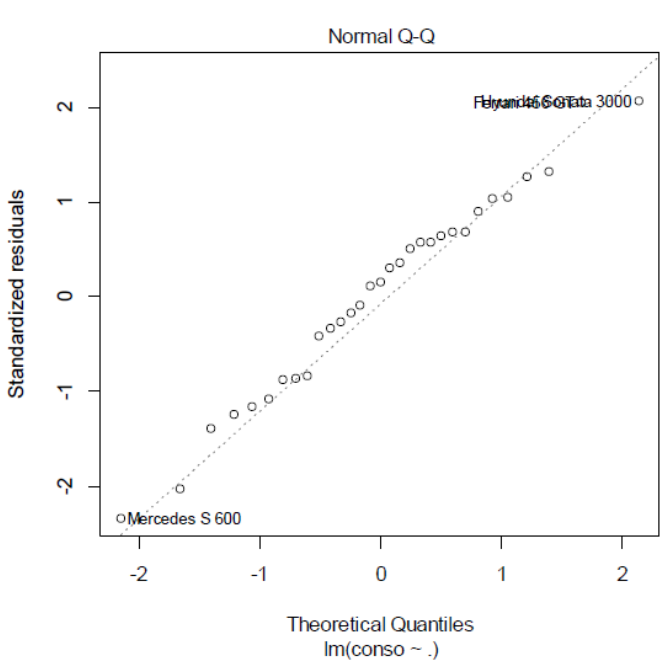
Call:
lm(formula = conso ~ ., data = voitures)

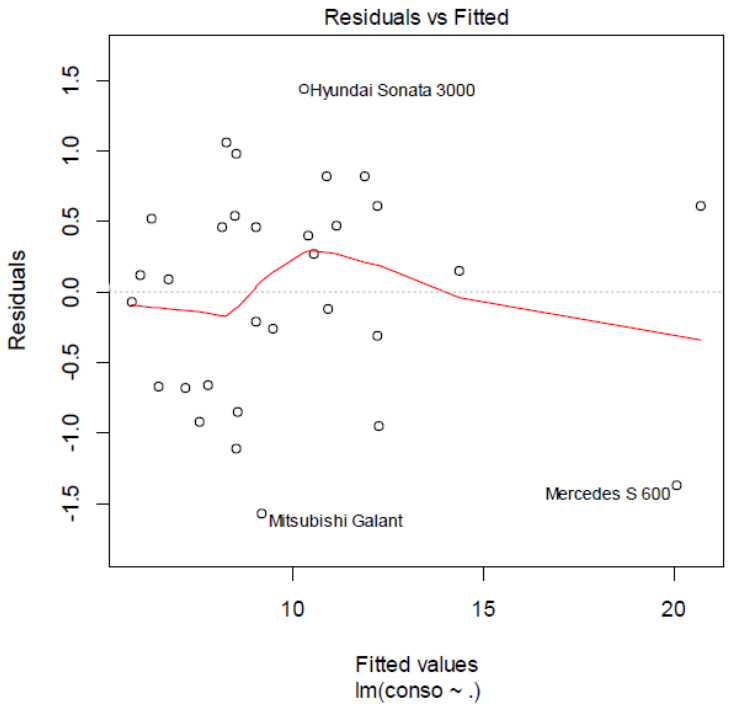
Residuals:
    Min      1Q  Median      3Q     Max
-1.5677 -0.6704  0.1183  0.5283  1.4361

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.456e+00  6.268e-01   3.919 0.000578 ***
prix         2.042e-05  8.731e-06   2.339 0.027297 *
cylindree   -5.006e-04  5.748e-04  -0.871 0.391797
puissance    2.499e-02  9.992e-03   2.501 0.018993 *
poids        4.161e-03  8.788e-04   4.734 6.77e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.8172 on 26 degrees of freedom
Multiple R-squared:  0.9546,    Adjusted R-squared:  0.9476
F-statistic: 136.5 on 4 and 26 DF,  p-value: < 2.2e-16
```

7. Interpréter les deux schémas suivants :





8. Donner la consommation des véhicules suivants en utilisant votre formulation de régression :

Véhicule	prix	cylindree	puissance	poids
Daihatsu Cuore	11600	846	32	650
Suzuki Swift 1.0 GLS	12490	993	39	790
Fiat Panda Mambo L	10450	899	29	730