TD n°1 : Segmentation

Partie QCM :

1-L'algorithme des K moyennes mobiles est un algorithme itératif. Une des étapes suivantes est répétée dans sa boucle interne. Trouver cette étape :

□ A. Le choix de l'hyperparamètre K.

□ B. Le déplacement des centres de gravité des groupes où les coordonnées de ces centres sont mises à jour.

□ C. Le choix de la formule de la distance.

□ D. L'affectation des centres de gravité.

2- Parmi les propositions suivantes, choisir celle où on peut appliquer un algorithme de segmentation sur des données non labellisées. Veuillez choisir une réponse :

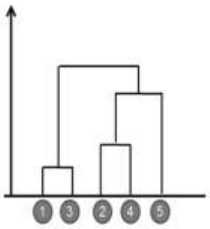
□ A. Étant donné un grand nombre d'e-mails, on souhaite déterminer si l'e-mail est un spam ou non-spam.

□ B. On dispose d'un ensemble de tickets de caisse et on souhaite détecter l'article le plus préconisé par les consommateurs.

□ C. Compte tenu des données météorologiques historiques collectées pendant le mois passé, on veut prédire si le temps de demain permettra de jouer au tennis ou pas.

□ D. A partir des tweets échangés sur le réseau social, on veut déterminer le sentiment général des internautes.

3- On considère le dendrogramme suivant et on souhaite détecter le / les individu(s) atypique(s). La meilleur coupe à considérer ce fait en:



□ A. Deux groupes.

□ B. Trois groupes.

□ C. Quatre groupes.

□ D. Cinq groupes.

Source : Examen Session principale 2021.

Exercice 1 :

Utilisez l'algorithme des k-moyennes et la distance euclidienne pour regrouper les 8 exemples suivants en 3 groupes : A1=(2,10), A2=(2,5), A3=(8,4), A4=(5,8) , A5=(7,5), A6=(6,4), A7=(1,2), A8=(4,9). La matrice de distance basée sur la distance euclidienne est donnée ci-dessous :

ESPRIT©2022-2023

	A1	A2	A3	A4	A5	A6	A7	A8
A1	0	5	6	3.6	7.2	8	8.06	2.23
A2		0	6	4.2	5	4.12	3.16	4.47
A3			0	5	1.4	1.4	7.28	6.4
A4				0	3.6	4.1	7.21	1.41
A5					0	1.4	6.7	5
A6						0	5.38	5.38
A7							0	7.61
A8								0

Supposons que les centres de chaque cluster sont A1, A4 et A7. Exécutez l'algorithme des k-moyennes pour une itération seulement. À la fin de cette époque :

a) Identifiez les nouveaux clusters.
b) Identifiez les centres des nouveaux clusters
c) Dessinez un espace 10 par 10 avec les 6 points et montrez les clusters après la première époque et les nouveaux centroïdes.
d) Combien d'itérations supplémentaires sont nécessaires pour converger ? Dessinez le résultat pour chaque époque.

Source : Examen Session covid 2022.

Exercice 2 :

Un magazine français a publié un comparatif des **12** principaux Smartphones (téléphones mobiles connectés disponibles sur le marché en novembre 2010.

Chaque Smartphone est décrit et évalué par les points suivants :

- **Prise en main** : facilité de prise en main (note sur 20)
- **Communication** : qualité des communications téléphoniques (note sur 20)
- **Organisation** : fonctionnalités d'organisation : agenda, carnet d'adresses, etc. (note sur 20)
- **Divertissement** : offre en divertissement : jeux, etc. (note sur 20)
- **Navigation** : offre en logiciel de navigation : Maps, GPS, etc. (note sur 20)
- **Prix** : prix public hors abonnement (en euros)
- **Autonomie** : autonomie en communication (en heures)

Source : Le Point no 2045, 11 novembre 2010 : Le guide du numérique 2011.

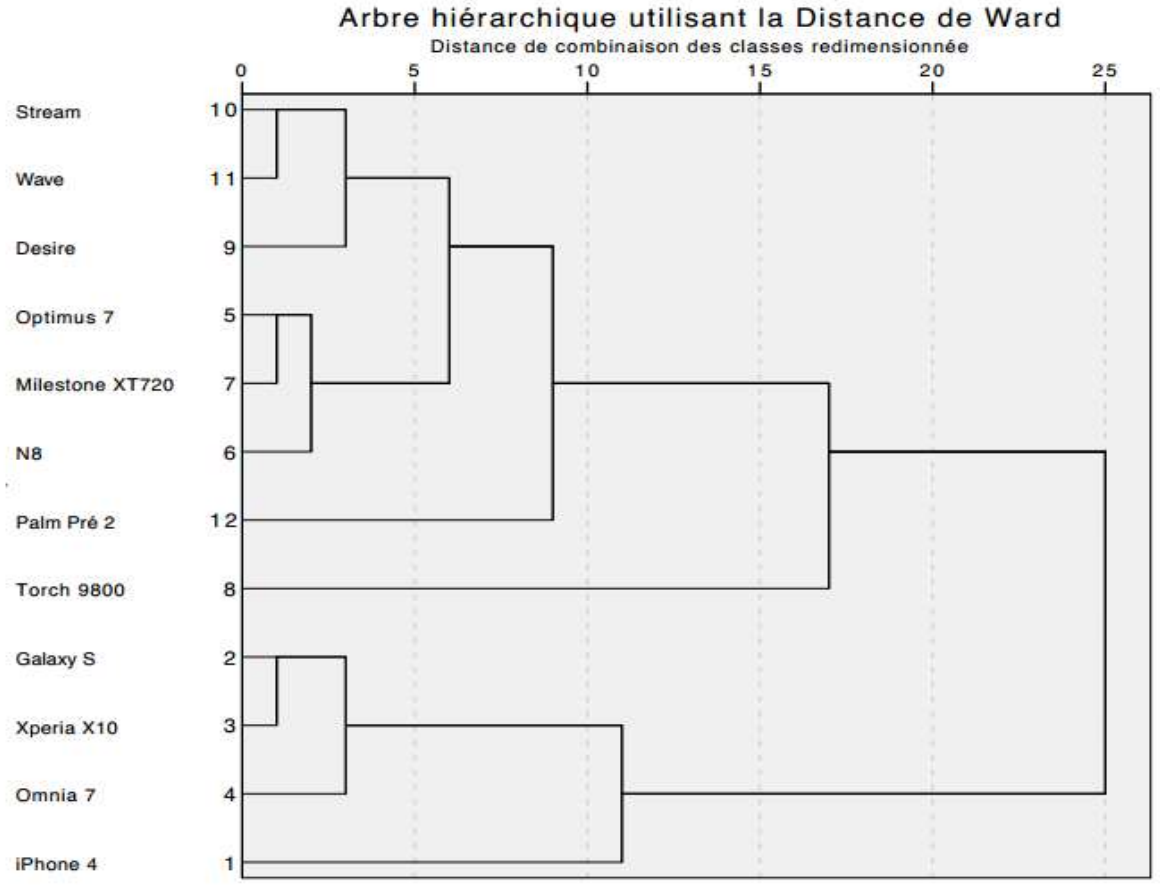
En premier lieu, des statistiques descriptives ont été réalisées afin de mieux comprendre les données collectées.

Classification hiérarchique ascendante (Distance de Ward)

Matrice de proximité (partielle)

Observation	Carré de la distance Euclidienne					
	1:iPhone 4	2:Galaxy S	3:Xperia X10	4:Omnia 7	5:Optimus 7	6:N8
1:iPhone 4	,000	15,363	10,147	19,802	17,778	9,404
2:Galaxy S	15,363	,000	4,646	6,689	6,650	8,749
3:Xperia X10	10,147	4,646	,000	7,072	7,021	5,046
4:Omnia 7	19,802	6,689	7,072	,000	6,066	11,997
5:Optimus 7	17,778	6,650	7,021	6,066	,000	4,333
6:N8	9,404	8,749	5,046	11,997	4,333	,000
7:Milestone XT720	25,689	17,004	14,286	18,843	4,239	6,412
8:Torch 9800	32,665	19,939	29,435	19,794	15,608	21,283
9:Desire	26,524	12,791	13,648	23,693	9,694	7,378
10:Stream	23,774	6,550	7,237	11,263	6,710	6,537
11:Wave	29,204	9,759	9,806	8,295	4,261	8,483
12:Palm Pré 2	47,485	24,117	23,348	16,397	9,552	19,032

Dendrogramme :



Une segmentation automatique des Smartphones est réalisée.

1. La segmentation était réalisée sur des données centrées et réduites. Justifier ce choix ?
2. Justifier le choix d'une méthode hiérarchique ascendante pour réaliser la segmentation au lieu de k-means.
3. Selon les résultats fournis en annexe de la segmentation hiérarchique ascendante, quel est le Smartphone qui pourra remplacer le plus un Iphone 4.
4. Combien de groupes suggérez-vous de retenir selon le dendrogramme ?
5. Quel est le critère utilisé pour déterminer la meilleure segmentation possible avec la coupe du dendrogramme ?

Exercice 3: Segmentation via CAH

On donne la dataset suivant qui caractérise 5 individus en fonction de 2 variables X1 et X2:

Individus	X1	X2
I1	5	3
I2	1	2.14
I3	5.2	3
I4	5	6
I5	4	3.5

1. Enoncer le principe algorithmique de segmentation hiérarchique ascendante. [1pt]
2. Calculer la matrice de distance correspondante en considérant la formule de distance suivante: **d(I, J) = |X1(I) – X1(J)| + |X2(I) – X2(J)|**
3. Tracer le dendrogramme en considérant le saut minimal.
4. Proposer une segmentation. Justifier votre choix.

Source : Examen Session principale 2022.

ESPRIT©2022-2023