TD: ANALYSE EN COMPOSANTES PRINCIPALES

1. L'ACP permet:

□ A. D'étudier la variabilité des individus;

□ B. D'étudier les liaisons entre les variables

□ C. De regrouper les variables liées en nouvelles variables synthétiques pour réduire le nombre de colonnes de nos données

☒ *D. Toutes les réponses*

2. Parmi les affirmations suivantes, lesquelles sont recommandées pour l'algorithme d'analyse par composantes principales? Sélectionner la réponse correcte:

□A. L'ACP permet d'améliorer la visualisation des données puisqu'on réduit les données vers un espace à deux dimensions ou à 3 dimensions.

□B. L'ACP permet de réduire le risque de sur-apprentissage puisque on réduit le nombre de colonnes alors on améliore la performance du modèle.

☒ *C. Les réponses A et B sont correctes.*

□D. Aucune de ces réponses

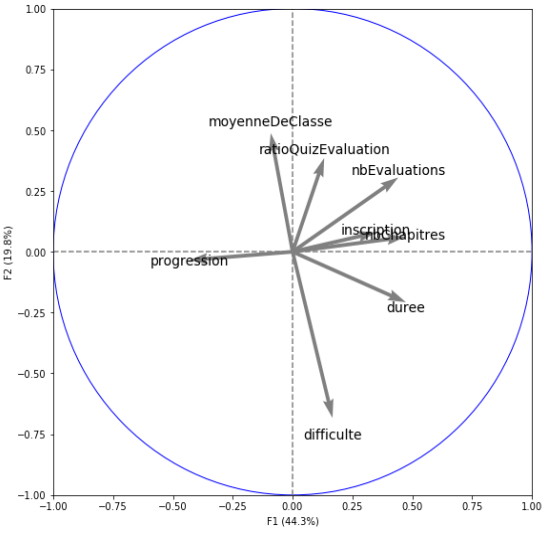
3. Parmi les propositions suivantes laquelle est correcte:

A. La progression du cours est corrélée positivement avec la première composante.

B. ☒ La progression du cours est corrélée négativement avec la première composante.

C. La progression du cours est bien représentée par le plan factoriel.

D. Aucune de ces réponses.



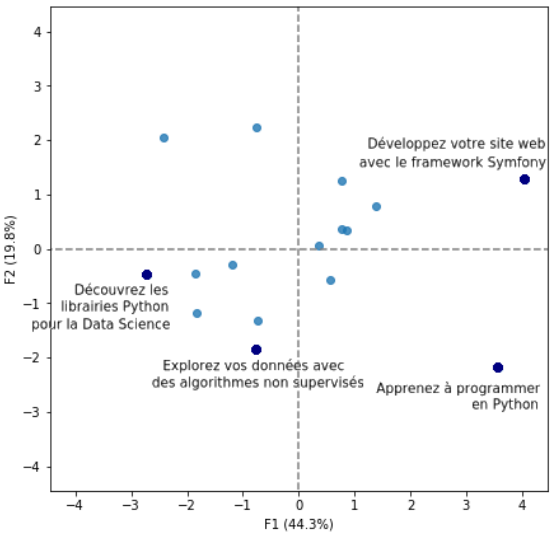
4. En superposant la carte des individus au cercle de corrélation, Quelle proposition est incorrecte **:**

A. *Les moyennes du cours "explorez vos données avec des algorithmes non supervisés" sont très bonnes.*

B. Le cours " Apprenez à programmer en Python" est très difficile.

C. Les moyennes des étudiants en "symphony" sont bonnes.

D. ☒ Le cours "apprenez à programmer en Python" est court.



5. Parmi les affirmations suivantes, lesquelles sont recommandées pour l'algorithme d'analyse par composantes principales? Sélectionner la réponse correcte :

A. L'ACP permet d'améliorer la visualisation des données puisqu'on réduit les données vers un espace à deux dimensions ou à 3 dimensions.

Wiem.trabelsi@esprit.tn

ESPRIT©2021-22

B. L'ACP permet de réduire le risque de sur-apprentissage puisqu'on réduit le nombre de colonnes alors on améliore la performance du modèle.

C. L'ACP permet de synthétiser les données représentées sur un échantillon de données.

D. *les. Les réponses A, B et C.*

E.

Exercice 1 :

Le tableau suivant fournit la structure du bilan d'un groupe pétrolier de 1969 à 1984 :

Année	NET	INT	SUB	LMT	DCT	IMM	EXP	VRD
1969	17.93	3.96	0.88	7.38	19.86	25.45	5.34	19.21
1970	16.21	3.93	0.94	9.82	19.11	26.58	5.01	18.40
1971	19.01	3.56	1.91	9.43	17.87	25.94	5.40	16.88
1972	18.05	3.33	1.73	9.72	18.83	26.05	5.08	17.21
1973	16.56	3.10	2.14	9.39	20.36	23.95	6.19	18.31
1974	13.09	2.64	2.44	8.10	25.05	19.48	11.61	17.59
1975	13.43	2.42	2.45	10.83	22.07	22.13	11.17	15.49
1976	9.83	2.46	1.79	11.81	24.10	22.39	11.31	16.30
1977	9.46	2.33	2.30	11.46	24.45	23.07	11.16	15.77
1978	10.93	2.95	2.25	10.72	23.16	24.17	9.64	16.20
1979	13.02	3.74	2.21	7.99	23.04	19.53	12.60	17.87
1980	13.43	3.60	2.29	7.09	23.59	17.61	16.67	15.72
1981	13.37	3.35	2.58	6.76	23.94	18.04	15.42	16.54
1982	11.75	2.74	3.11	7.37	25.04	18.11	14.71	17.18
1983	12.59	3.05	3.85	7.12	23.40	19.17	11.86	18.97
1984	13.00	3.00	4.00	7.00	24.00	20.00	12.00	17.00

Les postes de bilan sont les suivants :

NET : Situation nette ; représente l'ensemble des capitaux propres de l'entreprise.

INT : Intérêts ; représente l'ensemble des frais financiers supportés par l'entreprise.

SUB : Subventions ; représente le montant total des subventions accordées par l'Etat.

LMT : Dettes à long et moyen terme.

DCT : Dettes à court terme.

IMM : Immobilisations ; représente l'ensemble des terrains et du matériel de l'entreprise.

EXP : Valeurs d'exploitation.

VRD : Valeurs réalisables et disponibles ; ensemble des créances à court terme de l'entreprise.

Les données ont été ventilées en pourcentage par année, la somme des éléments d'une même ligne vaut 100, de manière à éviter les effets dus à l'inflation. On propose d'appliquer une Analyse en Composantes Principales (ACP) afin d'analyser l'évolution de la structure de bilan sur 15 ans. Les résultats de l'ACP sont présentés dans les tableaux et les figures ci-dessous :

Tableau1 :

Eigenvalues of the Correlation Matrix

	Eigenvalue	Difference	Proportion	Cumulative
1	4.47037150	2.35552573	0.5588	0.5588
2	2.11484576	1.43418677	0.2644	0.8232
3	0.68065899	0.17991239	0.0851	0.9082
4	0.50074660	0.34116829	0.0626	0.9708
5	0.15957831	0.09542998	0.0199	0.9908
6	0.06414833	0.05449844	0.0080	0.9988
7	0.00964990	0.00964928	0.0012	1.0000
8	0.00000062	0.0000	1.0000	

Tableau 3 :

Coordonnees des variables sur les axes

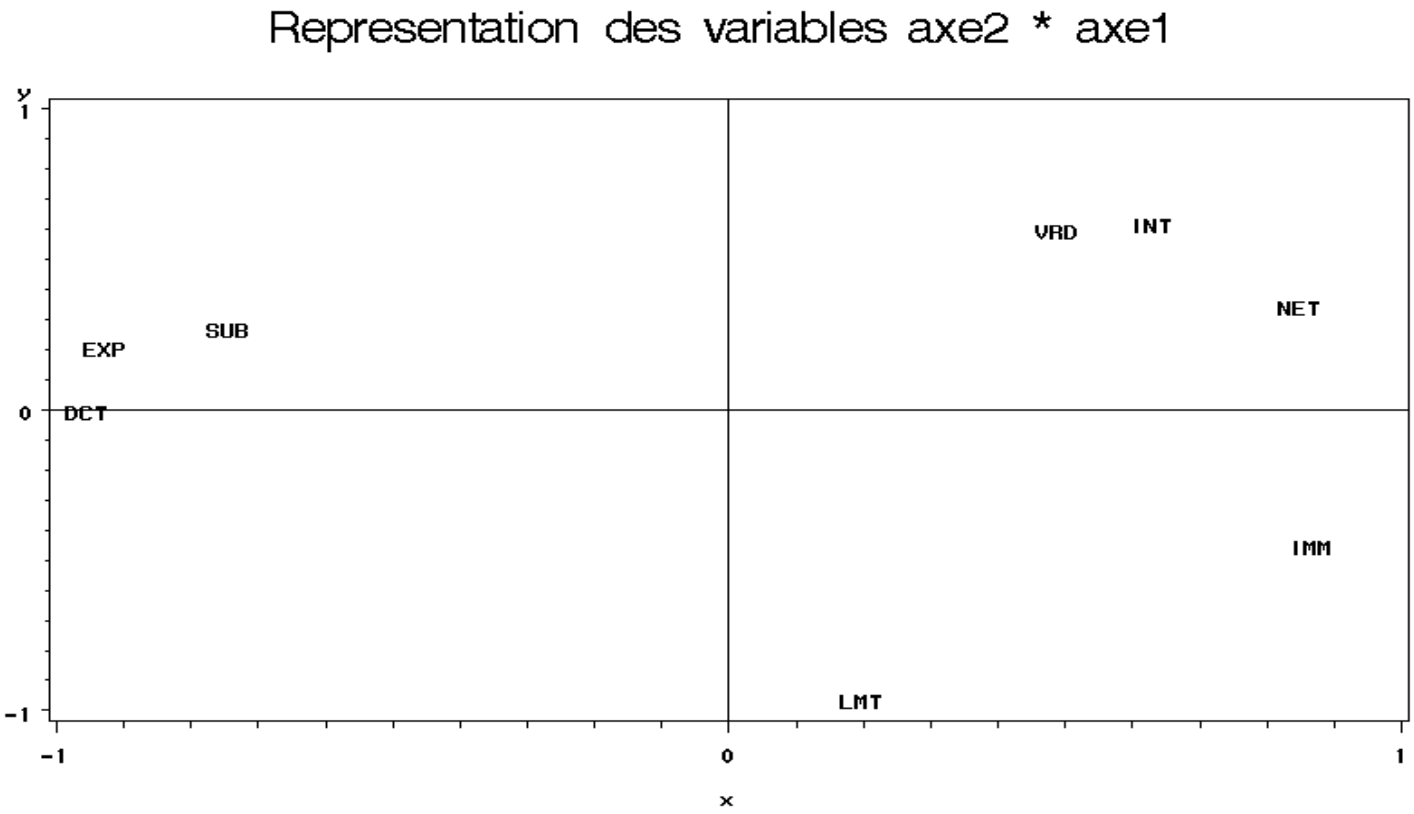
Pearson Correlation Coefficients, N = 16

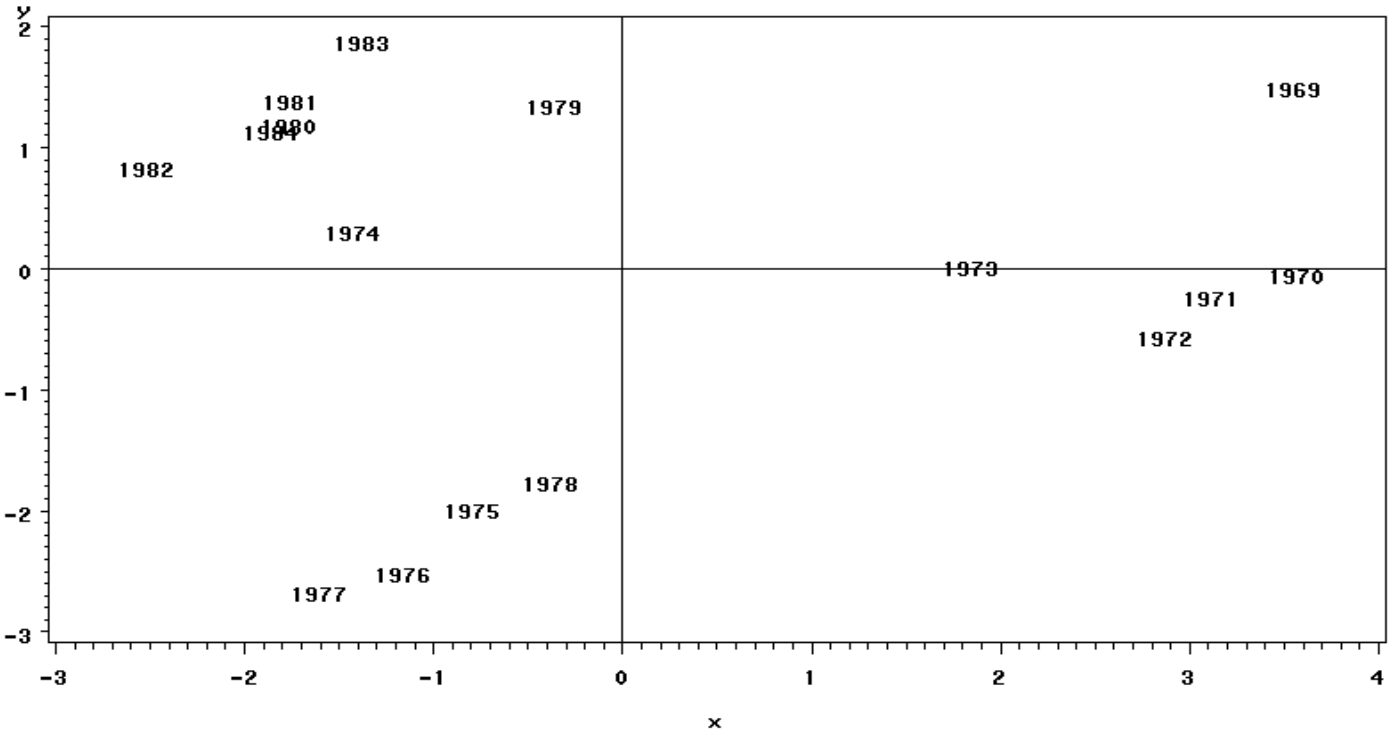
	Prin1	Prin2
NET	0.85014	0.34678
INT	0.62963	0.62173
SUB	-0.74214	0.27580
LMT	0.20017	-0.96163
DCT	-0.95386	0.00168
IMM	0.86787	-0.44767
EXP	-0.92571	0.20985
VRD	0.49025	0.60233

Tableau 2 :

Coordonnees et qualite de representation des individus sur les axes

annee	Prin1	Prin2	cos2_prin1	cos2_prin2
1969	3.55662	1.50535	0.78441	0.14052
1970	3.57546	-0.04273	0.93110	0.00013
1971	3.12027	-0.21808	0.83031	0.00406
1972	2.87553	-0.54758	0.89332	0.03239
1973	1.84936	0.02352	0.75517	0.00012
1974	-1.42432	0.32194	0.57269	0.02926
1975	-0.79476	-1.97215	0.11144	0.68621
1976	-1.16070	-2.50400	0.15851	0.73770
1977	-1.59726	-2.65758	0.25931	0.71786
1978	-0.37918	-1.74803	0.03739	0.79463
1979	-0.36150	1.35612	0.04004	0.56350
1980	-1.75965	1.20307	0.34868	0.16299
1981	-1.75001	1.40025	0.49152	0.31468
1982	-2.51840	0.84115	0.87166	0.09724
1983	-1.37918	1.88579	0.21797	0.40752
1984	-1.85228	1.15298	0.50000	0.19373





1. Expliquer les objectifs de l'Analyse en Composantes Principales (ACP) en Informatique décisionnelle.

2. Etude du tableau des valeurs propres.

2.1. A quoi correspond la somme des valeurs propres ?

2.2. On choisit de n'étudier que les deux premières composantes principales. Justifier ce choix en analysant le tableau 1 des valeurs propres (Eigenvalues).

2.3. Calculer le pourcentage d'information quantifié par les deux premières composantes principales sélectionnées.

3. Analyse des résultats de l'ACP

3.1. Sélectionner les individus (les années) qui sont bien représentés sur le plan factoriel en analysant les qualités de leurs représentations (cos2) dans le tableau 2.

3.2. Sélectionner les variables corrélées avec les premières composantes principales à partir du tableau 3.

3.3. Commenter les positions des années bien représentées sur le plan factoriel par rapport aux variables corrélées avec les deux premières composantes principales.

Exercice 2 :

On a rassemblé les résultats de 15 enfants de 10 ans à 6 subtests du WISC (scores 0 à 5). Les variables observées sont : CUB (Cubes de Kohs), PUZ (Assemblage d'objets), CAL (Calcul mental), MEM (Mémoire immédiate des chiffres), COM (Compréhension de phrases), VOC (Vocabulaire).

On traite ces données par une analyse en composantes principales normée. Les principaux résultats de cette ACP sont indiqués ci-dessous.

I. Etude du tableau des valeurs propres :

	Val. propr	% Total variance	Cumul Val. propr	Cumul %
1	3,2581	54,3020	3,2581	**54,3020**
2	1,8372	30,6194	5,0953	**84,9214**
3	0,4430	7,3831	5,5383	**92,3044**
4	0,2538	4,2292	5,7920	**96,5337**
5	0,1679	2,7990	5,9600	**99,3327**
6	0,0400	0,6673	6,0000	**100,0000**

Valeurs propres & statistiques associées

1. A quoi correspond la **somme** des valeurs propres ?

2. **<u>On choisit de n'étudier que les deux premières composantes principales</u>**. Justifier ce choix en analysant le tableau des valeurs propres.
3. **II.** Etude des qualités de représentation dans le premier plan principal

	Score Fact. 1	Score Fact. 2	Contribution Fact.1	Contribution Fact.2	Cos^2 Fact.1	Cos^2 Fact. 2
I1	-2,5616	3,0568	13,43	33,91	0,4078	0,5807
I2	-0,9661	0,9370	1,91	3,19	0,3907	0,3676
I3	0,6765	-0,6624	0,94	1,59	0,4446	0,4263
I4	-2,7969	-1,4636	16,01	7,77	0,7160	0,1961
I5	-1,8423	0,1211	6,95	0,05	0,8142	0,0035
I6	1,8891	0,1350	7,30	0,07	0,8426	0,0043
I7	-2,3396	-1,5487	11,20	8,70	0,6028	0,2641
I8	0,7275	-2,2054	1,08	17,65	0,0816	0,7499
I9	2,8400	0,5423	16,50	1,07	0,8745	0,0319
I10	2,1733	0,6117	9,66	1,36	0,7433	0,0589
I11	1,2940	2,0373	3,43	15,06	0,2256	0,5592
I12	-0,9947	0,8181	2,02	2,43	0,3120	0,2110
I13	-0,6099	-0,8730	0,76	2,77	0,1949	0,3994
I14	2,0150	-0,9470	8,31	3,25	0,7548	0,1667
I15	0,4957	-0,5591	0,50	1,13	0,1151	0,1464

Scores, contributions et qualités de représentation des individus

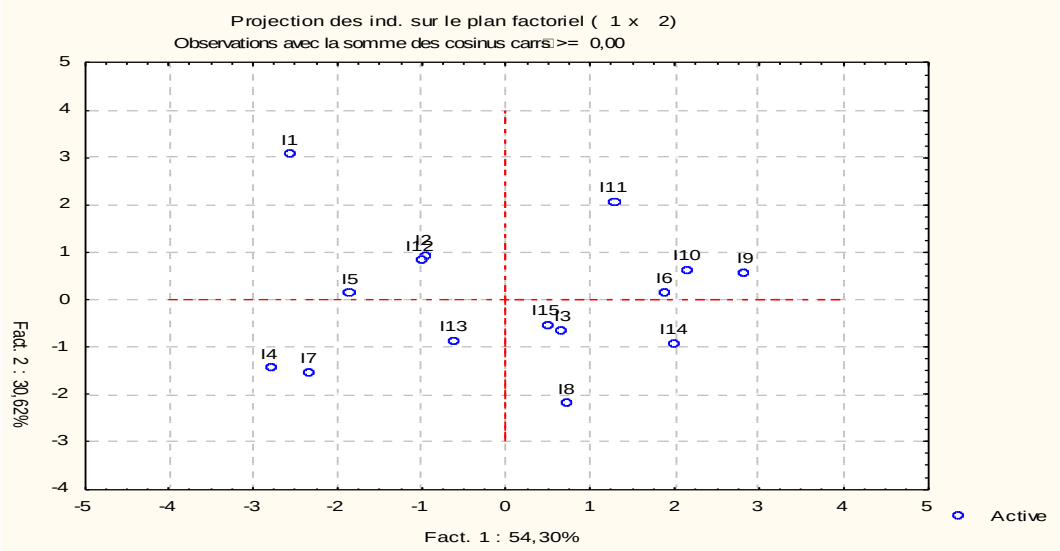
	Saturation Fact. 1	Saturation Fact. 2	Contribution Fact.1	Contribution Fact.2	Cos^2 Fact.1	Cos^2 Fact.1&2
CUB	-0,8970	0,2018	0,25	0,02	0,8046	0,8453
PUZ	-0,8652	0,2883	0,23	0,05	0,7485	0,8316
CAL	-0,9458	0,0390	0,27	0,00	0,8945	0,8960
MEM	0,4449	-0,7861	0,06	0,34	0,1980	0,8160
COM	-0,5382	-0,7627	0,09	0,32	0,2897	0,8714
VOC	-0,5683	-0,7156	0,10	0,28	0,3229	0,8350

Saturations, contributions et qualités de représentation des variables

3. Comment quantifie-t-on la qualité de représentation des individus par le plan factoriel ?

4. Quel est l'individu le moins représenté par le premier plan principal ? Quel est l'individu le mieux représenté ?

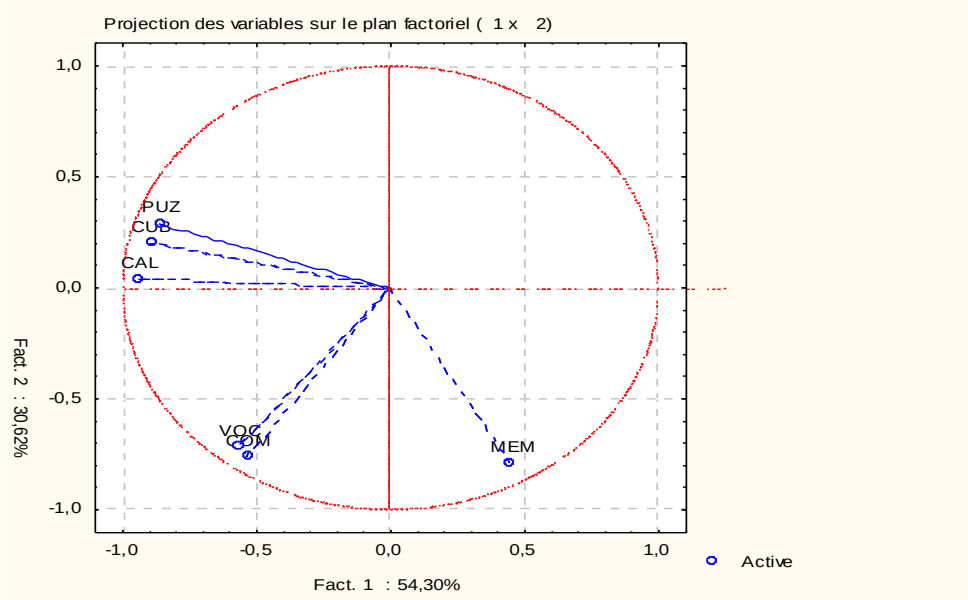
III. Etude du nuage des individus.



5. Quels sont les individus dont la contribution à la formation de la première composante principale est supérieure à la moyenne ? Pour chacun d'eux, préciser le signe de la coordonnée correspondante. Caractériser cet axe en termes d'opposition entre individus.

6. Même question pour la deuxième composante principale.

IV. Etude du nuage des variables



7. La représentation graphique des variables montre qu'elles sont toutes très bien représentées dans le plan (CP1, CP2). Justifier cette affirmation.

8. Quelles sont les variables qui sont corrélées positivement avec le premier facteur principal ? Quelles sont celles qui sont corrélées négativement ? Comment peut-on caractériser cet axe par rapport aux variables de départ ? (1.5)

9. Quelles sont les variables qui ont joué un rôle dominant dans la formation du deuxième axe

Exercice 3 :

Un magazine français a publié un comparatif des **12** principaux Smartphones (téléphones mobiles connectés) disponibles sur le marché en novembre 2010.

Chaque Smartphone est décrit et évalué par les points suivants :

- **Prise en main** : facilité de prise en main (note sur 20)
- **Communication** : qualité des communications téléphoniques (note sur 20)
- **Organisation** : fonctionnalités d'organisation : agenda, carnet d'adresses, etc. (note sur 20)
- **Divertissement** : offre en divertissement : jeux, etc. (note sur 20)
- **Navigation** : offre en logiciel de navigation : Maps, GPS, etc. (note sur 20)
- **Prix** : prix public hors abonnement (en euros)
- **Autonomie** : autonomie en communication (en heures)

Source : Le Point no 2045, 11 novembre 2010 : Le guide du numérique 2011.

En premier lieu, des statistiques descriptives ont été réalisées afin de mieux comprendre les données collectées.

4. En analysant le tableau **'Statistiques uni et bi variées'** (voir annexe) donner la caractéristique la mieux notée ? La moins bien ? Et Par rapport à quelle caractéristique les Smartphones étudiés différent-ils le plus ? Ensuite, l'équipe a effectué une analyse en composantes principales entre les 6 premières variables (Hors Autonomie).

5. Quelle est le principe de l'analyse en composantes principales ?

6. On choisit de n'étudier que les deux premières composantes principales. Justifier ce choix en analysant le tableau **'Variance totale expliquée'** (voir les figures).

7. Calculer le pourcentage d'information quantifié par les deux premières composantes principales sélectionnées.

8. Analyse des résultats de l'ACP

8.1. Sélectionner les variables corrélées avec les deux premières composantes principales à partir du tableau '**Matrice des composantes après rotation'**.

8.2. Donner les conclusions adéquates pour cette étude en analysant les deux graphiques résultants de l'ACP.

Tableau des données

Récapitulatif des observations

Marque	Modèle	Prise En Main	Communi-cation	Organisa-tion	Divertisse-ment	Naviga-tion	Prix	Autono-mie
Apple	iPhone 4	17	14	17	17	17	630	10
Samsung	Galaxy S	18	16	16	13	15	599	6
Sony-Ericsson	Xperia X10	18	14	16	15	14	600	5
Samsung	Omnia 7	18	16	13	15	14	600	6
LG	Optimus 7	15	16	15	15	14	499	5
Nokia	N8	14	14	16	15	15	549	7
Motorola	Milestone XT720	13	15	16	15	13	399	6
RIM	Torch 9800	13	18	14	13	13	559	12
HTC	Desire	14	14	17	12	14	430	6
ACER	Stream	16	14	15	12	14	500	5
Samsung	Wave	15	15	14	13	12	499	5
HP	Palm Pré 2	13	16	13	14	10	449	4

Statistiques uni et bivariées

Statistiques descriptives

	Moyenne	Ecart-type	n analyse
PriseEnMain	15,33	2,015	12
Communication	15,17	1,267	12
Organisation	15,17	1,403	12
Divertissement	14,08	1,505	12
Navigation	13,75	1,712	12
Prix	526,08	75,150	12
Autonomie	6,38	2,265	12

Analyse factorielle 1 (ACP)

Variance totale expliquée

	Valeurs propres initiales			Extraction Sommes des carrés des facteurs retenus **pour la rotation**		
Composante	Total	% de la variance	% cumulés	Total	% de la variance	% cumulés
1	2,871	47,843	47,843	2,410	40,175	40,175
2	1,542	25,699	73,542	2,002	33,367	73,542
3	,810	13,496	87,037			
4	,537	8,957	95,994			
5	,146	2,436	98,430			
6	,094	1,570	100,000			

Qualité de représentation

	Initial	Extraction
PriseEnMain	1,000	,721
Communication	1,000	,738
Organisation	1,000	,866
Divertissement	1,000	,323
Navigation	1,000	,848
Prix	1,000	,917

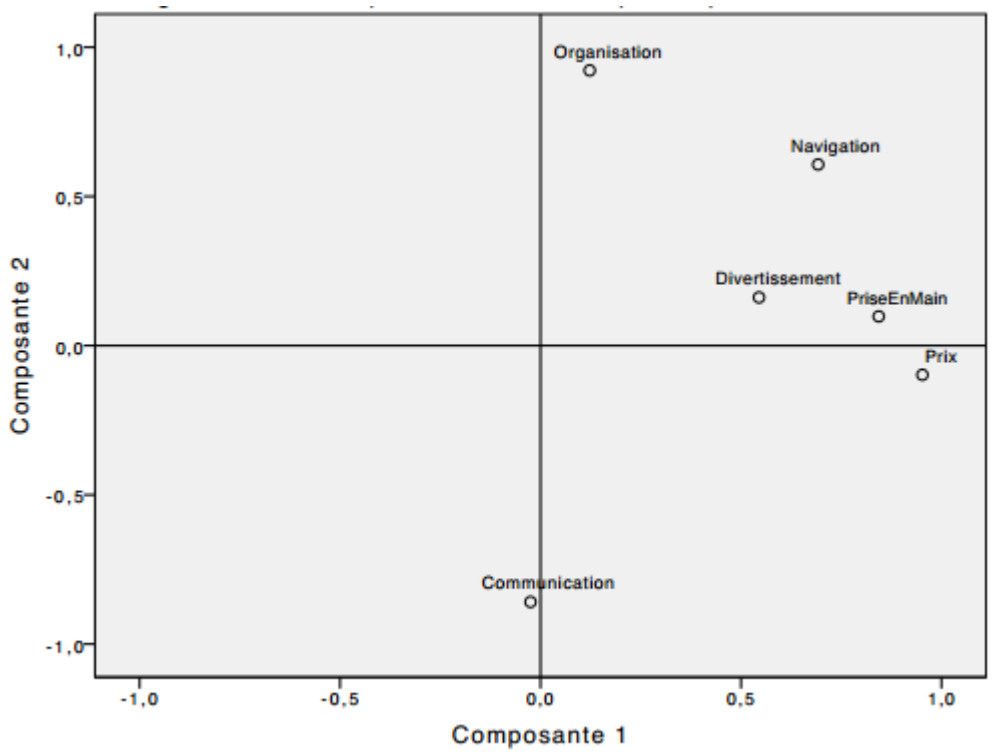
Méthode d'extraction : Analyse en composantes principales.

Matrice des composantes après rotation

	Composante	
	1	2
PriseEnMain	,843	,098
Communication	-,025	-,859
Organisation	,123	,922
Divertissement	,545	,162
Navigation	,692	,607
Prix	,952	-,098

Méthode de rotation : Varimax avec normalisation de Kaiser.

Cercle de corrélation :



Carte des individus :

